

Inferenza frequentista in psicologia

Modulo introduttivo

Corrado Caudek

26 luglio 2026

Percorso e obiettivi

Questo sito ospita il **modulo sull'inferenza frequentista** del progetto UTET, concepito a supporto del manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza. Fondamenti, workflow e applicazioni*. Il percorso offre un'introduzione critica alle tecniche statistiche tradizionali, quali le stime puntuali, gli intervalli di confidenza e i test di ipotesi, accompagnata da un'approfondita riflessione sulle loro premesse concettuali e sulle criticità metodologiche che hanno contribuito alla crisi di replicabilità nella ricerca psicologica.

- **Origini storiche:** da Galton e Fisher ai fondamenti del pensiero frequentista.
- **Stima dei parametri:** concetti di media campionaria, varianza, stimatori corretti.
- **Intervalli di confidenza:** costruzione, interpretazione, equivoci comuni.
- **Test di ipotesi:** logica, errori di I e II tipo, potenza statistica.

Il sito non intende sostituire il manuale principale, ma integrarlo: fornisce il **background propedeutico** e il contesto critico indispensabili per apprezzare in profondità le ragioni e la struttura dell'alternativa bayesiana.

Come usare il modulo

- **Leggi con spirito critico:** lo scopo è capire potenzialità e limiti del frequentismo.
- **Collega al manuale:** ciascun tema trattato in questo modulo costituisce il presupposto teorico o il termine di confronto necessario per apprezzare l'approccio bayesiano sviluppato nel manuale principale, dove viene proposto un superamento delle criticità discusse.
- **Utilizza le appendici:** per un riferimento rapido, sono disponibili appendici dedicate alla notazione matematica, ai simboli e a richiami di concetti fondamentali, consultabili sul sito companion [Inferenza bayesiana in psicologia: ragionare con l'incertezza](#).

Licenza d'uso

Materiali rilasciati con licenza

[CC BY-NC-ND 4.0](#):

è consentita la condivisione con attribuzione **solo per usi non commerciali** e **senza modifiche**.

Parte I.

Frequentismo

Introduzione all'inferenza frequentista in un percorso bayesiano

In sintesi

Da sapere L'inferenza frequentista valuta stime, intervalli e decisioni attraverso il loro comportamento in ripetuti campionamenti. I parametri del modello sono trattati come fissi ma ignoti; la variabilità riguarda i dati e le statistiche calcolate sui campioni.

Da saper fare Distinguere una domanda sul comportamento di una procedura da una domanda sulla plausibilità di un parametro; interpretare correttamente intervalli di confidenza, valori- p e significatività statistica.

Introduzione

Questo modulo introduce l'inferenza frequentista all'interno di un percorso più ampio dedicato al ragionamento bayesiano. La scelta non è paradossale. Gran parte della letteratura psicologica utilizza ancora intervalli di confidenza, test di significatività, valori- p , livelli di significatività e analisi di potenza. Per leggere criticamente un articolo, progettare uno studio o comprendere una tabella di risultati, è quindi necessario conoscere bene questi strumenti.

Li studieremo come un sistema coerente di procedure che risponde a domande specifiche. Il confronto con l'approccio bayesiano servirà a distinguere due obiettivi diversi:

- valutare come si comporta una procedura statistica quando viene applicata ripetutamente a nuovi campioni;
- rappresentare direttamente l'incertezza su un parametro o su un'ipotesi dopo avere osservato i dati.

Il primo obiettivo è caratteristico dell'inferenza frequentista. Il secondo è affrontato in modo esplicito dall'inferenza bayesiana. Le due prospettive possono partire dallo stesso modello probabilistico dei dati, ma organizzano l'inferenza in modo diverso.

Perché studiare il frequentismo in un percorso bayesiano?

L'inferenza frequentista è stata, e in molti ambiti continua a essere, il linguaggio standard della ricerca empirica. Espressioni come *statisticamente significativo*, *intervallo di confidenza al 95%*, *errore di primo tipo*, *potenza statistica* e *test t* compaiono regolarmente negli articoli di psicologia, neuroscienze, medicina e scienze sociali.

Ignorare questo linguaggio renderebbe difficile comprendere la letteratura esistente. Accettarlo in modo meccanico, però, favorirebbe errori interpretativi molto diffusi. Questo modulo ha quindi una duplice funzione:

1. spiegare la logica e il funzionamento delle procedure frequentiste più comuni;
2. chiarire che cosa i loro risultati permettono di concludere e che cosa, invece, non esprimono direttamente.

i Una prospettiva didattica, non polemica

Studiare il frequentismo non significa presentarlo come un errore da correggere. Le procedure frequentiste forniscono strumenti importanti per controllare i tassi di errore, valutare la precisione delle stime e progettare studi informativi. Il punto è comprenderne con precisione la logica, senza attribuire ai risultati un significato che non possiedono.

Panoramica del capitolo

Il capitolo procede in cinque passaggi:

1. chiarisce il ruolo delle ripetizioni ipotetiche nell'inferenza frequentista;
2. distingue parametri, dati, statistiche e distribuzioni campionarie;
3. confronta le domande frequentiste e bayesiane attraverso un esempio binomiale;
4. presenta le interpretazioni scorrette più comuni;
5. anticipa il percorso dei capitoli successivi.

i Preparazione del notebook

Questo capitolo è interamente concettuale e non richiede l'esecuzione di codice R. Nei capitoli successivi useremo simulazioni e calcoli per rendere visibile il comportamento delle procedure in campioni ripetuti.

Probabilità e ripetizione campionaria

Nell'inferenza frequentista, le probabilità sono utilizzate per descrivere il comportamento di dati e statistiche sotto un modello specificato. Operativamente, ci si chiede che cosa accadrebbe se il processo di raccolta dei dati fosse ripetuto molte volte nelle stesse condizioni rilevanti.

Se, per esempio, un modello assegna probabilità 0.5 all'esito *testa* di una moneta, una lunga sequenza di lanci indipendenti prodotti da quel modello avrà una proporzione di teste che tende a stabilizzarsi intorno a 0.5. Questa affermazione riguarda il comportamento del processo generativo nelle ripetizioni, non la probabilità attribuita a un parametro dopo avere osservato un singolo campione.

Esistono diverse interpretazioni filosofiche della probabilità. Per comprendere le procedure frequentiste, tuttavia, è sufficiente concentrarsi sul loro significato operativo: distribuzioni campionarie, copertura degli intervalli e tassi di errore sono definiti attraverso ripetizioni reali o ipotetiche del campionamento.

Parametri fissi, dati variabili

Nel modello frequentista:

- il **parametro** è trattato come fisso ma ignoto;

- il **campione**, prima di essere osservato, è una variabile casuale;
- una **statistica**, essendo una funzione del campione, varia da un campione all'altro;
- la **procedura inferenziale** viene valutata considerando il suo comportamento nelle ripetizioni del campionamento.

Supponiamo di voler stimare la media del benessere psicologico in una popolazione di studenti. Il modello assume che la media della popolazione abbia un unico valore, anche se non lo conosciamo. Campioni diversi produrrebbero invece medie campionarie differenti. L'inferenza frequentista studia questa variabilità per valutare la precisione della stima e costruire procedure con proprietà controllate.

Da questa impostazione derivano concetti fondamentali:

- la **distribuzione campionaria**, cioè la distribuzione che una statistica assumerebbe in ripetuti campionamenti;
- l'**errore standard**, che descrive la variabilità della statistica da un campione all'altro;
- l'**intervallo di confidenza**, costruito mediante una procedura con una copertura prefissata sotto il modello e le assunzioni adottate;
- il **test di ipotesi**, che valuta la compatibilità dei dati con una specifica ipotesi di riferimento attraverso una statistica test e la sua distribuzione sotto tale ipotesi.

! Che cosa è casuale?

Prima del campionamento, dati, stime e intervalli possibili sono casuali perché dipendono dal campione che verrà osservato. Dopo il campionamento, il particolare insieme di dati, la stima e l'intervallo calcolato sono valori osservati. Le proprietà frequentiste continuano però a riferirsi alla procedura che li ha prodotti.

Una stessa osservazione, due domande diverse

Consideriamo una moneta lanciata 20 volte. Osserviamo 14 teste e 6 croci.

Un'analisi frequentista può partire dall'ipotesi nulla che la probabilità di testa sia $\theta = 0.5$. Se questa ipotesi e il modello binomiale fossero appropriati, il numero di teste avrebbe distribuzione

$$Y \sim \text{Binomiale}(20, 0.5).$$

La domanda frequentista è:

Quanto sono incompatibili i dati osservati con l'ipotesi di una moneta equilibrata, secondo la statistica test e la regola di estremità definite prima dell'analisi?

Il valore- p quantifica la probabilità, assumendo vera l'ipotesi nulla, di ottenere un valore della statistica test almeno altrettanto incompatibile con l'ipotesi quanto quello osservato. Non è la probabilità che la moneta sia equilibrata.

Un'analisi bayesiana usa lo stesso possibile modello binomiale per i dati, ma tratta l'incertezza su θ mediante una distribuzione. Combina una distribuzione a priori con la verosimiglianza e ottiene una distribuzione a posteriori:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

La domanda bayesiana è:

Dopo avere osservato 14 teste su 20 lanci, come cambia la plausibilità relativa dei diversi valori di θ ?

! Non invertire la probabilità condizionata

Il valore- p riguarda una probabilità dei dati, o di una statistica test, **assumendo** l'ipotesi nulla. Non fornisce direttamente la probabilità dell'ipotesi nulla dati i risultati. In simboli, una quantità del tipo $P(\text{dati estremi} \mid H_0)$ non coincide con $P(H_0 \mid \text{dati})$.

Che cosa esprimono le procedure frequentiste

Le procedure frequentiste sono progettate per garantire proprietà controllate nel lungo periodo, purché il modello e le assunzioni rilevanti siano adeguati.

Un intervallo di confidenza al 95%, per esempio, deriva da una procedura che, in ripetuti campionamenti condotti secondo il modello, produce intervalli contenenti il parametro vero nel 95% dei casi. Una volta calcolato un particolare intervallo, il parametro fisso è contenuto oppure non è contenuto in quell'intervallo. Il 95% descrive la procedura, non una probabilità a posteriori assegnata al parametro.

Analogamente, un test con livello di significatività $\alpha = 0.05$ è costruito affinché, quando l'ipotesi nulla è vera e le assunzioni sono rispettate, la probabilità di rifiutarla non superi il 5% nelle ripetizioni previste dal disegno.

Queste proprietà sono utili, ma sono sempre condizionate alla qualità del modello, del disegno e delle misure. Un tasso di errore formalmente controllato non corregge automaticamente un campione distorto, una misura poco valida o una specificazione inadeguata.

Interpretazioni da evitare

Molti errori nella lettura della letteratura scientifica derivano dall'attribuzione di un significato intuitivo ma scorretto a risultati tecnici.

Intervallo di confidenza

Un intervallo di confidenza al 95% non significa, nell'interpretazione frequentista standard, che il parametro abbia il 95% di probabilità di trovarsi nell'intervallo osservato. La copertura riguarda la procedura nelle ripetizioni.

Valore- p

Un valore- p non è:

- la probabilità che l'ipotesi nulla sia vera;
- la probabilità che il risultato sia dovuto al caso;
- la probabilità che lo studio non si replichi;
- una misura diretta dell'ampiezza o dell'importanza dell'effetto.

Significatività statistica

La significatività statistica non implica automaticamente importanza teorica, rilevanza clinica, precisione elevata o replicabilità. Dipende, tra le altre cose, dall'ampiezza dell'effetto, dalla variabilità, dalla dimensione campionaria e dal modello utilizzato.

Non significatività

La mancata significatività non dimostra che l'effetto sia esattamente nullo. Può riflettere dati poco informativi, misure rumorose, campioni piccoli oppure effetti compatibili con un'ampia gamma di valori.

 La soglia non sostituisce l'interpretazione

Ridurre un risultato alla dicotomia *significativo/non significativo* nasconde informazioni importanti. Stima dell'effetto, incertezza, qualità del disegno, plausibilità delle assunzioni e rilevanza sostantiva devono essere considerate insieme.

Il ruolo del frequentismo nella ricerca psicologica

Il frequentismo ha fornito alla ricerca psicologica strumenti condivisi per stimare quantità, confrontare gruppi, progettare studi e controllare tassi di errore. Molte delle sue procedure restano utili, soprattutto quando la domanda scientifica è accompagnata da un disegno ben definito e da un'interpretazione coerente con il metodo.

I problemi emergono quando le procedure vengono usate in modo automatico oppure quando il loro risultato viene trasformato in un verdetto sull'esistenza, sull'importanza o sulla verità di un effetto. L'uso rigido della soglia $\alpha = 0.05$ ha favorito una comunicazione dicotomica: *significativo/non significativo*, *effetto presente/effetto assente*, *ipotesi confermata/ipotesi respinta*.

Comprendere il frequentismo significa quindi apprendere sia i suoi strumenti sia i limiti delle conclusioni che possono essere tratte da essi.

Il percorso del modulo

I capitoli successivi sviluppano il ragionamento in modo graduale.

1. Origini storiche dell'approccio frequentista

Il contesto scientifico e sociale nel quale si sono sviluppati alcuni concetti fondamentali della statistica moderna.

2. Stime, stimatori e distribuzioni campionarie

Il modo in cui la variabilità tra campioni viene usata per valutare precisione e proprietà degli stimatori.

3. Intervalli di confidenza

Costruzione, copertura e interpretazione degli intervalli frequentisti.

4. Test di ipotesi e valore- p

Ipotesi nulla, statistica test, distribuzione di riferimento, regione critica, valore- p ed errori decisionali.

5. Dimensione campionaria e potenza statistica

Relazioni tra ampiezza dell'effetto, variabilità, errore di secondo tipo e capacità dello studio di produrre risultati informativi.

6. Confronto tra due gruppi indipendenti

Applicazione integrata degli strumenti al test t per due campioni indipendenti.

7. Considerazioni conclusive

Sintesi dei risultati ottenuti e passaggio al quadro bayesiano.

Come leggere i prossimi capitoli

Per ogni procedura è utile tenere separate quattro domande:

1. Qual è il modello dei dati?

Quale processo probabilistico viene assunto per le osservazioni?

2. Quale quantità viene calcolata?

Una stima, un errore standard, un intervallo, una statistica test, un valore- p o una misura di potenza?

3. Quale ripetizione ipotetica definisce la procedura?

Che cosa cambierebbe da un campione all'altro e quali elementi resterebbero fissi?

4. Quale conclusione è giustificata?

Il risultato riguarda la precisione della stima, la compatibilità con un'ipotesi, un tasso di errore oppure la capacità del disegno di rilevare determinati effetti?

Le formule sono necessarie, ma molti errori statistici non nascono dal calcolo. Nascono dal passaggio ingiustificato dal valore calcolato a una conclusione che quella quantità non sostiene.

Dalle procedure all'aggiornamento dell'incertezza

L'inferenza frequentista valuta le procedure attraverso distribuzioni campionarie, copertura e tassi di errore. Questa impostazione risponde bene a domande sul comportamento ripetuto di un metodo.

L'inferenza bayesiana affronta esplicitamente un'altra domanda: dati un modello, le conoscenze iniziali e le osservazioni disponibili, come deve cambiare l'incertezza sui parametri? Per rispondere, rappresenta tale incertezza mediante distribuzioni di probabilità e la aggiorna attraverso il teorema di Bayes.

Il confronto non va ridotto a una contrapposizione tra un metodo corretto e uno scorretto. È più utile riconoscere due grammatiche inferenziali:

- il frequentismo parla soprattutto il linguaggio delle procedure, delle distribuzioni campionarie e dei tassi di errore;
- il bayesianesimo parla il linguaggio della plausibilità condizionata al modello, della verosimiglianza e dell'aggiornamento.

Comprendere entrambe permette di leggere la ricerca empirica con maggiore precisione e di capire quali domande richiedono strumenti diversi.

Riflessioni conclusive

Il frequentismo non coincide con il semplice uso di una soglia né con il calcolo meccanico di un valore- p . È un sistema inferenziale nel quale le procedure vengono progettate e valutate attraverso il loro comportamento in campioni ripetuti.

Per comprenderlo è necessario distinguere il parametro fisso dalle statistiche variabili, il risultato osservato dalla procedura che lo ha prodotto e la probabilità dei dati sotto un'ipotesi dalla probabilità dell'ipotesi dopo i dati.

I capitoli successivi svilupperanno questi concetti uno alla volta. Il criterio guida resterà lo stesso: prima capire quale domanda viene posta, poi interpretare la risposta nel linguaggio appropriato.

Esercizi

1. In uno studio viene stimata la media di una popolazione. Che cosa è considerato fisso e che cosa varierebbe se lo studio fosse ripetuto con nuovi campioni?
2. Che cosa descrive la distribuzione campionaria di una statistica?
3. Un intervallo di confidenza al 95% viene calcolato come $[4.2, 7.1]$. Perché non è corretto affermare, nell'interpretazione frequentista standard, che vi sia il 95% di probabilità che il parametro sia compreso tra 4.2 e 7.1?
4. Uno studio riporta $p = 0.03$. Quale delle seguenti conclusioni è giustificata: «l'ipotesi nulla ha probabilità 0.03» oppure «sotto l'ipotesi nulla, un risultato almeno altrettanto incompatibile avrebbe probabilità 0.03»?
5. Perché un risultato statisticamente significativo può essere poco importante dal punto di vista psicologico o clinico?
6. Perché un risultato non significativo non dimostra automaticamente l'assenza di un effetto?
7. Due analisi usano lo stesso modello binomiale per 14 teste su 20 lanci. In che cosa differiscono la domanda frequentista e quella bayesiana?
8. Perché il controllo formale del tasso di errore non basta a garantire la validità scientifica di una conclusione?

Soluzioni

1. Il parametro della popolazione è trattato come fisso ma ignoto. Il campione e la media campionaria cambierebbero da una ripetizione all'altra.
2. Descrive come varierebbe la statistica se il campionamento fosse ripetuto secondo lo stesso modello e disegno.
3. Il 95% è la copertura della procedura nelle ripetizioni. Dopo il calcolo, il particolare intervallo contiene oppure non contiene il parametro fisso; la procedura frequentista non assegna direttamente una probabilità a posteriori al parametro.
4. È giustificata la seconda formulazione, purché «almeno altrettanto incompatibile» sia definito dalla statistica test e dalla regola di estremità utilizzate.

5. La significatività dipende anche da numerosità e variabilità. Un effetto molto piccolo può risultare statisticamente significativo in un campione grande senza avere rilevanza sostantiva.
6. La non significatività può derivare da scarsa precisione, bassa potenza, misure rumorose o dati compatibili con molti valori dell'effetto.
7. La domanda frequentista valuta quanto i dati siano incompatibili con un valore ipotizzato del parametro secondo una procedura definita. La domanda bayesiana aggiorna la plausibilità relativa dei diversi valori del parametro dopo i dati.
8. Le garanzie frequentiste sono condizionate al modello, al disegno e alle assunzioni. Campionamento distorto, misure non valide o modelli inadeguati possono produrre conclusioni fuorvianti anche quando il tasso di errore nominale è controllato.

i Punti chiave

- Nel frequentismo i parametri sono trattati come fissi ma ignoti; dati e statistiche variano tra campioni.
- Le proprietà inferenziali sono definite mediante ripetizioni reali o ipotetiche del campionamento.
- Un intervallo di confidenza descrive la copertura di una procedura, non direttamente una probabilità a posteriori sul parametro.
- Un valore- p è calcolato assumendo l'ipotesi nulla; non è la probabilità che l'ipotesi nulla sia vera.
- Significatività statistica, importanza dell'effetto e validità scientifica sono concetti distinti.
- Frequentismo e bayesianesimo possono condividere il modello dei dati ma rispondono a domande inferenziali differenti.

i Ambiente di sviluppo

Questo capitolo non richiede pacchetti aggiuntivi. Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
```

1. Origini storiche dell'approccio frequentista

i In sintesi

Da sapere La statistica frequentista si è sviluppata attraverso contributi diversi, legati allo studio della variabilità, alla stima, alla significatività e al controllo degli errori. Questa storia è scientificamente feconda ma anche intrecciata con il movimento eugenetico.

Da saper fare Collegare Galton, Pearson, Fisher e Neyman–Pearson ai problemi statistici che hanno affrontato; distinguere i contributi tecnici dal loro contesto storico; riconoscere i principi operativi del ragionamento frequentista.

Introduzione

La statistica non è soltanto un insieme di formule. È anche un modo di organizzare l'incertezza, definire che cosa conta come evidenza e stabilire quali conclusioni siano giustificate dai dati.

Questo capitolo ricostruisce alcuni passaggi che hanno condotto alla pratica frequentista contemporanea. Non presenta una sequenza completa di nomi e date. Seleziona invece quattro problemi che restano centrali nella ricerca psicologica:

1. descrivere la variabilità tra individui;
2. quantificare le associazioni tra misure;
3. valutare quanto i dati siano incompatibili con un modello di riferimento;
4. progettare procedure che controllino gli errori nelle ripetizioni.

La storia di questi strumenti è ambivalente. Correlazione, regressione, distribuzioni campionarie, test e intervalli hanno contribuito in modo decisivo allo sviluppo della scienza empirica. Una parte della loro genealogia, tuttavia, è intrecciata con l'eugenetica e con progetti di classificazione gerarchica delle persone. Comprendere questa storia non significa rifiutare gli strumenti, ma usarli con maggiore consapevolezza scientifica ed etica.

1.1. Perché partire dalla storia?

Le procedure statistiche non sono nate tutte insieme come parti di un sistema unitario. Sono state elaborate per rispondere a problemi differenti e, in seguito, combinate nella pratica scientifica.

Conoscere questa origine aiuta a evitare due errori:

- trattare il frequentismo come un insieme perfettamente omogeneo;
- applicare una procedura senza chiedersi quale domanda fosse stata progettata per affrontare.

i Una chiave di lettura

Nel ragionamento frequentista, una domanda fondamentale è:

Come si comporterebbe questa procedura se il campionamento o l'esperimento fossero ripetuti molte volte in condizioni analoghe?

Stime, errori standard, intervalli di confidenza, livelli di significatività e potenza ricevono il loro significato da questa prospettiva sulle ripetizioni.

💡 Prerequisiti

È utile avere letto l'introduzione al modulo sull'inferenza frequentista. Non sono richieste conoscenze tecniche avanzate: il capitolo costruisce una mappa storica e concettuale prima di affrontare le singole procedure.

Panoramica del capitolo

Il capitolo procede in sei passaggi:

1. descrive il passaggio dallo studio del singolo individuo allo studio delle distribuzioni;
2. presenta i contributi di Francis Galton alla regressione verso la media e alla correlazione;
3. colloca questi sviluppi nel contesto dell'eugenetica;
4. introduce la formalizzazione statistica associata a Karl Pearson;
5. distingue la significatività fisheriana dal quadro decisionale di Neyman–Pearson;
6. ricava da questa storia i principi operativi del paradigma frequentista.

i Preparazione del notebook

Il capitolo è interamente concettuale e non richiede l'esecuzione di codice R. Nei capitoli successivi useremo simulazioni per rendere visibili distribuzioni campionarie, copertura, errori decisionali e potenza.

1.2. La quantificazione della variabilità umana

1.2.1. Dal singolo individuo alla distribuzione

Nel corso dell'Ottocento si afferma l'idea che molti fenomeni biologici, psicologici e sociali possano essere studiati quantitativamente. L'attenzione si sposta progressivamente dal singolo individuo alla distribuzione dei tratti in una popolazione.

Altezza, tempi di reazione, prestazioni cognitive e risposte a questionari vengono considerate grandezze che variano tra persone. Diventa quindi possibile:

- descrivere la posizione e la dispersione di una distribuzione;
- confrontare individui e gruppi;
- studiare come due caratteristiche variano insieme;
- costruire previsioni a partire da misure osservate.

Per la psicologia scientifica questo passaggio è decisivo: la variabilità non viene trattata soltanto come rumore, ma come un fenomeno da descrivere e spiegare.

1.2.2. Galton: regressione e associazione

Francis Galton (1822–1911) contribuì alla misurazione sistematica delle differenze individuali. Raccolse dati su caratteristiche fisiche e prestazioni, studiò somiglianze familiari e promosse l'uso delle distribuzioni per rappresentare la variazione tra persone.

Due concetti associati al suo lavoro sono particolarmente importanti.

1. Regressione verso la media.

Quando due misure sono correlate ma non perfettamente, valori estremi della prima variabile tendono a essere associati, in media, a valori meno estremi della seconda. Galton osservò questo schema studiando caratteristiche di genitori e figli. Il fenomeno non implica che gli individui estremi debbano necessariamente cambiare, né costituisce una legge causale: è una proprietà statistica dell'associazione imperfetta.

2. Correlazione.

Lo studio delle somiglianze e delle relazioni tra misure contribuì allo sviluppo di strumenti per quantificare quanto due variabili varino insieme. In psicologia, la correlazione è centrale nella psicometria, nella validazione dei test e nello studio delle differenze individuali.

 Regressione verso la media non significa miglioramento

Se si selezionano persone con valori estremi in una prima misurazione, una seconda misurazione tende spesso a risultare meno estrema anche in assenza di un intervento efficace. Per valutare un cambiamento causale non basta quindi confrontare meccanicamente il prima e il dopo.

1.3. Statistica ed eugenetica: una genealogia ambivalente

Galton coniò il termine *eugenetica* e sostenne un programma volto a classificare e selezionare i tratti umani. Anche altri protagonisti della statistica britannica, tra cui Karl Pearson e Ronald Fisher, furono coinvolti in idee, istituzioni o dibattiti eugenetici (Chivers, 2024).

Questa storia non trasforma correlazione, regressione o analisi della varianza in strumenti intrinsecamente eugenetici. Le proprietà matematiche di una procedura non dipendono dagli obiettivi morali di chi contribuì a svilupparla. Tuttavia, la storia mostra che misurare non è un'attività completamente neutrale.

Prima di interpretare una differenza tra persone o gruppi occorre chiedersi:

- quale costrutto è stato definito;
- come è stato misurato;
- chi è stato incluso o escluso dal campione;
- quali assunzioni collegano la misura al fenomeno;
- quali conseguenze può avere la classificazione prodotta.

! Responsabilità scientifica ed etica

Riconoscere la genealogia eugenetica di una parte della statistica moderna non significa rifiutare gli strumenti. Significa evitare che differenze osservate vengano trasformate automaticamente in gerarchie di valore o in spiegazioni biologiche, senza considerare misurazione, contesto, campionamento e alternative causali.

1.4. Karl Pearson e la formalizzazione della variazione

Karl Pearson (1857–1936) contribuì in modo decisivo alla matematizzazione della statistica. Sviluppò e sistematizzò strumenti per descrivere distribuzioni, quantificare associazioni e confrontare frequenze osservate con frequenze previste da un modello.

Tra i concetti associati alla sua tradizione troviamo:

- il coefficiente di correlazione prodotto-momento;
- la deviazione standard;
- famiglie di distribuzioni;
- il test del chi-quadrato.

Il test del chi-quadrato illustra un'idea che resterà centrale: si specifica un modello che produce frequenze attese e si misura quanto i dati osservati se ne discostino. Il risultato non dice, da solo, perché esista lo scarto né quale modello alternativo sia corretto. Fornisce una misura della compatibilità tra dati e modello secondo una procedura definita.

L'influenza di Pearson sulla psicologia è stata profonda. Correlazioni, standardizzazione dei punteggi e analisi delle differenze individuali sono diventate componenti ordinarie della psicometria e della ricerca quantitativa.

1.5. Fisher: verosimiglianza, disegno e significatività

Ronald A. Fisher (1890–1962) contribuì allo sviluppo del disegno sperimentale, dell'analisi della varianza, della massima verosimiglianza e dei test di significatività.

Nel quadro fisheriano, si considera spesso un'ipotesi nulla e si valuta quanto i dati osservati siano insoliti se tale ipotesi e il modello probabilistico fossero appropriati. Il valore- p può essere espresso come la probabilità, calcolata sotto l'ipotesi nulla, di ottenere un valore della statistica test almeno altrettanto incompatibile con l'ipotesi quanto quello osservato.

La definizione richiede quindi tre elementi:

1. un'ipotesi nulla;
2. una statistica test;
3. una regola che stabilisca quali risultati siano almeno altrettanto estremi.

⚠ Che cosa non dice il valore- p

Un valore- p non è:

- la probabilità che l'ipotesi nulla sia vera;
- la probabilità che il risultato sia dovuto al caso;

- la probabilità che una replica produca lo stesso risultato;
- una misura diretta della grandezza o dell'importanza dell'effetto.

Fisher attribuiva al valore- p soprattutto un ruolo di misura graduata dell'incompatibilità tra dati e ipotesi nulla. Non lo concepiva semplicemente come un interruttore automatico che divide ogni risultato in *significativo* e *non significativo*.

1.6. Neyman–Pearson: decisioni ed errori controllati

Jerzy Neyman e **Egon Pearson** svilupparono un quadro differente. Invece di concentrarsi soltanto sull'evidenza contro una singola ipotesi nulla, formularono procedure decisionali che confrontano ipotesi e controllano le conseguenze degli errori nelle ripetizioni.

In questo quadro diventano centrali:

- l'**errore di tipo I**, cioè rifiutare l'ipotesi nulla quando è vera;
- l'**errore di tipo II**, cioè non rifiutare l'ipotesi nulla quando un'alternativa specificata è vera;
- il livello α , scelto prima dell'analisi;
- la **potenza**, cioè la probabilità di rifiutare l'ipotesi nulla sotto una specifica alternativa.

La distinzione è importante perché la pratica contemporanea combina spesso elementi provenienti da Fisher e da Neyman–Pearson. Per esempio, si riporta un valore- p graduato ma lo si confronta anche con una soglia $\alpha = 0.05$ per prendere una decisione.

i Una pratica ibrida

Espressioni come « $p < 0.05$, quindi il risultato è significativo» uniscono due tradizioni:

- il valore- p come misura fisheriana di incompatibilità;
- la soglia prefissata e la decisione come elementi del quadro Neyman–Pearson.

Questa combinazione è comune, ma è utile sapere che i concetti non sono nati come parti di un unico sistema.

1.7. Il nucleo operativo del frequentismo

Dalla storia precedente emergono alcuni principi comuni alla maggior parte delle procedure frequentiste moderne.

1.7.1. Parametri fissi, dati variabili

Il parametro del modello viene trattato come fisso ma ignoto. Prima dell'osservazione, il campione è casuale; di conseguenza variano anche le statistiche calcolate sul campione.

Se campionassimo ripetutamente dalla stessa popolazione, otterremmo stime differenti. La **distribuzione campionaria** descrive questa variabilità.

1.7.2. Procedure valutate nelle ripetizioni

Uno stimatore, un intervallo o un test vengono giudicati attraverso il loro comportamento in campioni ripetuti. Per esempio:

- uno stimatore può essere valutato per distorsione, variabilità e consistenza;
- una procedura di confidenza al 95% mira a contenere il parametro vero nel 95% delle ripetizioni, sotto il modello e le assunzioni adottate;
- un test di livello $\alpha = 0.05$ mira a limitare al 5% la probabilità di errore di tipo I nelle condizioni specificate.

Queste sono proprietà della **procedura**, non garanzie assolute sul singolo risultato osservato.

1.7.3. Probabilità e modello di campionamento

Nelle applicazioni frequentiste, la probabilità descrive il comportamento di dati e statistiche generati da un modello. Le ripetizioni possono essere reali oppure ipotetiche, ma devono essere definite con sufficiente precisione: che cosa viene mantenuto fisso, che cosa viene ripetuto e quali dati possibili vengono considerati?

! La domanda guida

Prima di interpretare un risultato frequentista, chiediti:

Quale insieme di ripetizioni definisce questa probabilità e quali assunzioni rendono valido il calcolo?

Senza una risposta, valori- p , intervalli e livelli di errore rischiano di essere letti come numeri privi del loro significato procedurale.

1.8. Una riflessione per la ricerca psicologica

La psicologia ha fatto ampio uso di test t , ANOVA, regressioni, intervalli di confidenza, valori- p e analisi di potenza. Conoscerli è indispensabile per leggere la letteratura e progettare studi.

La crisi della replicabilità ha però mostrato che l'applicazione meccanica di procedure standardizzate non garantisce conoscenze affidabili. Campioni piccoli, misure poco valide, analisi flessibili, selezione dei risultati e attenzione esclusiva alla soglia 0.05 possono produrre evidenze fragili.

La conclusione non è che ogni procedura frequentista sia inadeguata. È che nessuna procedura statistica può sostituire:

- un disegno di ricerca informativo;
- misure valide;
- assunzioni plausibili;
- trasparenza nelle decisioni analitiche;
- attenzione alla dimensione e all'incertezza degli effetti.

1.9. Frequentismo e bayesianesimo: domande differenti

Il frequentismo valuta soprattutto il comportamento delle procedure sotto campionamenti ripetuti. Il bayesianesimo rappresenta e aggiorna esplicitamente l'incertezza su parametri o ipotesi, condizionatamente al modello, alla prior e ai dati.

Le due prospettive possono condividere lo stesso modello probabilistico delle osservazioni e la stessa funzione di verosimiglianza. Differiscono nel modo in cui costruiscono e interpretano l'inferenza.

Un valore- p , per esempio, esprime una probabilità dei dati o di risultati più estremi sotto un'ipotesi. Una probabilità a posteriori esprime invece l'incertezza su un parametro o un'ipotesi dopo avere combinato prior e dati. Le due quantità non sono intercambiabili.

Riflessioni conclusive

La statistica frequentista non deriva da un'unica teoria elaborata in un solo momento. La pratica contemporanea combina strumenti nati dallo studio della variabilità, dalla modellizzazione delle associazioni, dalla significatività fisheriana e dal controllo decisionale degli errori di Neyman-Pearson.

Questa storia ha prodotto strumenti fondamentali, ma è anche legata a progetti eugenetici e a usi gerarchici della misurazione. La risposta non è separare artificialmente tecnica e storia, né rifiutare ogni strumento: è usare i metodi con competenza, consapevolezza e responsabilità.

Nel prossimo capitolo passeremo dalla cornice storica alla stima. Vedremo come una statistica campionaria viene usata per stimare un parametro e perché la distribuzione campionaria è il fondamento della valutazione frequentista della precisione.

Esercizi

1. Perché lo studio delle distribuzioni ha rappresentato un passaggio importante per la psicologia scientifica?
2. Che cosa significa regressione verso la media? Perché non dimostra, da sola, che un intervento abbia prodotto un cambiamento?
3. Perché riconoscere il contesto eugenetico della statistica non implica che correlazione e regressione debbano essere abbandonate?
4. Quale domanda generale esprime un test del chi-quadrato quando confronta frequenze osservate e attese?
5. Che cosa misura un valore- p e quale informazione non fornisce sull'ipotesi nulla?
6. Qual è la differenza principale tra la logica fisheriana della significatività e il quadro Neyman-Pearson?
7. Perché la frase « $p < 0.05$, quindi rifiuto l'ipotesi nulla» può essere considerata una formulazione ibrida?
8. Perché il controllo nominale degli errori non basta a garantire una conclusione scientificamente valida?

Soluzioni

1. Ha permesso di trattare la variabilità tra individui come un fenomeno descrivibile e modellizzabile, invece che come semplice rumore. Da qui derivano strumenti per confrontare misure, studiare associazioni e costruire previsioni.
2. Quando due misure sono correlate ma non perfettamente, valori estremi della prima tendono a essere associati, in media, a valori meno estremi della seconda. Un cambiamento verso valori meno estremi può quindi comparire anche senza un effetto causale dell'intervento.
3. Gli strumenti matematici possono essere utilizzati per scopi diversi da quelli storici. La consapevolezza della loro genealogia serve però a controllare come vengono definiti i costrutti, interpretate le differenze e utilizzate le classificazioni.
4. Chiede quanto le frequenze osservate si discostino da quelle previste dal modello di riferimento, secondo la statistica e la distribuzione di campionamento adottate.
5. Misura, sotto l'ipotesi nulla, la probabilità di un valore della statistica test almeno altrettanto incompatibile con l'ipotesi quanto quello osservato. Non fornisce la probabilità che l'ipotesi nulla sia vera.
6. Fisher usava il valore- p soprattutto come misura graduata dell'incompatibilità con l'ipotesi nulla. Neyman-Pearson formulavano regole decisionali prefissate e valutate attraverso errori di tipo I, errori di tipo II e potenza.
7. Il valore- p appartiene alla tradizione fisheriana, mentre la soglia prefissata e la decisione di rifiuto richiamano il quadro Neyman-Pearson. La pratica comune combina i due elementi.
8. I tassi di errore sono garantiti soltanto sotto il modello, il disegno e le assunzioni specificate. Campionamento distorto, misure non valide, analisi flessibili o modelli inadeguati possono rendere fuorviante il risultato.

Punti chiave

- Lo sviluppo della statistica frequentista deriva da contributi storici differenti.
- Galton contribuì allo studio della regressione verso la media e dell'associazione tra variabili.
- Una parte della statistica moderna è storicamente intrecciata con il movimento eugenetico.
- Pearson formalizzò strumenti per descrivere distribuzioni e confrontare dati osservati e attesi.
- Fisher sviluppò la logica della significatività, la massima verosimiglianza e il disegno sperimentale.
- Neyman-Pearson introdussero un quadro decisionale fondato sul controllo degli errori e sulla potenza.
- La pratica contemporanea combina spesso concetti fisheriani e Neyman-Pearson.
- Le proprietà frequentiste riguardano procedure valutate sotto campionamenti ripetuti.

i Ambiente di sviluppo

Il capitolo non richiede pacchetti aggiuntivi. Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
```

Bibliografia

2. Stime, stimatori e parametri

In sintesi

Da sapere Nell'inferenza frequentista, il parametro è una quantità fissa del modello, lo stimatore è una regola applicata ai dati e la stima è il valore numerico osservato. Le proprietà di uno stimatore vengono valutate immaginando di ripetere il campionamento nelle stesse condizioni.

Da saper fare Distinguere parametro, stimatore e stima; interpretare bias, consistenza, efficienza ed errore quadratico medio; distinguere deviazione standard ed errore standard; spiegare perché una stima puntuale deve essere accompagnata da una misura di precisione.

Introduzione

Il capitolo precedente ha mostrato come la statistica frequentista si sia formata attraverso contributi differenti: lo studio della variabilità, la regressione e la correlazione, la significatività fisheriana e il controllo degli errori di Neyman–Pearson. Passiamo ora dalla storia al primo problema operativo dell'inferenza:

Come possiamo usare un campione per stimare una quantità sconosciuta della popolazione o del modello?

La risposta frequentista non consiste soltanto nel calcolare un numero. Occorre anche valutare la procedura che produce quel numero: quanto varia da campione a campione, se tende sistematicamente a sbagliare e se diventa più precisa quando aumentano le informazioni disponibili.

Questo capitolo introduce il lessico necessario per comprendere i capitoli successivi. Gli intervalli di confidenza e i test di ipotesi dipendono infatti dalla stessa idea fondamentale: una statistica osservata va interpretata attraverso il comportamento che avrebbe sotto campionamenti ripetuti.

2.1. Perché la stima è il primo passo dell'inferenza?

Immaginiamo di voler conoscere il livello medio di ansia degli studenti iscritti a un'università. Non possiamo osservare ogni studente, quindi selezioniamo un campione e calcoliamo la media dei punteggi.

La media campionaria descrive il campione osservato. Per usarla come informazione sulla popolazione dobbiamo però affrontare due domande:

1. **Quale quantità vogliamo stimare?**
2. **Quanto cambierebbe la nostra stima se osservassimo un altro campione?**

La prima domanda riguarda il parametro o, più precisamente, la **quantità bersaglio** dell'analisi. La seconda riguarda la variabilità campionaria dello stimatore.

! Prima della formula viene la domanda

Una stima è interpretabile soltanto se sono definiti con chiarezza:

- la popolazione o il processo a cui si vuole generalizzare;
- il costrutto psicologico e il modo in cui viene misurato;
- la quantità da stimare;
- il meccanismo di campionamento o di assegnazione;
- il modello che collega i dati alla quantità bersaglio.

Una procedura può essere matematicamente precisa e stimare con grande accuratezza la quantità sbagliata.

💡 Prerequisiti

È utile avere letto:

- l'introduzione a questo modulo e il capitolo sulle origini storiche del frequentismo;
- il capitolo [Dal campione all'evidenza](#) del sito dedicato alla probabilità;
- i richiami su valore atteso, varianza e distribuzioni campionarie.

Qui non ridimostreremo la Legge dei Grandi Numeri o il Teorema del Limite Centrale. Useremo quei risultati per comprendere la logica frequentista della stima.

Panoramica del capitolo

Il capitolo procede in sette passaggi:

1. distingue parametro, stimatore e stima;
2. chiarisce che cosa significa produrre una stima puntuale;
3. introduce correttezza e bias;
4. presenta consistenza, efficienza ed errore quadratico medio;
5. collega lo stimatore alla sua distribuzione campionaria;
6. distingue deviazione standard ed errore standard;
7. confronta, senza sovrapporle, la stima frequentista e quella bayesiana.

i Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>
  source()
```

2.2. Il problema della stima

Una ricercatrice raccoglie un campione di studenti e osserva un punteggio medio di ansia pari a 18.4. Questo numero è una descrizione esatta del campione, ma è soltanto una possibile stima della media della popolazione.

2. Stime, stimatori e parametri

Se venisse selezionato un altro campione, la media sarebbe probabilmente diversa. Il problema inferenziale nasce quindi dalla distanza tra:

- la quantità della popolazione o del modello che interessa alla ricerca;
- l'informazione parziale e variabile fornita dal campione.

Nel frequentismo standard, il parametro viene trattato come **fisso ma ignoto** all'interno del modello. La nostra conoscenza del parametro è incompleta, ma la probabilità non viene normalmente usata per assegnare una distribuzione ai suoi valori possibili. Viene invece usata per descrivere dati, statistiche e procedure sotto ripetizioni reali o ipotetiche.

La domanda frequentista

Una domanda frequentista tipica è:

Se applicassimo lo stesso stimatore a molti campioni generati nelle stesse condizioni, come si comporterebbero le stime?

Questa domanda consente di definire bias, errore standard, copertura ed errori decisionali.

2.3. Parametro, stimatore e stima

I tre termini descrivono livelli differenti dell'analisi.

Termine	Significato	Esempio
Parametro	Quantità fissa e ignota del modello o della popolazione	La media della popolazione, μ
Stimatore	Regola o funzione dei dati usata per stimare il parametro	La media campionaria, $\bar{X}$
Stima	Valore numerico assunto dallo stimatore nel campione osservato	$\bar{x} = 18.4$

Il **parametro** è l'obiettivo dell'inferenza. Può essere una media, una proporzione, una varianza, una differenza tra gruppi, una correlazione o un coefficiente di regressione.

Lo **stimatore** è una funzione dei dati. Prima di osservare il campione, il suo valore non è noto perché dipende da quali dati verranno raccolti. Per questo motivo viene rappresentato con una variabile casuale, come $\bar{X}$ o $\hat{\theta}$.

La **stima** è la realizzazione osservata dello stimatore, indicata spesso con lettere minuscole, come $\bar{x}$ o $\hat{\theta}_{\text{obs}}$.

Stimatore e stima non sono sinonimi

Correttezza, consistenza, varianza ed efficienza sono proprietà dello **stimatore come procedura**. La singola **stima osservata** può essere vicina o lontana dal parametro. Poiché il valore vero è ignoto, la sua accuratezza non può essere letta direttamente dal numero osservato.

2.4. La stima puntuale

Una **stima puntuale** usa un singolo numero come sintesi del parametro di interesse. Esempi comuni sono:

- $\bar{x}$ per stimare la media μ ;
- $\hat{p}$ per stimare una proporzione p ;
- $\bar{x}_1 - \bar{x}_2$ per stimare una differenza tra medie;
- r per stimare una correlazione ρ .

Il termine *puntuale* non significa che quel valore sia certamente corretto, né necessariamente che sia il valore «più probabile». Significa soltanto che la procedura restituisce un singolo valore.

Due studi possono produrre la stessa stima ma livelli molto differenti di precisione:

Studio	Stima della media	Errore standard
A	18.4	0.30
B	18.4	1.80

La stima puntuale coincide, ma nello studio B lo stimatore varia molto di più da campione a campione. Il numero 18.4 non contiene, da solo, questa informazione.

! Precisione non significa accuratezza

Un errore standard piccolo indica che la procedura produce stime poco variabili nelle condizioni assunte. Non dimostra che la stima sia vicina alla quantità scientificamente rilevante.

Un campione molto grande può produrre una stima estremamente precisa ma sistematicamente distorta a causa di selezione dei partecipanti, misurazione inadeguata o modello errato.

2.5. Come si sceglie uno stimatore?

Uno stesso parametro può essere stimato in modi differenti. La scelta può derivare:

- da una sintesi naturale dei dati, come la media campionaria;
- dal metodo dei minimi quadrati;
- dalla massimizzazione della verosimiglianza;
- da criteri di robustezza o regolarizzazione;
- da proprietà teoriche considerate desiderabili.

La **massima verosimiglianza**, per esempio, sceglie il valore del parametro che rende massimi i dati osservati secondo il modello. Il sito dedicato alla probabilità introduce separatamente il concetto di [verosimiglianza](#).

La scelta di uno stimatore non dipende soltanto dalla disponibilità di una formula. Dipende dal modello, dallo scopo dell'analisi e dal costo attribuito ai diversi tipi di errore.

2.6. Che cosa rende buono uno stimatore?

Le proprietà seguenti descrivono il comportamento dello stimatore sotto il modello e il meccanismo di campionamento specificati. Nessuna di esse garantisce, da sola, che il modello o la misura siano adeguati alla domanda psicologica.

2.6.1. Correttezza e bias

Uno stimatore $\hat{\theta}$ è **corretto**, o **non distorto**, se il suo valore atteso coincide con il parametro:

$$E(\hat{\theta}) = \theta.$$

Il **bias statistico** è definito come:

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

Uno stimatore corretto è centrato sul parametro nel lungo periodo. Non segue che ogni singola stima sia vicina al valore vero: uno stimatore può essere non distorto ma molto variabile.

Due significati diversi di bias

Il bias dello stimatore è una proprietà matematica definita rispetto a un modello e a ripetizioni del campionamento.

Espressioni come *bias di selezione*, *bias di misurazione* o *bias di pubblicazione* indicano invece distorsioni del processo di ricerca. Non sono automaticamente rappresentate da $\text{Bias}(\hat{\theta})$ e non vengono eliminate scegliendo uno stimatore non distorto.

2.6.2. Consistenza

Uno stimatore è **consistente** se converge al parametro quando la dimensione del campione cresce. Una formulazione comune è la convergenza in probabilità:

$$\hat{\theta}_n \xrightarrow{P} \theta \quad \text{quando } n \rightarrow \infty.$$

La consistenza è una proprietà asintotica. Non garantisce che lo stimatore funzioni bene in un campione piccolo, né corregge automaticamente errori di misura, campionamento non rappresentativo o specificazione errata del modello.

Uno stimatore può essere consistente pur essendo lievemente distorto nei campioni finiti, purché il bias e la variabilità si riducano con l'aumentare di n .

2.6.3. Efficienza

All'interno di una classe specificata di stimatori e sotto un dato modello, uno stimatore viene detto più **efficiente** se raggiunge una precisione maggiore, spesso espressa da una varianza inferiore.

Il confronto richiede cautela:

- deve riguardare lo stesso parametro;
- deve usare lo stesso modello e lo stesso schema di campionamento;
- deve chiarire la classe di stimatori considerata;
- può essere esatto in campioni finiti oppure soltanto asintotico.

L'efficienza non è quindi una proprietà assoluta separata dalle assunzioni.

2.6.4. Il compromesso bias-varianza

Uno stimatore lievemente distorto può avere una varianza molto inferiore a quella di uno stimatore non distorto. Per uno stimatore scalare con secondo momento finito, l'**errore quadratico medio** è:

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2.$$

La formula mostra due modi diversi di sbagliare:

- le stime possono essere molto disperse;
- le stime possono essere sistematicamente spostate rispetto al parametro.

Ridurre una componente può aumentare l'altra. Per questo motivo la non distorsione non è sempre l'unico criterio rilevante.

2.7. La distribuzione campionaria

La **distribuzione campionaria** descrive i valori che lo stimatore assumerebbe in campioni ripetuti generati secondo lo stesso modello e lo stesso disegno.

Non è:

- la distribuzione dei dati individuali;
- la distribuzione osservata in un singolo campione;
- una distribuzione di probabilità sul parametro.

È una distribuzione dello **stimatore**.

La distribuzione campionaria permette di:

- calcolare errori standard;
- confrontare stimatori;
- costruire intervalli di confidenza;
- definire statistiche test e valori critici;
- valutare errori di tipo I, errori di tipo II e potenza.

i Collegamento con il sito sulla probabilità

Il sito sulla probabilità sviluppa il passaggio dal campione alla distribuzione campionaria. Qui cambiamo prospettiva: usiamo quella distribuzione per valutare una procedura inferenziale. Questa separazione evita di ripetere la teoria probabilistica e chiarisce il ruolo specifico del modulo frequentista.

2.8. L'errore standard

L'**errore standard** è la deviazione standard della distribuzione campionaria di uno stimatore:

$$SE(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}.$$

Per una media calcolata su n osservazioni indipendenti con la stessa varianza finita σ^2 :

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Poiché σ è generalmente ignota, nel caso elementare viene stimata mediante la deviazione standard campionaria:

$$\widehat{SE}(\bar{X}) = \frac{s}{\sqrt{n}}.$$

Questa formula non è universale. Dati raggruppati, misure ripetute, dipendenza temporale, campionamenti complessi o eteroschedasticità richiedono errori standard appropriati alla struttura dei dati.

! Deviazione standard ed errore standard

La **deviazione standard** descrive la dispersione delle osservazioni.

L'**errore standard** descrive la dispersione campionaria di uno stimatore.

Aumentando n , l'errore standard della media tende a diminuire, ma la variabilità tra gli individui non scompare.

i Che cosa comunica l'errore standard

L'errore standard è una misura della **precisione campionaria della procedura**, sotto le assunzioni adottate.

Non misura direttamente:

- la validità del costrutto;
- il bias di selezione;
- l'importanza dell'effetto;
- la probabilità che il parametro si trovi vicino alla stima;
- la probabilità di replicare un risultato statisticamente significativo.

2.9. Dalla stima puntuale all'intervallo

Una stima puntuale risponde alla domanda:

Quale valore ha restituito lo stimatore nel campione osservato?

L'errore standard aggiunge:

Quanto varierebbe lo stimatore sotto ripetizioni del campionamento?

Il capitolo successivo combinerà stima, errore standard e valore critico per costruire un **intervallo di confidenza**. L'obiettivo non sarà assegnare una probabilità al parametro, ma costruire una procedura con una frequenza di copertura controllata sotto il modello.

Non anticipiamo qui la derivazione. È sufficiente riconoscere il passaggio logico:

stima puntuale $\longrightarrow$ variabilità campionaria $\longrightarrow$ procedura intervallare.

2.10. Stima frequentista e stima bayesiana

Frequentismo e bayesianesimo possono condividere:

- lo stesso insieme di dati;
- lo stesso modello generativo;
- la stessa funzione di verosimiglianza;
- la stessa domanda sostantiva.

Differiscono nel modo in cui rappresentano l'incertezza inferenziale.

Aspetto	Stima frequentista	Stima bayesiana
Parametro	Fisso all'interno del modello	Rappresentato mediante una distribuzione di probabilità
Quantità probabilistiche	Dati, statistiche e procedure sotto campionamento	Parametri e predizioni condizionati a prior, modello e dati
Oggetto centrale	Stimatore e distribuzione campionaria	Distribuzione a posteriori
Misura elementare di precisione	Errore standard	Dispersione a posteriori
Valutazione	Proprietà sotto ripetizioni	Coerenza dell'aggiornamento e adeguatezza del modello

La distinzione non implica che un'analisi frequentista produca soltanto un numero o che un'analisi bayesiana non possa essere valutata nelle ripetizioni. Indica quale oggetto viene usato come base immediata dell'inferenza.

! Un confronto utile, non una gara di slogan

L'errore standard non è una deviazione standard a posteriori e un intervallo di confidenza non è un intervallo di credibilità.

Le quantità possono talvolta risultare numericamente simili, ma hanno significati diversi perché derivano da costruzioni probabilistiche differenti.

Riflessioni conclusive

Stimare un parametro significa molto più che calcolare una statistica descrittiva. Nel frequentismo, lo stimatore viene trattato come una procedura casuale prima dell'osservazione dei dati e valutato attraverso la sua distribuzione campionaria.

Abbiamo distinto parametro, stimatore e stima; introdotto correttezza, bias, consistenza, efficienza ed errore quadratico medio; chiarito che l'errore standard misura la precisione campionaria e non la variabilità individuale o la validità scientifica.

La lezione centrale è duplice:

1. una stima puntuale senza una misura di precisione è incompleta;
2. una stima molto precisa può essere scientificamente fuorviante se il campione, la misura o il modello sono inadeguati.

Nel prossimo capitolo vedremo come la logica della distribuzione campionaria conduce agli intervalli di confidenza e perché la loro interpretazione riguarda la copertura della procedura, non una probabilità assegnata al parametro osservato.

Esercizi

1. In uno studio su 120 studenti, la media osservata di una scala di stress è 24.6. Identifica il parametro, lo stimatore e la stima.
2. Due studi producono la stessa stima, ma il primo ha errore standard 0.4 e il secondo 2.1. Che cosa puoi concludere sulla loro precisione? Che cosa non puoi concludere sulla loro accuratezza?
3. Perché uno stimatore non distorto può produrre una singola stima molto lontana dal parametro?
4. Uno stimatore è lievemente distorto nei campioni piccoli, ma il bias e la varianza tendono a zero quando n aumenta. Può essere consistente? Spiega.
5. Perché un campione molto grande non elimina automaticamente il bias di selezione o gli errori di misurazione?
6. Qual è la differenza tra la deviazione standard dei punteggi e l'errore standard della media?
7. Che cosa mostra la decomposizione $MSE = Var + Bias^2$?
8. Frequentismo e bayesianesimo usano la stessa verosimiglianza. In che modo differisce l'oggetto immediato con cui rappresentano l'incertezza sul parametro?

Soluzioni

1. Il parametro è la media della scala di stress nella popolazione definita dallo studio. Lo stimatore è la media campionaria $\bar{X}$. La stima osservata è $\bar{x} = 24.6$.
2. Il primo studio ha una stima campionariamente più precisa: lo stimatore varia meno

sotto le ripetizioni assunte. Non possiamo però sapere dal solo errore standard quale stima sia più vicina al parametro vero, né se campione e misura siano privi di distorsioni.

3. La non distorsione riguarda la media delle stime in molte ripetizioni. Se la distribuzione campionaria è molto dispersa, una singola stima può comunque risultare lontana dal parametro.
4. Sì. La consistenza richiede che lo stimatore converga al parametro quando n cresce. Non richiede necessariamente che sia non distorto per ogni dimensione campionaria.
5. Aumentare n riduce soprattutto la variabilità campionaria. Se il campione esclude sistematicamente una parte della popolazione o lo strumento misura in modo distorto, più dati possono rendere molto precisa una stima sistematicamente errata.
6. La deviazione standard descrive quanto differiscono le osservazioni individuali. L'errore standard descrive quanto varierebbe la media campionaria tra campioni ripetuti.
7. Mostra che l'errore complessivo di uno stimatore dipende sia dalla sua dispersione sia dallo spostamento sistematico rispetto al parametro. Uno stimatore può migliorare riducendo una componente anche se l'altra aumenta leggermente.
8. Nel frequentismo l'incertezza viene rappresentata immediatamente attraverso lo stimatore e la sua distribuzione campionaria. Nel bayesianesimo viene rappresentata mediante la distribuzione a posteriori del parametro, condizionata a prior, modello e dati.

i Punti chiave

- Il parametro è la quantità fissa che si vuole conoscere all'interno del modello.
- Lo stimatore è una funzione dei dati; la stima è il valore osservato.
- La stima puntuale non contiene, da sola, una misura di precisione.
- La non distorsione riguarda il valore atteso dello stimatore, non la vicinanza di ogni singola stima al parametro.
- La consistenza è una proprietà asintotica.
- L'efficienza dipende dal modello e dalla classe di stimatori considerata.
- L'MSE combina varianza e bias al quadrato.
- L'errore standard descrive la variabilità campionaria dello stimatore.
- Precisione campionaria, accuratezza, validità della misura e rappresentatività del campione sono concetti distinti.
- Frequentismo e bayesianesimo possono condividere la verosimiglianza, ma rappresentano diversamente l'incertezza inferenziale.

i Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

2. Stime, stimatori e parametri

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2        ggdist_3.3.3
#> [7] tidybayes_3.0.7      bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0       posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0          Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0     janitor_2.2.1          matrixStats_1.5.0
#> [22] modelr_0.1.11        tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2          rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8          tidymodels_1.2.1      farver_2.1.2
#> [4] S7_0.2.2             fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39         timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5       magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0           tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51            bridgesampling_1.2-1  pkgbuild_1.4.8
#> [19] curl_7.1.0            RColorBrewer_1.1-3    abind_1.4-8
#> [22] purrr_1.2.2           grid_4.6.1            stats4_4.6.1
#> [25] xtable_1.8-8          inline_0.3.21         emmeans_2.0.4
#> [28] scales_1.4.0          cli_3.6.6             mvtnorm_1.4-2
#> [31] rmarkdown_2.31        generics_0.1.4         otel_0.2.0
#> [34] RcppParallel_5.1.11-2 cachem_1.1.0          stringr_1.6.0
#> [37] parallel_4.6.1        vctrs_0.7.3           V8_8.2.0
#> [40] Matrix_1.7-6          jsonlite_2.0.0         arrayhelpers_1.1-2
#> [43] glue_1.8.1            codetools_0.2-20      distributional_0.8.1
#> [46] lubridate_1.9.5       stringi_1.8.7         gtable_0.3.6
#> [49] QuickJSR_1.10.0       pillar_1.11.1         htmltools_0.5.9
#> [52] Brodingtonag_1.2-9    R6_2.6.1              textshaping_1.0.5
#> [55] rprojroot_2.1.1       evaluate_1.0.5        lattice_0.22-9
#> [58] backports_1.5.1       memoise_2.0.1         broom_1.0.13
#> [61] snakecase_0.11.1      rstantools_2.6.0      coda_0.19-4.1
#> [64] gridExtra_2.3.1       nlme_3.1-170          checkmate_2.3.4
#> [67] xfun_0.60             pkgconfig_2.0.3
```


3. Intervalli di confidenza

i In sintesi

Da sapere Un intervallo di confidenza combina una stima puntuale e una misura della sua variabilità campionaria. Il livello di confidenza descrive la copertura della procedura sotto ripetizioni del campionamento e non assegna una probabilità al parametro nell'intervallo osservato.

Da saper fare Interpretare correttamente un intervallo di confidenza; distinguere copertura, precisione e validità; spiegare il ruolo di errore standard, valore critico e dimensione campionaria; confrontare intervalli di confidenza e intervalli di credibilità senza confonderli.

Introduzione

Nel capitolo precedente abbiamo distinto **parametro**, **stimatore** e **stima**. Abbiamo inoltre visto che una stima puntuale, come una media campionaria, è incompleta se non viene accompagnata da una misura della sua precisione.

L'intervallo di confidenza sviluppa questa idea. Parte dalla distribuzione campionaria dello stimatore e costruisce, intorno alla stima osservata, un intervallo mediante una procedura progettata per raggiungere una determinata frequenza di copertura.

Il punto più delicato è interpretativo. Un intervallo di confidenza al 95% non significa che il parametro abbia il 95% di probabilità di trovarsi tra i due estremi osservati. Il 95% qualifica la procedura prima dell'osservazione dei dati: sotto il modello e il piano di campionamento assunti, il 95% degli intervalli prodotti in ripetizioni analoghe contiene il parametro vero.

3.1. Perché una stima puntuale non basta?

Supponiamo di osservare una media campionaria pari a 24.8. Questo numero risponde alla domanda:

Quale valore ha assunto lo stimatore nel campione osservato?

Non risponde però a una seconda domanda:

Quanto cambierebbe la stima se osservassimo un altro campione generato nelle stesse condizioni?

Due studi possono ottenere la stessa media e avere precisioni molto diverse. L'intervallo di confidenza rende visibile questa seconda informazione, combinando:

1. la stima puntuale;
2. l'errore standard;
3. un valore critico associato al livello di confidenza.

! Precisione, non garanzia di verità

Un intervallo stretto indica una bassa variabilità campionaria della procedura nelle condizioni assunte. Non garantisce che il campione sia rappresentativo, che la misura sia valida o che il modello sia corretto.

Una stima può essere molto precisa e tuttavia sistematicamente fuorviante.

💡 Prerequisiti

È utile avere letto:

- Capitolo 2, per la distinzione tra parametro, stimatore, stima ed errore standard;
- il capitolo [Dal campione all'evidenza](#), per il significato della distribuzione campionaria;
- l'introduzione al modulo frequentista, per la distinzione tra probabilità della procedura e incertezza sul parametro.

Qui useremo questi concetti senza ripeterne la teoria probabilistica.

Panoramica del capitolo

Il capitolo procede in otto passaggi:

1. introduce la forma generale di un intervallo di confidenza;
2. deriva l'intervallo per una media con varianza nota;
3. presenta l'intervallo t per una media con varianza ignota;
4. calcola un esempio numerico in R;
5. rende intuitiva la copertura mediante simulazione;
6. discute i principali fraintendimenti;
7. mostra che ampiezza e copertura dipendono da procedura e assunzioni;
8. distingue l'intervallo di confidenza dall'intervallo di credibilità e prepara il passaggio ai test di ipotesi.

i Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>
  source()
```

3.2. Dalla stima all'intervallo

Molti intervalli di confidenza hanno la forma:

$$\text{stima} \pm \text{valore critico} \times \text{errore standard}.$$

Il prodotto tra valore critico ed errore standard è il **marginale di errore**.

La stima determina il centro dell'intervallo. L'errore standard descrive la variabilità campionaria dello stimatore. Il valore critico stabilisce quanto dobbiamo allontanarci dal centro per ottenere il livello di copertura desiderato.

Questa forma non è universale. Esistono intervalli asimmetrici, intervalli basati sulla verosimiglianza, intervalli bootstrap e procedure specifiche per proporzioni, varianze e coefficienti di regressione. Tuttavia, il caso della media rende visibile la logica fondamentale.

3.3. Caso ideale: media con varianza nota

Consideriamo osservazioni indipendenti da una popolazione normale con media ignota μ e deviazione standard nota σ . La media campionaria ha distribuzione:

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Di conseguenza,

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

Per un livello di confidenza del 95%:

$$P(-1.96 \leq Z \leq 1.96) = 0.95.$$

Sostituendo la definizione di Z e riordinando la disuguaglianza:

$$P\left(\bar{X} - 1.96 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + 1.96 \frac{\sigma}{\sqrt{n}}\right) = 0.95.$$

Prima di osservare il campione, gli estremi sono variabili casuali perché dipendono da $\bar{X}$. La procedura produce quindi un intervallo casuale con copertura 0.95.

Dopo aver osservato i dati, otteniamo due estremi numerici. Il parametro, nel modello frequentista, è fisso: l'intervallo osservato lo contiene oppure non lo contiene.

i Dove si trova la probabilità?

Nell'espressione precedente, la probabilità riguarda gli estremi casuali dell'intervallo prima dell'osservazione dei dati. Non riguarda una distribuzione di probabilità assegnata a μ .

3.4. Caso usuale: media con varianza ignota

Nella ricerca psicologica, σ è quasi sempre ignota. La sostituiamo quindi con la deviazione standard campionaria s .

Se le osservazioni sono indipendenti e provengono da una popolazione normale, la statistica

$$T = \frac{\bar{X} - \mu}{s/\sqrt{n}}$$

segue esattamente una distribuzione t di Student con $n - 1$ gradi di libertà:

$$T \sim t_{n-1}.$$

L'intervallo bilaterale al livello $1 - \alpha$ è:

$$\bar{X} \pm t_{1-\alpha/2, n-1} \frac{s}{\sqrt{n}}.$$

La distribuzione t ha code più pesanti della normale standard. Nei campioni piccoli, il valore critico è quindi più grande e l'intervallo più ampio. Al crescere dei gradi di libertà, la distribuzione t si avvicina alla normale standard.

⚠ Esatto e approssimato

L'intervallo t classico ha copertura esatta sotto indipendenza e normalità della popolazione. Con campioni grandi può essere usato come approssimazione anche in situazioni non perfettamente normali, ma la qualità dell'approssimazione dipende dalla forma della distribuzione, dalla presenza di valori estremi e dalla struttura di dipendenza. Un campione grande non rende irrilevante qualunque violazione.

3.5. Un esempio numerico

Consideriamo dieci punteggi di benessere psicologico:

```
punteggi <- c(28, 22, 26, 18, 30, 24, 27, 17, 21, 25)

n <- length(punteggi)
media <- mean(punteggi)
dev_std <- sd(punteggi)
errore_standard <- dev_std / sqrt(n)

c(
  media = media,
  deviazione_standard = dev_std,
  errore_standard = errore_standard,
  n = n
)
#>          media deviazione_standard  errore_standard      n
#>          23.80             4.26             1.35    10.00
```

La media osservata è 23.8, la deviazione standard campionaria è circa 4.26 e l'errore standard è circa 1.35.

Calcoliamo manualmente l'intervallo di confidenza al 95%:

```
alpha <- 0.05
t_star <- qt(1 - alpha / 2, df = n - 1)
margine_errore <- t_star * errore_standard

limite_inferiore <- media - margine_errore
limite_superiore <- media + margine_errore

c(
  t_critico = t_star,
  margine_errore = margine_errore,
  limite_inferiore = limite_inferiore,
  limite_superiore = limite_superiore
)
#>          t_critico  margine_errore limite_inferiore limite_superiore
#>             2.26           3.05           20.75           26.85
```

Otteniamo approssimativamente:

$$23.8 \pm 2.262 \times 1.348 = [20.75, 26.85].$$

La stessa procedura è disponibile in R:

```
t.test(punteggi, conf.level = 0.95)
#>
#> One Sample t-test
#>
#> data: punteggi
#> t = 18, df = 9, p-value = 3e-08
#> alternative hypothesis: true mean is not equal to 0
#> 95 percent confidence interval:
#>  20.8 26.8
#> sample estimates:
#> mean of x
#>      23.8
```

`t.test()` restituisce anche una statistica test e un valore-*p*. In questo capitolo usiamo soltanto l'intervallo; i test di ipotesi saranno introdotti nel capitolo successivo.

Come comunicare il risultato

Una formulazione appropriata è:

Nel campione, il punteggio medio di benessere è 23.8. L'intervallo di confidenza al 95% per la media, costruito con la procedura *t*, è [20.75, 26.85].

È utile riportare anche unità di misura, numerosità campionaria e condizioni dell'analisi. Da evitare:

C'è il 95% di probabilità che la media vera sia compresa tra 20.75 e 26.85.

3.6. La logica della copertura

La **copertura** è la proporzione di intervalli che contengono il parametro quando la procedura viene ripetuta secondo il modello e il piano di campionamento specificati.

Per rendere visibile questa idea, simuliamo molti campioni da una popolazione normale con media nota e costruiamo un intervallo t per ciascun campione.

```
set.seed(42)

mu_vero <- 50
sigma_vera <- 10
n <- 25
n_simulazioni <- 1000

intervalli <- replicate(n_simulazioni, {
  campione <- rnorm(n, mean = mu_vero, sd = sigma_vera)
  ic <- t.test(campione, conf.level = 0.95)$conf.int
  c(inferiore = ic[1], superiore = ic[2])
})

contiene_mu <- intervalli["inferiore", ] <= mu_vero &
  intervalli["superiore", ] >= mu_vero

mean(contiene_mu)
#> [1] 0.948

n_mostra <- 50

dati_grafico <- data.frame(
  campione = seq_len(n_mostra),
  inferiore = intervalli["inferiore", seq_len(n_mostra)],
  superiore = intervalli["superiore", seq_len(n_mostra)],
  contiene = contiene_mu[seq_len(n_mostra)]
)

ggplot(
  dati_grafico,
  aes(
    x = campione,
    y = inferiore,
    yend = superiore,
    linetype = contiene
  )
) +
  geom_segment(aes(xend = campione), linewidth = 0.7) +
  geom_hline(yintercept = mu_vero, linetype = "dashed") +
  coord_flip() +
```

```
labs(
  x = "Campione simulato",
  y = "Intervallo di confidenza",
  linetype = "Contiene la media vera"
)
```




Figura 3.1.: Cinquanta intervalli di confidenza al 95% ottenuti da campioni ripetuti. La linea tratteggiata indica la media vera.

Nella simulazione, la copertura empirica oscilla intorno al 95%. Non deve risultare esattamente 0.95 in un numero finito di ripetizioni.

Figura 3.1 mostra che alcuni intervalli non contengono il parametro. Il livello di confidenza non identifica quali siano. Dopo aver osservato un singolo intervallo, la proprietà di copertura non si trasforma in una probabilità riferita a quello specifico intervallo.

! Copertura nominale e copertura effettiva

Il 95% è una proprietà nominale della procedura sotto determinate assunzioni. Se il modello, l'indipendenza, il piano di campionamento o il metodo di calcolo non sono appropriati, la copertura effettiva può essere diversa dal valore nominale.

3.7. Interpretazioni corrette e fraintendimenti

Affermazione	Valutazione	Motivo
«La procedura produce intervalli che contengono il parametro nel 95% delle ripetizioni previste dal modello.»	Corretta	Descrive la copertura frequentista.

3. Intervalli di confidenza

Affermazione	Valutazione	Motivo
«Il parametro ha il 95% di probabilità di trovarsi in questo intervallo.»	Scorretta	Il parametro è fisso nel modello frequentista; la probabilità riguarda la procedura.
«Il 95% dei valori individuali si trova nell'intervallo.»	Scorretta	L'intervallo riguarda un parametro, non la dispersione dei punteggi individuali.
«I valori centrali sono più probabili di quelli vicini agli estremi.»	Non giustificata	L'intervallo non è una distribuzione di probabilità sul parametro.
«Un intervallo più stretto indica maggiore precisione campionaria, a parità di metodo e livello di confidenza.»	Corretta	L'ampiezza dipende dall'errore standard e dal valore critico.
«Tutti i valori interni sono ugualmente plausibili.»	Non giustificata	La procedura non assegna probabilità o plausibilità ai singoli valori del parametro.

A volte un intervallo di confidenza viene descritto come insieme di valori **compatibili con i dati**. Questa espressione può essere utile, ma deve essere completata:

valori non esclusi dalla procedura, dato il modello, le assunzioni e il livello scelto.

Non significa che tutti i valori interni siano ugualmente credibili, né che quelli esterni siano impossibili.

3.8. Che cosa determina l'ampiezza?

3.8.1. Errore standard

A parità di valore critico, un errore standard maggiore produce un intervallo più ampio. L'errore standard dipende dalla variabilità dei dati e dalla struttura dello stimatore.

3.8.2. Livello di confidenza

Aumentare il livello di confidenza richiede un valore critico più grande. Sullo stesso campione, un intervallo al 99% è quindi più ampio di uno al 95%, che a sua volta è più ampio di uno al 90%.

```
livelli <- c(0.80, 0.90, 0.95, 0.99)

data.frame(
  livello = livelli,
  t_critico = qt(1 - (1 - livelli) / 2, df = n - 1)
) |>
transform(
  limite_inferiore =
    media - t_critico * errore_standard,
  limite_superiore =
```



```

    media + t_critico * errore_standard,
    ampiezza =
      2 * t_critico * errore_standard
  )
#>   livello t_critico limite_inferiore limite_superiore ampiezza
#> 1    0.80      1.32           22.0           25.6      3.55
#> 2    0.90      1.71           21.5           26.1      4.61
#> 3    0.95      2.06           21.0           26.6      5.57
#> 4    0.99      2.80           20.0           27.6      7.54

```

Una copertura nominale più elevata viene ottenuta al prezzo di un intervallo più largo.

3.8.3. Dimensione campionaria

Nel caso elementare della media indipendente:

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

A parità di variabilità e metodo, quadruplicare n dimezza l'errore standard. Per questo motivo ottenere intervalli molto più stretti richiede aumenti sostanziali della numerosità.

L'aumento di n riduce la variabilità campionaria, ma non corregge automaticamente:

- campionamento distorto;
- misurazione inadeguata;
- dipendenza ignorata;
- modello mal specificato.

3.9. Intervalli e validità del modello

La copertura non è una proprietà magica dei due estremi numerici. Dipende dall'intero procedimento:

- definizione della popolazione;
- disegno di campionamento o assegnazione;
- stimatore usato;
- formula dell'errore standard;
- distribuzione di riferimento;
- trattamento di dipendenza, eterogeneità e valori estremi.

Nel semplice intervallo t per una media, per esempio, l'indipendenza è essenziale. Se i dati provengono da studenti raggruppati in classi o da misure ripetute sulla stessa persona, la formula $s/\sqrt{n}$ può sottostimare la variabilità dello stimatore.

 Un intervallo ben calcolato può rispondere alla domanda sbagliata

La copertura riguarda il parametro definito dal modello e dal processo di campionamento. Non garantisce che quel parametro corrisponda al costrutto psicologico che interessa realmente. Precisione statistica e validità sostantiva devono essere valutate separatamente.

3.10. Intervalli di confidenza e intervalli di credibilità

I due strumenti possono produrre estremi numericamente simili, ma derivano da costruzioni differenti.

Aspetto	Intervallo di confidenza	Intervallo di credibilità
Oggetto probabilistico immediato	Intervallo casuale sotto campionamenti ripetuti	Parametro sotto la distribuzione a posteriori
Significato del 95%	Copertura della procedura, sotto le assunzioni	Massa a posteriori contenuta nell'intervallo
Dipendenza da una prior	Non nella procedura standard	Sì
Dipendenza dal modello dei dati	Sì	Sì
Interpretazione del singolo intervallo	Non assegna probabilità al parametro	Assegna probabilità a posteriori al parametro, condizionatamente a prior, modello e dati

Un intervallo di credibilità al 95% contiene il 95% della distribuzione a posteriori scelta. Questa interpretazione è diretta sul parametro, ma rimane condizionata alla prior, alla verosimiglianza e all'adeguatezza del modello.

! Non basta cambiare il nome

Un intervallo di confidenza non diventa un intervallo di credibilità perché viene interpretato in modo intuitivo. Allo stesso modo, un intervallo bayesiano non è automaticamente affidabile soltanto perché consente un'affermazione probabilistica sul parametro. Entrambi richiedono un modello adeguato e una comunicazione coerente con la procedura che li ha generati.

3.11. Dall'intervallo al test di ipotesi

Per molte procedure standard, un intervallo bilaterale al livello $1 - \alpha$ è collegato al corrispondente test bilaterale di livello α .

Nel caso della media con test t :

- se il valore ipotizzato μ_0 è fuori dall'intervallo al 95%, il test bilaterale di livello 0.05 rifiuta $H_0 : \mu = \mu_0$;
- se μ_0 è dentro l'intervallo, il test non rifiuta H_0 allo stesso livello.

Questa è una relazione tra procedure costruite in modo coerente. Non significa che i valori interni siano «veri» o che quelli esterni siano impossibili.

Il capitolo successivo svilupperà la logica dei test, distinguendo:

- ipotesi nulla e alternativa;
- statistica test;
- livello α ;
- valore- p ;

- errori di tipo I e II;
- potenza.

Riflessioni conclusive

Un intervallo di confidenza collega una stima puntuale alla distribuzione campionaria dello stimatore. Il suo livello descrive la copertura della procedura sotto ripetizioni definite dal modello e dal disegno.

La distinzione più importante è tra:

- la probabilità che una **procedura casuale** produca un intervallo contenente il parametro;
- una probabilità assegnata al **parametro**, che non appartiene all'interpretazione frequentista standard.

L'ampiezza dell'intervallo informa sulla precisione campionaria, ma non certifica rappresentatività, validità della misura o correttezza del modello. La copertura nominale è affidabile soltanto nella misura in cui la procedura e le sue assunzioni sono adeguate.

Questo capitolo completa il passaggio dalla stima puntuale all'inferenza intervallare. Il prossimo userà le stesse distribuzioni di riferimento per introdurre i test di ipotesi.

Esercizi

1. Che cosa aggiunge un intervallo di confidenza rispetto a una stima puntuale?
2. Che cosa significa affermare che una procedura ha copertura del 95%?
3. Perché non è corretto dire che il parametro ha il 95% di probabilità di trovarsi nell'intervallo osservato?
4. Due studi riportano la stessa stima e lo stesso livello di confidenza. Il primo intervallo è molto più stretto. Che cosa puoi concludere e che cosa non puoi concludere?
5. Perché quadruplicare la dimensione campionaria dimezza approssimativamente l'errore standard della media?
6. Un intervallo al 99% è più ampio dell'intervallo al 95% costruito sugli stessi dati. Quale compromesso esprime questa differenza?
7. Perché ignorare la dipendenza tra osservazioni può compromettere la copertura?
8. Qual è la differenza fondamentale tra il 95% di un intervallo di confidenza e il 95% di un intervallo di credibilità?

Soluzioni

1. Aggiunge informazione sulla precisione campionaria della procedura, combinando stima, errore standard e valore critico.
2. Significa che, sotto il modello e il piano di campionamento assunti, il 95% degli intervalli costruiti in ripetizioni analoghe contiene il parametro vero.
3. Dopo l'osservazione, gli estremi sono fissi e il parametro è trattato come fisso nel modello frequentista. Il 95% qualifica il comportamento della procedura prima dell'osservazione, non una distribuzione di probabilità sul parametro.

3. Intervalli di confidenza

4. Il primo studio ha maggiore precisione campionaria, a parità di metodo e assunzioni. Non puoi concludere, dai soli estremi, che la stima sia più accurata, che il campione sia più rappresentativo o che la misura sia più valida.
5. L'errore standard della media è proporzionale a $1/\sqrt{n}$. Sostituendo $4n$ a n , otteniamo $1/\sqrt{4n} = 1/(2\sqrt{n})$.
6. Una copertura nominale più alta richiede un valore critico maggiore e quindi un intervallo più ampio. Si guadagna copertura procedurale e si perde precisione.
7. La formula standard può trattare come informazione indipendente osservazioni che condividono fonti di variabilità. L'errore standard può risultare troppo piccolo e la copertura effettiva inferiore a quella nominale.
8. Nel primo caso, il 95% descrive la frequenza di copertura della procedura. Nel secondo descrive la massa della distribuzione a posteriori contenuta nell'intervallo, condizionatamente a prior, modello e dati.

Punti chiave

- Un intervallo di confidenza combina stima, errore standard e valore critico.
- Il livello di confidenza è una proprietà della procedura.
- Il singolo intervallo osservato non assegna probabilità al parametro.
- L'intervallo t classico è esatto sotto indipendenza e normalità.
- La copertura effettiva può differire da quella nominale quando le assunzioni non sono adeguate.
- Un intervallo stretto indica precisione campionaria, non necessariamente accuratezza o validità.
- L'ampiezza aumenta con il livello di confidenza e diminuisce, in genere, con la dimensione campionaria.
- Gli intervalli di confidenza e di credibilità possono essere numericamente simili ma hanno significati differenti.
- Per procedure standard, intervalli e test bilaterali possono essere duali.

Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0     ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0     posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0     estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1          yaml_2.3.12
#> [16] knitr_1.51          labeling_0.4.3        bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8         purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1        xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.4       scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-2       rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0          RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0       parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-6          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2  glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5       stringi_1.8.7
#> [49] gtable_0.3.6        QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9     Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5   rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9      backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13        snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1       gridExtra_2.3.1       nlme_3.1-170
#> [67] checkmate_2.3.4     xfun_0.60             pkgconfig_2.0.3

```

4. Test di ipotesi e valore- p

In sintesi

Da sapere Un test frequentista confronta una statistica osservata con la sua distribuzione sotto un'ipotesi nulla. Il valore- p misura quanto il risultato sia incompatibile con quel modello, ma non assegna una probabilità all'ipotesi. La pratica contemporanea combina spesso la significatività fisheriana con le decisioni e il controllo degli errori di Neyman–Pearson.

Da saper fare Distinguere ipotesi, statistica test, distribuzione nulla, valore- p e livello α ; interpretare correttamente errori di tipo I, errori di tipo II e potenza; separare significatività statistica, dimensione dell'effetto e rilevanza sostanziale.

Introduzione

Nei capitoli precedenti abbiamo costruito una progressione:

stima puntuale $\longrightarrow$ errore standard $\longrightarrow$ intervallo di confidenza.

Il test di ipotesi usa gli stessi elementi per affrontare una domanda diversa:

Quanto è incompatibile il risultato osservato con un modello di riferimento?

Nella ricerca psicologica, i test vengono usati per studiare differenze tra gruppi, associazioni tra variabili, effetti di interventi e scostamenti da valori teorici o normativi. La loro diffusione rende indispensabile comprenderne sia la logica sia i limiti.

Il test frequentista standard non calcola la probabilità che un'ipotesi sia vera dopo aver osservato i dati. Costruisce invece una distribuzione dei risultati possibili sotto un'ipotesi nulla e colloca il risultato osservato all'interno di quella distribuzione.

4.1. Perché è facile fraintendere un test?

Il linguaggio ordinario invita a leggere un test come un confronto diretto tra due spiegazioni:

- l'ipotesi nulla è vera;
- l'ipotesi alternativa è vera.

La procedura standard non assegna però probabilità posteriori a queste possibilità. La sua domanda è condizionale:

Se l'ipotesi nulla e le altre assunzioni del modello fossero appropriate, quanto sarebbe estremo il risultato osservato?

L'inversione tra

$$P(\text{dati} \mid H_0)$$

e

$$P(H_0 \mid \text{dati})$$

è una delle principali fonti di errore interpretativo.

! La direzione del condizionamento

Il valore- p riguarda la distribuzione dei dati o della statistica test **assumendo** H_0 . Non è la probabilità di H_0 dopo avere osservato i dati.

💡 Prerequisiti

È utile avere letto:

- Capitolo 2, per stimatore, distribuzione campionaria ed errore standard;
- Capitolo 3, per copertura, valori critici e livello α ;
- il capitolo [Probabilità condizionata](#), per distinguere $P(A \mid B)$ da $P(B \mid A)$.

La potenza viene introdotta qui come proprietà del test e sarà approfondita nel capitolo successivo sulla numerosità campionaria.

Panoramica del capitolo

Il capitolo procede in nove passaggi:

1. distingue la significatività fisheriana dalla teoria dei test di Neyman–Pearson;
2. identifica gli elementi che definiscono un test;
3. introduce il valore- p e il livello α ;
4. presenta errori di tipo I, errori di tipo II e potenza;
5. applica la logica al test del chi-quadrato;
6. applica la stessa struttura a un test t per una media;
7. chiarisce test monodirezionali e bidirezionali;
8. separa significatività, grandezza dell'effetto e rilevanza sostanziale;
9. confronta il tipo di domanda frequentista con quello bayesiano.

i Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>
  source()
```

4.2. Due tradizioni nella pratica contemporanea

La pratica comunemente chiamata *NHST* (*Null Hypothesis Significance Testing*) combina spesso elementi provenienti da due tradizioni.

4.2.1. Fisher: significatività e incompatibilità

Nell'impostazione fisheriana, il valore- p è una misura graduata di quanto i dati risultino incompatibili con un'ipotesi nulla. Un valore piccolo segnala che il risultato osservato occupa una regione poco frequente della distribuzione nulla.

Questa lettura non richiede necessariamente una decisione automatica e definitiva. Il valore- p viene considerato insieme al disegno, alla qualità dei dati e alla conoscenza scientifica disponibile.

4.2.2. Neyman–Pearson: decisioni ed errori

Nell'impostazione Neyman–Pearson si specificano ipotesi, una regola decisionale e probabilità di errore valutate nelle ripetizioni. Diventano centrali:

- il livello α ;
- l'errore di tipo I;
- l'errore di tipo II;
- la potenza;
- la regione di rifiuto.

La decisione non dichiara che una delle ipotesi sia probabilmente vera. Applica una procedura progettata per controllare gli errori nel lungo periodo.

i Una procedura ibrida

La regola

«calcolo un valore- p e, se $p \leq 0.05$, dichiaro il risultato significativo»

combina una misura fisheriana di incompatibilità con una soglia e una decisione di tipo Neyman–Pearson.

Questa pratica è diffusa, ma interpretarla correttamente richiede sapere che valore- p e livello α non sono la stessa quantità.

4.3. Anatomia di un test

Un test è definito da più elementi. Il solo valore- p non basta a descriverlo.

4.3.1. Ipotesi nulla e alternativa

L'**ipotesi nulla** H_0 specifica il modello di riferimento. L'**ipotesi alternativa** H_1 descrive i valori o i modelli rispetto ai quali la procedura deve essere sensibile.

Per una media:

$$H_0 : \mu = 24.$$

Un'alternativa bilaterale è:

$$H_1 : \mu \neq 24,$$

mentre un'alternativa unilaterale può essere:

$$H_1 : \mu > 24.$$

L'ipotesi nulla non deve necessariamente rappresentare una teoria scientifica completa o «assenza di qualunque effetto». È una restrizione precisa del modello usata per derivare la distribuzione di riferimento.

4.3.2. Statistica test

La **statistica test** è una funzione dei dati progettata per misurare una discrepanza rilevante rispetto a H_0 .

Esempi comuni sono:

- una statistica z ;
- una statistica t ;
- una statistica χ^2 ;
- una statistica F ;
- una differenza, un rapporto o un coefficiente standardizzato.

Per interpretare l'estremità occorre sapere quali valori della statistica siano più incompatibili con H_0 .

4.3.3. Distribuzione sotto l'ipotesi nulla

La **distribuzione nulla** descrive i valori che la statistica test assumerebbe se H_0 , il modello e il piano di analisi fossero corretti.

Può essere:

- derivata esattamente;
- ottenuta mediante un'approssimazione asintotica;
- costruita attraverso permutazioni o simulazioni.

4.3.4. Regola di estremaità

Il valore- p dipende anche dalla regola che stabilisce quali risultati siano «almeno altrettanto estremi» di quello osservato.

In un test unilaterale superiore si considera una coda. In un test bilaterale si considerano discrepanze in entrambe le direzioni, secondo la procedura specificata.

 Il valore- p non è determinato dai soli dati

Dipende anche da:

- ipotesi nulla;
- statistica test;
- distribuzione di riferimento;
- scelta unilaterale o bilaterale;
- regola di arresto, quando rilevante;
- correzioni per confronti multipli;
- altre decisioni previste dal piano di analisi.

4.4. Il valore- p

In forma generale, il valore- p è:

la probabilità, calcolata sotto H_0 , di ottenere un valore della statistica test almeno altrettanto incompatibile con H_0 quanto quello osservato.

In simboli schematici:

$$p = P_{H_0}(T(Y) \text{ almeno altrettanto estremo di } T(y_{\text{obs}})).$$

Un valore- p piccolo indica che il risultato osservato occupa una regione rara della distribuzione nulla. Segnala quindi incompatibilità tra i dati e l'insieme delle assunzioni usate per costruire il test.

Non identifica da solo quale assunzione sia inadeguata. Un valore piccolo può riflettere:

- una deviazione reale dal valore nullo;
- una specificazione errata del modello;
- dipendenza o eterogeneità ignorata;
- bias di campionamento o misurazione;
- selezione analitica o confronti multipli non corretti.

4.4.1. Valore- p e livello α

Il **valore- p** è calcolato dai dati. Il **livello α** è una soglia decisionale scelta prima dell'analisi.

La regola convenzionale è:

- se $p \leq \alpha$, rifiutare H_0 ;
- se $p > \alpha$, non rifiutare H_0 .

«Non rifiutare» è intenzionale. Un risultato non significativo non prova che H_0 sia vera.

 Che cosa non è un valore-p

Il valore- p non è:

- $P(H_0 \mid \text{dati})$;
- la probabilità che il risultato sia «dovuto al caso»;
- la probabilità che H_1 sia vera;
- la dimensione dell'effetto;
- la probabilità di replicare la significatività;
- il tasso di falsi positivi tra tutti i risultati significativi pubblicati.

4.5. Errori di tipo I, errori di tipo II e potenza

Una procedura decisionale può produrre quattro combinazioni:

Stato rispetto alle ipotesi specificate	Rifiutare H_0	Non rifiutare H_0
H_0 vera	Errore di tipo I	Decisione corretta
Alternativa specificata vera	Decisione corretta	Errore di tipo II

4.5.1. Errore di tipo I

L'errore di tipo I consiste nel rifiutare H_0 quando è vera. Sotto le condizioni previste dalla procedura:

$$P(\text{rifiutare } H_0 \mid H_0) = \alpha.$$

Il controllo vale per la procedura e per la famiglia di analisi definita. Se vengono provati molti test e riportati soltanto quelli significativi, il tasso effettivo di falsi positivi può superare quello nominale.

4.5.2. Errore di tipo II e potenza

Per una specifica alternativa, l'errore di tipo II ha probabilità:

$$\beta = P(\text{non rifiutare } H_0 \mid H_1).$$

La potenza è:

$$1 - \beta = P(\text{rifiutare } H_0 \mid H_1).$$

La potenza non è un unico numero indipendente dall'effetto. Dipende dal valore del parametro sotto l'alternativa, oltre che da:

- numerosità campionaria;
- variabilità;

4. Test di ipotesi e valore-p

- livello α ;
- struttura del disegno;
- test unilaterale o bilaterale;
- qualità della misurazione.

i Perché la potenza viene ripresa nel prossimo capitolo

Qui la potenza serve a comprendere la logica degli errori. Il capitolo successivo discuterà come scegliere un effetto bersaglio e una numerosità adeguata prima di raccogliere i dati.

4.6. Esempio 1: test del chi-quadrato di indipendenza

Supponiamo di studiare la relazione tra **stress percepito** e **qualità del sonno**.

```
osservati <- matrix(  
  c(  
    42, 40,  
    19, 39  
  ),  
  nrow = 2,  
  byrow = TRUE,  
  dimnames = list(  
    Stress = c("Basso", "Alto"),  
    Sonno = c("Buono", "Scarso")  
  )  
)  
  
knitr::kable(osservati)
```

Tabella 4.1.: Frequenze osservate per stress percepito e qualità del sonno.

	Buono	Scarso
Basso	42	40
Alto	19	39

Le ipotesi sono:

H_0 : stress e qualità del sonno sono indipendenti,

H_1 : stress e qualità del sonno non sono indipendenti.

4.6.1. Frequenze attese

Sotto l'indipendenza, la frequenza attesa nella cella ij è:

$$E_{ij} = \frac{R_i C_j}{N},$$

dove R_i è il totale della riga, C_j quello della colonna e N il totale complessivo.

```
totali_riga <- rowSums(osservati)
totali_colonna <- colSums(osservati)
totale <- sum(osservati)

attesi <- outer(totali_riga, totali_colonna) / totale
dimnames(attesi) <- dimnames(osservati)

knitr::kable(round(attesi, 2))
```

Tabella 4.2.: Frequenze attese sotto l'ipotesi nulla di indipendenza.

	Buono	Scarso
Basso	35.7	46.3
Alto	25.3	32.7

4.6.2. Statistica test

La statistica è:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

```
chi2_osservato <- sum((osservati - attesi)^2 / attesi)
gradi_liberta <- (nrow(osservati) - 1) * (ncol(osservati) - 1)
p_chi <- pchisq(
  chi2_osservato,
  df = gradi_liberta,
  lower.tail = FALSE
)

c(
  chi_quadrato = chi2_osservato,
  gradi_liberta = gradi_liberta,
  valore_p = p_chi
)

#>   chi_quadrato gradi_liberta   valore_p
#>         4.71         1.00         0.03
```

4. Test di ipotesi e valore-p

Il calcolo produce circa:

$$\chi^2(1) = 4.71, \quad p = 0.030.$$

Verifichiamo con R:

```
chisq.test(osservati, correct = FALSE)
#>
#>  Pearson's Chi-squared test
#>
#> data:  osservati
#> X-squared = 5, df = 1, p-value = 0.03
```

Disattiviamo la correzione di continuità per riprodurre il calcolo manuale.

4.6.3. Visualizzazione

```
x_massimo <- qchisq(0.999, df = gradi_liberta)

dati_chi <- data.frame(
  x = seq(0.001, x_massimo, length.out = 2000)
)

dati_chi$densita <- dchisq(dati_chi$x, df = gradi_liberta)

ggplot(dati_chi, aes(x = x, y = densita)) +
  geom_line(linewidth = 0.9) +
  geom_area(
    data = subset(dati_chi, x >= chi2_osservato),
    alpha = 0.35
  ) +
  geom_vline(
    xintercept = chi2_osservato,
    linetype = "dashed",
    linewidth = 0.8
  ) +
  labs(
    x = expression(chi^2),
    y = "Densità"
  )
```




Figura 4.1.: Distribuzione chi-quadrato sotto l'ipotesi nulla. L'area oltre la statistica osservata rappresenta il valore-p.

In Figura 4.1, l'area a destra di χ_{obs}^2 è circa 0.030. Al livello $\alpha = 0.05$, la procedura rifiuta l'ipotesi di indipendenza.

Una formulazione appropriata è:

Nel campione è emersa un'associazione statisticamente significativa tra stress percepito e qualità del sonno, $\chi^2(1) = 4.71$, $p = 0.030$.

Questa conclusione non indica:

- la probabilità che le variabili siano associate;
- la grandezza dell'associazione;
- una relazione causale;
- la validità delle categorie utilizzate.

Per completare l'analisi occorre stimare la dimensione dell'associazione e discuterne il significato sostantivo.

4.7. Esempio 2: test t per una media

Consideriamo dieci punteggi di benessere psicologico e un valore normativo pari a 24.

```
punteggi <- c(28, 22, 26, 18, 30, 24, 27, 17, 21, 25)

n <- length(punteggi)
media <- mean(punteggi)
deviazione_standard <- sd(punteggi)
errore_standard <- deviazione_standard / sqrt(n)

c(
```

4. Test di ipotesi e valore-p

```
media = media,  
deviazione_standard = deviazione_standard,  
errore_standard = errore_standard,  
n = n  
)  
#>          media deviazione_standard      errore_standard      n  
#>          23.80           4.26           1.35          10.00
```

Supponiamo che l'ipotesi, formulata prima di osservare i dati, sia:

$$H_0 : \mu = 24,$$

$$H_1 : \mu > 24.$$

La statistica è:

$$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}.$$

```
mu_0 <- 24  
  
t_osservato <- (media - mu_0) / errore_standard  
gradi_liberta_t <- n - 1  
p_unilaterale <- pt(  
  t_osservato,  
  df = gradi_liberta_t,  
  lower.tail = FALSE  
)  
  
c(  
  t = t_osservato,  
  gradi_liberta = gradi_liberta_t,  
  valore_p = p_unilaterale  
)  
#>          t gradi_liberta      valore_p  
#>      -0.148          9.000          0.557
```

Otteniamo circa:

$$t(9) = -0.15, \quad p = 0.557.$$

La media osservata, 23.8, non è nella direzione dell'alternativa superiore. Non rifiutiamo H_0 .

```
t.test(  
  punteggi,  
  mu = 24,  
  alternative = "greater"  
)
```



```
#>
#> One Sample t-test
#>
#> data: punteggi
#> t = -0.1, df = 9, p-value = 0.6
#> alternative hypothesis: true mean is greater than 24
#> 95 percent confidence interval:
#> 21.3 Inf
#> sample estimates:
#> mean of x
#> 23.8
```

Una formulazione adeguata è:

I dati non forniscono evidenza, secondo questo test unilaterale, che la media sia superiore a 24, $t(9) = -0.15$, $p = 0.557$.

Non è adeguato concludere:

Abbiamo dimostrato che la media è uguale a 24.

Il test non significativo lascia aperte molte possibilità, comprese una differenza piccola, dati poco informativi o una deviazione nella direzione opposta.

4.8. Test unilaterali e bilaterali

Un test bilaterale considera deviazioni in entrambe le direzioni:

$$H_1 : \mu \neq \mu_0.$$

```
t.test(
  punteggi,
  mu = 24,
  alternative = "two.sided"
)
#>
#> One Sample t-test
#>
#> data: punteggi
#> t = -0.1, df = 9, p-value = 0.9
#> alternative hypothesis: true mean is not equal to 24
#> 95 percent confidence interval:
#> 20.8 26.8
#> sample estimates:
#> mean of x
#> 23.8
```

Per gli stessi dati, il valore- p bilaterale è circa 0.885.

La scelta tra test unilaterale e bilaterale deve essere motivata dalla domanda e definita prima di osservare i risultati. Scegliere a posteriori la coda favorevole altera il controllo dell'errore di tipo I.

4. Test di ipotesi e valore- p

Un test unilaterale non dovrebbe essere usato soltanto per ottenere maggiore potenza. Deve essere scientificamente sensato escludere, dalla regola di evidenza, una deviazione nella direzione opposta.

4.9. Interpretare un risultato

Una lettura completa separa almeno quattro livelli.

4.9.1. Compatibilità con il modello nullo

Il valore- p descrive quanto il risultato sia estremo sotto H_0 e le assunzioni del test.

4.9.2. Decisione procedurale

Il confronto con α applica una regola di rifiuto o non rifiuto.

4.9.3. Grandezza e precisione dell'effetto

La stima e l'intervallo di confidenza mostrano quanto è grande l'effetto e con quale precisione è stato stimato.

4.9.4. Significato scientifico

La rilevanza dipende da teoria, qualità della misura, disegno, costi, benefici e contesto applicativo.

! Significativo non significa importante

Un risultato può essere statisticamente significativo ma troppo piccolo per avere rilievo teorico o pratico.

Un risultato non significativo può essere compatibile sia con effetti trascurabili sia con effetti rilevanti stimati con scarsa precisione.

4.10. Limiti e usi appropriati

4.10.1. La soglia crea una discontinuità decisionale

$p = 0.049$ e $p = 0.051$ rappresentano livelli di incompatibilità molto simili. Trasformarli in categorie opposte può esagerare la differenza tra i risultati.

La soglia può essere utile in una procedura decisionale, ma non deve sostituire la lettura continua dei dati.

4.10.2. L'ipotesi nulla puntuale può essere poco informativa

In molti contesti, sapere che un effetto non è esattamente zero è meno utile che sapere se sia:

- sufficientemente grande;
- praticamente rilevante;
- compatibile con una regione di equivalenza;
- stabile tra popolazioni e contesti.

La difficoltà non rende sempre illegittima un'ipotesi puntuale. Indica che la domanda deve essere scelta in funzione dello scopo scientifico.

4.10.3. Un risultato non significativo non dimostra equivalenza

Per sostenere che un effetto sia abbastanza piccolo da essere trascurabile occorre definire che cosa significhi «abbastanza piccolo» e usare una procedura adatta, come un test di equivalenza o un'analisi con una regione di effetti praticamente trascurabili.

4.10.4. Il valore-p è sensibile al piano di analisi

Arresto opzionale, confronti multipli, esclusioni flessibili e scelta post hoc delle analisi modificano le proprietà nominali della procedura. Preregistrazione, trasparenza e analisi di sensibilità aiutano a rendere interpretabili i risultati.

4.10.5. Il test non controlla la validità scientifica

Un test può essere calcolato correttamente su:

- un campione non rappresentativo;
- una misura poco valida;
- un disegno confuso;
- un modello inadeguato.

La significatività non corregge questi problemi.

i Quando il test è utile

Un test frequentista è particolarmente interpretabile quando:

- la domanda decisionale è definita prima dei dati;
- il disegno consente di collegare il parametro alla domanda scientifica;
- il modello e l'errore standard sono adeguati;
- la famiglia di test è chiaramente specificata;
- vengono riportati anche stime, intervalli e misure dell'effetto.

4.11. Confronto con l'inferenza bayesiana

Il confronto più utile parte dalle domande, non dagli slogan.

Un test frequentista standard chiede:

Quanto è estremo il risultato sotto H_0 ?

Un'analisi bayesiana può chiedere:

Come si distribuisce l'incertezza sul parametro dopo avere combinato prior e dati?

oppure, in un modello che assegna probabilità a ipotesi discrete:

Come cambiano le probabilità relative delle ipotesi dopo i dati?

Queste non sono riformulazioni dello stesso numero. Un valore- p non è una probabilità a posteriori, e una probabilità a posteriori non possiede automaticamente il controllo frequentista degli errori.

Il Companion approfondisce la fragilità del valore- p e mostra come il workflow bayesiano sposti l'attenzione verso modello generativo, distribuzione a posteriori, predizioni e controllo del modello. Il modulo frequentista conserva però una funzione indispensabile: permettere di leggere correttamente la letteratura e comprendere quali proprietà procedurali vengono garantite dai metodi classici.

4.12. Verso la pianificazione dello studio

Un risultato non significativo può dipendere da:

- un effetto assente o trascurabile;
- un campione troppo piccolo;
- una misura poco precisa;
- grande eterogeneità;
- un modello o un test poco sensibile.

Per valutare in anticipo quanto uno studio sia informativo, occorre specificare:

1. quale effetto minimo sia scientificamente rilevante;
2. quale livello di errore di tipo I sia accettabile;
3. quale potenza si desideri;
4. quale variabilità e struttura dei dati siano plausibili.

Questi elementi conducono al capitolo successivo sulla pianificazione della numerosità campionaria.

Riflessioni conclusive

Il test di ipotesi colloca una statistica osservata nella distribuzione che avrebbe sotto un'ipotesi nulla e un insieme di assunzioni. Il valore- p misura l'estremità del risultato in quella distribuzione; il confronto con α applica una regola decisionale.

La distinzione tra Fisher e Neyman–Pearson chiarisce perché nella pratica convivano due usi:

- il valore- p come misura graduata di incompatibilità;
- il test come procedura di decisione con errori controllati.

Nessuno dei due usi autorizza a leggere il valore- p come probabilità dell'ipotesi o come misura dell'importanza dell'effetto.

Una comunicazione scientifica adeguata affianca al risultato del test:

- stima dell'effetto;
- intervallo di confidenza;
- informazioni sul disegno e sulle assunzioni;
- valutazione della rilevanza sostantiva.

Il prossimo capitolo completerà la logica decisionale studiando il rapporto tra effetto bersaglio, potenza e numerosità campionaria.

Esercizi

1. Qual è la differenza tra un valore- p e il livello α ?
2. Perché $p = 0.03$ non significa che l'ipotesi nulla abbia una probabilità del 3% di essere vera?
3. Quale ruolo svolge la regola di estremità nella definizione del valore- p ?
4. Un risultato produce $p = 0.18$. Qual è la conclusione frequentista corretta? Quale conclusione non è giustificata?
5. Perché la potenza non può essere descritta senza specificare un effetto sotto l'alternativa?
6. Nel test del chi-quadrato emerge $p = 0.030$. Quali informazioni importanti non sono contenute in questo numero?
7. Perché scegliere un test unilaterale dopo aver osservato la direzione dell'effetto altera l'interpretazione del test?
8. In che modo un'analisi bayesiana e un test frequentista formulano domande diverse sugli stessi dati?

Soluzioni

1. Il valore- p è calcolato dai dati e misura l'estremità del risultato sotto H_0 . α è una soglia decisionale scelta prima dell'analisi per controllare l'errore di tipo I della procedura.
2. Il 3% riguarda la probabilità di risultati almeno altrettanto estremi sotto H_0 . Non riguarda la probabilità di H_0 condizionata ai dati.
3. Stabilisce quali valori della statistica siano almeno altrettanto incompatibili con H_0 quanto quello osservato. Cambiando test unilaterale, bilaterale o statistica, può cambiare il valore- p .
4. Al livello convenzionale 0.05, non si rifiuta H_0 . Non è giustificato concludere che H_0 sia vera, che l'effetto sia esattamente zero o che i gruppi siano equivalenti.
5. La probabilità di rifiutare H_0 cambia con la distanza tra il parametro vero e il valore nullo. Non esiste quindi una potenza unica per tutte le possibili alternative.
6. Non contiene la grandezza dell'associazione, la sua precisione, la probabilità che l'associazione esista, l'eventuale causalità o la validità delle categorie e del disegno.

4. Test di ipotesi e valore-p

7. La coda viene selezionata usando informazione già contenuta nei dati, mentre il calcolo nominale presuppone che la direzione sia stata fissata in anticipo. Il controllo dell'errore di tipo I non è più quello dichiarato.
8. Il test frequentista valuta l'estremità dei dati sotto H_0 . L'analisi bayesiana rappresenta l'incertezza a posteriori su parametri o ipotesi mediante prior, verosimiglianza e dati.

Punti chiave

- Un test richiede ipotesi, statistica test, distribuzione nulla e regola di estremità.
- Il valore- p è calcolato sotto H_0 e non è la probabilità di H_0 .
- Il valore- p e il livello α svolgono funzioni diverse.
- La pratica NHST combina spesso elementi fisheriani e Neyman-Pearson.
- Gli errori di tipo I e II e la potenza sono proprietà della procedura sotto condizioni specificate.
- La potenza dipende dall'effetto sotto l'alternativa.
- Non rifiutare H_0 non significa accettarla o dimostrare equivalenza.
- Significatività statistica, dimensione dell'effetto e rilevanza sostantiva sono concetti distinti.
- La qualità di un test dipende da disegno, misurazione, modello e piano di analisi.
- Frequentismo e bayesianesimo rispondono a domande probabilistiche differenti.

Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0     ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0     posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0     estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51          labeling_0.4.3        bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8         purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1        xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.4       scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-2       rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0          RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0       parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-6          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2   glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5       stringi_1.8.7
#> [49] gtable_0.3.6        QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9     Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5   rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9      backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13        snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1       gridExtra_2.3.1       nlme_3.1-170
#> [67] checkmate_2.3.4     xfun_0.60             pkgconfig_2.0.3

```

5. Dimensione campionaria, precisione e potenza

In sintesi

Da sapere La numerosità campionaria può essere pianificata per ottenere una precisione prefissata oppure per raggiungere una determinata potenza rispetto a un effetto specifico. Entrambi i calcoli dipendono da assunzioni su variabilità, modello, disegno e quantità scientificamente rilevanti.

Da saper fare Distinguere pianificazione per precisione e per potenza; interpretare correttamente α , β e potenza; motivare un effetto minimo di interesse; leggere l'output di `power.t.test()`; riconoscere perché la potenza post hoc basata sull'effetto osservato è poco informativa.

Introduzione

Nel capitolo precedente abbiamo introdotto errori di tipo I, errori di tipo II e potenza. Questi concetti non servono soltanto a interpretare un test già eseguito: permettono anche di progettare lo studio prima della raccolta dei dati.

La numerosità campionaria condiziona ciò che uno studio può apprendere. Un campione piccolo produce generalmente stime poco precise e test poco sensibili agli effetti di interesse. Un campione molto grande può invece richiedere risorse non giustificate e rendere statisticamente rilevabili differenze troppo piccole per avere significato teorico o pratico.

Non esiste quindi una numerosità «giusta» in astratto. Il numero di partecipanti dipende dalla domanda, dalla procedura inferenziale, dalla variabilità attesa, dal disegno e dal livello di informazione che si desidera ottenere.

5.1. Perché pianificare prima di raccogliere i dati?

La pianificazione costringe a trasformare una domanda generica in un obiettivo quantitativo.

Per la **stima**, dobbiamo specificare quanta imprecisione siamo disposti ad accettare:

Quanto stretto dovrebbe essere l'intervallo di confidenza?

Per il **test**, dobbiamo specificare quale effetto vogliamo essere in grado di rilevare:

Con quale probabilità il test dovrebbe rifiutare l'ipotesi nulla se fosse presente un effetto scientificamente rilevante?

Queste domande sono collegate, perché entrambe dipendono dall'errore standard, ma non sono equivalenti. La prima riguarda la precisione di una stima. La seconda riguarda il comportamento di una regola decisionale sotto una specifica alternativa.

! Il calcolo non sceglie gli obiettivi scientifici

Una funzione software può calcolare n dopo che sono stati forniti margine di errore, variabilità, effetto bersaglio, α e potenza.

Non può stabilire:

- quale popolazione sia rilevante;
- quale effetto meriti attenzione;
- quale precisione sia sufficiente;
- quale perdita di partecipanti sia plausibile;
- se il disegno e la misura rispondano alla domanda scientifica.

💡 Prerequisiti

È utile avere letto:

- Capitolo 2, per errore standard e precisione;
- Capitolo 3, per margine di errore e livello di confidenza;
- Capitolo 4, per α , β e potenza.

Come approfondimento sul rapporto tra obiettivo scientifico e pianificazione, si veda Giner-Sorolla et al. (2024).

Panoramica del capitolo

Il capitolo procede in otto passaggi:

1. distingue pianificazione per precisione e pianificazione per potenza;
2. ricava una formula introduttiva per la precisione di una media;
3. mostra come margine di errore e variabilità influenzino n ;
4. interpreta la potenza come funzione di un'alternativa specifica;
5. introduce l'effetto minimo di interesse;
6. applica `power.t.test()` a uno e due gruppi;
7. trasforma la numerosità analitica in un obiettivo realistico di reclutamento;
8. discute sensibilità delle assunzioni, potenza post hoc e confronto con la pianificazione bayesiana.

i Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>
  source()
```

5.2. Due obiettivi distinti

5.2.1. Pianificare per la precisione

L'obiettivo è ottenere una stima con un intervallo sufficientemente stretto. La domanda centrale è:

Quale ampiezza dell'intervallo renderebbe la stima utile?

Questa strategia è naturale quando l'interesse principale riguarda la grandezza di una media, una proporzione o una differenza.

5.2.2. Pianificare per la potenza

L'obiettivo è costruire un test che abbia una probabilità prefissata di rifiutare H_0 sotto una specifica alternativa. La domanda centrale è:

Qual è il più piccolo effetto che lo studio dovrebbe riuscire a rilevare con adeguata probabilità?

Questa strategia è legata a una procedura decisionale. Richiede di specificare sia l'effetto bersaglio sia il livello α .

Obiettivo	Quantità da specificare	Risultato della pianificazione
Precisione	Margine di errore, variabilità e livello di confidenza	n necessario per un'ampiezza desiderata
Potenza	Effetto bersaglio, variabilità, α e potenza	n necessario per una probabilità di rifiuto desiderata

i Lo stesso studio può avere più obiettivi

Uno studio può essere pianificato sia per stimare con sufficiente precisione sia per raggiungere una determinata potenza. In tal caso, una scelta prudente consiste nel calcolare i requisiti per entrambi gli obiettivi e adottare quello più esigente, purché le ipotesi siano coerenti con il disegno.

5.3. Pianificare la precisione di una media

Nel caso ideale di osservazioni indipendenti, deviazione standard della popolazione nota e intervallo normale, il margine di errore per una media è:

$$E = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

Risolvendo rispetto a n :

$$n = \left(\frac{z_{1-\alpha/2} \sigma}{E} \right)^2.$$

La formula mostra che:

- una maggiore variabilità σ richiede più osservazioni;
- un margine di errore più piccolo richiede più osservazioni;
- un livello di confidenza maggiore richiede un valore critico più grande;
- dimezzare E moltiplica approssimativamente n per quattro.

5.3.1. Un esempio introduttivo

Vogliamo stimare il punteggio medio di autostima in una popolazione di studenti. Studi precedenti suggeriscono una deviazione standard di circa 6 punti. Desideriamo un intervallo al 95% con margine di errore non superiore a 2 punti.

```
sigma_attesa <- 6
margine_desiderato <- 2
z_critico <- qnorm(0.975)

n_precisione <- (
  z_critico * sigma_attesa / margine_desiderato
)^2

ceiling(n_precisione)
#> [1] 35
```

Il calcolo restituisce 35 partecipanti.

L'arrotondamento va sempre effettuato verso l'alto. Il valore rappresenta la numerosità **analizzabile** richiesta sotto le assunzioni del calcolo, non necessariamente il numero iniziale da reclutare.

5.3.2. Sensibilità al margine di errore

```
margini <- c(1, 1.5, 2, 2.5, 3)

risultati_precisione <- data.frame(
  margine_errore = margini,
  n_minimo = ceiling(
    (z_critico * sigma_attesa / margini)^2
  )
)

knitr::kable(risultati_precisione)
```

Tabella 5.1.: Numerosità richiesta al variare del margine di errore, assumendo deviazione standard pari a 6 e livello di confidenza del 95%.

margine_errore	n_minimo
1.0	139
1.5	62
2.0	35
2.5	23

5. Dimensione campionaria, precisione e potenza

Tabella 5.1.: Numerosità richiesta al variare del margine di errore, assumendo deviazione standard pari a 6 e livello di confidenza del 95%.

margine_errore	n_minimo
3.0	16

Tabella 5.1 rende visibile la relazione quadratica: una richiesta apparentemente modesta di maggiore precisione può aumentare molto il campione necessario.

⚠ Una formula introduttiva, non universale

La formula usa σ come se fosse nota e assume un modello elementare con osservazioni indipendenti.

Nella pratica:

- σ deve essere stimata o ipotizzata;
- l'ampiezza effettiva dell'intervallo può essere casuale;
- l'uso della distribuzione t può richiedere un calcolo iterativo;
- clustering, misure ripetute, pesi campionari o dati mancanti modificano la precisione;
- altri parametri richiedono formule o simulazioni differenti.

5.4. Pianificare la potenza di un test

Per una specifica alternativa, la potenza è:

$$1 - \beta = P(\text{rifiutare } H_0 \mid \theta = \theta_1),$$

dove θ_1 indica il valore del parametro assunto nella pianificazione.

Una potenza pari a 0.80 significa:

Se l'effetto specificato, il modello e il disegno fossero quelli assunti, circa l'80% delle ripetizioni produrrebbe un risultato che rifiuta H_0 al livello scelto.

Non significa:

- che H_1 abbia probabilità 0.80;
- che lo studio abbia l'80% di probabilità di essere «corretto»;
- che, dopo un risultato significativo, vi sia l'80% di probabilità che l'effetto sia reale.

5.4.1. La potenza è una funzione

La potenza cambia al cambiare del valore vero dell'effetto. Uno studio non è semplicemente «potente» o «non potente» senza specificare rispetto a quale alternativa.

Dipende inoltre da:

1. dimensione dell'effetto;
2. variabilità;
3. numerosità;

4. livello α ;
5. test unilaterale o bilaterale;
6. allocazione tra gruppi;
7. struttura di dipendenza e affidabilità della misura.

! Potenza per rilevare che cosa?

Dire «lo studio ha potenza 0.80» è incompleto.

Una formulazione interpretabile è:

Il test bilaterale di livello 0.05 ha potenza 0.80 per una differenza di 3 punti, assumendo deviazione standard pari a 6 e il modello specificato.

5.5. Scegliere l'effetto bersaglio

La numerosità non dovrebbe essere pianificata automaticamente sull'effetto osservato in un singolo studio precedente. Gli effetti pubblicati, soprattutto se ottenuti con campioni piccoli o selezionati perché significativi, possono essere sovrastimati.

Una strategia più trasparente è definire il **più piccolo effetto di interesse** (*smallest effect size of interest*, SESOI):

Qual è il più piccolo effetto che cambierebbe una conclusione teorica, clinica, educativa o decisionale?

La risposta può derivare da:

- una soglia di rilevanza clinica o pratica;
- costi e benefici di una decisione;
- precisione dello strumento;
- confronto con effetti già noti;
- vincoli derivati da una teoria;
- consenso tra esperti e portatori di interesse.

Quando possibile, è preferibile motivare l'effetto nella scala originale. Un effetto standardizzato dipende anche dalla deviazione standard prevista: lo stesso cambiamento grezzo può corrispondere a valori standardizzati diversi in popolazioni differenti.

! Convenzioni non equivalgono a rilevanza

Etichette come effetto «piccolo», «medio» o «grande» possono fornire un riferimento descrittivo, ma non stabiliscono quale effetto sia importante per la specifica domanda di ricerca.

5.6. Esempio: test t per una media

Vogliamo confrontare una media con un valore di riferimento. Consideriamo rilevante una differenza di 3 punti e prevediamo una deviazione standard pari a 6. Pianifichiamo un test bilaterale con $\alpha = 0.05$ e potenza 0.80.

5. Dimensione campionaria, precisione e potenza

```
piano_un_campione <- power.t.test(  
  delta = 3,  
  sd = 6,  
  sig.level = 0.05,  
  power = 0.80,  
  type = "one.sample",  
  alternative = "two.sided"  
)  
  
piano_un_campione  
#>  
#>      One-sample t test power calculation  
#>  
#>              n = 33.4  
#>          delta = 3  
#>           sd = 6  
#>    sig.level = 0.05  
#>       power = 0.8  
#> alternative = two.sided  
ceiling(piano_un_campione$n)  
#> [1] 34
```

Il risultato richiede 34 osservazioni analizzabili.

L'interpretazione è condizionale: se la differenza vera fosse 3, la deviazione standard 6 e le assunzioni del test fossero appropriate, il test rifiuterebbe H_0 in circa l'80% delle ripetizioni.

5.7. Esempio: due gruppi indipendenti

Consideriamo ora un confronto tra due gruppi di uguale numerosità. L'effetto minimo di interesse è una differenza di 5 punti e la deviazione standard comune prevista è 6.

```
piano_due_gruppi <- power.t.test(  
  delta = 5,  
  sd = 6,  
  sig.level = 0.05,  
  power = 0.80,  
  type = "two.sample",  
  alternative = "two.sided"  
)  
  
piano_due_gruppi  
#>  
#>      Two-sample t test power calculation  
#>  
#>              n = 23.6  
#>          delta = 5  
#>           sd = 6  
#>    sig.level = 0.05  
#>       power = 0.8
```

```
#> alternative = two.sided
#>
#> NOTE: n is number in *each* group
ceiling(piano_due_gruppi$n)
#> [1] 24
```

Il risultato richiede 24 partecipanti analizzabili **per gruppo**, quindi 48 complessivi.

Questo esempio prepara il capitolo successivo, nel quale applicheremo il test t al confronto tra gruppi indipendenti. Qui l'obiettivo non è ancora eseguire il test, ma capire quali assunzioni rendono interpretabile il numero di partecipanti.

5.7.1. Sensibilità all'effetto bersaglio

```
differenze <- c(2, 3, 4, 5, 6)

n_per_gruppo <- vapply(
  differenze,
  function(differenza) {
    risultato <- power.t.test(
      delta = differenza,
      sd = 6,
      sig.level = 0.05,
      power = 0.80,
      type = "two.sample",
      alternative = "two.sided"
    )
    ceiling(risultato$n)
  },
  numeric(1)
)

risultati_potenza <- data.frame(
  differenza_bersaglio = differenze,
  n_per_gruppo = n_per_gruppo,
  n_totale = 2 * n_per_gruppo
)

knitr::kable(risultati_potenza)
```

Tabella 5.2.: Numerosità per gruppo richiesta al variare della differenza bersaglio, assumendo deviazione standard pari a 6, test bilaterale, livello 0.05 e potenza 0.80.

differenza_bersaglio	n_per_gruppo	n_totale
2	143	286
3	64	128
4	37	74
5	24	48

Tabella 5.2.: Numerosità per gruppo richiesta al variare della differenza bersaglio, assumendo deviazione standard pari a 6, test bilaterale, livello 0.05 e potenza 0.80.

differenza_bersaglio	n_per_gruppo	n_totale
6	17	34

Tabella 5.2 mostra che la numerosità dipende fortemente dall'effetto scelto. Questa sensibilità non è un difetto del software: riflette il fatto che effetti più piccoli sono più difficili da distinguere dalla variabilità campionaria.

5.7.2. Curve di potenza

```
griglia_potenza <- expand.grid(
  n_per_gruppo = seq(10, 100, by = 2),
  differenza = c(2, 3, 5)
)

griglia_potenza$potenza <- mapply(
  function(n, differenza) {
    power.t.test(
      n = n,
      delta = differenza,
      sd = 6,
      sig.level = 0.05,
      type = "two.sample",
      alternative = "two.sided"
    )$power
  },
  n = griglia_potenza$n_per_gruppo,
  differenza = griglia_potenza$differenza
)

griglia_potenza$differenza <- factor(
  griglia_potenza$differenza
)

ggplot(
  griglia_potenza,
  aes(
    x = n_per_gruppo,
    y = potenza,
    linetype = differenza
  )
) +
  geom_line(linewidth = 0.9) +
  geom_hline(yintercept = 0.80, linetype = "dashed") +
  labs(
    x = "Partecipanti analizzabili per gruppo",
```



```

y = "Potenza",
linetype = "Differenza vera"
)

```




Figura 5.1.: Potenza di un test t bilaterale per due gruppi di uguale numerosità, per tre differenze vere e deviazione standard pari a 6.

Figura 5.1 rende evidente che la potenza non è una caratteristica fissa del disegno: ogni possibile effetto genera una curva differente.

5.8. Dalla numerosità analitica al reclutamento

Il valore restituito dal calcolo indica generalmente quante osservazioni **utilizzabili nell'analisi** sono necessarie. Il numero da reclutare può essere maggiore.

Se prevediamo una quota di perdita r , un calcolo elementare è:

$$n_{\text{reclutare}} = \left\lceil \frac{n_{\text{analizzabile}}}{1 - r} \right\rceil.$$

Per esempio, se servono 48 partecipanti analizzabili e prevediamo il 15% di abbandoni o dati inutilizzabili:

```

n_analizzabile <- 48
perdita_attesa <- 0.15

ceiling(
  n_analizzabile / (1 - perdita_attesa)
)
#> [1] 57

```

5. Dimensione campionaria, precisione e potenza

Occorre reclutare almeno 57 partecipanti, assumendo che la perdita sia plausibilmente vicina al 15%.

Questo aggiustamento non risolve automaticamente i problemi dei dati mancanti. Se l'abbandono è collegato all'esito o al trattamento, può introdurre bias oltre a ridurre la numerosità.

5.8.1. Disegni complessi

La numerosità richiesta può aumentare quando le osservazioni non forniscono informazione indipendente. Esempi:

- studenti raggruppati in classi;
- pazienti trattati dagli stessi terapeuti;
- misure ripetute sulla stessa persona;
- coppie o famiglie;
- più esiti o confronti primari.

In questi casi occorre pianificare usando un modello coerente con il disegno, spesso mediante formule specifiche o simulazioni. Applicare la formula per osservazioni indipendenti e aumentare arbitrariamente n non garantisce il controllo desiderato.

5.9. Analisi di sensibilità della pianificazione

Deviazione standard, tasso di abbandono ed effetto bersaglio sono spesso incerti prima dello studio. Presentare un unico valore di n può nascondere questa incertezza.

È più informativo valutare scenari:

- ottimistico;
- centrale;
- prudente.

Per esempio, possiamo calcolare la numerosità per più valori plausibili della deviazione standard o dell'effetto. La scelta finale dovrebbe essere accompagnata dalle assunzioni che la sostengono.

i Il calcolo è una conseguenza delle assunzioni

Un risultato come «servono 48 partecipanti» dovrebbe essere letto come abbreviazione di una frase più completa:

Servono 48 partecipanti analizzabili per il test, l'effetto, la variabilità, l'allocazione, α e la potenza specificati.

Cambiare una di queste quantità può cambiare sostanzialmente il risultato.

5.10. Perché la potenza post hoc è poco informativa?

Dopo uno studio, talvolta si sostituisce nella formula di potenza l'effetto osservato e si calcola la cosiddetta *potenza osservata*.

Questa quantità è quasi interamente determinata dalla statistica test o dal valore- p :

- un risultato significativo tende a produrre alta potenza osservata;
- un risultato non significativo tende a produrre bassa potenza osservata.

Non aggiunge quindi una valutazione indipendente dell'informazione contenuta nei dati.

Dopo la raccolta, è generalmente più utile esaminare:

- la stima dell'effetto;
- l'intervallo di confidenza;
- la compatibilità con effetti scientificamente rilevanti;
- le assunzioni e la qualità del disegno.

Una nuova analisi di potenza può essere utile per pianificare **uno studio futuro**, purché non utilizzi meccanicamente l'effetto instabile del primo studio come verità nota.

5.11. Pianificazione frequentista e bayesiana

La pianificazione frequentista formula obiettivi come:

- raggiungere una determinata copertura o ampiezza attesa;
- controllare α ;
- ottenere una certa potenza rispetto a un effetto bersaglio.

Una pianificazione bayesiana può invece definire criteri relativi a:

- ampiezza della distribuzione a posteriori;
- probabilità di superare una soglia pratica;
- probabilità predittiva di raggiungere una decisione;
- utilità attesa delle possibili decisioni.

Le due prospettive possono anche essere valutate con simulazioni comuni. Una procedura bayesiana può essere studiata per le sue proprietà frequentiste, e una pianificazione frequentista può incorporare informazioni precedenti nella scelta degli scenari.

La differenza centrale non è che una prospettiva pianifichi e l'altra no. È quale criterio definisce uno studio sufficientemente informativo.

! Un confronto senza scorciatoie

La potenza non risponde direttamente alla domanda «quanta incertezza resterà sul parametro?». Una distribuzione a posteriori stretta, d'altra parte, non garantisce automaticamente adeguata copertura frequentista o protezione da un modello mal specificato. Entrambe le pianificazioni richiedono obiettivi sostantivi, un modello plausibile e assunzioni esplicite.

Riflessioni conclusive

La numerosità campionaria non è una proprietà generale di un argomento di ricerca. È il risultato di una pianificazione riferita a una specifica domanda, procedura e serie di assunzioni.

Abbiamo distinto due obiettivi:

1. ottenere una precisione prefissata;
2. raggiungere una potenza desiderata per un effetto bersaglio.

La pianificazione per precisione rende esplicito quanto stretto debba essere un intervallo. La pianificazione per potenza rende esplicito quale effetto lo studio debba riuscire a rilevare e con quale probabilità.

In entrambi i casi, il numero calcolato è condizionale. Variabilità, abbandoni, dipendenza, affidabilità delle misure e differenze tra disegno ideale e realizzazione concreta possono modificare il fabbisogno effettivo.

Nel prossimo capitolo applicheremo questi concetti al confronto tra due gruppi indipendenti. La numerosità non sarà trattata come un'aggiunta finale, ma come parte del modello inferenziale e del disegno dello studio.

Esercizi

1. Qual è la differenza tra pianificare uno studio per precisione e pianificarlo per potenza?
2. Perché dimezzare il margine di errore richiede approssimativamente quattro volte le osservazioni, nel caso elementare della media?
3. Che cosa significa affermare che un test ha potenza 0.80 per una differenza di 3 punti?
4. Perché la frase «lo studio ha potenza 0.80» è incompleta?
5. Perché è preferibile motivare un effetto minimo di interesse nella scala originale, quando possibile?
6. Un calcolo richiede 48 partecipanti analizzabili e si prevede il 15% di perdite. Perché il numero da reclutare deve essere maggiore di 48?
7. Perché la potenza osservata, calcolata usando l'effetto ottenuto nello stesso studio, aggiunge poca informazione al valore- p ?
8. In che modo differiscono gli obiettivi tipici di una pianificazione frequentista e di una pianificazione bayesiana?

Soluzioni

1. La pianificazione per precisione sceglie n per ottenere un intervallo sufficientemente stretto. La pianificazione per potenza sceglie n per ottenere una probabilità prefissata di rifiutare H_0 sotto una specifica alternativa.
2. Il margine di errore è proporzionale a $1/\sqrt{n}$. Per ridurlo della metà occorre raddoppiare $\sqrt{n}$, quindi quadruplicare n .
3. Se la differenza vera fosse 3 punti e tutte le altre assunzioni fossero quelle della pianificazione, il test rifiuterebbe H_0 in circa l'80% delle ripetizioni.

4. La potenza dipende dall'effetto vero, dalla variabilità, da α , dalla numerosità, dal tipo di test e dal disegno. Senza specificare almeno l'alternativa, il numero non è interpretabile.
5. La rilevanza scientifica riguarda spesso una differenza concreta nel costrutto misurato. L'effetto standardizzato dipende anche dalla deviazione standard della popolazione e può cambiare significato tra contesti.
6. Il calcolo riguarda le osservazioni che entreranno nell'analisi. Se alcune persone abbandonano o producono dati inutilizzabili, occorre reclutarne di più per conservare la numerosità finale desiderata.
7. Usando l'effetto osservato, la potenza diventa quasi una trasformazione della statistica test: risultati significativi producono valori alti e risultati non significativi valori bassi. Non offre una nuova misura indipendente della precisione.
8. La pianificazione frequentista usa spesso copertura, ampiezza, errore di tipo I e potenza. Quella bayesiana può usare precisione a posteriori, probabilità di superare soglie decisionali o utilità attesa. Entrambe dipendono da modelli e obiettivi espliciti.

i Punti chiave

- Non esiste una numerosità adeguata indipendente dalla domanda e dal disegno.
- Precisione e potenza sono obiettivi collegati ma distinti.
- Il calcolo per la precisione dipende da variabilità, margine di errore e livello di confidenza.
- La potenza è definita rispetto a una specifica alternativa.
- L'effetto minimo di interesse deve essere motivato scientificamente.
- Gli effetti standardizzati dipendono dalla variabilità prevista.
- `power.t.test()` restituisce, nel caso a due gruppi, la numerosità per gruppo.
- La numerosità analitica deve essere distinta dall'obiettivo di reclutamento.
- Dipendenza, abbandoni e dati mancanti possono modificare il fabbisogno.
- La potenza post hoc basata sull'effetto osservato è generalmente ridondante.
- Pianificazione frequentista e bayesiana definiscono in modo diverso quando uno studio è sufficientemente informativo.

i Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2  patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1          matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidymodels_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51          labeling_0.4.3         bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8         purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1        xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.4       scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-2       rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0          RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0       parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-6          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2  glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5       stringi_1.8.7
#> [49] gtable_0.3.6        QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9     Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5   rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9      backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13        snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1       gridExtra_2.3.1       nlme_3.1-170
#> [67] checkmate_2.3.4     xfun_0.60             pkgconfig_2.0.3

```

Bibliografia

6. Confrontare due gruppi indipendenti

In sintesi

Da sapere Il confronto tra due gruppi indipendenti stima una differenza tra medie e ne valuta la precisione e la compatibilità con un valore nullo. Il test t di Welch è spesso una scelta predefinita appropriata perché non richiede l'uguaglianza delle varianze.

Da saper fare Definire la differenza di interesse; riconoscere quando i gruppi sono indipendenti; leggere stime descrittive, intervallo di confidenza, valore- p e dimensione dell'effetto; distinguere associazione e causalità; collegare il test t a un modello di regressione con predittore dicotomico.

Introduzione

Il confronto tra due gruppi indipendenti è una delle situazioni più comuni nella ricerca psicologica. Possiamo confrontare un gruppo sottoposto a un intervento con un gruppo di controllo, due condizioni sperimentali oppure due gruppi definiti da una caratteristica osservata.

Questo capitolo riunisce i concetti introdotti nel modulo:

stima $\rightarrow$ errore standard $\rightarrow$ intervallo di confidenza $\rightarrow$ test $\rightarrow$ dimensione dell'effetto.

L'obiettivo non è imparare una procedura isolata. È comprendere come questi elementi descrivano aspetti differenti dello stesso confronto.

Nel quadro frequentista, il test t risponde a una domanda condizionale:

Se la differenza tra le medie delle popolazioni fosse nulla e il modello fosse adeguato, quanto sarebbe estremo il risultato osservato?

Questa domanda non coincide con la probabilità che le medie siano uguali, con la probabilità che l'intervento funzioni o con la probabilità che la differenza superi una soglia clinicamente importante.

Prerequisiti

È utile avere letto:

- Capitolo 2, per stimatore, stima ed errore standard;
- Capitolo 3, per copertura e interpretazione degli intervalli;
- Capitolo 4, per valore- p , α ed errori decisionali;
- Capitolo 5, per effetto bersaglio, potenza e numerosità.

Questo capitolo applica tali concetti a un unico caso e conclude la parte operativa del modulo.

Panoramica del capitolo

Il capitolo procede in nove passaggi:

1. definisce la quantità che si vuole confrontare;
2. distingue gruppi indipendenti, dati appaiati e misure ripetute;
3. presenta il modello del test t classico e quello di Welch;
4. esamina disegno, distribuzioni e valori anomali;
5. svolge un esempio completo in R;
6. integra differenza grezza, intervallo, valore- p ed effetto standardizzato;
7. chiarisce quando una differenza può essere interpretata causalmente;
8. mostra l'equivalenza con la regressione lineare;
9. collega il confronto frequentista ai modelli bayesiani del Companion.

i Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>
  source()
```

6.1. Prima del test: definire il confronto

Immaginiamo uno studio su un intervento di regolazione emotiva. Un gruppo riceve l'intervento e un gruppo di controllo non lo riceve. Al termine dello studio viene misurato il benessere psicologico.

Indichiamo con:

μ_1 = media della popolazione del gruppo intervento,

μ_0 = media della popolazione del gruppo controllo.

La quantità bersaglio è:

$$\Delta = \mu_1 - \mu_0.$$

La sua stima campionaria è:

$$\widehat{\Delta} = \bar{X}_1 - \bar{X}_0.$$

Il segno dipende dall'ordine della sottrazione. Con la definizione adottata:

- $\widehat{\Delta} > 0$ indica una media maggiore nel gruppo intervento;
- $\widehat{\Delta} < 0$ indica una media maggiore nel gruppo controllo.

6. Confrontare due gruppi indipendenti

! Definire l'ordine prima di interpretare il segno

La stessa differenza può essere scritta come intervento meno controllo oppure controllo meno intervento. Il valore assoluto non cambia, ma il segno sì.

L'ordine deve essere dichiarato e mantenuto coerente in stima, intervallo, dimensione dell'effetto e resoconto.

6.1.1. Quale popolazione rappresentano le medie?

Le medie μ_1 e μ_0 dipendono da:

- popolazione a cui si vuole generalizzare;
- criteri di inclusione;
- modalità di assegnazione ai gruppi;
- momento e strumento di misurazione;
- trattamento dei dati mancanti;
- modello statistico.

Una differenza tra medie non è un oggetto separato dal disegno. Prima di calcolare il test occorre chiarire che cosa rappresentano i due gruppi e quale confronto sia scientificamente rilevante.

6.2. Gruppi indipendenti, dati appaiati e misure ripetute

Due gruppi sono **indipendenti** quando l'osservazione di una persona nel primo gruppo non è naturalmente collegata a una specifica osservazione del secondo gruppo.

Esempi:

- persone differenti assegnate a intervento e controllo;
- partecipanti provenienti da due popolazioni distinte;
- due gruppi osservazionali senza abbinamento individuale.

Non sono invece indipendenti:

- misure prima e dopo sulle stesse persone;
- coppie abbinate;
- gemelli o membri della stessa famiglia;
- studenti nella stessa classe, quando la dipendenza del gruppo non è modellata;
- più osservazioni prodotte dallo stesso partecipante.

Nel caso di coppie o misure ripetute, la quantità rilevante è spesso la media delle differenze entro coppia. Usare il test per gruppi indipendenti ignora la struttura dei dati e può produrre errori standard inadeguati.

! L'indipendenza non si verifica con un test automatico

È soprattutto una proprietà del disegno e del processo di raccolta. Un grafico o un test di normalità non possono dimostrare che osservazioni provenienti dalla stessa classe, famiglia o persona siano indipendenti.

6.3. Il modello inferenziale

6.3.1. Ipotesi nulla e alternativa

Nel test bilaterale:

$$H_0 : \Delta = 0,$$

$$H_1 : \Delta \neq 0.$$

Un'alternativa direzionale può essere:

$$H_1 : \Delta > 0.$$

La direzione deve essere scelta prima di osservare i dati e deve avere una motivazione sostantiva. Il test bilaterale è una scelta introduttiva prudente quando deviazioni in entrambe le direzioni sarebbero scientificamente rilevanti.

6.3.2. Struttura generale della statistica

La statistica test ha la forma:

$$t = \frac{\widehat{\Delta} - 0}{\widehat{SE}(\widehat{\Delta})}.$$

Il numeratore è la differenza osservata rispetto al valore nullo. Il denominatore misura quanto la differenza tra medie varierebbe sotto campionamenti ripetuti, secondo il modello adottato.

6.4. Test t classico e test di Welch

6.4.1. Test classico con varianze uguali

Il test classico assume una varianza comune nelle due popolazioni. La deviazione standard pooled è:

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_0 - 1)s_0^2}{n_1 + n_0 - 2}}.$$

L'errore standard è:

$$\widehat{SE}_{\text{pooled}} = s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_0}}.$$

La statistica segue una distribuzione t con:

6. Confrontare due gruppi indipendenti

$$df = n_1 + n_0 - 2$$

quando le assunzioni del modello sono soddisfatte.

6.4.2. Test di Welch

Il test di Welch non impone una varianza comune. Usa:

$$\widehat{SE}_{\text{Welch}} = \sqrt{\frac{s_1^2}{n_1} + \frac{s_0^2}{n_0}}.$$

I gradi di libertà vengono approssimati mediante la formula di Welch–Satterthwaite:

$$\nu = \frac{(s_1^2/n_1 + s_0^2/n_0)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_0^2/n_0)^2}{n_0-1}}.$$

In R, `t.test()` usa Welch per impostazione predefinita.

i Perché Welch è una buona scelta predefinita

Quando varianze e numerosità sono simili, Welch e il test classico producono spesso risultati quasi identici.

Quando differiscono, Welch protegge meglio dall'assunzione non giustificata di una varianza comune. Non è corretto descriverlo semplicemente come «più prudente»: è una procedura costruita per un modello che consente dispersioni differenti.

L'uso del test classico dovrebbe derivare da una ragione per assumere una varianza comune, non dal mancato rifiuto di un test preliminare sulle varianze. Testare prima l'uguaglianza delle varianze e scegliere poi il test sulla base dello stesso campione crea una procedura in due stadi con proprietà meno trasparenti.

6.5. Assunzioni e adeguatezza

6.5.1. Indipendenza e disegno

L'indipendenza è essenziale per le formule standard. Clustering, abbinamento o misure ripetute richiedono procedure differenti.

6.5.2. Esito quantitativo

Il test confronta medie. L'esito deve quindi essere quantitativo o trattato come una misura approssimativamente quantitativa. Questa scelta deve essere sostanzialmente difendibile, soprattutto per punteggi con pochi livelli o forti effetti di pavimento e soffitto.

6.5.3. Distribuzione entro i gruppi

L'esattezza del test classico e di Welch deriva da popolazioni normali. Le procedure sono spesso robuste a deviazioni moderate quando:

- i campioni non sono molto piccoli;
- le distribuzioni non sono fortemente asimmetriche;
- non sono presenti valori estremi influenti;
- il disegno non combina forte squilibrio e forte eteroschedasticità.

La robustezza non significa che la forma dei dati sia irrilevante. Con campioni piccoli, code pesanti o valori anomali, media, deviazione standard e test possono essere instabili.

6.5.4. Valori anomali

Un valore anomalo può:

- spostare una media;
- aumentare una deviazione standard;
- modificare l'errore standard;
- alterare il valore- p e la dimensione dell'effetto.

Non va eliminato automaticamente. Occorre verificare se derivi da errore, se sia plausibile per la popolazione e quanto le conclusioni dipendano dalla sua presenza.

! Il controllo delle assunzioni è parte dell'analisi

Non consiste nel cercare un test che autorizzi meccanicamente l'uso del test t . Richiede di collegare grafici, disegno, qualità delle misure e conseguenze delle deviazioni al modello.

6.6. Un esempio guidato

Consideriamo dati didattici sul benessere psicologico.

```
benessere_intervento <- c(
  27, 31, 29, 33, 35, 30,
  32, 28, 34, 31, 36, 29
)

benessere_controllo <- c(
  24, 26, 28, 25, 29, 27,
  23, 30, 26, 25, 28, 24
)

dati_benessere <- data.frame(
  gruppo = factor(
    rep(
      c("Controllo", "Intervento"),
      each = 12
    ),
  ),
```

6. Confrontare due gruppi indipendenti

```
levels = c("Controllo", "Intervento")
),
benessere = c(
  benessere_controllo,
  benessere_intervento
)
)
```

La codifica fissa l'ordine del confronto come:

$$\Delta = \mu_{\text{intervento}} - \mu_{\text{controllo}}.$$

6.6.1. Descrizione prima dell'inferenza

```
gruppi <- split(
  dati_benessere$benessere,
  dati_benessere$gruppo
)

descrittive <- data.frame(
  gruppo = names(gruppi),
  n = vapply(gruppi, length, integer(1)),
  media = vapply(gruppi, mean, numeric(1)),
  deviazione_standard = vapply(gruppi, sd, numeric(1)),
  row.names = NULL
)

descrittive$media <- round(descrittive$media, 2)
descrittive$deviazione_standard <-
  round(descrittive$deviazione_standard, 2)

knitr::kable(descrittive)
```

Tabella 6.1.: Statistiche descrittive dei punteggi di benessere nei due gruppi.

gruppo	n	media	deviazione_standard
Controllo	12	26.2	2.18
Intervento	12	31.2	2.83

Le medie campionarie sono:

$$\bar{x}_{\text{intervento}} = 31.25,$$

$$\bar{x}_{\text{controllo}} = 26.25.$$

La differenza osservata è:

$$\hat{\Delta} = 5.00.$$

6.6.2. Visualizzare distribuzioni e osservazioni

```
ggplot(
  dati_benessere,
  aes(x = gruppo, y = benessere)
) +
  geom_boxplot(
    width = 0.45,
    alpha = 0.35,
    outlier.shape = NA
  ) +
  geom_jitter(
    width = 0.08,
    alpha = 0.8,
    size = 2
  ) +
  stat_summary(
    fun = mean,
    geom = "point",
    shape = 18,
    size = 4
  ) +
  labs(
    x = "Gruppo",
    y = "Punteggio di benessere"
  )
)
```




Figura 6.1.: Punteggi individuali e distribuzioni nei gruppi controllo e intervento. Il simbolo a rombo indica la media.

Figura 6.1 mostra posizione, dispersione, sovrapposizione e singole osservazioni. Il grafico non sostituisce l'inferenza, ma impedisce che il risultato venga ridotto a un unico numero.

6.7. Eseguire il test di Welch

```
test_welch <- t.test(
  benessere ~ gruppo,
  data = dati_benessere,
  alternative = "two.sided",
  var.equal = FALSE,
  conf.level = 0.95
)

test_welch
#>
#> Welch Two Sample t-test
#>
#> data:  benessere by gruppo
#> t = -5, df = 21, p-value = 0.00009
#> alternative hypothesis: true difference in means between group Controllo and group Intervento
#> 95 percent confidence interval:
#>  -7.15 -2.85
#> sample estimates:
#> mean in group Controllo mean in group Intervento
#>                26.2                31.2
```

Poiché il primo livello del fattore è Controllo, la formula di R riporta inizialmente la differenza:

$$\mu_{\text{controllo}} - \mu_{\text{intervento}}$$

Per mantenere l'ordine scelto nel capitolo, calcoliamo esplicitamente intervento meno controllo:

```
n_intervento <- length(benessere_intervento)
n_controllo <- length(benessere_controllo)

m_intervento <- mean(benessere_intervento)
m_controllo <- mean(benessere_controllo)

s_intervento <- sd(benessere_intervento)
s_controllo <- sd(benessere_controllo)

differenza <- m_intervento - m_controllo

se_welch <- sqrt(
  s_intervento^2 / n_intervento +
  s_controllo^2 / n_controllo
)
```



```

df_welch <- (
  s_intervento^2 / n_intervento +
  s_controllo^2 / n_controllo
)^2 / (
  (s_intervento^2 / n_intervento)^2 /
  (n_intervento - 1) +
  (s_controllo^2 / n_controllo)^2 /
  (n_controllo - 1)
)

t_welch <- differenza / se_welch
p_welch <- 2 * pt(
  abs(t_welch),
  df = df_welch,
  lower.tail = FALSE
)

t_critico <- qt(0.975, df = df_welch)

ic_welch <- c(
  differenza - t_critico * se_welch,
  differenza + t_critico * se_welch
)

c(
  differenza = differenza,
  errore_standard = se_welch,
  t = t_welch,
  gradi_liberta = df_welch,
  valore_p = p_welch,
  limite_inferiore = ic_welch[1],
  limite_superiore = ic_welch[2]
)
#>      differenza  errore_standard          t  gradi_liberta
#>      5.0000000      1.0316947      4.8463950      20.6446253
#>      valore_p limite_inferiore limite_superiore
#>      0.0000901      2.8522224      7.1477776

```

Otteniamo approssimativamente:

$$\widehat{\Delta} = 5.00,$$

$$IC_{95\%} = [2.85, 7.15],$$

$$t(20.64) = 4.85, \quad p < 0.001.$$

Il valore- p indica che, sotto l'ipotesi di differenza nulla e le altre assunzioni del test, una statistica almeno altrettanto estrema sarebbe rara.

Non è la probabilità che $\Delta = 0$.

6.8. Il caso con varianza comune

Per confronto, eseguiamo il test classico:

```
test_pooled <- t.test(
  benessere_intervento,
  benessere_controllo,
  alternative = "two.sided",
  var.equal = TRUE,
  conf.level = 0.95
)

test_pooled
#>
#> Two Sample t-test
#>
#> data:  benessere_intervento and benessere_controllo
#> t = 5, df = 22, p-value = 0.00008
#> alternative hypothesis: true difference in means is not equal to 0
#> 95 percent confidence interval:
#>  2.86 7.14
#> sample estimates:
#> mean of x mean of y
#>      31.2      26.2
```

In questi dati, numerosità e deviazioni standard sono simili, quindi i due test producono risultati quasi identici.

Questa somiglianza non dimostra che le varianze delle popolazioni siano uguali. Mostra soltanto che, per questo campione, l'assunzione aggiuntiva ha conseguenze numeriche limitate.

6.9. Interpretare insieme le quantità

6.9.1. Differenza nella scala originale

La differenza di 5 punti è la quantità più direttamente interpretabile:

Nel campione, la media del gruppo intervento supera quella del gruppo controllo di 5 punti.

La sua importanza dipende dalla scala, dall'affidabilità dello strumento e dal contesto.

6.9.2. Intervallo di confidenza

L'intervallo al 95% è:

[2.85, 7.15].

Descrive la precisione della procedura frequentista. Non assegna il 95% di probabilità alla differenza vera entro questi estremi.

L'intervallo è utile anche per confrontare i dati con una soglia sostantiva. Se, per esempio, fossero necessari almeno 6 punti per una rilevanza pratica, l'intervallo mostrerebbe che i dati sono compatibili sia con differenze inferiori sia con differenze superiori a tale soglia.

6.9.3. Valore-p

Il valore- p sintetizza l'incompatibilità con $\Delta = 0$. Non descrive la grandezza della differenza né la sua importanza.

6.9.4. Dimensione dell'effetto standardizzata

Una misura comune è il d di Cohen:

$$d = \frac{\bar{x}_{\text{intervento}} - \bar{x}_{\text{controllo}}}{s_p}.$$

```
s_pooled <- sqrt(
  (
    (n_intervento - 1) * s_intervento^2 +
    (n_controllo - 1) * s_controllo^2
  ) /
  (
    n_intervento +
    n_controllo -
    2
  )
)

cohen_d <- differenza / s_pooled

correzione_hedges <- 1 -
  3 /
  (
    4 *
    (
      n_intervento +
      n_controllo
    ) -
    9
  )

hedges_g <- correzione_hedges * cohen_d

c(
  cohen_d = cohen_d,
  hedges_g = hedges_g
)
#> cohen_d hedges_g
#> 1.98 1.91
```

6. Confrontare due gruppi indipendenti

Per questi dati:

$$d \approx 1.98, \quad g \approx 1.91.$$

g di Hedges applica una correzione alla tendenza di d a sovrastimare l'effetto standardizzato nei piccoli campioni.

 L'effetto standardizzato non sostituisce la differenza grezza

d e g dipendono anche dalla dispersione dei punteggi. Lo stesso cambiamento di 5 punti può produrre valori standardizzati differenti in popolazioni con variabilità diversa.

Quando la scala originale è interpretabile, è opportuno riportare sia la differenza grezza sia una misura standardizzata.

6.10. Significatività, equivalenza e rilevanza pratica

Un risultato significativo rispetto a zero non dimostra che l'effetto sia abbastanza grande da essere utile.

Un risultato non significativo, d'altra parte, non dimostra che i gruppi siano equivalenti. Per sostenere equivalenza occorrono:

1. una regione di differenze considerate praticamente trascurabili;
2. una procedura progettata per valutare quella regione;
3. dati sufficientemente precisi.

La soglia di rilevanza dovrebbe essere motivata prima dell'analisi e collegata alla scala del fenomeno.

 Tre domande differenti

1. **Esclusione dello zero:** i dati sono incompatibili con $\Delta = 0$ secondo il test?
2. **Precisione:** quali differenze non vengono escluse dall'intervallo?
3. **Rilevanza:** quali differenze cambierebbero una conclusione teorica o pratica?

Rispondere alla prima non risponde automaticamente alle altre due.

6.11. Dalla differenza osservata all'effetto causale

Una differenza tra medie è sempre descrittiva del confronto definito. Diventa interpretabile come effetto causale soltanto sotto condizioni aggiuntive.

6.11.1. Studio randomizzato

Se i partecipanti sono assegnati casualmente ai gruppi, l'assegnazione è rispettata e non vi sono problemi sostanziali di attrito, aderenza o contaminazione, la differenza può sostenere un'interpretazione causale riferita alla popolazione e al trattamento definiti.

6.11.2. Gruppi osservazionali

Se i gruppi sono definiti da una caratteristica osservata, una differenza può dipendere da variabili confondenti.

Per esempio, una differenza tra persone che scelgono o non scelgono un trattamento non dimostra che il trattamento abbia prodotto la differenza. I gruppi possono differire già prima dell'intervento.

 Il test t non crea causalità

Randomizzazione, identificazione e qualità del disegno giustificano una conclusione causale. Il valore- p non può compensare l'assenza di queste condizioni.

6.12. Il test t come modello lineare

Il confronto tra due gruppi può essere scritto come una regressione con un predittore dicotomico:

$$Y_i = \alpha + \beta X_i + \varepsilon_i,$$

dove:

- $X_i = 0$ indica il controllo;
- $X_i = 1$ indica l'intervento.

Allora:

$$E(Y \mid X = 0) = \alpha,$$

$$E(Y \mid X = 1) = \alpha + \beta.$$

La differenza è:

$$E(Y \mid X = 1) - E(Y \mid X = 0) = \beta.$$

Il coefficiente β rappresenta quindi la stessa quantità:

$$\beta = \mu_{\text{intervento}} - \mu_{\text{controllo}}.$$

```
modello_lineare <- lm(
  benessere ~ gruppo,
  data = dati_benessere
)

summary(modello_lineare)
#>
#> Call:
#> lm(formula = benessere ~ gruppo, data = dati_benessere)
#>
```

6. Confrontare due gruppi indipendenti

```
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#>  -4.25  -2.25  -0.25   1.75   4.75
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> (Intercept)      26.25      0.73   35.98 < 2e-16
#> gruppoIntervento    5.00      1.03    4.85 0.000076
#>
#> Residual standard error: 2.53 on 22 degrees of freedom
#> Multiple R-squared:  0.516, Adjusted R-squared:  0.494
#> F-statistic: 23.5 on 1 and 22 DF, p-value: 0.0000765
confint(modello_lineare)
#>              2.5 % 97.5 %
#> (Intercept)    24.74 27.76
#> gruppoIntervento 2.86  7.14
```

Con varianza comune, il test del coefficiente del predittore è equivalente al test t classico per due gruppi.

Questa equivalenza è importante perché mostra che il test t non è un procedimento isolato. È il caso più semplice di una famiglia di modelli che può includere:

- più gruppi;
- covariate;
- interazioni;
- strutture gerarchiche;
- esiti non gaussiani.

Un ponte verso il progetto bayesiano

Il Companion usa la stessa rappresentazione con un predittore 0–1:

- [Confrontare due medie con Stan](#);
- il capitolo 26, *Due gruppi: codifiche, differenze e rilevanza pratica*.

Nel modello bayesiano, la distribuzione a posteriori di β rappresenta direttamente l'incertezza sulla differenza tra le medie.

6.13. Che cosa cambia nel modello bayesiano?

Il confronto frequentista e quello bayesiano possono condividere:

- gli stessi dati;
- lo stesso predittore dicotomico;
- una verosimiglianza normale;
- la stessa quantità bersaglio Δ ;
- modelli con dispersione comune o differente.

Cambiano l'oggetto inferenziale immediato e il significato delle probabilità.

Domanda	Procedura frequentista	Modello bayesiano
Quanto differiscono i gruppi?	Stima puntuale e intervallo di confidenza	Distribuzione a posteriori di Δ
Quanto è incompatibile lo zero?	Valore- p sotto H_0	Massa a posteriori rispetto a zero o confronto tra modelli
L'effetto supera una soglia pratica?	Intervallo, equivalenza o test dedicato	Probabilità a posteriori che Δ superi la soglia
Il modello descrive adeguatamente i dati?	Diagnostica e controlli frequentisti	Controlli predittivi e confronto predittivo

Nel modello bayesiano si possono calcolare quantità come:

$$P(\Delta > 0 \mid y)$$

oppure:

$$P(\Delta > \delta_{\min} \mid y),$$

dove $\delta_{\min}$ è una soglia sostantiva. Queste probabilità non sono valori- p e dipendono da prior, verosimiglianza e dati.

Il vantaggio di un'interpretazione diretta non elimina la necessità di controllare modello, misura, disegno e identificazione causale.

6.14. Come riportare il risultato

Un resoconto informativo dovrebbe includere:

- numerosità, media e deviazione standard dei gruppi;
- ordine della differenza;
- differenza grezza e intervallo;
- test utilizzato;
- statistica, gradi di libertà e valore- p ;
- dimensione dell'effetto;
- interpretazione sostantiva e limiti del disegno.

Per l'esempio:

Il gruppo sottoposto all'intervento ha riportato un punteggio medio di benessere maggiore ($M = 31.25$, $DS = 2.83$, $n = 12$) rispetto al gruppo di controllo ($M = 26.25$, $DS = 2.18$, $n = 12$). La differenza intervento meno controllo è stata di 5.00 punti, IC 95% [2.85, 7.15]. Il test t di Welch ha indicato incompatibilità con una differenza nulla, $t(20.64) = 4.85$, $p < .001$. La differenza standardizzata è risultata elevata nel campione, $g = 1.91$. L'interpretazione causale dipende dall'assegnazione e dalle altre caratteristiche del disegno.

i Perché nominare Welch

Scrivere soltanto «test t » lascia implicita un'assunzione importante. Specificare «test t di Welch» comunica che non è stata imposta l'uguaglianza delle varianze.

Riflessioni conclusive

Il confronto tra due gruppi indipendenti conclude il percorso applicativo del modulo frequentista perché riunisce tutti gli elementi introdotti nei capitoli precedenti.

Abbiamo definito la differenza tra le medie come quantità bersaglio, distinto gruppi indipendenti e dati appaiati, confrontato il test classico con quello di Welch e interpretato congiuntamente:

- differenza grezza;
- errore standard;
- intervallo di confidenza;
- valore- p ;
- dimensione dell'effetto.

Il risultato di un test non esaurisce l'analisi. Occorre chiedersi quale differenza sia rilevante, quanto precisamente sia stimata, se il modello sia adeguato e se il disegno autorizzi un'interpretazione causale.

L'equivalenza tra test t e regressione con predittore dicotomico crea il ponte più naturale verso il progetto bayesiano. La domanda sostantiva rimane la stessa — quanto differiscono i gruppi? — ma l'incertezza viene rappresentata mediante la distribuzione a posteriori del coefficiente che codifica la differenza.

L'epilogo userà questo punto di arrivo per confrontare in modo complessivo controllo dell'errore, interpretazione dell'incertezza e workflow scientifico.

Esercizi

1. Qual è la differenza tra la quantità $\Delta = \mu_1 - \mu_0$ e la stima $\hat{\Delta} = \bar{X}_1 - \bar{X}_0$?
2. Perché un disegno prima-dopo sulle stesse persone non dovrebbe essere analizzato come confronto tra gruppi indipendenti?
3. Quale assunzione aggiuntiva distingue il test t classico dal test di Welch?
4. Perché non è consigliabile scegliere tra test classico e Welch sulla base di un test preliminare delle varianze?
5. Un intervallo per la differenza è $[1.2, 6.8]$, mentre la soglia di rilevanza pratica è 5. Che cosa suggerisce l'intervallo?
6. Perché una differenza statisticamente significativa tra due gruppi osservazionali non dimostra un effetto causale?
7. Nel modello $Y_i = \alpha + \beta X_i + \varepsilon_i$, con controllo codificato 0 e intervento codificato 1, che cosa rappresentano α e β ?
8. Qual è la differenza tra un valore- p piccolo per $H_0 : \Delta = 0$ e una probabilità a posteriori elevata per $\Delta > 0$?

Soluzioni

1. Δ è la differenza tra le medie delle popolazioni o del modello. $\hat{\Delta}$ è la differenza osservata tra le medie campionarie e varia da campione a campione.
2. Le due osservazioni della stessa persona sono dipendenti. Un test indipendente ignora l'abbinamento e usa un errore standard non coerente con il disegno.
3. Il test classico assume una varianza comune nelle due popolazioni. Welch permette varianze differenti e modifica errore standard e gradi di libertà.
4. La procedura risultante dipende da una decisione presa sugli stessi dati e ha proprietà inferenziali meno trasparenti. Welch può essere adottato direttamente senza imporre l'uguaglianza delle varianze.
5. I dati sono compatibili, secondo la procedura, sia con differenze inferiori sia con differenze superiori a 5. L'esclusione dello zero non consente di stabilire con precisione che la soglia pratica sia superata.
6. I gruppi possono differire per confondenti, selezione o condizioni precedenti all'esposizione. Il test quantifica una differenza, ma non identifica da solo il meccanismo che l'ha prodotta.
7. α è la media del gruppo controllo. β è la differenza intervento meno controllo.
8. Il valore- p riguarda risultati estremi sotto $\Delta = 0$. La probabilità a posteriori riguarda l'incertezza su Δ dopo avere combinato prior, modello e dati.

Punti chiave

- Il confronto deve iniziare dalla definizione della differenza e del suo ordine.
- Gruppi indipendenti, dati appaiati e misure ripetute richiedono strutture inferenziali diverse.
- Il test di Welch non richiede una varianza comune ed è spesso una scelta predefinita adeguata.
- L'indipendenza è soprattutto un'assunzione del disegno.
- Differenza grezza, intervallo, valore- p e dimensione standardizzata comunicano informazioni diverse.
- Un risultato significativo rispetto a zero non dimostra rilevanza pratica.
- Un risultato non significativo non dimostra equivalenza.
- Il test t non trasforma un confronto osservazionale in un effetto causale.
- Il confronto tra due gruppi è equivalente a una regressione con predittore dicotomico.
- Nel modello bayesiano, la posterior del coefficiente dicotomico rappresenta l'incertezza sulla differenza tra le medie.

Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

6. Confrontare due gruppi indipendenti

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2  patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1          matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidymodels_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0          tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5         compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51          labeling_0.4.3         bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8         purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1        xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.4       scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-2       rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0          RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0       parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-6          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2  glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5       stringi_1.8.7
#> [49] gtable_0.3.6        QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9     Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5   rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9      backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13        snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1       gridExtra_2.3.1       nlme_3.1-170
#> [67] checkmate_2.3.4     xfun_0.60             pkgconfig_2.0.3
```

Parte II.

Epilogo

Conclusioni

In sintesi

Questo modulo ha presentato l'inferenza frequentista come un insieme di procedure valutate attraverso il loro comportamento sotto campionamenti ripetuti. Comprenderne la logica è necessario per leggere la letteratura psicologica, interpretare correttamente stime, intervalli e test e riconoscere quali domande richiedano una diversa rappresentazione dell'incertezza. Il passaggio al progetto bayesiano non consiste nel sostituire meccanicamente una tecnica con un'altra. Consiste nel riformulare il problema inferenziale: dal comportamento della procedura nelle ripetizioni alla distribuzione dell'incertezza su parametri, predizioni e modelli, condizionatamente alle assunzioni e ai dati.

Che cosa abbiamo imparato

Il percorso è iniziato dalle origini storiche del frequentismo e dal rapporto, scientificamente fecondo ma eticamente problematico, tra misurazione delle differenze individuali, statistica ed eugenetica.

Nei capitoli successivi abbiamo costruito il lessico operativo dell'inferenza frequentista:

- il **parametro** è una quantità fissa ma ignota all'interno del modello;
- lo **stimatore** è una regola applicata ai dati;
- la **stima** è il valore osservato dello stimatore;
- l'**errore standard** descrive la variabilità campionaria dello stimatore;
- l'**intervallo di confidenza** è una procedura con una determinata frequenza di copertura;
- il **valore- p** misura l'estremità del risultato sotto un'ipotesi nulla e un insieme di assunzioni;
- gli errori di tipo I e II e la **potenza** descrivono il comportamento di una regola decisionale;
- la numerosità campionaria deve essere pianificata rispetto a precisione, effetto bersaglio, variabilità e disegno.

Il confronto tra due gruppi ha infine mostrato come queste quantità si integrino nella pratica. Una conclusione scientifica non dovrebbe dipendere da un unico indicatore: stima, intervallo, valore- p , dimensione dell'effetto, qualità del disegno e rilevanza sostantiva rispondono a domande differenti.

Che cosa offre il frequentismo

L'inferenza frequentista fornisce strumenti fondamentali per valutare procedure e decisioni.

Permette, per esempio, di chiedere:

- quanto varia uno stimatore sotto campionamenti ripetuti;
- con quale frequenza una procedura intervallare contiene il parametro;
- quale tasso di errore di tipo I produce una regola decisionale;
- con quale probabilità un test rileva un effetto specificato;

- quante osservazioni sono necessarie per ottenere una precisione o una potenza prefissata.

Queste proprietà sono particolarmente importanti quando il disegno dell'indagine definisce chiaramente le ripetizioni rilevanti e quando il controllo degli errori costituisce un obiettivo centrale.

Il contributo del frequentismo non si riduce quindi al valore- p . Comprende teoria della stima, disegno sperimentale, randomizzazione, campionamento, intervalli, test, pianificazione e valutazione delle proprietà di lungo periodo.

I limiti da non dimenticare

Le garanzie frequentiste sono condizionate al modello e al disegno. Non proteggono automaticamente da:

- campioni non rappresentativi;
- misure poco valide o inaffidabili;
- dipendenze ignorate;
- modelli mal specificati;
- confronti multipli o scelte analitiche flessibili;
- selezione dei risultati;
- interpretazioni causali non sostenute dal disegno.

Anche quando una procedura è applicata correttamente, alcune domande restano fuori dal suo significato immediato.

Un intervallo di confidenza non assegna probabilità al parametro. Un valore- p non esprime la probabilità dell'ipotesi nulla. La potenza non indica quanto sia plausibile un effetto dopo avere osservato i dati.

Questi limiti non rendono inutili le procedure. Delimitano le conclusioni che possono sostenere.

 La critica corretta non è una caricatura

Il frequentismo non afferma che l'incertezza scientifica sia irrilevante e il bayesianesimo non elimina automaticamente gli errori di misura, i bias di selezione o i modelli inadeguati.

Il confronto utile riguarda il significato delle quantità inferenziali, le domande che possono ricevere risposta e il workflow con cui le assunzioni vengono rese esplicite e controllate.

Dal confronto frequentista al ragionamento bayesiano

Frequentismo e bayesianesimo possono condividere:

- la stessa domanda psicologica;
- gli stessi dati;
- la stessa funzione di verosimiglianza;
- lo stesso modello generativo;
- la stessa quantità di interesse.

Cambiano però il modo in cui l'incertezza viene rappresentata e aggiornata.

Nel quadro frequentista, la probabilità descrive principalmente dati, statistiche e procedure sotto ripetizioni reali o ipotetiche. Nel quadro bayesiano, la probabilità viene usata anche per rappresentare l'incertezza sui parametri e sulle predizioni, condizionatamente a prior, modello e dati.

Il passaggio centrale è:

$$p(\theta) \longrightarrow p(y \mid \theta) \longrightarrow p(\theta \mid y).$$

La distribuzione a priori rappresenta l'incertezza prima dei dati. La verosimiglianza collega parametri e osservazioni. La distribuzione a posteriori esprime come l'incertezza cambia dopo l'osservazione.

Da questa rappresentazione derivano domande come:

- qual è la probabilità a posteriori che un effetto sia positivo;
- quanto è probabile che superi una soglia sostantiva;
- quali valori futuri prevede il modello;
- quanto le conclusioni dipendono dalla prior;
- quanto bene il modello riproduce le caratteristiche rilevanti dei dati.

Queste quantità non sono reinterpretazioni bayesiane di valori- p e intervalli di confidenza. Appartengono a una diversa costruzione inferenziale.

Il ruolo di questo modulo nel progetto editoriale

Inferenza bayesiana in psicologia: Ragionare con l'incertezza costituisce il nucleo concettuale del progetto. Il manuale presenta i problemi epistemologici e metodologici, discute i limiti dell'uso meccanico della significatività statistica e sviluppa il ragionamento bayesiano come metodo di modellizzazione e apprendimento scientifico.

Questo sito svolge una funzione più circoscritta:

fornire il termine di confronto concettuale e tecnico necessario per comprendere che cosa cambia passando dall'inferenza frequentista a quella bayesiana.

Il modulo può quindi essere usato in due modi:

1. **prima del manuale**, come richiamo per chi proviene da una formazione statistica classica;
2. **durante o dopo la Parte II del manuale**, per consolidare il significato di stima, copertura, valore- p , potenza e confronto tra gruppi.

Il manuale non presuppone che ogni lettore padroneggi tutte le formule presentate qui. È più importante riconoscere quali affermazioni siano autorizzate da una procedura e quali costituiscano invece un'inversione o un'estensione indebita del suo significato.

Come proseguire

! Il percorso consigliato

Manuale UTET

Prosegui con *Inferenza bayesiana in psicologia: Ragionare con l'incertezza* di Corrado Caudek e Caterina Primi. Il volume costituisce il nucleo concettuale del progetto e introduce il passaggio dalla diagnosi dei limiti delle pratiche tradizionali al workflow bayesiano.

Guida permanente al manuale

La [Guida al manuale](#) mantiene il raccordo aggiornato tra i capitoli del volume, il Companion e i moduli di supporto.

Companion online

Il [Companion](#) è il laboratorio operativo del progetto. Sviluppa modelli generativi, prior, distribuzioni a posteriori, predizioni, diagnostica, controlli predittivi e implementazioni in R, brms e Stan.

Probabilità per la psicologia

Il modulo [Probabilità per la psicologia](#) offre il richiamo su probabilità condizionata, distribuzioni, verosimiglianza e teorema di Bayes necessario per affrontare il passaggio formale all'aggiornamento bayesiano.

Un ultimo criterio di lettura

Quando incontri un risultato statistico, non chiederti soltanto se sia significativo. Chiediti:

1. qual è la quantità che si vuole conoscere;
2. quale modello collega quella quantità ai dati;
3. quali aspetti del disegno giustificano l'inferenza;
4. come viene rappresentata l'incertezza;
5. quali conclusioni sono effettivamente autorizzate;
6. quali controlli mostrano che il modello è adeguato;
7. quale decisione o conoscenza scientifica dovrebbe cambiare.

Il contributo più importante del confronto tra paradigmi non è la scelta di una nuova etichetta. È imparare a formulare meglio le domande, rendere esplicite le assunzioni e trattare l'incertezza come parte costitutiva della conoscenza psicologica.

Chivers, T. (2024). *Everything is Predictable: How Bayesian Statistics Explain Our World*. Simon; Schuster.

Giner-Sorolla, R., Montoya, A. K., Reifman, A., Carpenter, T., Lewis Jr, N. A., Aberson, C. L., Bostyn, D. H., Conrique, B. G., Ng, B. W., Schoemann, A. M., et al. (2024). Power to detect what? Considerations for planning and evaluating sample size. *Personality and Social Psychology Review*, 28(3), 276–301.