

Inferenza frequentista in psicologia

Modulo introduttivo

Corrado Caudek

04 agosto 2026

Come usare il modulo

Progetto UTET · Materiali digitali di supporto

Un'introduzione critica all'inferenza frequentista per comprendere stima, intervalli di fiducia, test di ipotesi e pianificazione degli studi nella ricerca psicologica.

Questo modulo accompagna il manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*. Ricostruisce le premesse storiche e concettuali dell'approccio frequentista, chiarisce che cosa consentono di affermare i suoi principali strumenti e offre il termine di confronto necessario per comprendere la prospettiva bayesiana sviluppata nel volume principale.

[Inizia dall'introduzione](#) [Esamina il percorso](#) [Vai al companion principale](#)

Funzione

Inquadramento propedeutico e critico

Livello

Introduttivo

Ambito

Stima, test e pianificazione

Modalità

Studio sequenziale o consultazione

Il percorso è progressivo: parte dalla formazione storica del pensiero frequentista e conduce alle procedure di stima, ai test di ipotesi e alla pianificazione degli studi. Per una prima lettura conviene seguire l'ordine dei capitoli; in seguito il sito può essere usato come riferimento durante lo studio del manuale.

01

Inquadrare

Distingui le diverse tradizioni frequentiste e le domande inferenziali a cui cercano di rispondere.

02

Interpretare

Concentrati sul significato di stime, intervalli, valori p , errori e potenza, non soltanto sulle procedure di calcolo.

03

Confrontare

Collega ogni strumento al problema scientifico e osserva come cambiano domande e risposte nell'impostazione bayesiana.

Percorso del modulo

I capitoli seguono il passaggio dalle origini dell'approccio frequentista alla stima e alla verifica delle ipotesi, fino alla pianificazione campionaria e al confronto tra gruppi.

Orientamento · Inizio

Introduzione all'inferenza frequentista

Finalità del modulo, quadro concettuale e rapporto con il manuale bayesiano.

[Apri l'introduzione](#)

Capitolo 1 · Contesto storico

Origini dell'approccio frequentista

Dalla misurazione delle differenze individuali alla costruzione del pensiero statistico moderno.

[Apri il capitolo 1](#)

Capitolo 2 · Stima

Stime, stimatori e parametri

Popolazioni e campioni, proprietà degli stimatori e logica della stima puntuale.

[Apri il capitolo 2](#)

Capitolo 3 · Incertezza

Intervalli di fiducia

Costruzione, interpretazione frequentista ed equivoci ricorrenti sugli intervalli.

[Apri il capitolo 3](#)

Capitolo 4 · Decisione statistica

Test di ipotesi e significatività

Ipotesi nulla, valori p , errori di primo e secondo tipo e limiti interpretativi.

[Apri il capitolo 4](#)

Capitolo 5 · Pianificazione

Dimensione campionaria e potenza

Relazione tra effetto, variabilità, errore, potenza e numerosità dello studio.

[Apri il capitolo 5](#)

Capitolo 6 · Applicazione

Confronto tra due campioni indipendenti

Il test t come caso di studio per collegare assunzioni, calcolo e interpretazione.

[Apri il capitolo 6](#)

Epilogo · Sintesi critica

Considerazioni conclusive

Bilancio del percorso e passaggio dal quadro frequentista all'inferenza bayesiana.

[Apri l'epilogo](#)

Il modulo non presenta l'inferenza frequentista come un repertorio di procedure da applicare meccanicamente. L'obiettivo è comprendere quali affermazioni sono giustificate dai diversi strumenti, quali non lo sono e perché l'interpretazione metodologica è parte integrante dell'analisi statistica.

Collegamento con il manuale

Il manuale principale sviluppa l'inferenza bayesiana come un diverso modo di formulare e aggiornare l'incertezza. Questo modulo fornisce il contesto necessario per confrontare le due prospettive senza confonderne il linguaggio e gli obiettivi.

Durante lo studio è particolarmente importante saper riconoscere:

- la distinzione tra parametro, stimatore e stima osservata;
- il significato frequentista di un intervallo di fiducia;
- ciò che un valore p consente e non consente di concludere;
- la relazione tra errori, potenza e dimensione campionaria;
- il ruolo delle assunzioni nei test e nei modelli statistici;
- la differenza tra evidenza nei dati e probabilità attribuita a un'ipotesi.

Informazioni editoriali

Il materiale fa parte del progetto UTET a supporto del manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza*. Il sito è aggiornabile e può integrare correzioni, chiarimenti ed esempi successivi alla pubblicazione del volume.

- **Autore:** Corrado Caudek ([ORCID 0000-0002-1404-0420](#))
- **Segnalazioni:** usa il comando “Segnala un problema” presente nelle pagine oppure il [repository GitHub](#)
- **Licenza:** [CC BY-NC-ND 4.0](#)

Parte I

Frequentismo

Introduzione all'inferenza frequentista in un percorso bayesiano

i In sintesi

Da sapere L'inferenza frequentista valuta stime, intervalli e decisioni considerando il comportamento che essi mostrerebbero in una successione di campionamenti ripetuti. I parametri del modello sono trattati come quantità fisse ma ignote, mentre la variabilità riguarda i dati e le statistiche calcolate a partire dai campioni.

Da saper fare Al termine del capitolo, il lettore dovrebbe saper distinguere una domanda sul comportamento di una procedura da una domanda sulla plausibilità di un parametro e interpretare correttamente intervalli di confidenza, valori- p e significatività statistica.

Introduzione

Questo modulo introduce l'inferenza frequentista all'interno di un percorso più ampio dedicato al ragionamento bayesiano. La scelta può apparire insolita soltanto a prima vista. Gran parte della letteratura psicologica utilizza ancora intervalli di confidenza, test di significatività, valori- p , livelli di significatività e analisi di potenza. Per leggere criticamente un articolo, progettare uno studio o comprendere una tabella di risultati è quindi necessario conoscere il significato di questi strumenti e, soprattutto, i limiti delle conclusioni che consentono di formulare.

L'inferenza frequentista verrà presentata come un sistema coerente di procedure costruite per rispondere a domande specifiche. Il confronto con l'approccio bayesiano permetterà di distinguere due obiettivi che vengono spesso confusi. Da una parte, possiamo domandarci come si comporti una procedura statistica quando viene applicata ripetutamente a nuovi campioni. Dall'altra, possiamo voler rappresentare direttamente l'incertezza relativa a un parametro o a un'ipotesi dopo avere osservato i dati.

Il primo obiettivo è caratteristico dell'inferenza frequentista; il secondo viene affrontato in modo esplicito dall'inferenza bayesiana. Le due prospettive possono partire dallo stesso modello probabilistico dei dati, ma organizzano l'inferenza secondo logiche differenti. Comprendere questa distinzione è il primo passo per evitare

interpretazioni improprie e scegliere il linguaggio statistico più adatto alla domanda scientifica.

Perché studiare il frequentismo in un percorso bayesiano?

L'inferenza frequentista è stata, e in molti ambiti continua a essere, il linguaggio standard della ricerca empirica. Espressioni come *statisticamente significativo*, *intervallo di confidenza al 95%*, *errore di primo tipo*, *potenza statistica* e *test t* compaiono regolarmente negli articoli di psicologia, neuroscienze, medicina e scienze sociali. Ignorare questo linguaggio renderebbe difficile comprendere la letteratura esistente; accettarlo in modo meccanico, però, favorirebbe errori interpretativi molto diffusi.

Lo scopo del modulo è dunque duplice. Occorre anzitutto comprendere la logica e il funzionamento delle procedure frequentiste più comuni. Nello stesso tempo, è necessario imparare a riconoscere che cosa i loro risultati permettono effettivamente di concludere e che cosa, invece, non esprimono direttamente. Questa distinzione non ha una funzione polemica, ma didattica: serve a collegare ogni quantità statistica alla domanda per la quale è stata costruita.

i Una prospettiva didattica, non polemica

Studiare il frequentismo non significa presentarlo come un errore da correggere. Le procedure frequentiste offrono strumenti importanti per controllare i tassi di errore, valutare la precisione delle stime e progettare studi informativi. Il punto è comprenderne con precisione la logica, senza attribuire ai risultati un significato che non possiedono.

Panoramica del capitolo

Il capitolo procede gradualmente dalla logica generale dell'inferenza frequentista alle sue implicazioni interpretative. Inizieremo esaminando il ruolo delle ripetizioni ipotetiche e distinguendo parametri, dati, statistiche e distribuzioni campionarie. Un semplice esempio binomiale mostrerà poi come la stessa osservazione possa dare origine a una domanda frequentista e a una domanda bayesiana differenti. Su questa base sarà possibile chiarire le interpretazioni scorrette più comuni e preparare il percorso sviluppato nei capitoli successivi.

i Preparazione del notebook

Questo capitolo è interamente concettuale e non richiede l'esecuzione di codice R. Nei capitoli successivi useremo simulazioni e calcoli per rendere visibile il comportamento delle procedure in campioni ripetuti.

Probabilità e ripetizione campionaria

Nell'inferenza frequentista, le probabilità vengono utilizzate per descrivere il comportamento dei dati e delle statistiche sotto un modello specificato. In termini operativi, ci si domanda che cosa accadrebbe se il processo di raccolta dei dati fosse ripetuto molte volte nelle stesse condizioni rilevanti.

Consideriamo una moneta alla quale il modello assegna probabilità 0.5 di produrre l'esito *testa*. In una lunga sequenza di lanci indipendenti generati da quel modello, la proporzione di teste tende a stabilizzarsi intorno a 0.5. Questa affermazione descrive il comportamento del processo generativo nelle ripetizioni. Non assegna, invece, una probabilità a un parametro dopo l'osservazione di un singolo campione.

La probabilità ha ricevuto interpretazioni filosofiche differenti. Per comprendere il funzionamento delle procedure frequentiste, tuttavia, è sufficiente concentrarsi sul loro significato operativo. Distribuzioni campionarie, copertura degli intervalli e tassi di errore vengono definiti immaginando ripetizioni reali o ipotetiche del campionamento. È all'interno di questo insieme di risultati possibili che una procedura viene valutata.

Parametri fissi, dati variabili

Nel modello frequentista, il parametro viene trattato come una quantità fissa ma ignota. Prima che il campione sia osservato, i dati costituiscono invece una variabile casuale. Di conseguenza, anche una statistica, essendo una funzione dei dati, varia da un campione all'altro. La qualità della procedura inferenziale viene valutata studiando proprio questa variabilità.

Supponiamo di voler stimare la media del benessere psicologico in una popolazione di studenti. Il modello assume che la media della popolazione abbia un unico valore, anche se non lo conosciamo. Se estraessimo più campioni dalla stessa popolazione, otterremmo medie campionarie differenti. L'inferenza frequentista studia come queste medie si distribuiscono nelle ripetizioni per valutare la precisione della stima e costruire procedure dotate di proprietà controllate.

Da questa impostazione derivano alcuni dei concetti fondamentali del modulo. La **distribuzione campionaria** descrive i valori che una statistica assumerebbe in campionamenti ripetuti. L'**errore standard** riassume la variabilità della statistica da un campione all'altro. L'**intervallo di confidenza** viene costruito mediante una procedura che, sotto il modello e le assunzioni adottate, possiede una copertura prefissata. Il **test di ipotesi**, infine, valuta la compatibilità dei dati con un'ipotesi di riferimento attraverso una statistica test e la distribuzione che essa avrebbe se quell'ipotesi fosse vera.

! Che cosa è casuale?

Prima del campionamento, i dati, le stime e gli intervalli possibili sono casuali perché dipendono dal campione che verrà osservato. Dopo il campionamento,

il particolare insieme di dati, la stima e l'intervallo calcolato sono valori ormai osservati. Le proprietà frequentiste continuano tuttavia a riferirsi alla procedura che li ha prodotti e al modo in cui essa si comporterebbe nelle ripetizioni.

Una stessa osservazione, due domande diverse

Consideriamo una moneta lanciata 20 volte e supponiamo di osservare 14 teste e 6 croci. Un'analisi frequentista può partire dall'ipotesi nulla secondo cui la probabilità di ottenere testa sia $\theta = 0.5$. Se questa ipotesi e il modello binomiale fossero appropriati, il numero di teste avrebbe distribuzione

$$Y \sim \text{Binomiale}(20, 0.5).$$

La domanda frequentista può essere formulata nel modo seguente:

Quanto sono incompatibili i dati osservati con l'ipotesi di una moneta equilibrata, secondo la statistica test e la regola di estremità definite prima dell'analisi?

Il valore- p quantifica la probabilità, assumendo vera l'ipotesi nulla, di ottenere un valore della statistica test almeno altrettanto incompatibile con l'ipotesi quanto quello osservato. La sua interpretazione dipende quindi sia dall'ipotesi assunta sia dal criterio con cui vengono definiti i risultati estremi. Non rappresenta la probabilità che la moneta sia equilibrata.

Un'analisi bayesiana può usare lo stesso modello binomiale per i dati, ma rappresenta l'incertezza su θ mediante una distribuzione di probabilità. La distribuzione a priori viene combinata con la verosimiglianza e produce una distribuzione a posteriori:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

La domanda cambia di conseguenza:

Dopo avere osservato 14 teste su 20 lanci, come cambia la plausibilità relativa dei diversi valori di θ ?

L'esempio mostra che la differenza non risiede necessariamente nei dati o nella distribuzione usata per descriverli. Risiede nella domanda inferenziale e nel modo in cui l'incertezza viene rappresentata.

! Non invertire la probabilità condizionata

Il valore- p riguarda una probabilità dei dati, o di una statistica test, **assumendo** l'ipotesi nulla. Non fornisce direttamente la probabilità dell'ipotesi nulla dopo avere osservato i risultati.

In simboli, una quantità del tipo $P(\text{dati estremi} | H_0)$ non coincide con $P(H_0 |$

dati).

Che cosa esprimono le procedure frequentiste

Le procedure frequentiste sono progettate per possedere proprietà controllate nel lungo periodo, a condizione che il modello e le assunzioni rilevanti siano adeguati. Il significato di una singola stima, di un intervallo o di una decisione deve quindi essere ricondotto alla procedura che li ha generati.

Un intervallo di confidenza al 95%, per esempio, deriva da una procedura che, in ripetuti campionamenti condotti secondo il modello, produce intervalli contenenti il parametro vero nel 95% dei casi. Una volta calcolato un particolare intervallo, il parametro fisso è contenuto oppure non è contenuto al suo interno. Il 95% descrive la frequenza di copertura della procedura, non una probabilità a posteriori assegnata al parametro.

La stessa logica vale per i test di ipotesi. Un test con livello di significatività $\alpha = 0.05$ viene costruito affinché, quando l'ipotesi nulla è vera e le assunzioni sono rispettate, la probabilità di rifiutarla non superi il 5% nelle ripetizioni previste dal disegno. Il livello di significatività controlla dunque una proprietà della regola decisionale, non la probabilità che una particolare decisione sia corretta.

Queste proprietà sono importanti, ma rimangono sempre condizionate alla qualità del modello, del disegno e delle misure. Un tasso di errore formalmente controllato non corregge automaticamente un campione distorto, una misura poco valida o una specificazione inadeguata. La correttezza matematica della procedura non può compensare, da sola, le debolezze della ricerca che la precede.

Interpretazioni da evitare

Molti errori nella lettura della letteratura scientifica non derivano da un calcolo sbagliato, ma dall'attribuzione a un risultato tecnico di un significato intuitivo che esso non possiede.

Intervallo di confidenza

Nell'interpretazione frequentista standard, un intervallo di confidenza al 95% non significa che il parametro abbia il 95% di probabilità di trovarsi nell'intervallo osservato. La percentuale si riferisce alla copertura della procedura nelle ripetizioni: se la stessa strategia di campionamento e di costruzione dell'intervallo fosse applicata molte volte, il 95% degli intervalli ottenuti conterrebbe il parametro vero.

Valore- p

Il valore- p non è la probabilità che l'ipotesi nulla sia vera e non misura la probabilità che il risultato sia semplicemente «dovuto al caso». Non indica neppure, da solo, la probabilità che lo studio non si replichi. Inoltre, non costituisce una misura diretta dell'ampiezza o dell'importanza dell'effetto. Esprime una relazione tra i dati osservati, l'ipotesi nulla, la statistica test e la regola con cui vengono definiti i risultati almeno altrettanto estremi.

Significatività statistica

La significatività statistica non implica automaticamente importanza teorica, rilevanza clinica, elevata precisione o replicabilità. Il suo raggiungimento dipende, tra le altre cose, dall'ampiezza dell'effetto, dalla variabilità dei dati, dalla dimensione campionaria e dal modello utilizzato. Un effetto molto piccolo può risultare significativo in un campione ampio, mentre un effetto potenzialmente rilevante può non raggiungere la soglia convenzionale in uno studio poco informativo.

Non significatività

La mancata significatività non dimostra che l'effetto sia esattamente nullo. Può riflettere dati poco informativi, misure rumorose, campioni piccoli oppure risultati compatibili con un'ampia gamma di valori. Interpretare un esito non significativo richiede quindi di considerare la precisione della stima, la potenza dello studio e l'insieme dei valori dell'effetto ancora compatibili con i dati.

 La soglia non sostituisce l'interpretazione

Ridurre un risultato alla dicotomia *significativo/non significativo* nasconde informazioni importanti. La stima dell'effetto, l'incertezza, la qualità del disegno, la plausibilità delle assunzioni e la rilevanza sostantiva devono essere considerate insieme.

Il ruolo del frequentismo nella ricerca psicologica

Il frequentismo ha fornito alla ricerca psicologica strumenti condivisi per stimare quantità, confrontare gruppi, progettare studi e controllare tassi di errore. Molte delle sue procedure rimangono utili, soprattutto quando la domanda scientifica è accompagnata da un disegno ben definito e l'interpretazione dei risultati resta coerente con la logica del metodo.

I problemi emergono quando le procedure vengono applicate in modo automatico o quando il loro risultato viene trasformato in un verdetto sull'esistenza, sull'importanza o sulla verità di un effetto. L'uso rigido della soglia $\alpha = 0.05$ ha favorito una comunicazione dicotomica nella quale *significativo* viene spesso fatto coincidere con

effetto presente o ipotesi confermata, mentre *non significativo* viene assimilato a *effetto assente o ipotesi respinta*. Questi passaggi non sono autorizzati dal solo risultato del test.

Comprendere il frequentismo significa quindi apprenderne sia gli strumenti sia i confini interpretativi. Una procedura è informativa soltanto quando la quantità che produce viene letta alla luce della domanda scientifica, del modello, del disegno e delle assunzioni che ne rendono possibile l'uso.

Il percorso del modulo

I capitoli successivi sviluppano questo ragionamento in modo graduale. Il percorso inizierà dalle origini storiche dell'approccio frequentista, mettendo in relazione lo sviluppo di alcuni concetti fondamentali della statistica moderna con il contesto scientifico e sociale nel quale sono nati. Passerà quindi alla distinzione tra stime, stimatori e distribuzioni campionarie, mostrando come la variabilità tra campioni venga usata per valutare la precisione e le proprietà degli stimatori.

Su queste basi verranno introdotti gli intervalli di confidenza, con particolare attenzione alla loro costruzione, alla copertura e all'interpretazione. Il capitolo dedicato ai test di ipotesi esaminerà l'ipotesi nulla, la statistica test, la distribuzione di riferimento, la regione critica, il valore- p e gli errori decisionali. La discussione si sposterà poi sulla dimensione campionaria e sulla potenza statistica, chiarendo le relazioni tra ampiezza dell'effetto, variabilità, errore di secondo tipo e capacità dello studio di produrre risultati informativi.

Il confronto tra due gruppi indipendenti offrirà infine un'applicazione integrata di questi strumenti attraverso il test t per due campioni. Le considerazioni conclusive ricomporranno il percorso e prepareranno il passaggio al quadro bayesiano.

Come leggere i prossimi capitoli

Nello studio di ogni procedura sarà utile mantenere separate alcune domande fondamentali. La prima riguarda il modello dei dati: quale processo probabilistico viene assunto per descrivere le osservazioni? La seconda riguarda la quantità calcolata: si tratta di una stima, di un errore standard, di un intervallo, di una statistica test, di un valore- p o di una misura di potenza?

Occorre poi chiarire quale ripetizione ipotetica definisca la procedura. In altre parole, bisogna stabilire che cosa cambierebbe da un campione all'altro e quali elementi resterebbero fissi. Soltanto a questo punto è possibile domandarsi quale conclusione sia giustificata: il risultato riguarda la precisione della stima, la compatibilità con un'ipotesi, un tasso di errore oppure la capacità del disegno di rilevare determinati effetti?

Le formule sono necessarie, ma molti errori statistici non nascono dal calcolo. Nascono nel passaggio, spesso implicito, dal valore calcolato a una conclusione che quella quantità non sostiene. Imparare a riconoscere questo passaggio è uno degli

obiettivi principali del modulo.

Dalle procedure all'aggiornamento dell'incertezza

L'inferenza frequentista valuta le procedure attraverso distribuzioni campionarie, copertura e tassi di errore. Questa impostazione risponde in modo naturale a domande sul comportamento ripetuto di un metodo: quanto varia una stima, con quale frequenza un intervallo contiene il parametro e quanto spesso una regola decisionale produce un determinato errore.

L'inferenza bayesiana affronta esplicitamente una domanda diversa. Dati un modello, le conoscenze iniziali e le osservazioni disponibili, come deve cambiare l'incertezza sui parametri? Per rispondere, rappresenta tale incertezza mediante distribuzioni di probabilità e la aggiorna attraverso il teorema di Bayes.

Il confronto non dovrebbe essere ridotto alla contrapposizione tra un metodo corretto e uno scorretto. È più utile riconoscere due grammatiche inferenziali. Il frequentismo parla soprattutto il linguaggio delle procedure, delle distribuzioni campionarie e dei tassi di errore. Il bayesianesimo parla il linguaggio della plausibilità condizionata al modello, della verosimiglianza e dell'aggiornamento. Comprendere entrambe le prospettive permette di leggere la ricerca empirica con maggiore precisione e di riconoscere quali domande richiedano strumenti differenti.

Riflessioni conclusive

Il frequentismo non coincide con il semplice uso di una soglia né con il calcolo meccanico di un valore- p . È un sistema inferenziale nel quale le procedure vengono progettate e valutate attraverso il loro comportamento in campioni ripetuti.

Per comprenderlo è necessario distinguere il parametro fisso dalle statistiche variabili, il risultato osservato dalla procedura che lo ha prodotto e la probabilità dei dati sotto un'ipotesi dalla probabilità dell'ipotesi dopo i dati. Queste distinzioni non sono dettagli terminologici: determinano il significato delle conclusioni statistiche.

I capitoli successivi svilupperanno questi concetti uno alla volta. Il criterio guida resterà costante: prima occorre capire quale domanda venga posta; soltanto dopo sarà possibile interpretare la risposta nel linguaggio appropriato.

Esercizi

1. In uno studio viene stimata la media di una popolazione. Che cosa è considerato fisso e che cosa varierebbe se lo studio fosse ripetuto con nuovi campioni?
2. Che cosa descrive la distribuzione campionaria di una statistica?
3. Un intervallo di confidenza al 95% viene calcolato come $[4.2, 7.1]$. Perché non è corretto affermare, nell'interpretazione frequentista standard, che vi sia il 95% di probabilità che il parametro sia compreso tra 4.2 e 7.1?

4. Uno studio riporta $p = 0.03$. Quale delle seguenti conclusioni è giustificata: «l'ipotesi nulla ha probabilità 0.03» oppure «sotto l'ipotesi nulla, un risultato almeno altrettanto incompatibile avrebbe probabilità 0.03»?
5. Perché un risultato statisticamente significativo può essere poco importante dal punto di vista psicologico o clinico?
6. Perché un risultato non significativo non dimostra automaticamente l'assenza di un effetto?
7. Due analisi usano lo stesso modello binomiale per 14 teste su 20 lanci. In che cosa differiscono la domanda frequentista e quella bayesiana?
8. Perché il controllo formale del tasso di errore non basta a garantire la validità scientifica di una conclusione?

Soluzioni

1. Il parametro della popolazione è trattato come fisso ma ignoto. Il campione e la media campionaria cambierebbero da una ripetizione all'altra.
2. La distribuzione campionaria descrive come varierebbe la statistica se il campionamento fosse ripetuto secondo lo stesso modello e lo stesso disegno.
3. Il 95% indica la copertura della procedura nelle ripetizioni. Dopo il calcolo, il particolare intervallo contiene oppure non contiene il parametro fisso; la procedura frequentista non assegna direttamente una probabilità a posteriori al parametro.
4. È giustificata la seconda formulazione, purché l'espressione «almeno altrettanto incompatibile» sia definita dalla statistica test e dalla regola di estremità utilizzate.
5. La significatività dipende anche dalla numerosità campionaria e dalla variabilità. Un effetto molto piccolo può risultare statisticamente significativo in un campione grande senza possedere una rilevanza sostantiva.
6. La non significatività può derivare da scarsa precisione, bassa potenza, misure rumorose o dati compatibili con molti valori dell'effetto.
7. La domanda frequentista valuta quanto i dati siano incompatibili con un valore ipotizzato del parametro secondo una procedura definita. La domanda bayesiana aggiorna la plausibilità relativa dei diversi valori del parametro dopo l'osservazione dei dati.
8. Le garanzie frequentiste sono condizionate al modello, al disegno e alle assunzioni. Un campionamento distorto, misure non valide o modelli inadeguati possono produrre conclusioni fuorvianti anche quando il tasso di errore nominale è controllato.

i Punti chiave

Nel frequentismo, i parametri sono trattati come quantità fisse ma ignote, mentre dati e statistiche variano tra campioni. Le proprietà inferenziali vengono definite attraverso ripetizioni reali o ipotetiche del campionamento. Un intervallo di confidenza descrive la copertura di una procedura e non assegna direttamente una probabilità a posteriori al parametro. Un valore- p viene calcolato assumendo l'ipotesi nulla e non rappresenta la probabilità che essa sia vera. Significatività statistica, importanza dell'effetto e validità scientifica rimangono concetti distinti. Frequentismo e bayesianesimo possono condividere il modello dei dati, ma rispondono a domande inferenziali differenti.

i Ambiente di sviluppo

Questo capitolo non richiede pacchetti aggiuntivi. Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
```

Origini storiche dell'approccio frequentista

i In sintesi

Da sapere La statistica frequentista non nasce da un'unica teoria formulata in un solo momento, ma dall'incontro tra tradizioni diverse: lo studio della variabilità, la misura delle associazioni, la teoria della stima, i test di significatività e il controllo degli errori. Questa storia ha prodotto strumenti fondamentali per la ricerca empirica, ma è anche intrecciata con il movimento eugenetico.

Da saper fare Al termine del capitolo, il lettore dovrebbe saper collegare Galton, Pearson, Fisher e Neyman-Pearson ai problemi statistici che affrontarono, distinguere il valore tecnico dei loro contributi dal contesto storico nel quale furono sviluppati e riconoscere i principi operativi che caratterizzano il ragionamento frequentista.

Introduzione

La statistica non è soltanto un insieme di formule. È anche un modo di organizzare l'incertezza, definire che cosa possa essere considerato evidenza e stabilire quali conclusioni siano giustificate dai dati. Per questa ragione, comprendere una procedura statistica richiede qualcosa di più che conoscerne il calcolo: occorre ricostruire le domande alle quali essa cercava di rispondere e il contesto scientifico nel quale ha assunto la propria forma.

Questo capitolo ripercorre alcuni passaggi che hanno condotto alla pratica frequentista contemporanea. Non propone una storia completa della statistica e non segue una semplice successione di nomi e date. Si concentra invece su quattro problemi che continuano a essere centrali nella ricerca psicologica: descrivere la variabilità tra individui, quantificare le associazioni tra misure, valutare quanto i dati siano incompatibili con un modello di riferimento e progettare procedure capaci di controllare gli errori nel lungo periodo.

La storia di questi strumenti è ambivalente. Correlazione, regressione, distribu-

zioni campionarie, test e intervalli hanno contribuito in modo decisivo allo sviluppo della scienza empirica. Una parte della loro genealogia, tuttavia, è intrecciata con l'eugenetica e con progetti di classificazione gerarchica delle persone. Riconoscere questa eredità non significa rifiutare gli strumenti statistici, ma comprenderli in modo più completo e usarli con maggiore consapevolezza scientifica ed etica.

1.1 Perché partire dalla storia?

Le procedure che oggi vengono riunite sotto l'etichetta di *inferenza frequentista* non nacquero tutte insieme come componenti di un sistema unitario. Furono elaborate in momenti diversi, per affrontare problemi differenti, e soltanto in seguito vennero integrate nella pratica scientifica. La significatività fisheriana, per esempio, non coincide con il quadro decisionale di Neyman–Pearson, anche se nella ricerca contemporanea i due approcci vengono spesso combinati.

Conoscere questa origine aiuta a evitare due semplificazioni. La prima consiste nel trattare il frequentismo come una teoria perfettamente omogenea. La seconda consiste nell'applicare una procedura senza domandarsi quale problema fosse stata progettata per risolvere. La prospettiva storica permette invece di collegare ogni strumento alla propria domanda originaria e di comprendere meglio il significato delle quantità che produce.

Una chiave di lettura

Nel ragionamento frequentista ritorna una domanda fondamentale:

Come si comporterebbe questa procedura se il campionamento o l'esperimento fossero ripetuti molte volte in condizioni analoghe?

Stime, errori standard, intervalli di confidenza, livelli di significatività e potenza ricevono il loro significato da questa prospettiva sulle ripetizioni.

Prerequisiti

È utile avere letto l'introduzione al modulo sull'inferenza frequentista. Non sono richieste conoscenze tecniche avanzate: il capitolo costruisce anzitutto una mappa storica e concettuale, che verrà sviluppata nei capitoli dedicati alle singole procedure.

Panoramica del capitolo

Il percorso inizia dal passaggio, avvenuto nel corso dell'Ottocento, dallo studio del singolo individuo allo studio delle distribuzioni. In questo contesto verranno presentati i contributi di Francis Galton alla regressione verso la media e alla correla-

zione, insieme al legame tra la sua ricerca e il progetto eugenetico. La discussione proseguirà con Karl Pearson e con la formalizzazione matematica della variazione, per poi distinguere la logica della significatività sviluppata da Ronald Fisher dal quadro decisionale proposto da Jerzy Neyman ed Egon Pearson. Nell'ultima parte, questi sviluppi storici verranno ricondotti ai principi operativi che caratterizzano il paradigma frequentista.

Preparazione del notebook

Il capitolo è interamente concettuale e non richiede l'esecuzione di codice R. Nei capitoli successivi useremo simulazioni per rendere visibili distribuzioni campionarie, copertura, errori decisionali e potenza.

1.2 La quantificazione della variabilità umana

1.2.1 Dal singolo individuo alla distribuzione

Nel corso dell'Ottocento si affermò progressivamente l'idea che molti fenomeni biologici, psicologici e sociali potessero essere studiati quantitativamente. L'attenzione si spostò dal singolo individuo alla distribuzione dei tratti in una popolazione. Altezza, tempi di reazione, prestazioni cognitive e, in seguito, risposte a questionari vennero trattati come grandezze capaci di variare sistematicamente tra persone.

Questo cambiamento rese possibile descrivere non soltanto un valore tipico, ma anche la dispersione delle osservazioni; confrontare individui e gruppi; esaminare il modo in cui due caratteristiche variano insieme; costruire previsioni a partire da misure osservate. Per la psicologia scientifica si trattò di un passaggio decisivo. La variabilità individuale non veniva più considerata soltanto come un disturbo da eliminare, ma diventava essa stessa un fenomeno da descrivere, misurare e spiegare.

La distribuzione forniva così un nuovo oggetto di studio. Un tratto non era rappresentato soltanto dal suo valore medio, ma anche dalla forma con cui si distribuiva nella popolazione e dalle relazioni che intratteneva con altre caratteristiche. Questa prospettiva preparò il terreno per lo sviluppo della psicometria, dello studio delle differenze individuali e di molte tecniche ancora oggi centrali nella ricerca psicologica.

1.2.2 Galton: regressione e associazione

Francis Galton (1822–1911) contribuì in modo importante alla misurazione sistematica delle differenze individuali. Raccolse dati su caratteristiche fisiche e prestazioni, studiò le somiglianze familiari e promosse l'uso delle distribuzioni per rappresentare la variazione tra persone. Due idee associate al suo lavoro sono diventate particolarmente rilevanti per la statistica moderna: la regressione verso la media e la correlazione.

La regressione verso la media descrive ciò che accade quando due misure sono

associate, ma non perfettamente. In questa situazione, valori estremi della prima variabile tendono a essere accompagnati, in media, da valori meno estremi della seconda. Galton osservò questo schema studiando alcune caratteristiche di genitori e figli. Il fenomeno non implica che ogni individuo estremo debba necessariamente avvicinarsi alla media e non costituisce, da solo, una spiegazione causale. È una conseguenza statistica dell'associazione imperfetta tra le misure.

Questa idea è importante anche nella ricerca contemporanea. Quando le persone vengono selezionate perché mostrano un valore particolarmente alto o basso in una prima misurazione, una seconda misurazione tende spesso a risultare meno estrema. Il cambiamento può verificarsi anche in assenza di un intervento efficace, soprattutto quando la misura contiene errore o fluttuazioni casuali. Per attribuire causalmente il miglioramento a un trattamento non è quindi sufficiente confrontare il valore osservato prima dell'intervento con quello rilevato dopo.

La seconda idea riguarda la correlazione. Lo studio delle somiglianze familiari e delle relazioni tra misure contribuì alla costruzione di strumenti capaci di quantificare quanto due variabili tendano a variare insieme. In psicologia, la correlazione è diventata essenziale per analizzare l'associazione tra costrutti, valutare l'attendibilità e la validità dei test e studiare le differenze individuali. Essa descrive una struttura di covariazione, ma non stabilisce, da sola, quale meccanismo causale la produca.

 Regressione verso la media non significa miglioramento

Se si selezionano persone con valori estremi in una prima misurazione, una seconda misurazione tende spesso a risultare meno estrema anche in assenza di un intervento efficace. Per valutare un cambiamento causale non basta quindi confrontare meccanicamente il prima e il dopo.

1.3 Statistica ed eugenetica: una genealogia ambivalente

Galton coniò il termine *eugenetica* e sostenne un programma volto a classificare e selezionare i tratti umani. Anche altri protagonisti della statistica britannica, tra cui Karl Pearson e Ronald Fisher, furono coinvolti in idee, istituzioni o dibattiti eugenetici (Chivers, 2024). Questo legame non costituisce un dettaglio marginale della storia della disciplina, perché mostra come la quantificazione della variabilità umana sia stata impiegata anche per costruire gerarchie sociali e biologiche.

Correlazione, regressione e analisi della varianza non sono, per questo, strumenti intrinsecamente eugenetici. Le loro proprietà matematiche non dipendono dagli obiettivi morali di chi contribuì a svilupparle e le stesse procedure possono essere impiegate per finalità scientifiche molto diverse. Tuttavia, la loro storia ricorda che misurare non è un'attività completamente neutrale. La scelta del costrutto, la definizione dell'indicatore, la selezione del campione e l'interpretazione delle differenze dipendono da decisioni teoriche e sociali.

Prima di attribuire un significato sostantivo a una differenza tra persone o gruppi,

occorre quindi chiarire che cosa sia stato definito e misurato, chi sia stato incluso o escluso dal campione, quali assunzioni colleghino la misura al fenomeno e quali conseguenze possa avere la classificazione prodotta. Una differenza statistica non diventa automaticamente una differenza naturale, immutabile o gerarchicamente rilevante.

! Responsabilità scientifica ed etica

Riconoscere la genealogia eugenetica di una parte della statistica moderna non significa rifiutare gli strumenti. Significa evitare che differenze osservate vengano trasformate automaticamente in gerarchie di valore o in spiegazioni biologiche, senza considerare misurazione, contesto, campionamento e alternative causali.

1.4 Karl Pearson e la formalizzazione della variazione

Karl Pearson (1857–1936) contribuì in modo decisivo alla matematizzazione della statistica. Il suo lavoro sistematizzò strumenti per descrivere distribuzioni, quantificare associazioni e confrontare frequenze osservate con quelle previste da un modello. Alla tradizione pearsoniana vengono associati il coefficiente di correlazione prodotto-momento, la deviazione standard, lo studio di famiglie di distribuzioni e il test del chi-quadrato.

Il test del chi-quadrato esemplifica un'idea destinata a diventare centrale nell'inferenza statistica. Si formula un modello capace di produrre frequenze attese e si misura quanto le frequenze osservate se ne discostino. Quanto maggiore è lo scarto, tanto meno i dati appaiono compatibili con il modello secondo il criterio adottato. Il risultato, tuttavia, non spiega perché esista la discrepanza e non identifica automaticamente un modello alternativo corretto. Esprime una relazione tra dati, modello e procedura di confronto.

L'influenza di Pearson sulla psicologia fu profonda. La quantificazione delle associazioni, la standardizzazione dei punteggi e l'analisi delle differenze individuali divennero componenti ordinarie della psicometria e della ricerca quantitativa. Questa formalizzazione rese possibile descrivere in modo più sistematico la variazione, ma contribuì anche a consolidare l'idea che fenomeni complessi potessero essere sintetizzati in indicatori numerici. Proprio per questo, l'uso delle misure richiede sempre una riflessione sul significato del costrutto rappresentato.

1.5 Fisher: verosimiglianza, disegno e significatività

Ronald A. Fisher (1890–1962) contribuì allo sviluppo del disegno sperimentale, dell'analisi della varianza, della massima verosimiglianza e dei test di significatività.

Nel suo lavoro, la statistica non era soltanto uno strumento per descrivere dati già raccolti, ma una componente dell'intero processo sperimentale. Randomizzazione, replicazione e controllo delle fonti di variabilità permettevano di costruire studi nei quali l'evidenza potesse essere interpretata in modo più convincente.

Nel quadro fisheriano si considera spesso un'ipotesi nulla e si valuta quanto i dati osservati siano insoliti se tale ipotesi, insieme al modello probabilistico, fosse appropriata. Il valore- p può essere definito come la probabilità, calcolata sotto l'ipotesi nulla, di ottenere un valore della statistica test almeno altrettanto incompatibile con l'ipotesi quanto quello osservato.

Questa definizione presuppone un'ipotesi nulla, una statistica test e una regola che stabilisca quali risultati siano almeno altrettanto estremi. Il valore- p non è quindi una proprietà dei dati isolati. Dipende dal modello adottato, dalla statistica scelta e dal modo in cui viene definita l'estremità della distribuzione di riferimento.

Che cosa non dice il valore- p

Un valore- p non esprime la probabilità che l'ipotesi nulla sia vera, non misura la probabilità che il risultato sia semplicemente «dovuto al caso» e non indica quanto sia probabile ottenere lo stesso esito in una replica. Non costituisce neppure una misura diretta dell'ampiezza o dell'importanza dell'effetto.

Fisher attribuiva al valore- p soprattutto il ruolo di misura graduata dell'incompatibilità tra dati e ipotesi nulla. Un valore più piccolo indicava una maggiore tensione tra ciò che era stato osservato e ciò che il modello nullo rendeva plausibile. Questa concezione non coincide con l'uso puramente meccanico di una soglia capace di dividere ogni risultato in *significativo* e *non significativo*.

1.6 Neyman–Pearson: decisioni ed errori controllati

Jerzy Neyman ed **Egon Pearson** svilupparono un quadro differente. Il loro obiettivo non era soltanto misurare l'evidenza contro una singola ipotesi nulla, ma costruire regole decisionali il cui comportamento potesse essere controllato nelle ripetizioni. In questo contesto, la scelta tra ipotesi veniva valutata considerando le conseguenze dei possibili errori.

L'errore di tipo I consiste nel rifiutare l'ipotesi nulla quando essa è vera. L'errore di tipo II si verifica quando non si rifiuta l'ipotesi nulla mentre è vera una specifica alternativa. Il livello α , stabilito prima dell'analisi, controlla la probabilità dell'errore di tipo I nelle condizioni previste dal modello. La potenza esprime invece la probabilità di rifiutare l'ipotesi nulla quando è vera una determinata alternativa.

Queste quantità non descrivono la plausibilità delle ipotesi dopo avere osservato i dati. Descrivono il comportamento di una regola decisionale in una successione di applicazioni. Una procedura può essere progettata, per esempio, affinché produca falsi positivi con una frequenza non superiore a un valore prefissato e possieda una certa capacità di individuare effetti di una determinata ampiezza.

La distinzione tra Fisher e Neyman–Pearson è importante perché la pratica contemporanea combina spesso elementi delle due tradizioni. Si riporta un valore- p come misura graduata, ma lo si confronta anche con una soglia, solitamente $\alpha = 0.05$, per formulare una decisione dicotomica. Questa consuetudine è diffusa, ma non corrisponde a un sistema teorico originariamente unitario.

i Una pratica ibrida

L'espressione « $p < 0.05$, quindi il risultato è significativo» riunisce il valore- p come misura fisheriana di incompatibilità e la soglia prefissata come elemento del quadro decisionale di Neyman–Pearson. Sapere che i due concetti provengono da tradizioni differenti aiuta a interpretare con maggiore precisione il risultato.

1.7 Il nucleo operativo del frequentismo

Dai contributi storici esaminati emerge una struttura comune alla maggior parte delle procedure frequentiste moderne.

1.7.1 Parametri fissi, dati variabili

Il parametro del modello viene trattato come una quantità fissa ma ignota. Il campione, prima di essere osservato, è invece casuale; di conseguenza variano anche le statistiche che possono essere calcolate a partire da esso.

Se ripetessimo il campionamento dalla stessa popolazione secondo il medesimo disegno, otterremmo stime differenti. La distribuzione campionaria descrive proprio questa variabilità. Essa permette di studiare quanto uno stimatore sia distorto, quanto vari da un campione all'altro e se tenda ad avvicinarsi al parametro all'aumentare della quantità di informazione disponibile.

1.7.2 Procedure valutate nelle ripetizioni

La stessa logica viene applicata agli intervalli e ai test. Una procedura di confidenza al 95% è costruita in modo da generare, sotto il modello e le assunzioni adottate, intervalli che contengono il parametro vero nel 95% delle ripetizioni. Un test di livello $\alpha = 0.05$ è progettato affinché, quando l'ipotesi nulla è vera, la probabilità di rifiutarla non superi il 5% nelle condizioni specificate. Queste sono proprietà della procedura nel lungo periodo, non garanzie assolute riferite al singolo risultato osservato.

1.7.3 Probabilità e modello di campionamento

Nelle applicazioni frequentiste, la probabilità descrive quindi il comportamento di dati e statistiche generati da un modello. Le ripetizioni possono essere reali oppure ipotetiche, ma devono essere definite con sufficiente precisione. Occorre stabilire che

cosa rimanga fisso, che cosa venga ripetuto e quali esiti possibili contribuiscano alla distribuzione di riferimento.

! La domanda guida

Prima di interpretare un risultato frequentista, occorre chiedersi:

Quale insieme di ripetizioni definisce questa probabilità e quali assunzioni rendono valido il calcolo?

Senza una risposta, valori- p , intervalli e livelli di errore rischiano di essere letti come numeri separati dal loro significato procedurale.

1.8 Una riflessione per la ricerca psicologica

La psicologia ha fatto ampio uso di test t , analisi della varianza, regressioni, intervalli di confidenza, valori- p e analisi di potenza. Conoscere questi strumenti è indispensabile per leggere la letteratura e progettare studi. Il loro impiego, tuttavia, non garantisce automaticamente la qualità delle conclusioni.

La crisi della replicabilità ha mostrato che l'applicazione meccanica di procedure standardizzate può produrre evidenze fragili. Campioni piccoli, misure poco valide, decisioni analitiche flessibili, selezione dei risultati e attenzione esclusiva alla soglia di 0.05 possono rendere instabile una conclusione anche quando il calcolo formale è stato eseguito correttamente.

Il problema non risiede semplicemente nel frequentismo e non si risolve sostituendo una procedura con un'altra. Nessun metodo statistico può compensare, da solo, un disegno poco informativo, misure inadeguate, assunzioni implausibili o una comunicazione selettiva dei risultati. L'analisi deve essere inserita in un processo di ricerca trasparente, nel quale la dimensione degli effetti, la loro incertezza e la qualità delle misure ricevano almeno la stessa attenzione attribuita alla significatività statistica.

1.9 Frequentismo e bayesianesimo: domande differenti

Il frequentismo valuta soprattutto il comportamento delle procedure sotto campionamenti ripetuti. Il bayesianesimo rappresenta e aggiorna esplicitamente l'incertezza relativa a parametri o ipotesi, condizionatamente al modello, alla distribuzione a priori e ai dati osservati.

Le due prospettive possono condividere lo stesso modello probabilistico delle osservazioni e la stessa funzione di verosimiglianza. Differiscono però nella domanda inferenziale e nel significato attribuito alla probabilità. Nel quadro frequentista, la probabilità viene utilizzata per descrivere dati e statistiche sotto valori specificati

dei parametri. Nel quadro bayesiano, viene impiegata anche per rappresentare l'incertezza sui parametri dopo avere osservato i dati.

Un valore- p , per esempio, esprime una probabilità relativa ai dati, o a risultati più estremi, sotto un'ipotesi. Una probabilità a posteriori esprime invece l'incertezza su un parametro o su un'ipotesi dopo avere combinato distribuzione a priori e informazione campionaria. Le due quantità rispondono a domande differenti e non possono essere sostituite l'una con l'altra.

Riflessioni conclusive

La statistica frequentista non deriva da un'unica teoria elaborata in un solo momento. La pratica contemporanea combina strumenti nati dallo studio della variabilità, dalla modellizzazione delle associazioni, dalla significatività fisheriana e dal controllo decisionale degli errori sviluppato da Neyman e Pearson.

Questa storia ha prodotto strumenti fondamentali per la ricerca empirica, ma è anche legata a progetti eugenetici e a usi gerarchici della misurazione. Non è utile separare artificialmente la tecnica dalla storia, così come non sarebbe ragionevole rifiutare ogni strumento a causa del contesto nel quale è stato sviluppato. La risposta più responsabile consiste nell'usare i metodi con competenza, rendendo esplicite le assunzioni e valutando criticamente il significato delle classificazioni prodotte.

Nel prossimo capitolo passeremo dalla cornice storica alla teoria della stima. Vedremo come una statistica campionaria venga utilizzata per stimare un parametro e perché la distribuzione campionaria costituisca il fondamento della valutazione frequentista della precisione.

Esercizi

1. Perché lo studio delle distribuzioni ha rappresentato un passaggio importante per la psicologia scientifica?
2. Che cosa significa regressione verso la media? Perché non dimostra, da sola, che un intervento abbia prodotto un cambiamento?
3. Perché riconoscere il contesto eugenetico della statistica non implica che correlazione e regressione debbano essere abbandonate?
4. Quale domanda generale esprime un test del chi-quadrato quando confronta frequenze osservate e attese?
5. Che cosa misura un valore- p e quale informazione non fornisce sull'ipotesi nulla?
6. Qual è la differenza principale tra la logica fisheriana della significatività e il quadro Neyman-Pearson?
7. Perché la frase « $p < 0.05$, quindi rifiuto l'ipotesi nulla» può essere considerata una formulazione ibrida?
8. Perché il controllo nominale degli errori non basta a garantire una conclusione

scientificamente valida?

Soluzioni

1. Lo studio delle distribuzioni ha permesso di trattare la variabilità tra individui come un fenomeno descrivibile e modellizzabile, anziché come semplice rumore. Da questa prospettiva derivano strumenti per confrontare misure, studiare associazioni e costruire previsioni.
2. Quando due misure sono correlate ma non perfettamente, valori estremi della prima tendono a essere associati, in media, a valori meno estremi della seconda. Un cambiamento verso valori meno estremi può quindi comparire anche senza un effetto causale dell'intervento.
3. Gli strumenti matematici possono essere impiegati per scopi differenti da quelli che caratterizzarono il loro sviluppo storico. La consapevolezza di questa genealogia è però necessaria per controllare come vengono definiti i costrutti, interpretate le differenze e utilizzate le classificazioni.
4. Il test valuta quanto le frequenze osservate si discostino da quelle previste dal modello di riferimento, secondo la statistica e la distribuzione campionaria adottate.
5. Il valore- p misura, sotto l'ipotesi nulla, la probabilità di ottenere un valore della statistica test almeno altrettanto incompatibile con l'ipotesi quanto quello osservato. Non fornisce la probabilità che l'ipotesi nulla sia vera.
6. Fisher utilizzava il valore- p soprattutto come misura graduata dell'incompatibilità con l'ipotesi nulla. Neyman e Pearson formulavano invece regole decisionali prefissate, valutate attraverso errori di tipo I, errori di tipo II e potenza.
7. Il valore- p appartiene alla tradizione fisheriana, mentre la soglia prefissata e la decisione di rifiuto richiamano il quadro Neyman–Pearson. La pratica comune combina quindi elementi provenienti da due impostazioni differenti.
8. I tassi di errore sono garantiti soltanto sotto il modello, il disegno e le assunzioni specificate. Campionamento distorto, misure non valide, analisi flessibili o modelli inadeguati possono rendere fuorviante il risultato.

Punti chiave

La statistica frequentista si è formata attraverso contributi storici differenti. Galton contribuì allo studio della regressione verso la media e dell'associazione tra variabili; Pearson formalizzò strumenti per descrivere distribuzioni e confrontare dati osservati e attesi; Fisher sviluppò la logica della significatività, la massima verosimiglianza e il disegno sperimentale; Neyman e Pearson costruirono un quadro decisionale fondato sul controllo degli errori e sulla potenza. La pratica contemporanea combina spesso concetti fisheriani e Neyman–Pearson. In tutti questi casi, le proprietà frequentiste riguardano procedure valutate sotto

campionamenti ripetuti. Una parte di questa storia è intrecciata con il movimento eugenetico e richiede quindi una lettura scientificamente ed eticamente consapevole.

i Ambiente di sviluppo

Il capitolo non richiede pacchetti aggiuntivi. Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
```

Bibliografia

Riferimenti bibliografici

Chivers, T. (2024). *Everything is Predictable: How Bayesian Statistics Explain Our World*. Simon; Schuster.

Stime, stimatori e parametri

i In sintesi

Da sapere Nell'inferenza frequentista, il parametro è una quantità fissa del modello, lo stimatore è una regola applicata ai dati e la stima è il valore numerico assunto da quella regola nel campione osservato. Le proprietà di uno stimatore vengono valutate immaginando di ripetere il campionamento nelle stesse condizioni.

Da saper fare Al termine del capitolo, il lettore dovrebbe saper distinguere parametro, stimatore e stima; interpretare bias, consistenza, efficienza ed errore quadratico medio; distinguere deviazione standard ed errore standard; spiegare perché una stima puntuale deve essere accompagnata da una misura di precisione.

Introduzione

Il capitolo precedente ha mostrato come la statistica frequentista sia nata dall'incontro di tradizioni differenti: lo studio della variabilità, la regressione e la correlazione, la significatività fisheriana e il controllo degli errori sviluppato da Neyman e Pearson. Passiamo ora dalla ricostruzione storica al primo problema operativo dell'inferenza:

Come possiamo usare un campione per conoscere una quantità ignota della popolazione o del modello?

La risposta frequentista non consiste semplicemente nel calcolare un numero. Una stima acquista significato soltanto quando viene considerata insieme alla procedura che l'ha prodotta. Occorre quindi domandarsi quanto quella procedura vari da un campione all'altro, se tenda a sbagliare sistematicamente e se diventi più precisa quando aumentano le informazioni disponibili.

Questo capitolo introduce il lessico necessario per affrontare i temi successivi. Gli intervalli di confidenza e i test di ipotesi, pur rispondendo a domande diverse, dipendono infatti dalla stessa idea fondamentale: una statistica osservata deve

essere interpretata attraverso il comportamento che avrebbe in una successione di campionamenti ripetuti.

2.1 Perché la stima è il primo passo dell'inferenza?

Immaginiamo di voler conoscere il livello medio di ansia degli studenti iscritti a un'università. Osservare ogni studente sarebbe spesso impossibile, costoso o comunque poco realistico. Selezioniamo quindi un campione e calcoliamo la media dei punteggi rilevati.

La media campionaria descrive esattamente il gruppo osservato, ma per utilizzarla come informazione sulla popolazione dobbiamo chiarire due aspetti. Il primo riguarda la quantità che desideriamo conoscere: in questo caso, la media dei punteggi di ansia nella popolazione definita dallo studio. Il secondo riguarda la stabilità della nostra conclusione: quanto cambierebbe la media se osservassimo un altro campione estratto nelle stesse condizioni?

La prima domanda definisce il parametro o, più in generale, la **quantità bersaglio** dell'analisi. La seconda introduce la variabilità campionaria dello stimatore. L'inferenza nasce precisamente dalla relazione tra questi due livelli: una quantità ignota e fissa nel modello, da una parte, e un'informazione osservata ma variabile, dall'altra.

! Prima della formula viene la domanda

Una stima può essere interpretata soltanto dopo avere definito la popolazione o il processo al quale si intende generalizzare, il costrutto psicologico e il modo in cui viene misurato, la quantità bersaglio, il meccanismo di campionamento o di assegnazione e il modello che collega i dati alla domanda scientifica.

Una procedura può essere matematicamente impeccabile e stimare con grande precisione la quantità sbagliata.

💡 Prerequisiti

Per seguire il capitolo è utile avere letto l'introduzione al modulo e il capitolo sulle origini storiche del frequentismo. È inoltre consigliabile richiamare il capitolo [Dal campione all'evidenza](#) del sito dedicato alla probabilità, insieme alle nozioni di valore atteso, varianza e distribuzione campionaria.

Non ridimostreremo la Legge dei Grandi Numeri o il Teorema del Limite Centrale. Utilizzeremo questi risultati per comprendere la logica frequentista della stima.

Panoramica del capitolo

Il percorso parte dalla distinzione tra parametro, stimatore e stima, per chiarire poi che cosa significhi produrre una stima puntuale. Su questa base verranno introdotti

correttezza e bias, consistenza, efficienza ed errore quadratico medio. La discussione si sposterà quindi sulla distribuzione campionaria e sull'errore standard, fino a mostrare perché una stima debba essere accompagnata da una misura della propria precisione. L'ultima parte confronterà la logica della stima frequentista con quella bayesiana, mantenendo distinti i significati delle rispettive quantità inferenziali.

i Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>  
  source()
```

2.2 Il problema della stima

Supponiamo che una ricercatrice raccolga un campione di studenti e osservi un punteggio medio di ansia pari a 18.4. Questo valore descrive esattamente il campione disponibile, ma rappresenta soltanto una delle molte medie che si sarebbero potute ottenere selezionando partecipanti differenti.

Se lo studio venisse ripetuto, la nuova media sarebbe probabilmente diversa. Il problema inferenziale nasce dunque dalla distanza tra la quantità della popolazione o del modello che interessa alla ricerca e l'informazione inevitabilmente parziale e variabile contenuta nel campione.

Nel frequentismo standard, il parametro viene trattato come **fisso ma ignoto** all'interno del modello. Il fatto che non ne conosciamo il valore esprime un limite della nostra informazione, ma non comporta normalmente l'assegnazione di una distribuzione di probabilità ai suoi valori possibili. La probabilità viene invece utilizzata per descrivere il comportamento dei dati, delle statistiche e delle procedure in ripetizioni reali o ipotetiche del campionamento.

i La domanda frequentista

Una domanda tipicamente frequentista può essere formulata così:

Se applicassimo lo stesso stimatore a molti campioni generati nelle stesse condizioni, come si comporterebbero le stime?

Da questa domanda derivano concetti quali bias, errore standard, copertura ed errori decisionali.

2.3 Parametro, stimatore e stima

Parametro, stimatore e stima appartengono a livelli differenti dell'analisi. La distinzione è essenziale perché molte incomprensioni derivano dal loro uso come se

fossero sinonimi.

Termine	Significato	Esempio
Parametro	Quantità fissa e ignota del modello o della popolazione	La media della popolazione, μ
Stimatore	Regola o funzione dei dati usata per stimare il parametro	La media campionaria, $\bar{X}$
Stima	Valore numerico assunto dallo stimatore nel campione osservato	$\bar{x} = 18.4$

Il **parametro** costituisce l'obiettivo dell'inferenza. Può essere una media, una proporzione, una varianza, una differenza tra gruppi, una correlazione o un coefficiente di regressione. All'interno del modello possiede un unico valore, anche quando quel valore rimane sconosciuto.

Lo **stimatore** è una funzione dei dati. Prima di osservare il campione, il suo valore non è noto perché dipende da quali osservazioni verranno raccolte. Per questo viene rappresentato mediante una variabile casuale, come $\bar{X}$ o $\hat{\theta}$.

La **stima** è invece il valore assunto dallo stimatore nel campione effettivamente osservato. Viene spesso indicata con lettere minuscole, come $\bar{x}$, oppure con una notazione che ne segnala il carattere osservato, come $\hat{\theta}_{\text{obs}}$.



Stimatore e stima non sono sinonimi

Correttezza, consistenza, varianza ed efficienza sono proprietà dello **stimatore inteso come procedura**. Una singola **stima osservata** può risultare vicina o lontana dal parametro. Poiché il valore vero è ignoto, la sua accuratezza non può essere dedotta direttamente dal numero calcolato.

2.4 La stima puntuale

Una **stima puntuale** utilizza un singolo numero per rappresentare il parametro di interesse. La media campionaria $\bar{x}$ può essere usata per stimare la media della popolazione μ ; una proporzione campionaria $\hat{p}$ può stimare la proporzione p ; la differenza $\bar{x}_1 - \bar{x}_2$ può stimare una differenza tra medie; la correlazione campionaria r può essere impiegata per stimare la correlazione ρ della popolazione.

Il termine *puntuale* non implica che il valore ottenuto sia certamente corretto, né che debba essere interpretato come il valore più probabile del parametro. Significa soltanto che la procedura restituisce un unico valore numerico.

Due studi possono produrre la stessa stima puntuale e, nello stesso tempo, offrire quantità di informazione molto differenti:

Studio	Stima della media	Errore standard
A	18.4	0.30
B	18.4	1.80

La media osservata è identica, ma nello studio B lo stimatore varia molto di più da un campione all'altro. Il solo valore 18.4 non permette di cogliere questa differenza. Per comprendere quanto la stima sia informativa è necessario affiancarle una misura della variabilità campionaria.

! Precisione non significa accuratezza

Un errore standard piccolo indica che, nelle condizioni assunte, la procedura produrrebbe stime poco variabili. Non dimostra però che il valore osservato sia vicino alla quantità scientificamente rilevante.

Un campione molto grande può generare una stima estremamente precisa e tuttavia sistematicamente distorta a causa della selezione dei partecipanti, di una misurazione inadeguata o di un modello errato.

2.5 Come si sceglie uno stimatore?

Uno stesso parametro può essere stimato attraverso procedure differenti. In alcuni casi la scelta appare naturale, come quando si utilizza la media campionaria per stimare la media della popolazione. In altri casi lo stimatore deriva da un criterio generale, come il metodo dei minimi quadrati o la massimizzazione della verosimiglianza. In problemi più complessi possono diventare rilevanti anche la robustezza rispetto alle osservazioni anomale, la stabilità numerica o l'impiego di forme di regolarizzazione.

La **massima verosimiglianza**, per esempio, seleziona il valore del parametro che rende i dati osservati più compatibili con il modello, nel senso preciso definito dalla funzione di verosimiglianza. Il sito dedicato alla probabilità introduce separatamente questo concetto nel capitolo sulla [verosimiglianza](#).

La scelta di uno stimatore non dipende quindi soltanto dalla disponibilità di una formula. Dipende dal modello, dallo scopo dell'analisi, dalla quantità di dati disponibili e dal costo attribuito ai diversi tipi di errore. Una procedura adeguata in un contesto può essere poco utile in un altro.

2.6 Quali proprietà campionarie definiscono l'ottimalità di uno stimatore?

Le proprietà di uno stimatore vengono definite rispetto a un modello e a un determinato meccanismo di campionamento. Esse descrivono il comportamento

matematico della procedura, ma non garantiscono da sole che il modello, il campione o la misura siano adeguati alla domanda psicologica.

2.6.1 Correttezza e bias

Uno stimatore $\hat{\theta}$ è detto **corretto**, o **non distorto**, quando il suo valore atteso coincide con il parametro:

$$E(\hat{\theta}) = \theta.$$

Il **bias statistico** dello stimatore è definito come

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

Uno stimatore corretto è dunque centrato sul parametro nel lungo periodo. Se il campionamento fosse ripetuto molte volte e lo stimatore venisse applicato a ogni campione, la media delle stime coinciderebbe con il valore del parametro.

Questa proprietà non implica che ogni singola stima sia vicina al valore vero. Uno stimatore può essere non distorto e, nello stesso tempo, possedere una distribuzione campionaria molto ampia. In tal caso le stime risulterebbero mediamente centrate, ma potrebbero essere spesso lontane dal parametro.

Due significati diversi di bias

Il bias dello stimatore è una proprietà matematica definita rispetto a un modello e a una successione di campionamenti.

Espressioni come *bias di selezione*, *bias di misurazione* o *bias di pubblicazione* indicano invece distorsioni del processo di ricerca. Non coincidono automaticamente con $\text{Bias}(\hat{\theta})$ e non vengono eliminate scegliendo uno stimatore non distorto.

2.6.2 Consistenza

Uno stimatore è **consistente** quando converge al parametro al crescere della dimensione campionaria. Una formulazione comune utilizza la convergenza in probabilità:

$$\hat{\theta}_n \xrightarrow{P} \theta \quad \text{quando } n \rightarrow \infty.$$

La consistenza esprime quindi un comportamento asintotico. Aumentando progressivamente il numero delle osservazioni, lo stimatore tende a concentrarsi sempre più vicino al parametro.

Questa proprietà non garantisce che la procedura funzioni bene in un campione piccolo. Non corregge neppure errori di misura, campionamenti non rappresentativi o specificazioni errate del modello. Uno stimatore può inoltre essere consistente pur mostrando un lieve bias nei campioni finiti, purché tale bias e la variabilità si riducano quando n aumenta.

2.6.3 Efficienza

All'interno di una classe specificata di stimatori e sotto un determinato modello, uno stimatore viene detto più **efficiente** quando raggiunge una maggiore precisione, spesso espressa da una varianza più piccola.

Il confronto ha senso soltanto se gli stimatori riguardano lo stesso parametro, vengono valutati sotto lo stesso modello e lo stesso schema di campionamento e appartengono a una classe chiaramente definita. L'efficienza può inoltre essere stabilita esattamente per una particolare dimensione campionaria oppure soltanto in termini asintotici.

Non si tratta quindi di una qualità assoluta. Uno stimatore non è efficiente in generale, ma rispetto a precise alternative e sotto specifiche assunzioni.

2.6.4 Il compromesso bias-varianza

La non distorsione non è sempre l'unico criterio utile per scegliere uno stimatore. Una procedura lievemente distorta può infatti possedere una varianza molto inferiore a quella di uno stimatore non distorto e produrre, nel complesso, stime migliori.

Per uno stimatore scalare con secondo momento finito, l'**errore quadratico medio** è definito come

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2.$$

La decomposizione mostra che uno stimatore può sbagliare in due modi. Le stime possono essere molto disperse da un campione all'altro, oppure possono essere sistematicamente spostate rispetto al parametro. Ridurre una componente può comportare un aumento dell'altra.

Il criterio dell'MSE rende quindi esplicito il compromesso tra variabilità e distorsione. In alcuni problemi, accettare un piccolo bias permette di ottenere una riduzione sostanziale della varianza e, di conseguenza, un errore complessivo minore.

2.7 La distribuzione campionaria

La **distribuzione campionaria** descrive i valori che uno stimatore assumerebbe se il campionamento fosse ripetuto molte volte secondo lo stesso modello e lo stesso disegno.

Non coincide con la distribuzione delle osservazioni individuali e non rappresenta la semplice distribuzione empirica rilevata in un singolo campione. Non è neppure una distribuzione di probabilità sul parametro. Il suo oggetto è lo **stimatore**.

Supponiamo di estrarre ripetutamente campioni della stessa dimensione e di calcolare ogni volta la media. Le medie ottenute formerebbero una distribuzione campionaria. Il suo centro informerebbe sul bias dello stimatore, mentre la sua dispersione ne descriverebbe la precisione. La forma complessiva della distribuzione permetterebbe inoltre di stabilire quali valori siano più o meno comuni sotto le assunzioni del modello.

La distribuzione campionaria costituisce il fondamento operativo dell'inferenza frequentista. Da essa derivano gli errori standard, il confronto tra stimatori, la costruzione degli intervalli di confidenza, le distribuzioni di riferimento dei test, i valori critici, gli errori di tipo I e di tipo II e la potenza statistica.

i Collegamento con il sito sulla probabilità

Il sito dedicato alla probabilità sviluppa il passaggio dal campione alla distribuzione campionaria. Qui adottiamo una prospettiva diversa e utilizziamo quella distribuzione per valutare il comportamento di una procedura inferenziale. Questa separazione evita di ripetere la teoria probabilistica e chiarisce il ruolo specifico del modulo frequentista.

2.8 L'errore standard

L'**errore standard** è la deviazione standard della distribuzione campionaria di uno stimatore:

$$SE(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}.$$

Esso descrive quanto lo stimatore tenderebbe a cambiare da un campione all'altro nelle condizioni definite dal modello e dal disegno.

Per una media calcolata su n osservazioni indipendenti con la stessa varianza finita σ^2 , l'errore standard è

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Poiché la deviazione standard della popolazione σ è generalmente ignota, nel caso elementare viene sostituita dalla deviazione standard campionaria:

$$\widehat{SE}(\bar{X}) = \frac{s}{\sqrt{n}}.$$

La formula mostra che, a parità di variabilità, l'errore standard della media diminuisce quando cresce la dimensione del campione. La riduzione segue però la radice quadrata di n : per dimezzare l'errore standard occorre quadruplicare il numero delle osservazioni.

Questa espressione non è universale. Dati raggruppati, misure ripetute, dipendenza temporale, campionamenti complessi o eteroschedasticità richiedono errori standard coerenti con la struttura effettiva dei dati. Applicare la formula elementare ignorando tali dipendenze può produrre una rappresentazione eccessivamente ottimistica della precisione.

⚠ Deviazione standard ed errore standard

La **deviazione standard** descrive la dispersione delle osservazioni individuali. L'**errore standard** descrive la dispersione campionaria di uno stimatore. Aumentando n , l'errore standard della media tende a diminuire, ma la variabilità tra gli individui non scompare.

i Che cosa comunica l'errore standard

L'errore standard misura la **precisione campionaria della procedura** sotto le assunzioni adottate. Non misura direttamente la validità del costrutto, il bias di selezione, l'importanza dell'effetto o la probabilità che il parametro sia vicino alla stima. Non indica neppure, da solo, la probabilità che un risultato statisticamente significativo venga replicato.

2.9 Dalla stima puntuale all'intervallo

Una stima puntuale risponde alla domanda:

Quale valore ha restituito lo stimatore nel campione osservato?

L'errore standard aggiunge una seconda informazione:

Quanto varierebbe lo stimatore se il campionamento fosse ripetuto nelle stesse condizioni?

Il capitolo successivo combinerà la stima, l'errore standard e un valore critico per costruire un **intervallo di confidenza**. L'obiettivo non sarà assegnare una probabilità al parametro, ma definire una procedura capace di raggiungere una determinata frequenza di copertura sotto il modello.

Il passaggio logico può essere rappresentato così:

stima puntuale $\rightarrow$ variabilità campionaria $\rightarrow$ procedura intervallare.

La stima puntuale fornisce il centro dell'inferenza, mentre la distribuzione campionaria permette di quantificare quanto quel centro sia sensibile alla particolare realizzazione del campione.

2.10 Stima frequentista e stima bayesiana

Frequentismo e bayesianesimo possono partire dagli stessi dati, adottare lo stesso modello generativo, utilizzare la stessa funzione di verosimiglianza e affrontare la stessa domanda sostantiva. La differenza riguarda il modo in cui l'incertezza inferenziale viene rappresentata.

Aspetto	Stima frequentista	Stima bayesiana
Parametro	Fisso all'interno del modello	Rappresentato mediante una distribuzione di probabilità
Quantità probabilistiche	Dati, statistiche e procedure sotto campionamento	Parametri e predizioni condizionati a prior, modello e dati
Oggetto centrale	Stimatore e distribuzione campionaria	Distribuzione a posteriori
Misura elementare di precisione	Errore standard	Dispersione a posteriori
Valutazione	Proprietà sotto ripetizioni	Coerenza dell'aggiornamento e adeguatezza del modello

Nel quadro frequentista, la variabilità viene attribuita allo stimatore attraverso la sua distribuzione campionaria. Il parametro resta fisso e la precisione viene descritta, nel caso più semplice, mediante l'errore standard.

Nel quadro bayesiano, l'incertezza relativa al parametro viene rappresentata direttamente mediante una distribuzione a posteriori. Tale distribuzione deriva dalla combinazione tra distribuzione a priori e verosimiglianza e viene interpretata condizionatamente al modello e ai dati osservati.

La distinzione non implica che un'analisi frequentista produca soltanto un numero o che un metodo bayesiano non possa essere valutato attraverso simulazioni ripetute. Indica piuttosto quale oggetto probabilistico costituisca la base immediata dell'inferenza.

! Un confronto utile, non una gara di slogan

L'errore standard non è una deviazione standard a posteriori e un intervallo di confidenza non è un intervallo di credibilità.

Le quantità possono talvolta risultare numericamente simili, ma conservano significati diversi perché derivano da costruzioni probabilistiche differenti.

Riflessioni conclusive

Stimare un parametro significa molto più che calcolare una statistica descrittiva. Nell'inferenza frequentista, lo stimatore viene considerato come una procedura casuale prima dell'osservazione dei dati e valutato attraverso la propria distribuzione campionaria.

La distinzione tra parametro, stimatore e stima permette di separare la quantità bersaglio, la regola di calcolo e il valore osservato. Correttezza, bias, consistenza, efficienza ed errore quadratico medio descrivono aspetti diversi del comportamento dello stimatore. L'errore standard, a sua volta, quantifica la precisione campionaria

senza fornire informazioni dirette sulla validità della misura, sulla rappresentatività del campione o sull'importanza sostantiva dell'effetto.

Una stima puntuale priva di una misura di precisione rimane incompleta, perché non comunica quanto il risultato dipenda dal particolare campione osservato. Nello stesso tempo, una stima estremamente precisa può essere scientificamente fuorviante quando il campione, la misura o il modello sono inadeguati. La precisione statistica non può sostituire la qualità del disegno e della misurazione.

Nel prossimo capitolo vedremo come la distribuzione campionaria conduca alla costruzione degli intervalli di confidenza e perché il loro significato riguardi la copertura della procedura, non una probabilità assegnata al parametro dopo avere osservato i dati.

Esercizi

1. In uno studio su 120 studenti, la media osservata di una scala di stress è 24.6. Identifica il parametro, lo stimatore e la stima.
2. Due studi producono la stessa stima, ma il primo ha errore standard 0.4 e il secondo 2.1. Che cosa puoi concludere sulla loro precisione? Che cosa non puoi concludere sulla loro accuratezza?
3. Perché uno stimatore non distorto può produrre una singola stima molto lontana dal parametro?
4. Uno stimatore è lievemente distorto nei campioni piccoli, ma il bias e la varianza tendono a zero quando n aumenta. Può essere consistente? Spiega.
5. Perché un campione molto grande non elimina automaticamente il bias di selezione o gli errori di misurazione?
6. Qual è la differenza tra la deviazione standard dei punteggi e l'errore standard della media?
7. Che cosa mostra la decomposizione $MSE = Var + Bias^2$?
8. Frequentismo e bayesianesimo usano la stessa verosimiglianza. In che modo differisce l'oggetto immediato con cui rappresentano l'incertezza sul parametro?

Soluzioni

1. Il parametro è la media della scala di stress nella popolazione definita dallo studio. Lo stimatore è la media campionaria $\bar{X}$. La stima osservata è $\bar{x} = 24.6$.
2. Il primo studio ha una stima campionariamente più precisa: lo stimatore varia meno sotto le ripetizioni assunte. Non possiamo però sapere dal solo errore standard quale stima sia più vicina al parametro vero, né se campione e misura siano privi di distorsioni.
3. La non distorsione riguarda la media delle stime in molte ripetizioni. Se la distribuzione campionaria è molto dispersa, una singola stima può

comunque risultare lontana dal parametro.

4. Sì. La consistenza richiede che lo stimatore converga al parametro quando n cresce. Non richiede necessariamente che sia non distorto per ogni dimensione campionaria.
5. Aumentare n riduce soprattutto la variabilità campionaria. Se il campione esclude sistematicamente una parte della popolazione o lo strumento misura in modo distorto, più dati possono rendere molto precisa una stima sistematicamente errata.
6. La deviazione standard descrive quanto differiscono le osservazioni individuali. L'errore standard descrive quanto varierebbe la media campionaria tra campioni ripetuti.
7. Mostra che l'errore complessivo di uno stimatore dipende sia dalla sua dispersione sia dallo spostamento sistematico rispetto al parametro. Uno stimatore può migliorare riducendo una componente anche se l'altra aumenta leggermente.
8. Nel frequentismo l'incertezza viene rappresentata immediatamente attraverso lo stimatore e la sua distribuzione campionaria. Nel bayesianesimo viene rappresentata mediante la distribuzione a posteriori del parametro, condizionata a prior, modello e dati.

i Punti chiave

Nel modello frequentista, il parametro è una quantità fissa e ignota, lo stimatore è una funzione dei dati e la stima è il valore osservato. Una stima puntuale non contiene da sola una misura di precisione. La non distorsione riguarda il valore atteso dello stimatore, mentre la consistenza descrive il suo comportamento al crescere della dimensione campionaria. L'efficienza dipende dal modello e dalla classe di procedure considerate, e l'MSE combina la varianza con il quadrato del bias. L'errore standard descrive la variabilità campionaria dello stimatore, ma non la validità della misura o la rappresentatività del campione. Frequentismo e bayesianesimo possono condividere la stessa verosimiglianza, pur rappresentando in modo diverso l'incertezza inferenziale.

i Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()  
#> R version 4.6.1 (2026-06-24)  
#> Platform: aarch64-apple-darwin23  
#> Running under: macOS Tahoe 26.5.2  
#>  
#> Matrix products: default
```

```

#> BLAS:
  ↳ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
  ↳
#> LAPACK:
  ↳ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
  ↳ LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
  ↳
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
  ↳
#> [4] systemfonts_1.3.2  patchwork_1.3.2       ggdist_3.3.3
  ↳
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
  ↳
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
  ↳
#> [13] loo_2.10.1          rstan_2.32.7          StanHeaders_2.32.10
  ↳
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
  ↳
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
  ↳
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
  ↳
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
  ↳
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidyselect_1.2.1      farver_2.1.2
  ↳
#> [4] S7_0.2.2           fastmap_1.2.0         tensorA_0.36.2.1
  ↳
#> [7] digest_0.6.39       timechange_0.4.0      estimability_2.0.0
  ↳
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
  ↳
#> [13] rlang_1.3.0         tools_4.6.1           yaml_2.3.12
  ↳
#> [16] knitr_1.51          bridgesampling_1.2-1  pkgbuild_1.4.8
  ↳
#> [19] curl_7.1.0          RColorBrewer_1.1-3    abind_1.4-8
  ↳
#> [22] purrr_1.2.2         grid_4.6.1           stats4_4.6.1
  ↳

```

```
#> [25] xtable_1.8-8          inline_0.3.21          emmeans_2.0.4
#> [28] scales_1.4.0          cli_3.6.6             mvtnorm_1.4-2
#> [31] rmarkdown_2.31        generics_0.1.4        otel_0.2.0
#> [34] RcppParallel_5.1.11-2 cachem_1.1.0           stringr_1.6.0
#> [37] parallel_4.6.1        vctrs_0.7.3           V8_8.2.0
#> [40] Matrix_1.7-6          jsonlite_2.0.0        arrayhelpers_1.1-2
#> [43] glue_1.8.1            codetools_0.2-20
#> [46] lubridate_1.9.5        stringi_1.8.7         gtable_0.3.6
#> [49] QuickJSR_1.10.0       pillar_1.11.1         htmltools_0.5.9
#> [52] Brodningnag_1.2-9     R6_2.6.1              textshaping_1.0.5
#> [55] rprojroot_2.1.1       evaluate_1.0.5        lattice_0.22-9
#> [58] backports_1.5.1       memoise_2.0.1         broom_1.0.13
#> [61] snakecase_0.11.1      rstantools_2.6.0      coda_0.19-4.1
#> [64] gridExtra_2.3.1       nlme_3.1-170          checkmate_2.3.4
#> [67] xfun_0.60             pkgconfig_2.0.3
```

Intervalli di confidenza

i In sintesi

Da sapere Un intervallo di confidenza combina una stima puntuale con una misura della sua variabilità campionaria. Il livello di confidenza descrive la frequenza con cui la procedura contiene il parametro nelle ripetizioni previste dal modello e non assegna una probabilità al parametro all'interno dell'intervallo osservato.

Da saper fare Al termine del capitolo, il lettore dovrebbe saper interpretare correttamente un intervallo di confidenza, distinguere copertura, precisione e validità, spiegare il ruolo dell'errore standard, del valore critico e della dimensione campionaria e confrontare gli intervalli di confidenza con gli intervalli di credibilità senza confonderne il significato.

Introduzione

Nel capitolo precedente abbiamo distinto il parametro, lo stimatore e la stima. Abbiamo inoltre visto che una stima puntuale, come una media campionaria, descrive il valore assunto dallo stimatore nel campione osservato, ma non comunica quanto quel valore potrebbe cambiare se il campionamento fosse ripetuto nelle stesse condizioni.

L'intervallo di confidenza nasce per integrare queste due informazioni. Parte dalla distribuzione campionaria dello stimatore e costruisce, intorno alla stima osservata, un intervallo mediante una procedura progettata per raggiungere una determinata frequenza di copertura.

La difficoltà principale non riguarda il calcolo, ma l'interpretazione. Un intervallo di confidenza al 95% non significa che il parametro abbia il 95% di probabilità di trovarsi tra i due estremi osservati. Il 95% qualifica la procedura prima dell'osservazione dei dati: sotto il modello e il piano di campionamento assunti, il 95% degli intervalli prodotti in ripetizioni analoghe contiene il parametro vero.

Comprendere questa distinzione permette di usare gli intervalli in modo informativo senza attribuire loro un significato probabilistico che appartiene a un'altra

costruzione inferenziale.

3.1 Perché una stima puntuale non basta?

Supponiamo di osservare una media campionaria pari a 24.8. Questo numero risponde a una domanda precisa:

Quale valore ha assunto lo stimatore nel campione osservato?

Non risponde però a una seconda domanda, altrettanto importante:

Quanto cambierebbe la stima se osservassimo un altro campione generato nelle stesse condizioni?

Due studi possono produrre la stessa media e, nello stesso tempo, offrire livelli di precisione molto differenti. La stima puntuale, considerata da sola, non rende visibile questa differenza. L'intervallo di confidenza aggiunge l'informazione sulla variabilità campionaria combinando la stima, l'errore standard e un valore critico associato al livello di confidenza scelto.

! Precisione, non garanzia di verità

Un intervallo stretto indica che, nelle condizioni assunte, la procedura produce stime poco variabili da un campione all'altro. Non garantisce che il campione sia rappresentativo, che la misura sia valida o che il modello descriva adeguatamente il processo che ha generato i dati.

Una stima può essere molto precisa e, nello stesso tempo, sistematicamente fuorviante.

💡 Prerequisiti

Per seguire il capitolo è utile avere letto Capitolo 2, dove sono state introdotte la distinzione tra parametro, stimatore e stima e la nozione di errore standard. È inoltre consigliabile richiamare il capitolo [Dal campione all'evidenza](#), dedicato alla distribuzione campionaria, e l'introduzione al modulo frequentista, nella quale è stata distinta la probabilità della procedura dall'incertezza sul parametro. Qui utilizzeremo questi concetti senza ripeterne la teoria probabilistica.

Panoramica del capitolo

Il capitolo procede dalla forma generale di un intervallo di confidenza ai due casi fondamentali della media con varianza nota e ignota. Un esempio numerico in R mostrerà come costruire l'intervallo t , mentre una simulazione renderà visibile la logica della copertura. La parte successiva esaminerà i fraintendimenti più comuni

e chiarirà come l'ampiezza dell'intervallo dipenda dalla variabilità, dal livello di confidenza, dalla dimensione campionaria e dalle assunzioni della procedura. Il confronto con gli intervalli di credibilità permetterà infine di distinguere due modi diversi di rappresentare l'incertezza e preparerà il passaggio ai test di ipotesi.

i Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>
  source()
```

3.2 Dalla stima all'intervallo

Molti intervalli di confidenza possono essere espressi nella forma

$$\text{stima} \pm \text{valore critico} \times \text{errore standard}.$$

Il prodotto tra il valore critico e l'errore standard prende il nome di **margin di errore**. La stima determina il centro dell'intervallo; l'errore standard descrive la variabilità campionaria dello stimatore; il valore critico stabilisce quanto occorre allontanarsi dal centro per ottenere il livello di copertura desiderato.

Questa forma non è universale. Esistono intervalli asimmetrici, intervalli basati sulla verosimiglianza, intervalli bootstrap e procedure specifiche per proporzioni, varianze e coefficienti di regressione. Il caso della media rimane tuttavia un punto di partenza particolarmente utile, perché rende visibile la struttura fondamentale della costruzione frequentista.

3.3 Caso ideale: media con varianza nota

Consideriamo osservazioni indipendenti provenienti da una popolazione normale con media ignota μ e deviazione standard nota σ . La media campionaria ha distribuzione

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Di conseguenza,

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

Per un livello di confidenza del 95% vale la relazione

$$P(-1.96 \leq Z \leq 1.96) = 0.95.$$

Sostituendo la definizione di Z e riordinando la disuguaglianza otteniamo

$$P\left(\bar{X} - 1.96 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + 1.96 \frac{\sigma}{\sqrt{n}}\right) = 0.95.$$

Prima che il campione venga osservato, gli estremi dell'intervallo sono variabili casuali perché dipendono da $\bar{X}$. La procedura produce quindi un intervallo casuale che contiene il parametro nel 95% delle ripetizioni previste dal modello.

Dopo l'osservazione dei dati, la situazione cambia. Gli estremi diventano due valori numerici e il parametro, nel modello frequentista, rimane fisso. Il particolare intervallo ottenuto contiene il parametro oppure non lo contiene. La probabilità del 95% continua a descrivere il comportamento della procedura nel lungo periodo e non si trasferisce al parametro.

i Dove si trova la probabilità?

Nell'espressione precedente, la probabilità riguarda gli estremi casuali dell'intervallo prima dell'osservazione dei dati. Non riguarda una distribuzione di probabilità assegnata a μ .

3.4 Caso usuale: media con varianza ignota

Nella ricerca psicologica, la deviazione standard della popolazione σ è quasi sempre ignota. Viene quindi sostituita con la deviazione standard campionaria s .

Se le osservazioni sono indipendenti e provengono da una popolazione normale, la statistica

$$T = \frac{\bar{X} - \mu}{s/\sqrt{n}}$$

segue esattamente una distribuzione t di Student con $n - 1$ gradi di libertà:

$$T \sim t_{n-1}.$$

L'intervallo bilaterale al livello $1 - \alpha$ è pertanto

$$\bar{X} \pm t_{1-\alpha/2, n-1} \frac{s}{\sqrt{n}}.$$

La distribuzione t possiede code più pesanti della normale standard. Nei campioni piccoli il valore critico risulta quindi più grande e l'intervallo più ampio, perché la stima di σ introduce un'ulteriore fonte di incertezza. All'aumentare dei gradi di libertà, la distribuzione t si avvicina progressivamente alla normale standard.

! Esatto e approssimato

L'intervallo t classico possiede copertura esatta quando le osservazioni sono indipendenti e la popolazione è normale.

Con campioni grandi può essere utilizzato come approssimazione anche quando

la distribuzione non è perfettamente normale. La qualità dell'approssimazione dipende tuttavia dalla forma della distribuzione, dalla presenza di valori estremi e dalla struttura di dipendenza. Una numerosità elevata non rende irrilevante qualunque violazione delle assunzioni.

3.5 Un esempio numerico

Consideriamo dieci punteggi di benessere psicologico:

```
punteggi <- c(28, 22, 26, 18, 30, 24, 27, 17, 21, 25)

n <- length(punteggi)
media <- mean(punteggi)
dev_std <- sd(punteggi)
errore_standard <- dev_std / sqrt(n)

c(
  media = media,
  deviazione_standard = dev_std,
  errore_standard = errore_standard,
  n = n
)
#>               media deviazione_standard   errore_standard
#> n
#>      23.80              4.26              1.35
#>      10.00
```

La media osservata è 23.8, la deviazione standard campionaria è circa 4.26 e l'errore standard è circa 1.35. Queste tre quantità descrivono aspetti differenti dei dati. La media individua il centro del campione, la deviazione standard riassume la variabilità tra i punteggi individuali e l'errore standard esprime quanto la media campionaria tenderebbe a cambiare da un campione all'altro.

Calcoliamo manualmente l'intervallo di confidenza al 95%:

```
alpha <- 0.05
t_star <- qt(1 - alpha / 2, df = n - 1)
margine_errore <- t_star * errore_standard

limite_inferiore <- media - margine_errore
limite_superiore <- media + margine_errore

c(
  t_critico = t_star,
  margine_errore = margine_errore,
  limite_inferiore = limite_inferiore,
  limite_superiore = limite_superiore
)
#>      t_critico   margine_errore limite_inferiore limite_superiore
#>      2.26          3.05          20.75          26.85
```

Otteniamo approssimativamente

$$23.8 \pm 2.262 \times 1.348 = [20.75, 26.85].$$

La stessa procedura è disponibile in R:

```
t.test(punteggi, conf.level = 0.95)
#>
#> One Sample t-test
#>
#> data: punteggi
#> t = 18, df = 9, p-value = 3e-08
#> alternative hypothesis: true mean is not equal to 0
#> 95 percent confidence interval:
#> 20.8 26.8
#> sample estimates:
#> mean of x
#> 23.8
```

La funzione `t.test()` restituisce anche una statistica test e un valore-*p*. In questo capitolo utilizziamo soltanto l'intervallo; la logica dei test di ipotesi verrà introdotta nel capitolo successivo.

Come comunicare il risultato

Una formulazione appropriata è la seguente:

Nel campione, il punteggio medio di benessere è 23.8. L'intervallo di confidenza al 95% per la media, costruito mediante la procedura *t*, è [20.75, 26.85].

È opportuno riportare anche l'unità di misura, la numerosità campionaria e le condizioni dell'analisi.

Una formulazione da evitare è invece:

C'è il 95% di probabilità che la media vera sia compresa tra 20.75 e 26.85.

3.6 La logica della copertura

La **copertura** è la proporzione di intervalli che contengono il parametro quando la procedura viene ripetuta secondo il modello e il piano di campionamento specificati.

Per rendere visibile questa idea, simuliamo molti campioni da una popolazione normale con media nota e costruiamo un intervallo *t* per ciascun campione.

```
set.seed(42)

mu_vero <- 50
sigma_vera <- 10
```

```
n <- 25
n_simulazioni <- 1000

intervalli <- replicate(n_simulazioni, {
  campione <- rnorm(n, mean = mu_vero, sd = sigma_vera)
  ic <- t.test(campione, conf.level = 0.95)$conf.int
  c(inferiore = ic[1], superiore = ic[2])
})

contiene_mu <- intervalli["inferiore", ] <= mu_vero &
  intervalli["superiore", ] >= mu_vero

mean(contiene_mu)
#> [1] 0.948

n_mostra <- 50

dati_grafico <- data.frame(
  campione = seq_len(n_mostra),
  inferiore = intervalli["inferiore", seq_len(n_mostra)],
  superiore = intervalli["superiore", seq_len(n_mostra)],
  contiene = contiene_mu[seq_len(n_mostra)]
)

ggplot(
  dati_grafico,
  aes(
    x = campione,
    y = inferiore,
    yend = superiore,
    linetype = contiene
  )
) +
  geom_segment(aes(xend = campione), linewidth = 0.7) +
  geom_hline(yintercept = mu_vero, linetype = "dashed") +
  coord_flip() +
  labs(
    x = "Campione simulato",
    y = "Intervallo di confidenza",
    linetype = "Contiene la media vera"
  )
)
```




Figura 3.1: Cinquanta intervalli di confidenza al 95% ottenuti da campioni ripetuti. La linea tratteggiata indica la media vera.

In una simulazione finita, la copertura empirica oscilla intorno al 95% e non deve coincidere esattamente con 0.95. Figura 3.1 mostra inoltre che alcuni intervalli non contengono il parametro. Il livello di confidenza non permette di identificare, dopo l'osservazione, quali intervalli appartengano a questo gruppo.

Questo è il punto centrale della costruzione frequentista. La procedura possiede una determinata frequenza di successo nel lungo periodo, ma la proprietà di copertura non si trasforma in una probabilità riferita al singolo intervallo osservato.

! Copertura nominale e copertura effettiva

Il 95% è una proprietà nominale della procedura sotto determinate assunzioni. Se il modello, l'indipendenza, il piano di campionamento o il metodo di calcolo non sono appropriati, la copertura effettiva può essere diversa dal valore nominale.

3.7 Interpretazioni corrette e fraintendimenti

Affermazione	Valutazione	Motivo
«La procedura produce intervalli che contengono il parametro nel 95% delle ripetizioni previste dal modello.»	Corretta	Descrive la copertura frequentista.

Affermazione	Valutazione	Motivo
«Il parametro ha il 95% di probabilità di trovarsi in questo intervallo.»	Scorretta	Il parametro è fisso nel modello frequentista; la probabilità riguarda la procedura.
«Il 95% dei valori individuali si trova nell'intervallo.»	Scorretta	L'intervallo riguarda un parametro, non la dispersione dei punteggi individuali.
«I valori centrali sono più probabili di quelli vicini agli estremi.»	Non giustificata	L'intervallo non è una distribuzione di probabilità sul parametro.
«Un intervallo più stretto indica maggiore precisione campionaria, a parità di metodo e livello di confidenza.»	Corretta	L'ampiezza dipende dall'errore standard e dal valore critico.
«Tutti i valori interni sono ugualmente plausibili.»	Non giustificata	La procedura non assegna probabilità o plausibilità ai singoli valori del parametro.

Un intervallo di confidenza viene talvolta descritto come l'insieme dei valori **compatibili con i dati**. Questa formulazione può essere utile, purché venga completata. Si tratta dei valori non esclusi dalla procedura, dato il modello, le assunzioni e il livello di confidenza scelto.

L'espressione non implica che tutti i valori interni siano ugualmente credibili, né che quelli esterni siano impossibili. L'intervallo riassume l'esito di una regola inferenziale, non una distribuzione di plausibilità sui possibili valori del parametro.

3.8 Che cosa determina l'ampiezza?

L'ampiezza di un intervallo dipende dal modo in cui la procedura combina la variabilità dello stimatore con il livello di copertura desiderato.

3.8.1 Errore standard

A parità di valore critico, un errore standard maggiore produce un intervallo più ampio. L'errore standard dipende dalla variabilità dei dati, dalla dimensione campionaria e dalla struttura dello stimatore. Quando la procedura stima il parametro con maggiore variabilità, l'intervallo deve estendersi maggiormente intorno alla stima osservata.

3.8.2 Livello di confidenza

Aumentare il livello di confidenza richiede un valore critico più grande. Sullo stesso campione, un intervallo al 99% è quindi più ampio di uno al 95%, che a sua volta è più ampio di uno al 90%.

```
livelli <- c(0.80, 0.90, 0.95, 0.99)

data.frame(
  livello = livelli,
  t_critico = qt(1 - (1 - livelli) / 2, df = n - 1)
) |>
transform(
  limite_inferiore =
    media - t_critico * errore_standard,
  limite_superiore =
    media + t_critico * errore_standard,
  ampiezza =
    2 * t_critico * errore_standard
)
#>   livello t_critico limite_inferiore limite_superiore ampiezza
#> 1    0.80      1.32          22.0          25.6      3.55
#> 2    0.90      1.71          21.5          26.1      4.61
#> 3    0.95      2.06          21.0          26.6      5.57
#> 4    0.99      2.80          20.0          27.6      7.54
```

Una copertura nominale più elevata viene dunque ottenuta al prezzo di un intervallo più largo. Il compromesso è inevitabile: per aumentare la frequenza con cui la procedura contiene il parametro, occorre accettare una minore precisione intervallare.

3.8.3 Dimensione campionaria

Nel caso elementare della media indipendente,

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

A parità di variabilità e di metodo, quadruplicare n dimezza l'errore standard. Ottenere intervalli sensibilmente più stretti richiede quindi aumenti sostanziali della numerosità campionaria.

L'aumento di n riduce la variabilità campionaria, ma non corregge automaticamente un campionamento distorto, una misurazione inadeguata, una dipendenza ignorata o un modello mal specificato. Una grande quantità di dati può rendere molto precisa una conclusione che rimane sistematicamente errata.

3.9 Intervalli e validità del modello

La copertura non è una proprietà autonoma dei due estremi numerici. Dipende dall'intero procedimento che ha condotto alla costruzione dell'intervallo: dalla definizione della popolazione e dal disegno di campionamento o di assegnazione, dallo

stimatore utilizzato, dalla formula dell'errore standard, dalla distribuzione di riferimento e dal modo in cui vengono trattate dipendenza, eterogeneità e osservazioni estreme.

Nel semplice intervallo t per una media, per esempio, l'indipendenza svolge un ruolo essenziale. Se i dati provengono da studenti raggruppati nelle stesse classi o da misure ripetute sulle medesime persone, la formula $s/\sqrt{n}$ può trattare come indipendente informazione che in realtà condivide fonti di variabilità. L'errore standard risulta allora sottostimato e la copertura effettiva può scendere al di sotto di quella nominale.

La valutazione dell'intervallo richiede quindi di considerare non soltanto il calcolo, ma anche il processo che ha generato i dati e la relazione tra il parametro statistico e la domanda scientifica.

 Un intervallo ben calcolato può rispondere alla domanda sbagliata

La copertura riguarda il parametro definito dal modello e dal processo di campionamento. Non garantisce che quel parametro corrisponda al costrutto psicologico che interessa realmente.

Precisione statistica e validità sostantiva devono essere valutate separatamente.

3.10 Intervalli di confidenza e intervalli di credibilità

Gli intervalli di confidenza e gli intervalli di credibilità possono talvolta produrre estremi numericamente simili. Questa somiglianza non deve però nascondere la differenza tra le loro costruzioni probabilistiche.

Aspetto	Intervallo di confidenza	Intervallo di credibilità
Oggetto probabilistico immediato	Intervallo casuale sotto campionamenti ripetuti	Parametro sotto la distribuzione a posteriori
Significato del 95%	Copertura della procedura, sotto le assunzioni	Massa a posteriori contenuta nell'intervallo
Dipendenza da una prior	Non nella procedura standard	Sì
Dipendenza dal modello dei dati	Sì	Sì
Interpretazione del singolo intervallo	Non assegna probabilità al parametro	Assegna probabilità a posteriori al parametro, condizionatamente a prior, modello e dati

Un intervallo di credibilità al 95% contiene il 95% della massa di una distribuzione

a posteriori scelta. La sua interpretazione riguarda direttamente il parametro, ma rimane condizionata alla distribuzione a priori, alla verosimiglianza e all'adeguatezza del modello.

Un intervallo di confidenza, invece, conserva il proprio significato procedurale. Il 95% descrive la frequenza di copertura nelle ripetizioni specificate e non la probabilità che il parametro appartenga al particolare intervallo osservato.

! Non basta cambiare il nome

Un intervallo di confidenza non diventa un intervallo di credibilità perché viene interpretato in modo intuitivo. Allo stesso modo, un intervallo bayesiano non è automaticamente affidabile soltanto perché consente un'affermazione probabilistica sul parametro.

Entrambi richiedono un modello adeguato e una comunicazione coerente con la procedura che li ha generati.

3.11 Dall'intervallo al test di ipotesi

Per molte procedure standard, un intervallo bilaterale al livello $1 - \alpha$ è collegato al corrispondente test bilaterale di livello α .

Nel caso della media con test t , se il valore ipotizzato μ_0 si trova al di fuori dell'intervallo al 95%, il test bilaterale di livello 0.05 rifiuta l'ipotesi $H_0 : \mu = \mu_0$. Se invece μ_0 appartiene all'intervallo, il test non rifiuta l'ipotesi nulla allo stesso livello.

Questa corrispondenza esprime una relazione tra procedure costruite in modo coerente. Non implica che i valori interni all'intervallo siano veri, che quelli esterni siano impossibili o che tutti i valori non esclusi ricevano lo stesso sostegno dai dati.

Il capitolo successivo svilupperà questa logica introducendo l'ipotesi nulla e l'ipotesi alternativa, la statistica test, il livello α , il valore- p , gli errori di tipo I e di tipo II e la potenza statistica.

Riflessioni conclusive

Un intervallo di confidenza collega una stima puntuale alla distribuzione campionaria dello stimatore. Il suo livello descrive la frequenza con cui la procedura contiene il parametro nelle ripetizioni definite dal modello e dal disegno.

La distinzione fondamentale riguarda l'oggetto della probabilità. Nel quadro frequentista, la probabilità descrive il comportamento della procedura casuale prima dell'osservazione dei dati. Non viene assegnata direttamente al parametro fisso dopo che il particolare intervallo è stato calcolato.

L'ampiezza dell'intervallo informa sulla precisione campionaria, ma non certifica la rappresentatività del campione, la validità della misura o la correttezza del modello. Anche la copertura nominale rimane affidabile soltanto nella misura in cui la procedura e le sue assunzioni risultano adeguate al processo che ha generato i dati.

Questo capitolo completa il passaggio dalla stima puntuale all'inferenza interval-lare. Il prossimo utilizzerà le stesse distribuzioni di riferimento per introdurre i test di ipotesi e chiarire il significato dei valori- p e degli errori decisionali.

Esercizi

1. Che cosa aggiunge un intervallo di confidenza rispetto a una stima puntuale?
2. Che cosa significa affermare che una procedura ha copertura del 95%?
3. Perché non è corretto dire che il parametro ha il 95% di probabilità di trovarsi nell'intervallo osservato?
4. Due studi riportano la stessa stima e lo stesso livello di confidenza. Il primo intervallo è molto più stretto. Che cosa puoi concludere e che cosa non puoi concludere?
5. Perché quadruplicare la dimensione campionaria dimezza approssimativamente l'errore standard della media?
6. Un intervallo al 99% è più ampio dell'intervallo al 95% costruito sugli stessi dati. Quale compromesso esprime questa differenza?
7. Perché ignorare la dipendenza tra osservazioni può compromettere la copertura?
8. Qual è la differenza fondamentale tra il 95% di un intervallo di confidenza e il 95% di un intervallo di credibilità?

Soluzioni

1. L'intervallo aggiunge informazione sulla precisione campionaria della procedura, combinando la stima, l'errore standard e un valore critico.
2. Significa che, sotto il modello e il piano di campionamento assunti, il 95% degli intervalli costruiti in ripetizioni analoghe contiene il parametro vero.
3. Dopo l'osservazione, gli estremi sono fissi e il parametro è trattato come fisso nel modello frequentista. Il 95% qualifica il comportamento della procedura prima dell'osservazione, non una distribuzione di probabilità sul parametro.
4. Il primo studio possiede una maggiore precisione campionaria, a parità di metodo e assunzioni. Dai soli estremi non si può concludere che la stima sia più accurata, che il campione sia più rappresentativo o che la misura sia più valida.
5. L'errore standard della media è proporzionale a $1/\sqrt{n}$. Sostituendo $4n$ a n , si ottiene $1/\sqrt{4n} = 1/(2\sqrt{n})$.
6. Una copertura nominale più alta richiede un valore critico maggiore e produce quindi un intervallo più ampio. Si guadagna copertura procedurale e si perde precisione.

7. La formula standard può trattare come indipendenti osservazioni che condividono fonti di variabilità. L'errore standard può risultare troppo piccolo e la copertura effettiva inferiore a quella nominale.
8. Nel primo caso, il 95% descrive la frequenza di copertura della procedura. Nel secondo descrive la massa della distribuzione a posteriori contenuta nell'intervallo, condizionatamente alla prior, al modello e ai dati.

i Punti chiave

Un intervallo di confidenza combina una stima, un errore standard e un valore critico. Il livello di confidenza è una proprietà della procedura e non assegna una probabilità al parametro nel singolo intervallo osservato. L'intervallo t classico possiede copertura esatta sotto indipendenza e normalità, mentre violazioni delle assunzioni possono produrre una copertura effettiva diversa da quella nominale. Un intervallo stretto segnala una maggiore precisione campionaria, ma non garantisce accuratezza, rappresentatività o validità. L'ampiezza cresce con il livello di confidenza e tende a diminuire all'aumentare della dimensione campionaria. Gli intervalli di confidenza e di credibilità possono essere numericamente simili, ma rispondono a costruzioni e interpretazioni differenti. Per molte procedure standard, infine, gli intervalli bilaterali e i corrispondenti test di ipotesi sono legati da una relazione di dualità.

i Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK:
#>   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>   LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods   base
#>
```

```

#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.1          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2           fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39      timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5    magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0        tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51         labeling_0.4.3
#> [19] pkgbuild_1.4.8     curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8        purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1       xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.4      scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-2      rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0         RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0      parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0           Matrix_1.7-6          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2 glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5       stringi_1.8.7

```

```
#> [49] gtable_0.3.6           QuickJSR_1.10.0         pillar_1.11.1
↵
#> [52] htmltools_0.5.9        Brobdingnag_1.2-9       R6_2.6.1
↵
#> [55] textshaping_1.0.5      rprojroot_2.1.1        evaluate_1.0.5
↵
#> [58] lattice_0.22-9         backports_1.5.1         memoise_2.0.1
↵
#> [61] broom_1.0.13           snakecase_0.11.1        rstantools_2.6.0
↵
#> [64] coda_0.19-4.1          gridExtra_2.3.1         nlme_3.1-170
↵
#> [67] checkmate_2.3.4        xfun_0.60               pkgconfig_2.0.3
```

Test di ipotesi e valore- p

i In sintesi

Da sapere Un test frequentista confronta una statistica osservata con la distribuzione che essa avrebbe sotto un'ipotesi nulla e un insieme di assunzioni. Il valore- p descrive quanto il risultato sia incompatibile con quel modello di riferimento, ma non assegna una probabilità all'ipotesi. La pratica contemporanea combina spesso la concezione fisheriana della significatività con la teoria delle decisioni e degli errori sviluppata da Neyman e Pearson.

Da saper fare Al termine del capitolo, il lettore dovrebbe saper distinguere ipotesi, statistica test, distribuzione nulla, valore- p e livello α ; interpretare correttamente gli errori di tipo I e di tipo II e la potenza; separare la significatività statistica dalla dimensione dell'effetto e dalla sua rilevanza sostantiva.

Introduzione

Nei capitoli precedenti abbiamo seguito un percorso che dalla stima puntuale conduce alla quantificazione della sua incertezza:

stima puntuale $\rightarrow$ errore standard $\rightarrow$ intervallo di confidenza.

Il test di ipotesi utilizza gli stessi elementi, ma li organizza attorno a una domanda differente:

Quanto è incompatibile il risultato osservato con un modello assunto come riferimento?

Nella ricerca psicologica, questa domanda compare ogni volta che si confrontano gruppi, si studiano associazioni tra variabili, si valutano gli effetti di un intervento o si esamina lo scostamento da un valore teorico o normativo. La diffusione dei test rende quindi indispensabile comprenderne non soltanto il calcolo, ma anche la logica e i limiti interpretativi.

Un test frequentista standard non determina la probabilità che un'ipotesi sia vera dopo avere osservato i dati. Costruisce invece la distribuzione dei risultati

che sarebbero possibili sotto un'ipotesi nulla e colloca al suo interno il risultato effettivamente osservato. Il significato dell'analisi dipende da questa direzione del ragionamento.

4.1 Perché è facile fraintendere un test?

Nel linguaggio ordinario, verificare un'ipotesi sembra significare scegliere direttamente tra due spiegazioni: l'ipotesi nulla oppure l'ipotesi alternativa. La procedura frequentista standard non attribuisce però probabilità posteriori a queste possibilità. La domanda che formula è condizionale:

Se l'ipotesi nulla e le altre assunzioni del modello fossero appropriate, quanto sarebbe estremo il risultato osservato?

La differenza tra questa domanda e quella che spesso vorremmo porre può essere espressa distinguendo

$$P(\text{dati} \mid H_0)$$

da

$$P(H_0 \mid \text{dati}).$$

La prima quantità riguarda la distribuzione dei dati sotto l'ipotesi nulla. La seconda riguarda la probabilità dell'ipotesi dopo avere osservato i dati. Confondere le due direzioni del condizionamento costituisce una delle principali fonti di errore nell'interpretazione dei test.

! La direzione del condizionamento

Il valore- p riguarda la distribuzione dei dati, o della statistica test, **assumendo** H_0 . Non rappresenta la probabilità di H_0 dopo avere osservato i dati.

💡 Prerequisiti

Per seguire il capitolo è utile avere letto Capitolo 2, dove sono stati introdotti stimatore, distribuzione campionaria ed errore standard, e Capitolo 3, dedicato a copertura, valori critici e livello α . Il capitolo **Probabilità condizionata** aiuta inoltre a distinguere $P(A \mid B)$ da $P(B \mid A)$.

La potenza verrà introdotta qui come proprietà del test e approfondita nel capitolo successivo, dedicato alla pianificazione della numerosità campionaria.

Panoramica del capitolo

Il capitolo parte dalla distinzione tra la significatività fisheriana e la teoria dei test di Neyman–Pearson. Verranno quindi identificati gli elementi che definiscono una

procedura di test e chiarito il diverso ruolo del valore- p e del livello α . Su questa base sarà possibile introdurre gli errori di tipo I e di tipo II e la potenza statistica.

La logica generale verrà applicata prima a un test del chi-quadrato e poi a un test t per una media. La discussione dei test unilaterali e bilaterali permetterà di mostrare come la definizione dell'estremità dipenda dalla domanda formulata prima dell'analisi. L'ultima parte distinguerà significatività, grandezza dell'effetto e rilevanza sostantiva e metterà a confronto la domanda frequentista con quella bayesiana.

i Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>  
  source()
```

4.2 Due tradizioni nella pratica contemporanea

La pratica comunemente indicata come *NHST*, acronimo di *Null Hypothesis Significance Testing*, non coincide perfettamente con una singola teoria. Essa combina elementi provenienti da due tradizioni storicamente e concettualmente distinte.

4.2.1 Fisher: significatività e incompatibilità

Nell'impostazione fisheriana, il valore- p fornisce una misura graduata dell'incompatibilità tra i dati e un'ipotesi nulla. Un valore piccolo indica che il risultato osservato si trova in una regione poco frequente della distribuzione prevista sotto quell'ipotesi.

Questa lettura non richiede necessariamente una decisione automatica e definitiva. Il valore- p viene considerato insieme alla qualità del disegno, all'affidabilità delle misure, alle caratteristiche dei dati e alle conoscenze scientifiche disponibili. Esso rappresenta quindi un elemento dell'argomentazione, non un verdetto autosufficiente.

4.2.2 Neyman–Pearson: decisioni ed errori

Nella teoria di Neyman e Pearson, l'attenzione si sposta verso il comportamento di una regola decisionale nelle ripetizioni. Vengono specificate le ipotesi, la regione di rifiuto e le probabilità di commettere errori quando si applica la procedura. Il livello α controlla l'errore di tipo I, mentre l'errore di tipo II e la potenza descrivono il comportamento del test sotto alternative specificate.

La decisione di rifiutare o non rifiutare l'ipotesi nulla non dichiara che una delle ipotesi sia probabilmente vera. Applica una regola progettata per produrre determinate frequenze di errore nel lungo periodo.

i Una procedura ibrida

La regola

«calcolo un valore- p e, se $p \leq 0.05$, dichiaro il risultato significativo»

combina una misura fisheriana di incompatibilità con una soglia e una decisione di tipo Neyman–Pearson. Questa pratica è molto diffusa, ma può essere interpretata correttamente soltanto ricordando che il valore- p e il livello α sono quantità diverse e svolgono funzioni differenti.

4.3 Anatomia di un test

Un test non è definito dal solo valore- p . Per comprenderne il significato occorre ricostruire l'intera procedura: l'ipotesi nulla, l'alternativa, la statistica test, la distribuzione di riferimento e la regola che stabilisce quali risultati siano almeno altrettanto estremi di quello osservato.

4.3.1 Ipotesi nulla e alternativa

L'**ipotesi nulla** H_0 specifica il modello di riferimento. L'**ipotesi alternativa** H_1 descrive invece i valori o i modelli rispetto ai quali la procedura deve essere sensibile.

Nel caso di una media, l'ipotesi nulla può essere

$$H_0 : \mu = 24.$$

Un'alternativa bilaterale è

$$H_1 : \mu \neq 24,$$

mentre un'alternativa unilaterale superiore può essere espressa come

$$H_1 : \mu > 24.$$

L'ipotesi nulla non deve necessariamente rappresentare una teoria scientifica completa, né coincide sempre con l'assenza di qualunque effetto. È una restrizione precisa del modello che consente di derivare una distribuzione di riferimento per la statistica test.

4.3.2 Statistica test

La **statistica test** è una funzione dei dati costruita per quantificare una discrepanza rilevante rispetto a H_0 . Può assumere la forma di una statistica z , t , χ^2 o F , oppure di una differenza, un rapporto o un coefficiente standardizzato.

Il suo valore non è interpretabile isolatamente. Per stabilire quanto sia estremo

occorre conoscere la distribuzione che la statistica avrebbe sotto l'ipotesi nulla e sapere quali direzioni o valori rappresentino una maggiore incompatibilità con il modello di riferimento.

4.3.3 Distribuzione sotto l'ipotesi nulla

La **distribuzione nulla** descrive i valori che la statistica test assumerebbe se l'ipotesi nulla, il modello e il piano di analisi fossero corretti. A seconda del problema, questa distribuzione può essere derivata esattamente, approssimata mediante risultati asintotici oppure costruita attraverso permutazioni o simulazioni.

Essa traduce l'ipotesi nulla in una previsione sul comportamento della statistica. Soltanto grazie a questa distribuzione è possibile valutare la posizione del risultato osservato.

4.3.4 Regola di estrema

Il valore- p dipende anche dalla regola che definisce quali risultati siano almeno altrettanto incompatibili con H_0 quanto quello osservato. In un test unilaterale superiore si considera una sola coda della distribuzione; in un test bilaterale si considerano discrepanze in entrambe le direzioni, secondo la procedura stabilita.

La nozione di risultato estremo non è quindi contenuta nei dati in modo automatico. Dipende dalla domanda, dalla statistica scelta e dal piano di analisi.

 Il valore- p non è determinato dai soli dati

A parità di dati, il valore- p può cambiare quando cambiano l'ipotesi nulla, la statistica test, la distribuzione di riferimento, la scelta tra test unilaterale e bilaterale, la regola di arresto, le correzioni per confronti multipli o altre decisioni previste dal piano di analisi.

4.4 Il valore- p

In forma generale, il valore- p può essere definito come

la probabilità, calcolata sotto H_0 , di ottenere un valore della statistica test almeno altrettanto incompatibile con H_0 quanto quello osservato.

In simboli schematici,

$$p = P_{H_0} (T(Y) \text{ almeno altrettanto estremo di } T(y_{\text{obs}})) .$$

Un valore- p piccolo indica che il risultato osservato occupa una regione rara della distribuzione nulla. Esprime quindi una tensione tra i dati e l'insieme delle assunzioni utilizzate per costruire il test.

Questa tensione non identifica automaticamente quale componente sia problematica. Un valore piccolo può derivare da una deviazione reale rispetto al valore nullo,

ma anche da una specificazione inadeguata del modello, da dipendenze o forme di eterogeneità ignorate, da distorsioni del campionamento o della misurazione oppure da una selezione analitica e da confronti multipli non adeguatamente considerati.

4.4.1 Valore- p e livello α

Il **valore- p** viene calcolato a partire dai dati. Il **livello α** è invece una soglia decisionale stabilita prima dell'analisi.

La regola convenzionale prevede di rifiutare H_0 quando $p \leq \alpha$ e di non rifiutarla quando $p > \alpha$. L'espressione *non rifiutare* è intenzionale: un risultato non significativo non dimostra che l'ipotesi nulla sia vera.

Che cosa non è un valore- p

Il valore- p non è $P(H_0 \mid \text{dati})$, non rappresenta la probabilità che il risultato sia «dovuto al caso» e non esprime la probabilità che H_1 sia vera. Non misura la dimensione dell'effetto, non indica la probabilità di replicare la significatività e non coincide con il tasso di falsi positivi tra tutti i risultati significativi pubblicati.

4.5 Errori di tipo I, errori di tipo II e potenza

Quando un test viene utilizzato come regola decisionale, il suo risultato può essere classificato in relazione allo stato specificato dalle ipotesi:

Stato rispetto alle ipotesi specificate	Rifiutare H_0	Non rifiutare H_0
H_0 vera	Errore di tipo I	Decisione corretta
Alternativa specificata vera	Decisione corretta	Errore di tipo II

4.5.1 Errore di tipo I

L'errore di tipo I consiste nel rifiutare H_0 quando essa è vera. Sotto le condizioni previste dalla procedura,

$$P(\text{rifiutare } H_0 \mid H_0) = \alpha.$$

Il controllo riguarda la procedura e la famiglia di analisi effettivamente definita. Se vengono eseguiti numerosi test e riportati soltanto quelli significativi, oppure se le analisi vengono modificate dopo avere osservato i risultati, il tasso effettivo di falsi positivi può superare il livello nominale.

4.5.2 Errore di tipo II e potenza

Per una specifica alternativa, la probabilità di errore di tipo II è

$$\beta = P(\text{non rifiutare } H_0 \mid H_1).$$

La **potenza** è il suo complemento:

$$1 - \beta = P(\text{rifiutare } H_0 \mid H_1).$$

La potenza non è un unico numero valido per qualunque alternativa. Cambia al variare del parametro sotto H_1 e dipende anche dalla numerosità campionaria, dalla variabilità, dal livello α , dalla struttura del disegno, dalla scelta tra test unilaterale e bilaterale e dalla qualità della misurazione.

Un effetto molto distante dal valore nullo è generalmente più facile da rilevare di un effetto piccolo. Allo stesso modo, un campione più ampio o una misura più precisa rendono la procedura più sensibile, a parità delle altre condizioni.

i Perché la potenza viene ripresa nel prossimo capitolo

In questo capitolo la potenza serve a completare la logica degli errori decisionali. Nel capitolo successivo verrà utilizzata per discutere come scegliere un effetto bersaglio e una numerosità campionaria adeguata prima della raccolta dei dati.

4.6 Esempio 1: test del chi-quadrato di indipendenza

Supponiamo di studiare la relazione tra **stress percepito** e **qualità del sonno**.

```
osservati <- matrix(
  c(
    42, 40,
    19, 39
  ),
  nrow = 2,
  byrow = TRUE,
  dimnames = list(
    Stress = c("Basso", "Alto"),
    Sonno = c("Buono", "Scarso")
  )
)

knitr::kable(osservati)
```

Tabella 4.1: Frequenze osservate per stress percepito e qualità del sonno.

	Buono	Scarso
Basso	42	40
Alto	19	39

L'ipotesi nulla afferma che stress e qualità del sonno siano indipendenti:

H_0 : stress e qualità del sonno sono indipendenti.

L'alternativa sostiene invece che tra le due variabili vi sia un'associazione:

H_1 : stress e qualità del sonno non sono indipendenti.

4.6.1 Frequenze attese

Sotto l'ipotesi di indipendenza, la frequenza attesa nella cella ij è

$$E_{ij} = \frac{R_i C_j}{N},$$

dove R_i indica il totale della riga, C_j quello della colonna e N il totale complessivo. Le frequenze attese descrivono quindi la tabella che ci aspetteremmo di osservare, salvo la variabilità campionaria, se la distribuzione di una variabile non dipendesse dall'altra.

```
totali_riga <- rowSums(osservati)
totali_colonna <- colSums(osservati)
totale <- sum(osservati)

attesi <- outer(totali_riga, totali_colonna) / totale
dimnames(attesi) <- dimnames(osservati)

knitr::kable(round(attesi, 2))
```

Tabella 4.2: Frequenze attese sotto l'ipotesi nulla di indipendenza.

	Buono	Scarso
Basso	35.7	46.3
Alto	25.3	32.7

4.6.2 Statistica test

La statistica del chi-quadrato confronta sistematicamente frequenze osservate e attese:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Le discrepanze vengono elevate al quadrato, rapportate alle frequenze attese e sommate. Valori più grandi indicano una maggiore distanza dalla configurazione prevista sotto l'indipendenza.

```
chi2_osservato <- sum((osservati - attesi)^2 / attesi)
gradi_liberta <- (nrow(osservati) - 1) * (ncol(osservati) - 1)
p_chi <- pchisq(
  chi2_osservato,
  df = gradi_liberta,
  lower.tail = FALSE
)

c(
  chi_quadrato = chi2_osservato,
  gradi_liberta = gradi_liberta,
  valore_p = p_chi
)
#>   chi_quadrato gradi_liberta   valore_p
#>         4.71         1.00         0.03
```

Il calcolo produce approssimativamente

$$\chi^2(1) = 4.71, \quad p = 0.030.$$

Possiamo verificare il risultato mediante la funzione disponibile in R:

```
chisq.test(osservati, correct = FALSE)
#>
#> Pearson's Chi-squared test
#>
#> data:  osservati
#> X-squared = 5, df = 1, p-value = 0.03
```

La correzione di continuità viene disattivata per riprodurre il calcolo manuale.

4.6.3 Visualizzazione

```
x_massimo <- qchisq(0.999, df = gradi_liberta)

dati_chi <- data.frame(
  x = seq(0.001, x_massimo, length.out = 2000)
)

dati_chi$densita <- dchisq(dati_chi$x, df = gradi_liberta)

ggplot(dati_chi, aes(x = x, y = densita)) +
  geom_line(linewidth = 0.9) +
  geom_area(
    data = subset(dati_chi, x >= chi2_osservato),
    alpha = 0.35
  ) +
  geom_vline(
    xintercept = chi2_osservato,
    linetype = "dashed",
```

```

linewidth = 0.8
) +
labs(
  x = expression(chi^2),
  y = "Densità"
)

```




Figura 4.1: Distribuzione chi-quadrato sotto l'ipotesi nulla. L'area oltre la statistica osservata rappresenta il valore- p .

In Figura 4.1, l'area a destra di χ^2_{obs} è pari a circa 0.030. Se il livello α è stato fissato a 0.05, la procedura conduce al rifiuto dell'ipotesi di indipendenza.

Il risultato può essere comunicato nel modo seguente:

Nel campione è emersa un'associazione statisticamente significativa tra stress percepito e qualità del sonno, $\chi^2(1) = 4.71, p = 0.030$.

Questa conclusione non fornisce la probabilità che le variabili siano associate, non quantifica la grandezza dell'associazione e non dimostra una relazione causale. Non garantisce neppure che le categorie utilizzate siano valide o che il disegno consenta una generalizzazione appropriata. Per completare l'analisi occorre stimare la dimensione dell'associazione e discuterne il significato sostantivo.

4.7 Esempio 2: test t per una media

Consideriamo dieci punteggi di benessere psicologico e un valore normativo pari a 24.

```
punteggi <- c(28, 22, 26, 18, 30, 24, 27, 17, 21, 25)
```

```

n <- length(punteggi)
media <- mean(punteggi)
deviazione_standard <- sd(punteggi)
errore_standard <- deviazione_standard / sqrt(n)

c(
  media = media,
  deviazione_standard = deviazione_standard,
  errore_standard = errore_standard,
  n = n
)
#>               media deviazione_standard   errore_standard
#>               23.80              4.26              1.35
#>               10.00

```

Supponiamo che, prima di osservare i dati, sia stata formulata l'ipotesi nulla

$$H_0 : \mu = 24$$

e che l'alternativa di interesse sia

$$H_1 : \mu > 24.$$

La statistica test confronta la distanza tra la media osservata e il valore nullo con l'errore standard stimato:

$$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}.$$

```

mu_0 <- 24

t_osservato <- (media - mu_0) / errore_standard
gradi_liberta_t <- n - 1
p_unilaterale <- pt(
  t_osservato,
  df = gradi_liberta_t,
  lower.tail = FALSE
)

c(
  t = t_osservato,
  gradi_liberta = gradi_liberta_t,
  valore_p = p_unilaterale
)
#>               t gradi_liberta   valore_p
#>          -0.148           9.000       0.557

```

Otteniamo approssimativamente

$$t(9) = -0.15, \quad p = 0.557.$$

La media osservata, pari a 23.8, non si trova nella direzione indicata dall'alternativa superiore. La procedura non conduce quindi al rifiuto di H_0 .

```

t.test(
  punteggi,
  mu = 24,
  alternative = "greater"
)
#>
#> One Sample t-test
#>
#> data: punteggi
#> t = -0.1, df = 9, p-value = 0.6
#> alternative hypothesis: true mean is greater than 24
#> 95 percent confidence interval:
#> 21.3 Inf
#> sample estimates:
#> mean of x
#> 23.8

```

Una formulazione adeguata è:

I dati non forniscono evidenza, secondo questo test unilaterale, che la media sia superiore a 24, $t(9) = -0.15$, $p = 0.557$.

Non sarebbe invece corretto affermare di avere dimostrato che la media sia uguale a 24. Il risultato non significativo lascia aperte possibilità differenti: la differenza potrebbe essere piccola, i dati potrebbero essere poco informativi oppure lo scostamento potrebbe trovarsi nella direzione opposta a quella specificata.

4.8 Test unilaterali e bilaterali

Un test bilaterale considera deviazioni in entrambe le direzioni:

$$H_1 : \mu \neq \mu_0.$$

```

t.test(
  punteggi,
  mu = 24,
  alternative = "two.sided"
)
#>
#> One Sample t-test
#>
#> data: punteggi
#> t = -0.1, df = 9, p-value = 0.9
#> alternative hypothesis: true mean is not equal to 24
#> 95 percent confidence interval:
#> 20.8 26.8
#> sample estimates:
#> mean of x
#> 23.8

```

Per gli stessi dati, il valore- p bilaterale è circa 0.885. La differenza rispetto al valore unilaterale non dipende da un cambiamento dei dati, ma dalla diversa definizione dei risultati considerati estremi.

La scelta tra un test unilaterale e uno bilaterale deve essere motivata dalla domanda scientifica e stabilita prima di osservare i risultati. Se la coda favorevole viene scelta soltanto dopo avere visto la direzione dell'effetto, il controllo nominale dell'errore di tipo I non è più valido.

Un test unilaterale non dovrebbe dunque essere utilizzato semplicemente perché offre maggiore potenza nella direzione prevista. Deve essere scientificamente sensato escludere dalla regola di evidenza una deviazione nella direzione opposta, anche qualora essa risultasse ampia.

4.9 Interpretare un risultato

Una lettura completa di un test richiede di mantenere distinti quattro livelli dell'interpretazione.

4.9.1 Compatibilità con il modello nullo

Il valore- p descrive quanto il risultato osservato sia estremo sotto H_0 e sotto le altre assunzioni necessarie per costruire la distribuzione di riferimento. Esso informa quindi sulla compatibilità tra dati e modello nullo, non sulla probabilità dell'ipotesi.

4.9.2 Decisione procedurale

Il confronto con α applica una regola di rifiuto o di non rifiuto. Questa decisione possiede proprietà di errore definite nelle ripetizioni, ma non coincide con una dichiarazione di verità o falsità dell'ipotesi.

4.9.3 Grandezza e precisione dell'effetto

La stima e l'intervallo di confidenza mostrano quanto l'effetto sia grande e con quale precisione sia stato stimato. Queste informazioni non sono sostituite dal valore- p : risultati con lo stesso livello di significatività possono corrispondere a effetti e precisioni molto differenti.

4.9.4 Significato scientifico

La rilevanza del risultato dipende dalla teoria, dalla qualità della misura, dal disegno, dai costi e benefici e dal contesto applicativo. La significatività statistica non stabilisce da sola se una differenza sia importante sul piano psicologico, clinico o sociale.

! Significativo non significa importante

Un risultato può essere statisticamente significativo ma troppo piccolo per avere rilievo teorico o pratico. Al contrario, un risultato non significativo può essere compatibile sia con effetti trascurabili sia con effetti rilevanti stimati con scarsa precisione.

4.10 Limiti e usi appropriati

4.10.1 La soglia crea una discontinuità decisionale

Valori come $p = 0.049$ e $p = 0.051$ rappresentano livelli di incompatibilità molto simili. La loro trasformazione in categorie opposte può far apparire una differenza sostanziale dove esiste soltanto un piccolo scarto numerico.

Una soglia può essere utile quando occorre applicare una regola decisionale prestabilita, ma non dovrebbe sostituire la lettura continua dei risultati né la considerazione della grandezza dell'effetto e della sua incertezza.

4.10.2 L'ipotesi nulla puntuale può essere poco informativa

In molti contesti, sapere che un effetto non è esattamente uguale a zero è meno utile che stabilire se sia abbastanza grande da avere rilevanza pratica, se ricada all'interno di una regione di equivalenza oppure se rimanga stabile tra popolazioni e contesti differenti.

Ciò non rende sempre illegittima un'ipotesi nulla puntuale. Mostra piuttosto che l'ipotesi deve essere scelta in funzione della domanda scientifica e della decisione che si intende sostenere.

4.10.3 Un risultato non significativo non dimostra equivalenza

Per sostenere che un effetto sia sufficientemente piccolo da poter essere considerato trascurabile occorre definire in anticipo che cosa significhi *sufficientemente piccolo* e utilizzare una procedura coerente con questa domanda, come un test di equivalenza o un'analisi basata su una regione di effetti praticamente trascurabili.

Il semplice mancato rifiuto di un'ipotesi nulla puntuale non fornisce questa informazione.

4.10.4 Il valore- p è sensibile al piano di analisi

Arresto opzionale della raccolta, confronti multipli, criteri flessibili di esclusione e selezione post hoc delle analisi modificano le proprietà nominali della procedura. Lo stesso valore- p può quindi assumere significati diversi a seconda di come lo studio è stato condotto e analizzato.

Preregistrazione, trasparenza nelle scelte e analisi di sensibilità contribuiscono a rendere il risultato interpretabile, perché permettono di ricostruire il processo che ha prodotto la statistica osservata.

4.10.5 Il test non controlla la validità scientifica

Un test può essere calcolato correttamente anche quando il campione non è rappresentativo, la misura possiede scarsa validità, il disegno è confuso o il modello è inadeguato. La significatività statistica non corregge questi problemi e non può trasformare un disegno debole in una fonte affidabile di conoscenza.

i Quando il test è utile

Un test frequentista è particolarmente interpretabile quando la domanda decisionale è definita prima dei dati, il disegno collega chiaramente il parametro alla domanda scientifica, il modello e l'errore standard sono adeguati, la famiglia di test è specificata e il risultato viene accompagnato da stime, intervalli e misure della dimensione dell'effetto.

4.11 Confronto con l'inferenza bayesiana

Il confronto più utile tra frequentismo e bayesianesimo parte dalle domande che i due approcci consentono di formulare.

Un test frequentista standard chiede:

Quanto è estremo il risultato sotto H_0 ?

Un'analisi bayesiana può invece chiedere:

Come si distribuisce l'incertezza sul parametro dopo avere combinato la distribuzione a priori e i dati?

Quando il modello assegna probabilità a ipotesi discrete, la domanda può riguardare anche il modo in cui cambiano le loro probabilità relative dopo l'osservazione dei dati.

Queste formulazioni non rappresentano interpretazioni diverse dello stesso numero. Un valore- p non è una probabilità a posteriori, così come una probabilità a posteriori non possiede automaticamente il controllo frequentista degli errori.

Il Companion approfondisce i limiti dell'uso meccanico del valore- p e mostra come il workflow bayesiano sposti l'attenzione verso il modello generativo, la distribuzione a posteriori, le predizioni e il controllo dell'adeguatezza del modello. Il modulo frequentista conserva tuttavia una funzione essenziale: permette di leggere correttamente la letteratura esistente e di comprendere quali proprietà procedurali siano garantite dai metodi classici.

4.12 Verso la pianificazione dello studio

Un risultato non significativo può avere origini molto differenti. L'effetto potrebbe essere assente o trascurabile, ma il campione potrebbe anche essere troppo piccolo, la misura poco precisa, l'eterogeneità elevata oppure il modello e il test poco sensibili alla differenza di interesse.

Per valutare in anticipo quanto uno studio potrà essere informativo è necessario specificare quale effetto minimo abbia rilevanza scientifica, quale livello di errore di tipo I sia accettabile, quale potenza si desideri e quali valori della variabilità e della struttura dei dati siano plausibili.

Questi elementi collegano la teoria del test alla progettazione dello studio e introducono il capitolo successivo, dedicato alla pianificazione della numerosità campionaria.

Riflessioni conclusive

Il test di ipotesi colloca una statistica osservata nella distribuzione che essa avrebbe sotto un'ipotesi nulla e un insieme di assunzioni. Il valore- p misura l'estremità del risultato all'interno di quella distribuzione, mentre il confronto con α applica una regola decisionale.

La distinzione tra Fisher e Neyman–Pearson chiarisce perché nella pratica contemporanea convivano due usi differenti. Il valore- p può essere letto come misura graduata di incompatibilità oppure inserito in una procedura di decisione dotata di errori controllati. Nessuno dei due usi autorizza tuttavia a interpretarlo come probabilità dell'ipotesi o come misura dell'importanza dell'effetto.

Una comunicazione scientifica adeguata non si arresta quindi alla dichiarazione di significatività. Riporta la stima dell'effetto e il relativo intervallo, descrive il disegno e le assunzioni, chiarisce il piano di analisi e valuta la rilevanza sostantiva del risultato.

Il prossimo capitolo completerà la logica decisionale esaminando il rapporto tra effetto bersaglio, potenza e numerosità campionaria.

Esercizi

1. Qual è la differenza tra un valore- p e il livello α ?
2. Perché $p = 0.03$ non significa che l'ipotesi nulla abbia una probabilità del 3% di essere vera?
3. Quale ruolo svolge la regola di estremità nella definizione del valore- p ?
4. Un risultato produce $p = 0.18$. Qual è la conclusione frequentista corretta? Quale conclusione non è giustificata?
5. Perché la potenza non può essere descritta senza specificare un effetto sotto l'alternativa?

6. Nel test del chi-quadrato emerge $p = 0.030$. Quali informazioni importanti non sono contenute in questo numero?
7. Perché scegliere un test unilaterale dopo avere osservato la direzione dell'effetto altera l'interpretazione del test?
8. In che modo un'analisi bayesiana e un test frequentista formulano domande diverse sugli stessi dati?

Soluzioni

1. Il valore- p è calcolato dai dati e misura l'estremità del risultato sotto H_0 . α è una soglia decisionale scelta prima dell'analisi per controllare l'errore di tipo I della procedura.
2. Il 3% riguarda la probabilità di risultati almeno altrettanto estremi sotto H_0 . Non riguarda la probabilità di H_0 condizionata ai dati.
3. La regola stabilisce quali valori della statistica siano almeno altrettanto incompatibili con H_0 quanto quello osservato. Cambiando la statistica o la scelta tra test unilaterale e bilaterale può cambiare anche il valore- p .
4. Al livello convenzionale 0.05, non si rifiuta H_0 . Non è giustificato concludere che H_0 sia vera, che l'effetto sia esattamente zero o che i gruppi siano equivalenti.
5. La probabilità di rifiutare H_0 cambia con la distanza tra il parametro vero e il valore nullo. Non esiste quindi una potenza unica per tutte le possibili alternative.
6. Il valore- p non contiene la grandezza dell'associazione, la sua precisione, la probabilità che l'associazione esista, l'eventuale causalità o la validità delle categorie e del disegno.
7. La coda viene selezionata usando informazione già contenuta nei dati, mentre il calcolo nominale presuppone che la direzione sia stata fissata in anticipo. Il controllo dell'errore di tipo I non è quindi più quello dichiarato.
8. Il test frequentista valuta l'estremità dei dati sotto H_0 . L'analisi bayesiana rappresenta l'incertezza a posteriori su parametri o ipotesi mediante distribuzione a priori, verosimiglianza e dati.

Punti chiave

Un test richiede un'ipotesi nulla, un'alternativa, una statistica test, una distribuzione di riferimento e una regola di estremità. Il valore- p viene calcolato sotto H_0 e non rappresenta la probabilità di H_0 . Il valore- p e il livello α svolgono funzioni differenti, anche se vengono spesso combinati nella pratica NHST. Gli errori di tipo I e di tipo II e la potenza sono proprietà della procedura sotto condizioni specificate, e la potenza dipende dall'effetto considerato sotto l'alternativa. Non rifiutare H_0 non significa accettarla o dimostrare equivalenza. Significatività statistica, dimensione dell'effetto e rilevanza sostantiva rimangono concetti di-

stinti. La qualità dell'inferenza dipende dal disegno, dalla misurazione, dal modello e dal piano di analisi. Frequentismo e bayesianesimo rispondono infine a domande probabilistiche differenti.

i Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:
#>   ↪ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#>
#> LAPACK:
#>   ↪ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>   ↪ LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods   base
#>
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0    withr_3.0.3
#>   ↪
#> [4] systemfonts_1.3.2  patchwork_1.3.2     ggdist_3.3.3
#>   ↪
#> [7] tidybayes_3.0.7     bayesplot_1.15.0    ggplot2_4.0.3
#>   ↪
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0     posterior_1.7.0
#>   ↪
#> [13] loo_2.10.1          rstan_2.32.7        StanHeaders_2.32.10
#>   ↪
#> [16] brms_2.23.0         Rcpp_1.1.2          sessioninfo_1.2.4
#>   ↪
#> [19] conflicted_1.2.0    janitor_2.2.1        matrixStats_1.5.0
#>   ↪
#> [22] modelr_0.1.11       tibble_3.3.1         dplyr_1.2.1
#>   ↪
#> [25] tidyr_1.3.2         rio_1.3.0            here_1.0.2
#>   ↪
#>
#> loaded via a namespace (and not attached):
```

```

#> [1] svUnit_1.0.8          tidyselect_1.2.1        farver_2.1.2
↵
#> [4] S7_0.2.2                fastmap_1.2.0           tensorA_0.36.2.1
↵
#> [7] digest_0.6.39           timechange_0.4.0        estimability_2.0.0
↵
#> [10] lifecycle_1.0.5         magrittr_2.0.5          compiler_4.6.1
↵
#> [13] rlang_1.3.0             tools_4.6.1             yaml_2.3.12
↵
#> [16] knitr_1.51              labeling_0.4.3
↵ bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8          curl_7.1.0              RColorBrewer_1.1-3
↵
#> [22] abind_1.4-8            purrr_1.2.2             grid_4.6.1
↵
#> [25] stats4_4.6.1           xtable_1.8-8            inline_0.3.21
↵
#> [28] emmeans_2.0.4          scales_1.4.0            cli_3.6.6
↵
#> [31] mvtnorm_1.4-2          rmarkdown_2.31          generics_0.1.4
↵
#> [34] otel_0.2.0             RcppParallel_5.1.11-2  cachem_1.1.0
↵
#> [37] stringr_1.6.0          parallel_4.6.1          vctrs_0.7.3
↵
#> [40] V8_8.2.0               Matrix_1.7-6            jsonlite_2.0.0
↵
#> [43] arrayhelpers_1.1-2     glue_1.8.1              codetools_0.2-20
↵
#> [46] distributional_0.8.1   lubridate_1.9.5         stringi_1.8.7
↵
#> [49] gtable_0.3.6          QuickJSR_1.10.0         pillar_1.11.1
↵
#> [52] htmltools_0.5.9       Brodningnag_1.2-9       R6_2.6.1
↵
#> [55] textshaping_1.0.5     rprojroot_2.1.1         evaluate_1.0.5
↵
#> [58] lattice_0.22-9        backports_1.5.1         memoise_2.0.1
↵
#> [61] broom_1.0.13          snakecase_0.11.1        rstantools_2.6.0
↵
#> [64] coda_0.19-4.1         gridExtra_2.3.1        nlme_3.1-170
↵
#> [67] checkmate_2.3.4       xfun_0.60              pkgconfig_2.0.3

```


Dimensione campionaria, precisione e potenza

i In sintesi

Da sapere La numerosità campionaria può essere pianificata per ottenere una precisione prefissata oppure per raggiungere una determinata potenza rispetto a un effetto specifico. In entrambi i casi, il risultato dipende dalle assunzioni formulate sulla variabilità, sul modello, sul disegno e sulle quantità considerate scientificamente rilevanti.

Da saper fare Al termine del capitolo, il lettore dovrebbe saper distinguere la pianificazione per precisione da quella per potenza, interpretare correttamente α , β e potenza, motivare un effetto minimo di interesse, leggere l'output di `power.t.test()` e spiegare perché la potenza post hoc calcolata a partire dall'effetto osservato sia poco informativa.

Introduzione

Nel capitolo precedente abbiamo introdotto gli errori di tipo I e di tipo II e abbiamo definito la potenza come la probabilità di rifiutare l'ipotesi nulla quando è presente una specifica alternativa. Questi concetti non servono soltanto a interpretare un test già eseguito. Acquistano un ruolo ancora più importante prima della raccolta dei dati, quando occorre stabilire quale studio sia necessario per rispondere in modo informativo alla domanda di ricerca.

La numerosità campionaria condiziona infatti ciò che uno studio può apprendere. Un campione troppo piccolo tende a produrre stime poco precise e test scarsamente sensibili agli effetti di interesse. Un campione molto ampio può invece richiedere risorse non giustificate e rendere statisticamente rilevabili differenze così piccole da non avere conseguenze teoriche, cliniche o pratiche.

Non esiste, dunque, una numerosità corretta in astratto. Il numero di partecipanti dipende dalla domanda scientifica, dalla procedura inferenziale, dalla variabilità attesa, dalla struttura del disegno e dal livello di informazione che si desidera ottenere.

Pianificare significa rendere esplicite queste dipendenze prima che i risultati osservati possano influenzare le scelte analitiche.

5.1 Perché pianificare prima di raccogliere i dati?

La pianificazione trasforma una domanda generale in un obiettivo quantitativo. Quando l'interesse principale riguarda la stima, occorre stabilire quanta imprecisione sia accettabile:

Quanto stretto dovrebbe essere l'intervallo di confidenza affinché la stima sia utile?

Quando l'obiettivo riguarda un test, la domanda cambia:

Con quale probabilità il test dovrebbe rifiutare l'ipotesi nulla se fosse presente un effetto scientificamente rilevante?

Le due domande sono collegate, perché entrambe dipendono dall'errore standard e quindi dalla quantità di informazione contenuta nei dati. Non sono però equivalenti. La prima riguarda la precisione con cui viene stimata una quantità; la seconda riguarda il comportamento di una regola decisionale sotto una specifica alternativa.

! Il calcolo non sceglie gli obiettivi scientifici

Una funzione software può calcolare n dopo che sono stati specificati il margine di errore, la variabilità, l'effetto bersaglio, il livello α e la potenza desiderata. Non può però decidere quale popolazione sia rilevante, quale effetto meriti attenzione, quale precisione sia sufficiente, quale perdita di partecipanti sia plausibile o se il disegno e la misura siano realmente adeguati alla domanda scientifica.

La numerosità è una conseguenza degli obiettivi e delle assunzioni; non può sostituirli.

💡 Prerequisiti

Per seguire il capitolo è utile avere letto Capitolo 2, dove sono stati introdotti errore standard e precisione, Capitolo 3, dedicato al margine di errore e al livello di confidenza, e Capitolo 4, nel quale sono stati discussi α , β e potenza.

Per un approfondimento sul rapporto tra obiettivo scientifico e pianificazione si veda Giner-Sorolla et al. (2024).

Panoramica del capitolo

Il capitolo distingue anzitutto due obiettivi di pianificazione: ottenere una stima sufficientemente precisa e costruire un test dotato di una determinata potenza rispetto

a un effetto specificato. Verrà quindi ricavata una formula introduttiva per la precisione di una media, mostrando come il margine di errore e la variabilità influenzino la numerosità richiesta.

La seconda parte interpreterà la potenza come una funzione dell'alternativa e introdurrà il concetto di effetto minimo di interesse. Gli esempi con `power.t.test()` mostreranno come pianificare un test t per una media e un confronto tra due gruppi indipendenti. Infine, il numero di osservazioni richiesto dall'analisi verrà trasformato in un obiettivo realistico di reclutamento, tenendo conto delle perdite, della complessità del disegno e dell'incertezza delle assunzioni. La discussione si concluderà con la potenza post hoc e con il confronto tra pianificazione frequentista e bayesiana.

i Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>
  source()
```

5.2 Due obiettivi distinti

5.2.1 Pianificare per la precisione

Quando l'interesse principale riguarda la grandezza di una media, di una proporzione o di una differenza, la pianificazione può essere costruita attorno alla precisione della stima. L'obiettivo consiste nell'ottenere un intervallo sufficientemente stretto da distinguere valori scientificamente diversi.

La domanda centrale è:

Quale ampiezza dell'intervallo renderebbe la stima utile?

Una risposta adeguata richiede di stabilire quanto debba essere piccolo il margine di errore e di formulare un'ipotesi plausibile sulla variabilità dei dati.

5.2.2 Pianificare per la potenza

Quando l'analisi è organizzata attorno a una decisione di test, l'obiettivo consiste nel costruire una procedura che abbia una probabilità prefissata di rifiutare H_0 sotto una specifica alternativa.

La domanda centrale diventa:

Qual è il più piccolo effetto che lo studio dovrebbe riuscire a rilevare con una probabilità adeguata?

Questa strategia richiede di specificare sia l'effetto bersaglio sia il livello α . Il risultato del calcolo descrive quindi la numerosità necessaria affinché il test raggiunga una determinata sensibilità nelle condizioni assunte.

Obiettivo	Quantità da specificare	Risultato della pianificazione
Precisione	Margine di errore, variabilità e livello di confidenza	n necessario per un'ampiezza desiderata
Potenza	Effetto bersaglio, variabilità, α e potenza	n necessario per una probabilità di rifiuto desiderata

i Lo stesso studio può avere più obiettivi

Uno studio può essere progettato per produrre stime sufficientemente precise e, nello stesso tempo, per raggiungere una potenza prestabilita. In questo caso è opportuno calcolare separatamente i requisiti associati ai due obiettivi e adottare quello più esigente, purché le assunzioni utilizzate siano coerenti con lo stesso disegno e con la stessa popolazione.

5.3 Pianificare la precisione di una media

Consideriamo anzitutto il caso elementare di una media calcolata su osservazioni indipendenti. Se la deviazione standard della popolazione σ fosse nota e l'intervallo venisse costruito mediante l'approssimazione normale, il margine di errore sarebbe

$$E = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

Risolvendo l'equazione rispetto a n , otteniamo

$$n = \left(\frac{z_{1-\alpha/2} \sigma}{E} \right)^2.$$

La formula rende visibile il rapporto tra precisione e quantità di informazione. Una maggiore variabilità richiede più osservazioni, perché la media cambia maggiormente da un campione all'altro. Un margine di errore più piccolo richiede anch'esso un campione più ampio. Anche un livello di confidenza maggiore aumenta la numerosità, perché comporta l'impiego di un valore critico più grande.

La dipendenza quadratica dal margine di errore ha una conseguenza particolarmente importante: dimezzare E richiede, approssimativamente, di quadruplicare n . Un incremento moderato della precisione può quindi comportare un aumento considerevole delle risorse necessarie.

5.3.1 Un esempio introduttivo

Supponiamo di voler stimare il punteggio medio di autostima in una popolazione di studenti. Studi precedenti suggeriscono una deviazione standard di circa 6 punti.

Desideriamo costruire un intervallo al 95% con un margine di errore non superiore a 2 punti.

```
sigma_attesa <- 6
margine_desiderato <- 2
z_critico <- qnorm(0.975)

n_precision <- (
  z_critico * sigma_attesa / margine_desiderato
)^2

ceiling(n_precision)
#> [1] 35
```

Il calcolo restituisce 35 partecipanti. Poiché una frazione di partecipante non è osservabile e una numerosità inferiore non raggiungerebbe l'obiettivo stabilito, l'arrotondamento deve essere effettuato verso l'alto.

Il valore ottenuto indica il numero di osservazioni **analizzabili** richiesto sotto le assunzioni della formula. Non coincide necessariamente con il numero iniziale di persone da reclutare, perché una parte dei partecipanti può abbandonare lo studio o produrre dati non utilizzabili.

5.3.2 Sensibilità al margine di errore

Per comprendere quanto la numerosità dipenda dalla precisione desiderata, possiamo ripetere il calcolo per diversi margini di errore.

```
margini <- c(1, 1.5, 2, 2.5, 3)

risultati_precision <- data.frame(
  margine_errore = margini,
  n_minimo = ceiling(
    (z_critico * sigma_attesa / margini)^2
  )
)

knitr::kable(risultati_precision)
```

Tabella 5.1: Numerosità richiesta al variare del margine di errore, assumendo deviazione standard pari a 6 e livello di confidenza del 95%.

margine_errore	n_minimo
1.0	139
1.5	62
2.0	35
2.5	23
3.0	16

La Tabella 5.1 rende evidente la relazione quadratica. Ridurre il margine di errore da 3 a 2 punti può sembrare una modifica modesta sul piano sostantivo, ma richiede

un aumento notevole del campione. La scelta della precisione desiderata deve quindi essere motivata scientificamente e confrontata con i costi effettivi della raccolta.

 Una formula introduttiva, non universale

La formula precedente tratta σ come se fosse nota e assume un modello elementare con osservazioni indipendenti. Nella pratica, la deviazione standard deve essere stimata o ipotizzata e l'ampiezza effettiva dell'intervallo può risultare casuale. L'impiego della distribuzione t può richiedere un calcolo iterativo, mentre clustering, misure ripetute, pesi campionari e dati mancanti modificano la precisione. Parametri diversi dalla media richiedono inoltre formule specifiche o una pianificazione basata sulla simulazione.

5.4 Pianificare la potenza di un test

Per una specifica alternativa, la potenza è definita come

$$1 - \beta = P(\text{rifiutare } H_0 \mid \theta = \theta_1),$$

dove θ_1 rappresenta il valore del parametro assunto nella pianificazione.

Affermare che un test possiede potenza pari a 0.80 significa che, se l'effetto specificato, il modello e il disegno fossero quelli assunti, circa l'80% delle ripetizioni produrrebbe un risultato capace di rifiutare H_0 al livello scelto.

Questa affermazione non attribuisce probabilità alle ipotesi. Non significa che H_1 abbia probabilità 0.80, che lo studio abbia l'80% di probabilità di essere corretto o che, dopo un risultato significativo, vi sia l'80% di probabilità che l'effetto sia reale. La potenza descrive una proprietà della procedura sotto un'alternativa specificata.

5.4.1 La potenza è una funzione

La potenza cambia al variare del valore vero dell'effetto. Uno studio non può quindi essere descritto semplicemente come potente o non potente senza chiarire rispetto a quale alternativa venga valutato.

A parità delle altre condizioni, la potenza aumenta quando cresce la dimensione dell'effetto, quando diminuisce la variabilità o quando aumenta la numerosità. Dipende inoltre dal livello α , dalla scelta tra test unilaterale e bilaterale, dall'allocazione dei partecipanti tra i gruppi, dalla struttura di dipendenza dei dati e dall'affidabilità delle misure.

Queste dipendenze mostrano perché una singola percentuale non sia sufficiente a descrivere la capacità informativa di uno studio. La potenza è una funzione dell'effetto e delle assunzioni progettuali.

! Potenza per rilevare che cosa?

Dire che «lo studio ha potenza 0.80» è incompleto. Una formulazione interpretabile deve specificare almeno l'alternativa e le principali assunzioni:

Il test bilaterale di livello 0.05 ha potenza 0.80 per una differenza di 3 punti, assumendo una deviazione standard pari a 6 e il modello specificato.

5.5 Scegliere l'effetto bersaglio

La pianificazione non dovrebbe utilizzare automaticamente l'effetto osservato in un singolo studio precedente. Gli effetti pubblicati, soprattutto quando derivano da campioni piccoli o sono stati selezionati perché statisticamente significativi, possono sovrastimare la grandezza reale del fenomeno. Costruire il nuovo studio su una stima instabile rischia quindi di produrre una numerosità insufficiente.

Una strategia più trasparente consiste nel definire il **più piccolo effetto di interesse**, indicato spesso con l'acronimo SESOI, da *smallest effect size of interest*:

Qual è il più piccolo effetto che cambierebbe una conclusione teorica, clinica, educativa o decisionale?

La risposta può essere fondata su una soglia di rilevanza clinica o pratica, sui costi e benefici associati a una decisione, sulla precisione dello strumento, sul confronto con effetti già conosciuti, su vincoli derivati da una teoria o sul giudizio motivato di esperti e portatori di interesse. Nessuna di queste fonti è automatica: il loro compito è collegare il numero utilizzato nel calcolo a una conseguenza scientifica comprensibile.

Quando possibile, è preferibile esprimere l'effetto nella scala originale. Un effetto standardizzato dipende infatti anche dalla deviazione standard prevista. La stessa differenza grezza può quindi produrre valori standardizzati diversi in popolazioni caratterizzate da variabilità differente.

! Convenzioni non equivalgono a rilevanza

Le etichette convenzionali di effetto «piccolo», «medio» o «grande» possono offrire un riferimento descrittivo, ma non stabiliscono quale differenza sia importante per la specifica domanda di ricerca. La rilevanza deve essere motivata nel contesto teorico o applicativo dello studio.

5.6 Esempio: test t per una media

Supponiamo di voler confrontare una media con un valore di riferimento. Consideriamo scientificamente rilevante una differenza di 3 punti e prevediamo una

deviazione standard pari a 6. Pianifichiamo un test bilaterale con $\alpha = 0.05$ e potenza 0.80.

```
piano_un_campione <- power.t.test(
  delta = 3,
  sd = 6,
  sig.level = 0.05,
  power = 0.80,
  type = "one.sample",
  alternative = "two.sided"
)

piano_un_campione
#>
#>      One-sample t test power calculation
#>
#>              n = 33.4
#>          delta = 3
#>             sd = 6
#>    sig.level = 0.05
#>         power = 0.8
#> alternative = two.sided
ceiling(piano_un_campione$n)
#> [1] 34
```

Il risultato richiede 34 osservazioni analizzabili.

L'interpretazione resta interamente condizionale: se la differenza vera fosse pari a 3 punti, la deviazione standard fosse 6 e le assunzioni del test fossero appropriate, il test rifiuterebbe H_0 in circa l'80% delle ripetizioni. Se la differenza vera fosse più piccola o la variabilità maggiore, la potenza effettiva sarebbe inferiore.

5.7 Esempio: due gruppi indipendenti

Consideriamo ora un confronto tra due gruppi di uguale numerosità. L'effetto minimo di interesse è una differenza di 5 punti e la deviazione standard comune prevista è 6.

```
piano_due_gruppi <- power.t.test(
  delta = 5,
  sd = 6,
  sig.level = 0.05,
  power = 0.80,
  type = "two.sample",
  alternative = "two.sided"
)

piano_due_gruppi
#>
#>      Two-sample t test power calculation
#>
#>              n = 23.6
#>          delta = 5
```



```
#>          sd = 6
#>      sig.level = 0.05
#>          power = 0.8
#> alternative = two.sided
#>
#> NOTE: n is number in each group
ceiling(piano_due_gruppi$n)
#> [1] 24
```

Il risultato richiede 24 partecipanti analizzabili **per gruppo**, quindi 48 complessivi.

La distinzione tra numerosità per gruppo e numerosità totale è importante nella lettura dell'output di `power.t.test()`. Nel caso di un confronto a due campioni, il valore restituito da `n` si riferisce a ciascun gruppo quando l'allocazione è bilanciata.

L'esempio prepara il capitolo successivo, nel quale applicheremo il test *t* al confronto tra gruppi indipendenti. In questa fase, tuttavia, l'obiettivo non è ancora eseguire il test, ma comprendere quali assunzioni rendano interpretabile il numero ottenuto.

5.7.1 Sensibilità all'effetto bersaglio

Possiamo ora ripetere il calcolo per più differenze bersaglio, mantenendo costanti la deviazione standard, il livello α e la potenza desiderata.

```
differenze <- c(2, 3, 4, 5, 6)

n_per_gruppo <- vapply(
  differenze,
  function(differenza) {
    risultato <- power.t.test(
      delta = differenza,
      sd = 6,
      sig.level = 0.05,
      power = 0.80,
      type = "two.sample",
      alternative = "two.sided"
    )
    ceiling(risultato$n)
  },
  numeric(1)
)

risultati_potenza <- data.frame(
  differenza_bersaglio = differenze,
  n_per_gruppo = n_per_gruppo,
  n_totale = 2 * n_per_gruppo
)

knitr::kable(risultati_potenza)
```

Tabella 5.2: Numerosità per gruppo richiesta al variare della differenza bersaglio, assumendo deviazione standard pari a 6, test bilaterale, livello 0.05 e potenza 0.80.

differenza_bersaglio	n_per_gruppo	n_totale
2	143	286
3	64	128
4	37	74
5	24	48
6	17	34

La Tabella 5.2 mostra che la numerosità dipende fortemente dall'effetto scelto. Questa sensibilità non costituisce un difetto del software. Riflette una proprietà del problema inferenziale: effetti piccoli sono più difficili da distinguere dalla variabilità campionaria e richiedono quindi una quantità maggiore di informazione.

5.7.2 Curve di potenza

La relazione tra numerosità, dimensione dell'effetto e potenza può essere rappresentata attraverso curve distinte per differenti valori veri della differenza.

```
griglia_potenza <- expand.grid(
  n_per_gruppo = seq(10, 100, by = 2),
  differenza = c(2, 3, 5)
)

griglia_potenza$potenza <- mapply(
  function(n, differenza) {
    power.t.test(
      n = n,
      delta = differenza,
      sd = 6,
      sig.level = 0.05,
      type = "two.sample",
      alternative = "two.sided"
    )$power
  },
  n = griglia_potenza$n_per_gruppo,
  differenza = griglia_potenza$differenza
)

griglia_potenza$differenza <- factor(
  griglia_potenza$differenza
)

ggplot(
  griglia_potenza,
  aes(
    x = n_per_gruppo,
    y = potenza,
    linetype = differenza
  )
)
```

```

) +
geom_line(linewidth = 0.9) +
geom_hline(yintercept = 0.80, linetype = "dashed") +
labs(
  x = "Partecipanti analizzabili per gruppo",
  y = "Potenza",
  linetype = "Differenza vera"
)

```




Figura 5.1: Potenza di un test t bilaterale per due gruppi di uguale numerosità, per tre differenze vere e deviazione standard pari a 6.

La Figura 5.1 rende visibile che la potenza non è una caratteristica fissa del disegno. Ogni possibile effetto produce una curva differente. A una stessa numerosità, il test è più sensibile agli effetti grandi e meno sensibile a quelli piccoli; per una stessa differenza, la potenza cresce invece all'aumentare del numero di partecipanti.

5.8 Dalla numerosità analitica al reclutamento

Il valore restituito da un calcolo di pianificazione indica generalmente quante osservazioni **utilizzabili nell'analisi** siano necessarie. Il numero iniziale di persone da reclutare può essere maggiore, perché non tutti i partecipanti completano lo studio o producono dati conformi ai criteri stabiliti.

Se prevediamo una quota di perdita r , un aggiustamento elementare è

$$n_{\text{reclutare}} = \left\lceil \frac{n_{\text{analizzabile}}}{1 - r} \right\rceil.$$

Supponiamo, per esempio, che siano necessari 48 partecipanti analizzabili e che si preveda il 15% di abbandoni o dati inutilizzabili.

```
n_analizzabile <- 48
perdita_attesa <- 0.15

ceiling(
  n_analizzabile / (1 - perdita_attesa)
)
#> [1] 57
```

Il calcolo indica che occorre reclutare almeno 57 partecipanti, assumendo che la perdita sia plausibilmente vicina al 15%.

Questo aggiustamento protegge la numerosità finale, ma non risolve automaticamente i problemi generati dai dati mancanti. Se l'abbandono dipende dall'esito, dal trattamento o da caratteristiche rilevanti dei partecipanti, può introdurre una distorsione oltre a ridurre il campione. La pianificazione deve quindi considerare non soltanto quanti dati potrebbero mancare, ma anche perché potrebbero mancare.

5.8.1 Disegni complessi

La numerosità richiesta può aumentare quando le osservazioni non forniscono informazione indipendente. È ciò che accade, per esempio, quando gli studenti sono raggruppati in classi, i pazienti sono trattati dagli stessi terapeuti, la stessa persona viene misurata più volte oppure le unità statistiche appartengono a coppie o famiglie. Anche la presenza di più esiti o confronti primari può modificare i requisiti della pianificazione.

In questi contesti occorre utilizzare un modello coerente con la struttura del disegno, ricorrendo a formule specifiche o, più spesso, a simulazioni. Applicare la formula prevista per osservazioni indipendenti e aumentare arbitrariamente n non garantisce il livello di precisione o di potenza desiderato.

5.9 Analisi di sensibilità della pianificazione

Prima della raccolta dei dati, la deviazione standard, il tasso di abbandono e persino l'effetto bersaglio sono spesso incerti. Presentare un unico valore di n può nascondere questa incertezza e dare un'impressione di precisione che il calcolo non possiede.

È più informativo esaminare più scenari. Uno scenario ottimistico può utilizzare una variabilità relativamente contenuta e perdite modeste; uno scenario centrale può riflettere le ipotesi considerate più plausibili; uno scenario prudente può assumere una variabilità maggiore, un effetto più piccolo o un tasso di abbandono più elevato.

Calcolare la numerosità sotto ciascuno scenario permette di capire quali assunzioni guidino maggiormente il risultato e di valutare il rischio di progettare uno studio insufficiente. La scelta finale dovrebbe essere accompagnata dalla descrizione esplicita degli scenari e delle fonti utilizzate per definirli.

i Il calcolo è una conseguenza delle assunzioni

Un risultato come «servono 48 partecipanti» costituisce l'abbreviazione di una frase molto più completa:

Servono 48 partecipanti analizzabili per il test, l'effetto, la variabilità, l'allocazione, il livello α e la potenza specificati.

La modifica di una sola di queste quantità può cambiare sostanzialmente il risultato.

5.10 Perché la potenza post hoc è poco informativa?

Dopo la conclusione di uno studio, talvolta si inserisce nella formula di potenza l'effetto osservato e si calcola la cosiddetta *potenza osservata*. Questa pratica può sembrare un modo per stabilire se lo studio fosse adeguato, ma la quantità ottenuta è quasi interamente determinata dalla statistica test o dal valore- p .

Un risultato significativo tende a produrre una potenza osservata elevata; un risultato non significativo tende a produrre una potenza osservata bassa. Il nuovo numero riproduce quindi, in una forma diversa, un'informazione già contenuta nell'esito del test e non fornisce una valutazione indipendente della qualità o della precisione dello studio.

Dopo la raccolta dei dati è generalmente più utile esaminare la stima dell'effetto, il relativo intervallo di confidenza, la compatibilità dei dati con effetti scientificamente rilevanti e la plausibilità delle assunzioni. Anche la qualità del disegno e delle misure deve essere discussa direttamente, perché non può essere riassunta da una percentuale di potenza post hoc.

Un'analisi di potenza può tornare utile per progettare uno studio futuro. In questo caso, tuttavia, non è opportuno trattare meccanicamente l'effetto instabile osservato nel primo studio come se fosse il valore vero. La nuova pianificazione dovrebbe utilizzare un effetto bersaglio motivato e includere un'analisi di sensibilità.

5.11 Pianificazione frequentista e bayesiana

La pianificazione frequentista definisce spesso uno studio adeguato attraverso proprietà della procedura nelle ripetizioni. Può richiedere una determinata copertura o ampiezza attesa dell'intervallo, il controllo dell'errore di tipo I oppure una potenza prestabilita rispetto a un effetto bersaglio.

Una pianificazione bayesiana può invece formulare criteri relativi alla distribuzione a posteriori o alle conseguenze decisionali. Può domandare quanto debba essere stretta la distribuzione a posteriori, con quale probabilità il parametro debba superare una soglia pratica, quale sia la probabilità predittiva di raggiungere una decisione oppure quale disegno massimizzi l'utilità attesa.

Le due prospettive non sono necessariamente separate sul piano computazionale. Entrambe possono essere studiate mediante simulazione. Una procedura bayesiana può essere valutata anche per le sue proprietà frequentiste, mentre una pianificazione frequentista può utilizzare conoscenze precedenti per definire scenari realistici di variabilità ed effetto.

La differenza principale non consiste quindi nel fatto che una prospettiva pianifichi e l'altra no. Riguarda il criterio con cui viene stabilito che uno studio sia sufficientemente informativo.

! Un confronto senza scorciatoie

La potenza non risponde direttamente alla domanda relativa a quanta incertezza rimarrà sul parametro dopo lo studio. Una distribuzione a posteriori stretta, d'altra parte, non garantisce automaticamente una buona copertura frequentista né protegge dalle conseguenze di un modello mal specificato. Entrambe le forme di pianificazione richiedono obiettivi sostantivi, un modello plausibile e assunzioni formulate in modo trasparente.

Riflessioni conclusive

La numerosità campionaria non è una proprietà generale di un argomento di ricerca. È il risultato di una pianificazione riferita a una domanda, a una procedura e a un insieme specifico di assunzioni.

La pianificazione per precisione rende esplicito quanto debba essere stretto l'intervallo affinché la stima sia utile. La pianificazione per potenza stabilisce invece quale effetto il test debba riuscire a rilevare e con quale probabilità. I due obiettivi sono collegati dalla variabilità campionaria, ma non sono intercambiabili.

In entrambi i casi, il numero calcolato è condizionale. La variabilità effettiva, gli abbandoni, la dipendenza tra osservazioni, l'affidabilità delle misure e le differenze tra il disegno ideale e la sua realizzazione concreta possono modificare il fabbisogno. Per questa ragione, una buona pianificazione non presenta soltanto un numero finale, ma rende visibili le assunzioni da cui esso deriva e mostra quanto il risultato cambi sotto scenari alternativi.

Nel prossimo capitolo applicheremo questi concetti al confronto tra due gruppi indipendenti. La numerosità non verrà trattata come un'aggiunta finale all'analisi, ma come parte integrante del modello inferenziale e del disegno dello studio.

Esercizi

1. Qual è la differenza tra pianificare uno studio per precisione e pianificarlo per potenza?
2. Perché dimezzare il margine di errore richiede approssimativamente quattro volte le osservazioni nel caso elementare della media?

3. Che cosa significa affermare che un test ha potenza 0.80 per una differenza di 3 punti?
4. Perché la frase «lo studio ha potenza 0.80» è incompleta?
5. Perché è preferibile motivare un effetto minimo di interesse nella scala originale, quando possibile?
6. Un calcolo richiede 48 partecipanti analizzabili e si prevede il 15% di perdite. Perché il numero da reclutare deve essere maggiore di 48?
7. Perché la potenza osservata, calcolata usando l'effetto ottenuto nello stesso studio, aggiunge poca informazione al valore- p ?
8. In che modo differiscono gli obiettivi tipici di una pianificazione frequentista e di una pianificazione bayesiana?

Soluzioni

1. La pianificazione per precisione sceglie n affinché l'intervallo risulti sufficientemente stretto. La pianificazione per potenza sceglie invece n affinché il test raggiunga una probabilità prefissata di rifiutare H_0 sotto una specifica alternativa.
2. Il margine di errore è proporzionale a $1/\sqrt{n}$. Per ridurlo della metà occorre raddoppiare $\sqrt{n}$ e quindi quadruplicare n .
3. Se la differenza vera fosse pari a 3 punti e tutte le altre assunzioni corrispondessero a quelle della pianificazione, il test rifiuterebbe H_0 in circa l'80% delle ripetizioni.
4. La potenza dipende dall'effetto vero, dalla variabilità, da α , dalla numerosità, dal tipo di test e dal disegno. Senza specificare almeno l'alternativa rispetto alla quale è stata calcolata, la percentuale non è interpretabile.
5. La rilevanza scientifica riguarda spesso una differenza concreta nel costrutto misurato. Un effetto standardizzato dipende anche dalla deviazione standard della popolazione e può quindi assumere un significato diverso in contesti differenti.
6. Il calcolo riguarda le osservazioni che entreranno nell'analisi. Se alcune persone abbandonano lo studio o producono dati inutilizzabili, occorre reclutarne un numero maggiore per conservare la numerosità finale desiderata.
7. Quando viene calcolata usando l'effetto osservato, la potenza diventa quasi una trasformazione della statistica test: i risultati significativi producono valori elevati e quelli non significativi valori bassi. Non offre quindi una nuova misura indipendente della precisione o della qualità dello studio.
8. La pianificazione frequentista utilizza spesso criteri di copertura, ampiezza, errore di tipo I e potenza. Quella bayesiana può utilizzare la precisione a posteriori, la probabilità di superare soglie decisionali o l'utilità attesa. Entrambe dipendono da modelli e obiettivi espliciti.

i Punti chiave

Non esiste una numerosità adeguata indipendentemente dalla domanda e dal disegno. Precisione e potenza sono obiettivi collegati, ma distinti. La pianificazione per precisione dipende dalla variabilità, dal margine di errore e dal livello di confidenza; quella per potenza richiede una specifica alternativa e un effetto minimo di interesse motivato scientificamente. Gli effetti standardizzati dipendono dalla variabilità prevista e non sostituiscono una valutazione nella scala originale. Nel confronto tra due gruppi, `power.t.test()` restituisce la numerosità richiesta per ciascun gruppo. Il numero di osservazioni analizzabili deve essere distinto dall'obiettivo di reclutamento, perché abbandoni, dati mancanti e dipendenze possono aumentare il fabbisogno. La potenza post hoc basata sull'effetto osservato è generalmente ridondante. La pianificazione frequentista e quella bayesiana definiscono infine attraverso criteri differenti quando uno studio possa essere considerato sufficientemente informativo.

i Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:
#>   ↪ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#>
#> LAPACK:
#>   ↪ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>   ↪ LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices utils      datasets  methods   base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0    withr_3.0.3
#>
#> [4] systemfonts_1.3.2  patchwork_1.3.2     ggdist_3.3.3
#>
#> [7] tidybayes_3.0.7     bayesplot_1.15.0    ggplot2_4.0.3
#>
```



```

#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.1              rstan_2.32.7      StanHeaders_2.32.10
#> [16] brms_2.23.0             Rcpp_1.1.2        sessioninfo_1.2.4
#> [19] conflicted_1.2.0        janitor_2.2.1      matrixStats_1.5.0
#> [22] modelr_0.1.11           tibble_3.3.1       dplyr_1.2.1
#> [25] tidyr_1.3.2             rio_1.3.0          here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8            tidyselect_1.2.1     farver_2.1.2
#> [4] S7_0.2.2                fastmap_1.2.0        tensorA_0.36.2.1
#> [7] digest_0.6.39           timechange_0.4.0     estimability_2.0.0
#> [10] lifecycle_1.0.5         magrittr_2.0.5       compiler_4.6.1
#> [13] rlang_1.3.0             tools_4.6.1          yaml_2.3.12
#> [16] knitr_1.51              labeling_0.4.3
#> [19] pkgbuild_1.4.8          curl_7.1.0           RColorBrewer_1.1-3
#> [22] abind_1.4-8            purrr_1.2.2          grid_4.6.1
#> [25] stats4_4.6.1           xtable_1.8-8         inline_0.3.21
#> [28] emmeans_2.0.4          scales_1.4.0         cli_3.6.6
#> [31] mvtnorm_1.4-2          rmarkdown_2.31       generics_0.1.4
#> [34] otel_0.2.0             RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0          parallel_4.6.1       vctrs_0.7.3
#> [40] V8_8.2.0               Matrix_1.7-6         jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2     glue_1.8.1          codetools_0.2-20
#> [46] distributional_0.8.1   lubridate_1.9.5      stringi_1.8.7
#> [49] gtable_0.3.6           QuickJSR_1.10.0      pillar_1.11.1
#> [52] htmltools_0.5.9        Brodingtonag_1.2-9   R6_2.6.1
#> [55] textshaping_1.0.5      rprojroot_2.1.1     evaluate_1.0.5
#> [58] lattice_0.22-9         backports_1.5.1      memoise_2.0.1

```

```
#> [61] broom_1.0.13          snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1         gridExtra_2.3.1       nlme_3.1-170
#> [67] checkmate_2.3.4       xfun_0.60             pkgconfig_2.0.3
```

Bibliografia

Riferimenti bibliografici

Giner-Sorolla, R., Montoya, A. K., Reifman, A., Carpenter, T., Lewis Jr, N. A., Aberson, C. L., Bostyn, D. H., Conrique, B. G., Ng, B. W., Schoemann, A. M., et al. (2024). Power to detect what? Considerations for planning and evaluating sample size. *Personality and Social Psychology Review*, 28(3), 276–301.

Confrontare due gruppi indipendenti

i In sintesi

Da sapere Il confronto tra due gruppi indipendenti stima una differenza tra medie e ne valuta la precisione e la compatibilità con un valore nullo. Il test t di Welch costituisce spesso una scelta predefinita appropriata, perché non richiede di assumere che le due popolazioni abbiano la stessa varianza.

Da saper fare Al termine del capitolo, il lettore dovrebbe saper definire la differenza di interesse e il suo ordine, riconoscere quando i gruppi sono realmente indipendenti, interpretare congiuntamente statistiche descrittive, intervallo di confidenza, valore- p e dimensione dell'effetto, distinguere una differenza associativa da un effetto causale e collegare il test t a un modello di regressione con predittore dicotomico.

Introduzione

Il confronto tra due gruppi indipendenti è una delle situazioni più frequenti nella ricerca psicologica. Possiamo voler confrontare un gruppo che ha ricevuto un intervento con un gruppo di controllo, due condizioni sperimentali assegnate a persone differenti oppure due gruppi definiti da una caratteristica osservata. In tutti questi casi, la domanda iniziale riguarda una differenza tra medie, ma la sua interpretazione richiede di integrare i diversi concetti sviluppati nei capitoli precedenti:

stima $\rightarrow$ errore standard $\rightarrow$ intervallo di confidenza $\rightarrow$ test $\rightarrow$ dimensione dell'effetto.

L'obiettivo del capitolo non è presentare il test t come una procedura isolata da applicare meccanicamente. È mostrare come la differenza osservata, la sua precisione, la compatibilità con un valore nullo e la sua rilevanza sostantiva descrivano aspetti differenti dello stesso problema scientifico.

Nel quadro frequentista, il test t risponde a una domanda condizionale:

Se la differenza tra le medie delle popolazioni fosse nulla e il modello fosse adeguato, quanto sarebbe estremo il risultato osservato?

Questa domanda non coincide con la probabilità che le medie siano uguali, con la probabilità che un intervento funzioni o con la probabilità che la differenza superi una soglia clinicamente importante. Per rispondere a queste domande occorrono quantità inferenziali e, in alcuni casi, disegni differenti.

Prerequisiti

Il capitolo riunisce le nozioni introdotte in Capitolo 2, dedicate a stimatore, stima ed errore standard, in Capitolo 3, relative alla copertura degli intervalli, in Capitolo 4, dedicate al valore- p e agli errori decisionali, e in Capitolo 5, dove sono stati discussi effetto bersaglio, potenza e numerosità. Questi concetti vengono ora applicati a un unico problema e completano la parte operativa del modulo.

Panoramica del capitolo

Il percorso inizia dalla definizione della quantità che si desidera confrontare e dalla distinzione tra gruppi indipendenti, dati appaiati e misure ripetute. Verranno quindi introdotti il test t classico e il test di Welch, con particolare attenzione alle assunzioni che li distinguono e al ruolo del disegno.

Un esempio completo in R mostrerà come descrivere i dati, visualizzarne la distribuzione, eseguire il test e interpretare insieme la differenza grezza, l'intervallo di confidenza, il valore- p e la dimensione standardizzata dell'effetto. La discussione si estenderà poi alla rilevanza pratica, all'equivalenza e alle condizioni necessarie per attribuire un significato causale alla differenza osservata. Infine, il confronto tra gruppi verrà riscritto come un modello lineare con predittore dicotomico, creando un collegamento diretto con l'analisi bayesiana sviluppata nel Companion.

Preparazione del notebook

Per eseguire gli esempi, prepara l'ambiente comune del progetto:

```
here::here("code", "_common.R") |>  
  source()
```

6.1 Prima del test: definire il confronto

Immaginiamo uno studio dedicato a un intervento di regolazione emotiva. Un gruppo riceve l'intervento, mentre un gruppo di controllo non lo riceve. Al termine dello studio viene misurato il benessere psicologico.

Indichiamo con

μ_1 = media della popolazione del gruppo intervento

e con

μ_0 = media della popolazione del gruppo controllo.

La quantità bersaglio è la differenza

$$\Delta = \mu_1 - \mu_0.$$

La corrispondente stima campionaria è

$$\hat{\Delta} = \bar{X}_1 - \bar{X}_0.$$

Il segno della differenza dipende dall'ordine della sottrazione. Con la definizione adottata, un valore positivo di $\hat{\Delta}$ indica che la media del gruppo intervento è maggiore, mentre un valore negativo indica che la media del gruppo controllo è maggiore.

! Definire l'ordine prima di interpretare il segno

La stessa differenza può essere scritta come intervento meno controllo oppure come controllo meno intervento. Il valore assoluto non cambia, ma il segno sì. L'ordine deve essere dichiarato prima dell'analisi e mantenuto coerente nella stima, nell'intervallo, nella dimensione dell'effetto e nel resoconto finale.

6.1.1 Quale popolazione rappresentano le medie?

Le quantità μ_1 e μ_0 acquistano significato soltanto rispetto alla popolazione alla quale si intende generalizzare, ai criteri con cui i partecipanti sono stati inclusi, alla modalità di assegnazione ai gruppi, al momento e allo strumento con cui l'esito è stato misurato e alle decisioni relative ai dati mancanti. Anche il modello statistico contribuisce a definire ciò che viene stimato.

Una differenza tra medie non è dunque un oggetto separato dal disegno. Prima di calcolare il test occorre chiarire che cosa rappresentino i due gruppi, quale popolazione descrivano e perché il confronto scelto sia rilevante per la domanda scientifica.

6.2 Gruppi indipendenti, dati appaiati e misure ripetute

Due gruppi sono **indipendenti** quando l'osservazione di una persona nel primo gruppo non è naturalmente collegata a una specifica osservazione del secondo gruppo. È ciò che accade, per esempio, quando persone differenti vengono assegnate all'intervento e al controllo, quando i partecipanti provengono da due popolazioni distinte

oppure quando si confrontano due gruppi osservazionali privi di un abbinamento individuale.

La situazione cambia quando le osservazioni appartengono alle stesse persone in momenti diversi, a coppie appaiate, a gemelli o membri della stessa famiglia, oppure a individui inseriti nella stessa classe o nello stesso contesto. Anche più osservazioni prodotte dal medesimo partecipante sono dipendenti.

Nel caso di dati appaiati o di misure ripetute, la quantità rilevante è spesso la differenza calcolata all'interno di ciascuna coppia o persona. Trattare queste osservazioni come se provenissero da gruppi indipendenti ignora una parte essenziale della struttura dei dati e può produrre un errore standard non coerente con il disegno.



L'indipendenza non si verifica con un test automatico

L'indipendenza è soprattutto una proprietà del disegno e del processo di raccolta. Un grafico o un test di normalità non possono dimostrare che osservazioni provenienti dalla stessa classe, famiglia o persona siano indipendenti.

6.3 Il modello inferenziale

6.3.1 Ipotesi nulla e alternativa

Nel test bilaterale, l'ipotesi nulla stabilisce che la differenza tra le medie sia pari a zero:

$$H_0 : \Delta = 0.$$

L'alternativa ammette invece una differenza in una qualunque delle due direzioni:

$$H_1 : \Delta \neq 0.$$

Quando la domanda scientifica riguarda esclusivamente una direzione, può essere formulata un'alternativa come

$$H_1 : \Delta > 0.$$

La scelta deve precedere l'osservazione dei dati e deve avere una motivazione sostantiva. Il test bilaterale costituisce una scelta introduttiva prudente quando una deviazione in entrambe le direzioni avrebbe rilevanza scientifica.

6.3.2 Struttura generale della statistica

La statistica test ha la forma

$$t = \frac{\hat{\Delta} - 0}{\widehat{SE}(\hat{\Delta})}.$$

Il numeratore esprime la distanza tra la differenza osservata e il valore nullo. Il denominatore descrive quanto la differenza tra le medie cambierebbe da un campione all'altro secondo il modello adottato. La statistica mette quindi in relazione la grandezza dello scostamento con la variabilità campionaria prevista.

6.4 Test t classico e test di Welch

6.4.1 Test classico con varianze uguali

Il test t classico assume che le due popolazioni possiedano una varianza comune. Le due varianze campionarie vengono quindi combinate nella deviazione standard pooled:

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_0 - 1)s_0^2}{n_1 + n_0 - 2}}.$$

L'errore standard della differenza è

$$\widehat{SE}_{\text{pooled}} = s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_0}}.$$

Quando le assunzioni del modello sono soddisfatte, la statistica segue una distribuzione t con

$$df = n_1 + n_0 - 2.$$

6.4.2 Test di Welch

Il test di Welch non impone che le due popolazioni abbiano la stessa varianza. L'errore standard viene calcolato come

$$\widehat{SE}_{\text{Welch}} = \sqrt{\frac{s_1^2}{n_1} + \frac{s_0^2}{n_0}}.$$

I gradi di libertà vengono approssimati mediante la formula di Welch-Satterthwaite:

$$\nu = \frac{(s_1^2/n_1 + s_0^2/n_0)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_0^2/n_0)^2}{n_0 - 1}}.$$

In R, `t.test()` utilizza Welch come impostazione predefinita.

i Perché Welch è una buona scelta predefinita

Quando varianze e numerosità sono simili, Welch e il test classico producono spesso risultati quasi identici. Quando invece le dispersioni o le dimensioni dei gruppi differiscono, Welch evita di imporre un'uguaglianza non giustificata. Non è corretto descriverlo semplicemente come un test più prudente. È una procedura costruita per un modello che consente alle due popolazioni di avere dispersioni differenti.

L'impiego del test classico dovrebbe derivare da una ragione sostantiva o progettuale per assumere una varianza comune, non dal mancato rifiuto di un test preliminare sulle varianze. Verificare prima l'uguaglianza delle varianze e scegliere poi il test sulla base dello stesso campione produce una procedura in due stadi le cui proprietà inferenziali sono meno trasparenti.

6.5 Assunzioni e adeguatezza

6.5.1 Indipendenza e disegno

L'indipendenza è una condizione essenziale per le formule standard. Quando le osservazioni sono raggruppate, abbinate o ripetute, il modello deve rappresentare esplicitamente questa dipendenza. Non è sufficiente aumentare la numerosità o applicare una diversa correzione alla fine dell'analisi.

6.5.2 Esito quantitativo

Il test confronta le medie e richiede quindi un esito quantitativo, oppure una misura che possa essere trattata in modo difendibile come approssimativamente quantitativa. Questa scelta merita particolare attenzione quando il punteggio possiede pochi livelli, presenta forti effetti di pavimento o soffitto oppure deriva da una scala la cui unità di misura è difficile da interpretare.

6.5.3 Distribuzione entro i gruppi

L'esattezza del test classico e di Welch deriva dall'assunzione di popolazioni normali. Le procedure sono spesso robuste a deviazioni moderate quando i campioni non sono molto piccoli, le distribuzioni non sono fortemente asimmetriche, non compaiono valori estremi influenti e il disegno non combina un forte squilibrio delle numerosità con una marcata eteroschedasticità.

La robustezza non rende irrilevante la forma dei dati. Nei campioni piccoli, distribuzioni con code pesanti, forte asimmetria o osservazioni estreme possono rendere instabili la media, la deviazione standard e la statistica test. In questi casi è necessario esaminare i dati, valutare procedure alternative o utilizzare modelli più adatti alla struttura osservata.

6.5.4 Valori anomali

Un valore anomalo può spostare la media, aumentare la deviazione standard, modificare l'errore standard e influenzare sia il valore- p sia la dimensione standardizzata dell'effetto. Non deve però essere eliminato automaticamente.

Occorre anzitutto verificare se derivi da un errore di registrazione o di misurazione. Se il valore è plausibile, bisogna domandarsi se appartenga alla popolazione definita dallo studio e quanto le conclusioni dipendano dalla sua presenza. Un'analisi di sensibilità è spesso più informativa di una cancellazione priva di giustificazione.

! Il controllo delle assunzioni è parte dell'analisi

Controllare le assunzioni non significa cercare un test preliminare che autorizzi meccanicamente l'uso del test t . Significa collegare la forma dei dati, il disegno, la qualità delle misure e le conseguenze delle possibili deviazioni al modello utilizzato.

6.6 Un esempio guidato

Consideriamo un insieme di dati didattici sul benessere psicologico. Dodici partecipanti appartengono al gruppo intervento e dodici al gruppo di controllo.

```
benessere_intervento <- c(
  27, 31, 29, 33, 35, 30,
  32, 28, 34, 31, 36, 29
)

benessere_controllo <- c(
  24, 26, 28, 25, 29, 27,
  23, 30, 26, 25, 28, 24
)

dati_benessere <- data.frame(
  gruppo = factor(
    rep(
      c("Controllo", "Intervento"),
      each = 12
    ),
    levels = c("Controllo", "Intervento")
  ),
  benessere = c(
    benessere_controllo,
    benessere_intervento
  )
)
```

La codifica fissa l'ordine del confronto come

$$\Delta = \mu_{\text{intervento}} - \mu_{\text{controllo}}.$$

6.6.1 Descrizione prima dell'inferenza

Prima di eseguire il test, è necessario conoscere numerosità, media e dispersione di ciascun gruppo.

```
gruppi <- split(
  dati_benessere$benessere,
  dati_benessere$gruppo
)

descrittive <- data.frame(
  gruppo = names(gruppi),
  n = vapply(gruppi, length, integer(1)),
  media = vapply(gruppi, mean, numeric(1)),
  deviazione_standard = vapply(gruppi, sd, numeric(1)),
  row.names = NULL
)

descrittive$media <- round(descrittive$media, 2)
descrittive$deviazione_standard <-
  round(descrittive$deviazione_standard, 2)

knitr::kable(descrittive)
```

Tabella 6.1: Statistiche descrittive dei punteggi di benessere nei due gruppi.

gruppo	n	media	deviazione_standard
Controllo	12	26.2	2.18
Intervento	12	31.2	2.83

Le medie campionarie sono

$$\bar{x}_{\text{intervento}} = 31.25$$

e

$$\bar{x}_{\text{controllo}} = 26.25.$$

La differenza osservata è quindi

$$\hat{\Delta} = 5.00.$$

Questo valore descrive il campione: la media del gruppo intervento supera di 5 punti quella del gruppo controllo. Per stabilire quanto la differenza sia precisa e quanto sia compatibile con il valore nullo, dobbiamo però considerare anche la variabilità entro i gruppi e la distribuzione campionaria dello stimatore.

6.6.2 Visualizzare distribuzioni e osservazioni

```
ggplot(
```

```

dati_benessere,
aes(x = gruppo, y = benessere)
) +
geom_boxplot(
  width = 0.45,
  alpha = 0.35,
  outlier.shape = NA
) +
geom_jitter(
  width = 0.08,
  alpha = 0.8,
  size = 2
) +
stat_summary(
  fun = mean,
  geom = "point",
  shape = 18,
  size = 4
) +
labs(
  x = "Gruppo",
  y = "Punteggio di benessere"
)

```




Figura 6.1: Punteggi individuali e distribuzioni nei gruppi controllo e intervento. Il simbolo a rombo indica la media.

Figura 6.1 permette di osservare contemporaneamente la posizione delle distribuzioni, la loro dispersione, il grado di sovrapposizione e le singole osservazioni. Il grafico non sostituisce l'inferenza, ma impedisce che il confronto venga ridotto a una sola statistica. In particolare, aiuta a riconoscere eventuali valori influenti, asimmetrie o differenze di variabilità che meritino attenzione.

6.7 Eseguire il test di Welch

Eseguiamo ora il test bilaterale di Welch.

```
test_welch <- t.test(
  benessere ~ gruppo,
  data = dati_benessere,
  alternative = "two.sided",
  var.equal = FALSE,
  conf.level = 0.95
)

test_welch
#>
#> Welch Two Sample t-test
#>
#> data:  benessere by gruppo
#> t = -5, df = 21, p-value = 0.00009
#> alternative hypothesis: true difference in means between group Controllo
#>   and group Intervento is not equal to 0
#> 95 percent confidence interval:
#>  -7.15 -2.85
#> sample estimates:
#>  mean in group Controllo mean in group Intervento
#>                26.2                31.2
```

Poiché il primo livello del fattore è Controllo, la formula di R riporta inizialmente la differenza

$$\mu_{\text{controllo}} - \mu_{\text{intervento}}$$

Per mantenere l'ordine stabilito nel capitolo, calcoliamo esplicitamente intervento meno controllo:

```
n_intervento <- length(benessere_intervento)
n_controllo <- length(benessere_controllo)

m_intervento <- mean(benessere_intervento)
m_controllo <- mean(benessere_controllo)

s_intervento <- sd(benessere_intervento)
s_controllo <- sd(benessere_controllo)

differenza <- m_intervento - m_controllo

se_welch <- sqrt(
  s_intervento^2 / n_intervento +
  s_controllo^2 / n_controllo
)

df_welch <- (
  s_intervento^2 / n_intervento +
  s_controllo^2 / n_controllo
)^2 / (
  (s_intervento^2 / n_intervento)^2 /
```

```

      (n_intervento - 1) +
      (s_controllo^2 / n_controllo)^2 /
      (n_controllo - 1)
    )

t_welch <- differenza / se_welch
p_welch <- 2 * pt(
  abs(t_welch),
  df = df_welch,
  lower.tail = FALSE
)

t_critico <- qt(0.975, df = df_welch)

ic_welch <- c(
  differenza - t_critico * se_welch,
  differenza + t_critico * se_welch
)

c(
  differenza = differenza,
  errore_standard = se_welch,
  t = t_welch,
  gradi_liberta = df_welch,
  valore_p = p_welch,
  limite_inferiore = ic_welch[1],
  limite_superiore = ic_welch[2]
)
#>      differenza  errore_standard          t    gradi_liberta
#>      5.0000000      1.0316947      4.8463950      20.6446253
#>      valore_p limite_inferiore limite_superiore
#>      0.0000901      2.8522224      7.1477776

```

Otteniamo approssimativamente

$$\hat{\Delta} = 5.00,$$

$$IC_{95\%} = [2.85, 7.15],$$

e

$$t(20.64) = 4.85, \quad p < 0.001.$$

Il valore- p indica che, sotto l'ipotesi di una differenza nulla e le altre assunzioni del test, una statistica almeno altrettanto estrema di quella osservata sarebbe rara. Non rappresenta la probabilità che $\Delta = 0$.

La stima e l'intervallo forniscono informazioni ulteriori. La differenza osservata è pari a 5 punti e, secondo la procedura frequentista, i valori non esclusi dall'intervallo vanno approssimativamente da 2.85 a 7.15 punti. La significatività rispetto a zero non esaurisce dunque l'interpretazione del confronto.

6.8 Il caso con varianza comune

Per confronto, eseguiamo anche il test classico con varianza comune:

```
test_pooled <- t.test(
  benessere_intervento,
  benessere_controllo,
  alternative = "two.sided",
  var.equal = TRUE,
  conf.level = 0.95
)

test_pooled
#>
#> Two Sample t-test
#>
#> data:  benessere_intervento and benessere_controllo
#> t = 5, df = 22, p-value = 0.00008
#> alternative hypothesis: true difference in means is not equal to 0
#> 95 percent confidence interval:
#>  2.86 7.14
#> sample estimates:
#> mean of x mean of y
#>      31.2      26.2
```

In questi dati, le numerosità e le deviazioni standard dei gruppi sono simili. Di conseguenza, il test classico e quello di Welch producono risultati quasi identici.

La somiglianza numerica non dimostra che le varianze delle popolazioni siano uguali. Mostra soltanto che, in questo campione, l'assunzione aggiuntiva del modello pooled ha conseguenze limitate sul risultato. In altri contesti, soprattutto quando numerosità e dispersioni differiscono, la scelta può incidere in modo sostanziale sull'errore standard e sui gradi di libertà.

6.9 Interpretare insieme le quantità

6.9.1 Differenza nella scala originale

La differenza di 5 punti è la quantità più direttamente interpretabile:

Nel campione, la media del gruppo intervento supera quella del gruppo controllo di 5 punti.

Il significato di questo scarto dipende però dalla scala utilizzata, dall'affidabilità dello strumento, dalla distribuzione dei punteggi e dal contesto teorico o applicativo. Una differenza numericamente identica può assumere importanza diversa in strumenti e popolazioni differenti.

6.9.2 Intervallo di confidenza

L'intervallo al 95% è

[2.85, 7.15].

Esso descrive la precisione della procedura frequentista e non assegna il 95% di probabilità alla differenza vera all'interno di questi estremi.

L'intervallo permette anche di confrontare i dati con una soglia sostantiva. Supponiamo, per esempio, che una differenza debba raggiungere almeno 6 punti per essere considerata praticamente rilevante. L'intervallo mostra che i dati sono compatibili sia con differenze inferiori sia con differenze superiori a tale soglia. Sebbene lo zero venga escluso, la precisione non è sufficiente per stabilire con chiarezza che il criterio pratico sia superato.

6.9.3 Valore-p

Il valore- p sintetizza l'incompatibilità del risultato con l'ipotesi $\Delta = 0$, condizionatamente al modello e al piano di analisi. Non descrive la grandezza della differenza, la sua precisione o la sua importanza scientifica. Due studi possono produrre valori- p simili e, nello stesso tempo, stimare effetti molto differenti.

6.9.4 Dimensione dell'effetto standardizzata

Una misura comune della differenza standardizzata è il d di Cohen:

$$d = \frac{\bar{x}_{\text{intervento}} - \bar{x}_{\text{controllo}}}{s_p}.$$

```
s_pooled <- sqrt(
  (
    (n_intervento - 1) * s_intervento^2 +
    (n_controllo - 1) * s_controllo^2
  ) /
  (
    n_intervento +
    n_controllo -
    2
  )
)

cohen_d <- differenza / s_pooled

correzione_hedges <- 1 -
  3 /
  (
    4 *
    (
      n_intervento +
      n_controllo
    ) -
    9
  )
```

```
hedges_g <- correzione_hedges * cohen_d

c(
  cohen_d = cohen_d,
  hedges_g = hedges_g
)
#>   cohen_d hedges_g
#>     1.98     1.91
```

Per questi dati otteniamo

$$d \approx 1.98, \quad g \approx 1.91.$$

Il g di Hedges applica una correzione alla tendenza di d a sovrastimare l'effetto standardizzato nei piccoli campioni. Entrambe le misure esprimono la differenza in unità di deviazione standard, facilitando alcuni confronti tra scale e studi.

 L'effetto standardizzato non sostituisce la differenza grezza

d e g dipendono anche dalla dispersione dei punteggi. Lo stesso cambiamento di 5 punti può produrre valori standardizzati differenti in popolazioni con variabilità diversa.

Quando la scala originale è interpretabile, è opportuno riportare sia la differenza grezza sia una misura standardizzata, evitando di trattare quest'ultima come una misura universale dell'importanza dell'effetto.

6.10 Significatività, equivalenza e rilevanza pratica

Un risultato significativo rispetto a zero non dimostra che l'effetto sia abbastanza grande da avere utilità teorica, clinica o pratica. Stabilisce soltanto che, secondo il test e le sue assunzioni, i dati risultano difficilmente compatibili con una differenza esattamente nulla.

Allo stesso modo, un risultato non significativo non dimostra che i gruppi siano equivalenti. Per sostenere un'interpretazione di equivalenza occorre definire in anticipo una regione di differenze considerate praticamente trascurabili, utilizzare una procedura costruita per valutare quella regione e disporre di dati sufficientemente precisi.

La soglia di rilevanza dovrebbe essere motivata nella scala del fenomeno prima dell'analisi. Non può essere ricavata automaticamente dalla significatività statistica né da una convenzione generale sulla dimensione standardizzata dell'effetto.

 Tre domande differenti

Il confronto deve mantenere separate tre domande. La prima riguarda l'esclusione dello zero: i dati sono incompatibili con $\Delta = 0$ secondo il test? La seconda riguarda la precisione: quali differenze rimangono compatibili con

l'intervallo? La terza riguarda la rilevanza: quali differenze modificherebbero una conclusione teorica o una decisione pratica?

La risposta alla prima domanda non risponde automaticamente alle altre due.

6.11 Dalla differenza osservata all'effetto causale

Una differenza tra medie descrive sempre il confronto definito dai dati e dal modello. Per interpretarla come effetto causale sono necessarie condizioni ulteriori, che riguardano il disegno e non la grandezza del valore- p .

6.11.1 Studio randomizzato

Quando i partecipanti vengono assegnati casualmente ai gruppi, l'assegnazione viene rispettata e non emergono problemi sostanziali di attrito, aderenza o contaminazione, la differenza può sostenere un'interpretazione causale riferita alla popolazione, al trattamento e all'esito definiti dallo studio.

La randomizzazione rende comparabili i gruppi, in senso probabilistico, rispetto ai fattori precedenti al trattamento. Non garantisce però da sola che la misura sia valida, che i dati mancanti siano innocui o che il risultato possa essere generalizzato a popolazioni diverse da quella studiata.

6.11.2 Gruppi osservazionali

Quando i gruppi sono definiti da una caratteristica osservata o da una scelta dei partecipanti, la differenza può riflettere variabili confondenti. Le persone che scelgono un trattamento, per esempio, possono differire da quelle che non lo scelgono già prima dell'intervento per motivazione, gravità iniziale, accesso alle risorse o altre caratteristiche rilevanti.

In questa situazione, il test quantifica la differenza osservata ma non identifica da solo il processo che l'ha prodotta. Un valore- p piccolo non consente di distinguere l'effetto del trattamento dalle differenze preesistenti tra i gruppi.

Il test t non crea causalità

Sono la randomizzazione, le assunzioni di identificazione e la qualità del disegno a giustificare una conclusione causale. Il valore- p non può compensare l'assenza di queste condizioni.

6.12 Il test t come modello lineare

Il confronto tra due gruppi può essere riscritto come una regressione con un predittore dicotomico:

$$Y_i = \alpha + \beta X_i + \varepsilon_i,$$

dove $X_i = 0$ indica il gruppo di controllo e $X_i = 1$ il gruppo intervento.

Quando $X = 0$,

$$E(Y | X = 0) = \alpha.$$

Quando $X = 1$,

$$E(Y | X = 1) = \alpha + \beta.$$

La differenza tra i due valori attesi è quindi

$$E(Y | X = 1) - E(Y | X = 0) = \beta.$$

Il coefficiente β rappresenta la stessa quantità definita all'inizio del capitolo:

$$\beta = \mu_{\text{intervento}} - \mu_{\text{controllo}}.$$

```
modello_lineare <- lm(
  benessere ~ gruppo,
  data = dati_benessere
)

summary(modello_lineare)
#>
#> Call:
#> lm(formula = benessere ~ gruppo, data = dati_benessere)
#>
#> Residuals:
#>    Min     1Q  Median     3Q    Max
#> -4.25 -2.25 -0.25  1.75  4.75
#>
#> Coefficients:
#>                Estimate Std. Error t value Pr(>|t|)
#> (Intercept)        26.25      0.73   35.98 < 2e-16
#> gruppoIntervento     5.00      1.03    4.85 0.000076
#>
#> Residual standard error: 2.53 on 22 degrees of freedom
#> Multiple R-squared:  0.516, Adjusted R-squared:  0.494
#> F-statistic: 23.5 on 1 and 22 DF, p-value: 0.0000765
confint(modello_lineare)
#>                2.5 % 97.5 %
#> (Intercept)        24.74  27.76
#> gruppoIntervento    2.86   7.14
```

Quando si assume una varianza comune, il test sul coefficiente del predittore è equivalente al test t classico per due gruppi. Questa equivalenza mostra che il test t non è un procedimento separato dal resto della modellizzazione statistica. Rappresenta il caso più semplice di una famiglia di modelli che può essere estesa includendo più gruppi, covariate, interazioni, strutture gerarchiche ed esiti non gaussiani.

i Un ponte verso il progetto bayesiano

Il Companion utilizza la stessa rappresentazione con un predittore codificato 0–1 nel capitolo [Confrontare due medie con Stan](#) e nel capitolo 26, *Due gruppi: codifiche, differenze e rilevanza pratica*.

Nel modello bayesiano, la distribuzione a posteriori di β rappresenta direttamente l'incertezza sulla differenza tra le medie.

6.13 Che cosa cambia nel modello bayesiano?

Il confronto frequentista e quello bayesiano possono utilizzare gli stessi dati, lo stesso predittore dicotomico, una medesima verosimiglianza normale e la stessa quantità bersaglio Δ . Entrambi possono inoltre rappresentare dispersioni comuni o differenti. Ciò che cambia è l'oggetto inferenziale immediato e, di conseguenza, il significato delle probabilità utilizzate.

Domanda	Procedura frequentista	Modello bayesiano
Quanto differiscono i gruppi?	Stima puntuale e intervallo di confidenza	Distribuzione a posteriori di Δ
Quanto è incompatibile lo zero?	Valore- p sotto H_0	Massa a posteriori rispetto a zero o confronto tra modelli
L'effetto supera una soglia pratica?	Intervallo, equivalenza o test dedicato	Probabilità a posteriori che Δ superi la soglia
Il modello descrive adeguatamente i dati?	Diagnostica e controlli frequentisti	Controlli predittivi e confronto predittivo

Nel quadro bayesiano è possibile calcolare quantità come

$$P(\Delta > 0 \mid y)$$

oppure

$$P(\Delta > \delta_{\min} \mid y),$$

dove $\delta_{\min}$ rappresenta una soglia sostantiva. Queste probabilità non sono valori- p : descrivono l'incertezza sul parametro dopo avere combinato la distribuzione a priori, la verosimiglianza e i dati.

La possibilità di formulare un'interpretazione probabilistica diretta non elimina la necessità di controllare il modello, la qualità delle misure, la struttura del disegno e le condizioni necessarie per un'interpretazione causale. Un modello bayesiano non corregge automaticamente un confronto mal definito o un campione distorto.

6.14 Come riportare il risultato

Un resoconto informativo dovrebbe permettere al lettore di ricostruire il confronto senza ridurlo alla dichiarazione di significatività. È quindi necessario riportare numerosità, media e deviazione standard di ciascun gruppo, specificare l'ordine della differenza e presentare la differenza grezza con il relativo intervallo. Devono inoltre essere indicati il test utilizzato, la statistica, i gradi di libertà, il valore- p e una misura della dimensione dell'effetto. L'interpretazione deve infine discutere il significato sostantivo e i limiti del disegno.

Per l'esempio, il risultato può essere comunicato nel modo seguente:

Il gruppo sottoposto all'intervento ha riportato un punteggio medio di benessere maggiore ($M = 31.25$, $DS = 2.83$, $n = 12$) rispetto al gruppo di controllo ($M = 26.25$, $DS = 2.18$, $n = 12$). La differenza intervento meno controllo è stata di 5.00 punti, IC 95% [2.85, 7.15]. Il test t di Welch ha indicato incompatibilità con una differenza nulla, $t(20.64) = 4.85$, $p < .001$. La differenza standardizzata è risultata elevata nel campione, $g = 1.91$. L'interpretazione causale dipende dall'assegnazione e dalle altre caratteristiche del disegno.

i Perché nominare Welch

Scrivere soltanto «test t » lascia implicita un'assunzione importante. Specificare «test t di Welch» comunica che non è stata imposta l'uguaglianza delle varianze.

Riflessioni conclusive

Il confronto tra due gruppi indipendenti conclude il percorso applicativo del modulo frequentista perché riunisce in un unico esempio tutti gli elementi introdotti nei capitoli precedenti.

La differenza tra le medie costituisce la quantità bersaglio. L'errore standard descrive quanto la sua stima varierebbe tra campioni, l'intervallo di confidenza ne esprime la precisione e il valore- p valuta l'incompatibilità con una differenza nulla sotto il modello. La dimensione standardizzata colloca infine lo scarto in relazione alla dispersione dei punteggi, senza sostituire l'interpretazione nella scala originale.

Nessuna di queste quantità esaurisce l'analisi. Occorre stabilire quale differenza abbia rilevanza scientifica, quanto precisamente sia stata stimata, se il modello descriva adeguatamente i dati e se il disegno autorizzi una conclusione causale. La significatività rispetto a zero, la precisione e la rilevanza pratica rimangono domande distinte.

L'equivalenza tra il test t e la regressione con predittore dicotomico crea il collegamento più naturale con il progetto bayesiano. La domanda sostantiva rimane la stessa — quanto differiscono i gruppi? — ma l'incertezza viene rappresentata mediante la distribuzione a posteriori del coefficiente che codifica la differenza.

L'epilogo utilizzerà questo punto di arrivo per confrontare in modo complessivo il controllo frequentista degli errori, la rappresentazione bayesiana dell'incertezza e il ruolo del workflow scientifico nella costruzione di conclusioni affidabili.

Esercizi

1. Qual è la differenza tra la quantità $\Delta = \mu_1 - \mu_0$ e la stima $\hat{\Delta} = \bar{X}_1 - \bar{X}_0$?
2. Perché un disegno prima-dopo sulle stesse persone non dovrebbe essere analizzato come confronto tra gruppi indipendenti?
3. Quale assunzione aggiuntiva distingue il test t classico dal test di Welch?
4. Perché non è consigliabile scegliere tra test classico e Welch sulla base di un test preliminare delle varianze?
5. Un intervallo per la differenza è $[1.2, 6.8]$, mentre la soglia di rilevanza pratica è 5. Che cosa suggerisce l'intervallo?
6. Perché una differenza statisticamente significativa tra due gruppi osservazionali non dimostra un effetto causale?
7. Nel modello $Y_i = \alpha + \beta X_i + \varepsilon_i$, con controllo codificato 0 e intervento codificato 1, che cosa rappresentano α e β ?
8. Qual è la differenza tra un valore- p piccolo per $H_0 : \Delta = 0$ e una probabilità a posteriori elevata per $\Delta > 0$?

Soluzioni

1. Δ è la differenza tra le medie delle popolazioni o del modello. $\hat{\Delta}$ è la differenza osservata tra le medie campionarie e varia da campione a campione.
2. Le due osservazioni della stessa persona sono dipendenti. Un test per gruppi indipendenti ignora l'abbinamento e utilizza un errore standard non coerente con il disegno.
3. Il test classico assume una varianza comune nelle due popolazioni. Welch permette varianze differenti e modifica di conseguenza l'errore standard e i gradi di libertà.
4. La procedura risultante dipende da una decisione presa sugli stessi dati e possiede proprietà inferenziali meno trasparenti. Welch può essere adottato direttamente senza imporre l'uguaglianza delle varianze.
5. I dati sono compatibili, secondo la procedura, sia con differenze inferiori sia con differenze superiori a 5. L'esclusione dello zero non permette quindi di stabilire con precisione che la soglia pratica sia superata.
6. I gruppi possono differire per confondenti, selezione o condizioni precedenti all'esposizione. Il test quantifica una differenza, ma non identifica da solo il meccanismo che l'ha prodotta.

7. α è la media del gruppo controllo. β è la differenza intervento meno controllo.
8. Il valore- p riguarda la probabilità di risultati almeno altrettanto estremi sotto $\Delta = 0$. La probabilità a posteriori riguarda invece l'incertezza su Δ dopo avere combinato distribuzione a priori, modello e dati.

i Punti chiave

Il confronto deve iniziare dalla definizione della differenza e del suo ordine. Gruppi indipendenti, dati appaiati e misure ripetute richiedono strutture inferenziali diverse, e l'indipendenza è soprattutto una proprietà del disegno. Il test di Welch non richiede una varianza comune ed è spesso una scelta predefinita adeguata. Differenza grezza, intervallo, valore- p e dimensione standardizzata comunicano informazioni differenti e devono essere interpretati congiuntamente. Un risultato significativo rispetto a zero non dimostra rilevanza pratica, mentre un risultato non significativo non dimostra equivalenza. Il test t non trasforma un confronto osservazionale in un effetto causale. Il confronto tra due gruppi è equivalente a una regressione con predittore dicotomico e, nel modello bayesiano, la distribuzione a posteriori del relativo coefficiente rappresenta l'incertezza sulla differenza tra le medie.

i Ambiente di sviluppo

Le informazioni sull'ambiente R possono essere ottenute con:

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:
#> ↪ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#>
#> LAPACK:
#> ↪ /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#> ↪ LAPACK version 3.12.1
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Zagreb
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods   base
#>
#> other attached packages:
```

```

#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2    patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7      bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.1           rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0          Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0     janitor_2.2.1          matrixStats_1.5.0
#> [22] modelr_0.1.11        tibble_3.3.1           dplyr_1.2.1
#> [25] tidyr_1.3.2          rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8         tidyselect_1.2.1       farver_2.1.2
#> [4] S7_0.2.2             fastmap_1.2.0          tensorA_0.36.2.1
#> [7] digest_0.6.39        timechange_0.4.0       estimability_2.0.0
#> [10] lifecycle_1.0.5      magrittr_2.0.5         compiler_4.6.1
#> [13] rlang_1.3.0          tools_4.6.1            yaml_2.3.12
#> [16] knitr_1.51           labeling_0.4.3
#> [19] pkgbuild_1.4.8       curl_7.1.0             RColorBrewer_1.1-3
#> [22] abind_1.4-8          purrr_1.2.2            grid_4.6.1
#> [25] stats4_4.6.1         xtable_1.8-8           inline_0.3.21
#> [28] emmeans_2.0.4        scales_1.4.0           cli_3.6.6
#> [31] mvtnorm_1.4-2        rmarkdown_2.31         generics_0.1.4
#> [34] otel_0.2.0           RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0        parallel_4.6.1         vctrs_0.7.3
#> [40] V8_8.2.0             Matrix_1.7-6           jsonlite_2.0.0
#> [43] arrayhelpers_1.1-2   glue_1.8.1             codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5        stringi_1.8.7
#> [49] gtable_0.3.6         QuickJSR_1.10.0        pillar_1.11.1

```

```
#> [52] htmltools_0.5.9      Brobdingnag_1.2-9      R6_2.6.1
↵
#> [55] textshaping_1.0.5     rprojroot_2.1.1        evaluate_1.0.5
↵
#> [58] lattice_0.22-9        backports_1.5.1        memoise_2.0.1
↵
#> [61] broom_1.0.13          snakecase_0.11.1        rstantools_2.6.0
↵
#> [64] coda_0.19-4.1         gridExtra_2.3.1        nlme_3.1-170
↵
#> [67] checkmate_2.3.4       xfun_0.60              pkgconfig_2.0.3
```


Parte II

Epilogo

Conclusioni

i In sintesi

Questo modulo ha presentato l'inferenza frequentista come un insieme di procedure il cui valore dipende dal comportamento che esse mostrano in una successione, reale o ipotetica, di campionamenti ripetuti. Comprendere questa logica è indispensabile per leggere con consapevolezza la letteratura psicologica, interpretare correttamente stime, intervalli e test e riconoscere i casi in cui una diversa rappresentazione dell'incertezza diventa necessaria.

Il passaggio al progetto bayesiano non consiste nella sostituzione meccanica di una tecnica con un'altra. Richiede piuttosto una riformulazione del problema inferenziale: l'attenzione si sposta dalle proprietà di lungo periodo delle procedure alla distribuzione dell'incertezza relativa a parametri, predizioni e modelli, condizionatamente alle assunzioni formulate e ai dati osservati.

Che cosa abbiamo imparato

Il percorso è iniziato dalle origini storiche del frequentismo e dal legame, scientificamente fecondo ma eticamente problematico, tra la misurazione delle differenze individuali, lo sviluppo della statistica e il movimento eugenetico. Questo inquadramento ha mostrato fin dall'inizio che i metodi statistici non nascono in un vuoto culturale: essi rispondono a specifiche domande scientifiche, ma riflettono anche le finalità, i valori e i limiti del contesto nel quale vengono elaborati.

Nei capitoli successivi è stato costruito il lessico operativo dell'inferenza frequentista. All'interno di un modello, il parametro è una quantità fissa ma ignota, mentre lo stimatore è la regola che viene applicata ai dati per ricavare informazioni su di esso. La stima è il valore assunto dallo stimatore nel campione osservato e l'errore standard descrive quanto tale valore potrebbe variare da un campione all'altro. Su questa stessa logica si fonda l'intervallo di confidenza, che non attribuisce una probabilità al parametro, ma definisce una procedura capace di raggiungere una determinata frequenza di copertura nel lungo periodo.

La discussione dei test di ipotesi ha chiarito che il valore- p misura quanto il risultato osservato, o un risultato ancora più estremo, sia compatibile con l'ipotesi nulla e con l'insieme delle assunzioni adottate. Gli errori di tipo I e di tipo II, insieme alla potenza, descrivono invece il comportamento di una regola decisionale in differenti scenari. Anche la pianificazione della numerosità campionaria deve essere compresa in questa prospettiva: non esiste una dimensione del campione adeguata in assoluto,

perché essa dipende dalla precisione desiderata, dall'effetto assunto come rilevante, dalla variabilità dei dati e dalle caratteristiche del disegno.

Il confronto tra due gruppi ha infine mostrato come queste nozioni si integrino nell'analisi concreta. Una conclusione scientifica non dovrebbe dipendere da un singolo indicatore. La stima, l'intervallo di confidenza, il valore- p , la dimensione dell'effetto, la qualità del disegno e la rilevanza sostantiva rispondono infatti a domande differenti e devono essere interpretati congiuntamente.

Che cosa offre il frequentismo

L'inferenza frequentista mette a disposizione strumenti fondamentali per valutare la qualità delle procedure statistiche e delle decisioni che ne derivano. Consente di studiare quanto varia uno stimatore sotto campionamenti ripetuti, con quale frequenza una procedura intervallare contiene il parametro, quale tasso di errore di tipo I produce una determinata regola decisionale e con quale probabilità un test riesce a rilevare un effetto specificato. Permette inoltre di stabilire quante osservazioni siano necessarie per raggiungere un livello prefissato di precisione o di potenza.

Queste proprietà assumono un'importanza particolare quando il disegno dell'indagine definisce in modo chiaro quali ripetizioni siano rilevanti e quando il controllo degli errori costituisce uno degli obiettivi principali dell'analisi. In tali circostanze, la prospettiva frequentista offre criteri rigorosi per progettare gli studi e valutarne le prestazioni.

Il contributo del frequentismo non può quindi essere ridotto all'impiego del valore- p . Esso comprende la teoria della stima, il disegno sperimentale, la randomizzazione, il campionamento, la costruzione degli intervalli, i test di ipotesi, la pianificazione degli studi e, più in generale, la valutazione delle proprietà di lungo periodo delle procedure statistiche.

I limiti da non dimenticare

Le garanzie frequentiste sono sempre condizionate al modello e al disegno. Una procedura formalmente corretta non protegge, da sola, dalle conseguenze di un campione non rappresentativo, di misure poco valide o inaffidabili, di dipendenze ignorate o di un modello mal specificato. Allo stesso modo, non elimina i problemi prodotti dai confronti multipli, dalla flessibilità delle scelte analitiche, dalla selezione dei risultati o da interpretazioni causali che il disegno non consente di sostenere.

Anche quando la procedura viene applicata correttamente, alcune domande rimangono al di fuori della sua portata. Un intervallo di confidenza non assegna probabilità ai possibili valori del parametro; un valore- p non esprime la probabilità che l'ipotesi nulla sia vera; la potenza, infine, non indica quanto un effetto sia plausibile dopo che i dati sono stati osservati. Questi limiti non rendono inutili le procedure frequentiste, ma definiscono con precisione il tipo di conclusioni che esse possono autorizzare.

 La critica corretta non è una caricatura

Il frequentismo non sostiene che l'incertezza scientifica sia irrilevante, così come il bayesianesimo non elimina automaticamente gli errori di misura, i bias di selezione o le conseguenze di modelli inadeguati.

Il confronto più utile riguarda il significato delle quantità inferenziali, le domande alle quali esse permettono di rispondere e il processo attraverso il quale le assunzioni vengono rese esplicite, controllate e messe in relazione con i dati.

Dal confronto frequentista al ragionamento bayesiano

Frequentismo e bayesianesimo possono partire dalla stessa domanda psicologica, utilizzare gli stessi dati, adottare la stessa funzione di verosimiglianza e condividere tanto il modello generativo quanto la quantità di interesse. Ciò che cambia è il modo in cui l'incertezza viene rappresentata e aggiornata.

Nel quadro frequentista, la probabilità descrive principalmente il comportamento di dati, statistiche e procedure in una serie di ripetizioni reali o ipotetiche. Nel quadro bayesiano, la probabilità viene impiegata anche per rappresentare l'incertezza relativa ai parametri e alle predizioni, sempre condizionatamente alla distribuzione a priori, al modello e ai dati disponibili.

Il passaggio concettuale centrale può essere rappresentato nel modo seguente:

$$p(\theta) \longrightarrow p(y | \theta) \longrightarrow p(\theta | y).$$

La distribuzione a priori esprime l'incertezza prima dell'osservazione dei dati. La verosimiglianza stabilisce il collegamento tra i parametri del modello e le osservazioni possibili. La distribuzione a posteriori descrive infine come l'incertezza si modifica dopo che i dati sono stati osservati.

Questa rappresentazione consente di formulare domande che non trovano una risposta diretta nelle quantità frequentiste. Diventa possibile valutare la probabilità a posteriori che un effetto sia positivo o che superi una soglia sostanzialmente rilevante, esaminare i valori futuri previsti dal modello, studiare quanto le conclusioni dipendano dalla distribuzione a priori e verificare quanto bene il modello riesca a riprodurre le caratteristiche importanti dei dati. Non si tratta di reinterpretare in chiave bayesiana i valori- p o gli intervalli di confidenza, ma di costruire l'inferenza secondo una diversa concezione della probabilità e dell'apprendimento dai dati.

Il ruolo di questo modulo nel progetto editoriale

Inferenza bayesiana in psicologia: Ragionare con l'incertezza costituisce il nucleo concettuale del progetto. Il manuale affronta i problemi epistemologici e metodologici dell'inferenza, discute i limiti dell'uso meccanico della significatività statistica e sviluppa

pa il ragionamento bayesiano come metodo di modellizzazione e di apprendimento scientifico.

Questo sito svolge una funzione più circoscritta ma essenziale: fornisce il termine di confronto concettuale e tecnico necessario per comprendere che cosa cambia quando si passa dall'inferenza frequentista a quella bayesiana. Può essere utilizzato prima della lettura del manuale, come richiamo per chi proviene da una formazione statistica classica, oppure durante e dopo la Parte II, per consolidare il significato di stima, copertura, valore- p , potenza e confronto tra gruppi.

Il manuale non presuppone che ogni lettore padroneggi tutte le formule presentate in questo modulo. È più importante imparare a riconoscere quali affermazioni siano effettivamente autorizzate da una procedura e quali costituiscano, invece, un'inversione o un'estensione indebita del suo significato.

Come proseguire

! Il percorso consigliato

Il passo successivo è la lettura del manuale UTET *Inferenza bayesiana in psicologia: Ragionare con l'incertezza* di Corrado Caudek e Caterina Primi. Il volume costituisce il centro teorico del progetto e accompagna il lettore dalla diagnosi dei limiti delle pratiche statistiche tradizionali alla costruzione di un workflow bayesiano. La [Guida al manuale](#) mantiene il raccordo aggiornato tra i capitoli del volume, il Companion e i diversi moduli di supporto. Il [Companion online](#) rappresenta invece il laboratorio operativo del progetto: qui vengono sviluppati modelli generativi, distribuzioni a priori e a posteriori, predizioni, strumenti diagnostici, controlli predittivi e implementazioni in R, brms e Stan.

Per chi desidera consolidare i prerequisiti formali, il modulo [Probabilità per la psicologia](#) offre un richiamo alla probabilità condizionata, alle distribuzioni, alla verosimiglianza e al teorema di Bayes, fornendo le basi necessarie per comprendere l'aggiornamento bayesiano.

Un ultimo criterio di lettura

Di fronte a un risultato statistico, la prima domanda non dovrebbe essere soltanto se esso sia significativo. Occorre anzitutto chiarire quale quantità si desideri conoscere e quale modello colleghi quella quantità ai dati. È poi necessario chiedersi quali caratteristiche del disegno giustifichino l'inferenza, in che modo l'incertezza venga rappresentata e quali conclusioni siano realmente autorizzate dalle procedure adottate. A queste domande si aggiungono la verifica dell'adeguatezza del modello e la valutazione di quale decisione, previsione o conoscenza scientifica dovrebbe cambiare alla luce del risultato.

Il contributo più importante del confronto tra paradigmi non consiste dunque nella scelta di una nuova etichetta. Consiste nell'imparare a formulare domande

migliori, a rendere esplicite le assunzioni e a trattare l'incertezza non come un ostacolo accessorio, ma come una componente costitutiva della conoscenza psicologica.

