

Inferenza frequentista in psicologia

Modulo introduttivo

Corrado Caudek

14 luglio 2026

Percorso e obiettivi

Questo sito ospita il **modulo sull'inferenza frequentista** del progetto UTET, concepito a supporto del manuale *Inferenza bayesiana in psicologia: Ragionare con l'incertezza. Fondamenti, workflow e applicazioni*. Il percorso offre un'introduzione critica alle tecniche statistiche tradizionali, quali le stime puntuali, gli intervalli di confidenza e i test di ipotesi, accompagnata da un'approfondita riflessione sulle loro premesse concettuali e sulle criticità metodologiche che hanno contribuito alla crisi di replicabilità nella ricerca psicologica.

- **Origini storiche:** da Galton e Fisher ai fondamenti del pensiero frequentista.
- **Stima dei parametri:** concetti di media campionaria, varianza, stimatori corretti.
- **Intervalli di confidenza:** costruzione, interpretazione, equivoci comuni.
- **Test di ipotesi:** logica, errori di I e II tipo, potenza statistica.

Il sito non intende sostituire il manuale principale, ma integrarlo: fornisce il **background propedeutico** e il contesto critico indispensabili per apprezzare in profondità le ragioni e la struttura dell'alternativa bayesiana.

Come usare il modulo

- **Leggi con spirito critico:** lo scopo è capire potenzialità e limiti del frequentismo.
- **Collega al manuale:** ciascun tema trattato in questo modulo costituisce il presupposto teorico o il termine di confronto necessario per apprezzare l'approccio bayesiano sviluppato nel manuale principale, dove viene proposto un superamento delle criticità discusse.
- **Utilizza le appendici:** per un riferimento rapido, sono disponibili appendici dedicate alla notazione matematica, ai simboli e a richiami di concetti fondamentali, consultabili sul sito companion [Inferenza bayesiana in psicologia: ragionare con l'incertezza](#).

Licenza d'uso

Materiali rilasciati con licenza

[CC BY-NC-ND 4.0](#):

è consentita la condivisione con attribuzione **solo per usi non commerciali** e **senza modifiche**.

Parte I.

Frequentismo

Introduzione all'inferenza frequentista in un percorso bayesiano

Questo modulo introduce l'inferenza frequentista all'interno di un percorso più ampio dedicato all'inferenza bayesiana. La scelta potrebbe sembrare paradossale: perché studiare metodi frequentisti in un manuale che adotta una prospettiva bayesiana?

La risposta è semplice. Gran parte della letteratura psicologica utilizza ancora intervalli di confidenza, test di significatività, valori- p , livelli di significatività e analisi di potenza. Per leggere criticamente un articolo, progettare uno studio, comprendere una tabella di risultati o dialogare con colleghi formati nella tradizione statistica dominante, è necessario conoscere bene questi strumenti.

Tuttavia, li studieremo con un obiettivo preciso: non come l'unico modo possibile di fare inferenza, ma come un sistema coerente di procedure che risponde a domande specifiche. Il confronto con l'approccio bayesiano ci aiuterà a distinguere tra due compiti spesso confusi:

- controllare il comportamento di una procedura statistica nel lungo periodo;
- quantificare l'incertezza su un'ipotesi o su un parametro dopo aver osservato i dati.

La prima domanda è al centro dell'inferenza frequentista. La seconda è al centro dell'inferenza bayesiana.

Perché studiare il frequentismo in un companion bayesiano?

L'inferenza frequentista è stata, e in molti ambiti continua a essere, il linguaggio standard della ricerca empirica. Concetti come *statisticamente significativo*, *intervallo di confidenza al 95%*, *errore di primo tipo*, *potenza statistica* e *test t* compaiono regolarmente negli articoli di psicologia, neuroscienze, medicina e scienze sociali.

Ignorare questo linguaggio renderebbe difficile comprendere la letteratura esistente. Accettarlo in modo acritico, però, potrebbe portare a fraintendimenti diffusi. Questo modulo ha quindi una funzione duplice:

1. **fornire competenze operative**, ovvero spiegare il funzionamento delle procedure frequentiste più comuni;
2. **sviluppare una consapevolezza interpretativa**, cioè chiarire a quali domande tali procedure possono rispondere e a quali invece non possono rispondere direttamente.

i Una prospettiva didattica, non polemica

Studiare il frequentismo non significa considerarlo un errore da correggere. Molte procedure frequentiste sono utili, robuste e storicamente rilevanti. Il punto è comprenderne la logica: esse valutano il comportamento di procedure ripetute nel lungo periodo e non assegnano direttamente probabilità alle ipotesi o ai parametri dopo aver osservato i dati.

Due modi di intendere la probabilità

La differenza tra frequentismo e bayesianesimo nasce da una diversa interpretazione della probabilità.

Secondo la prospettiva frequentista, la probabilità è collegata alla frequenza relativa di un evento in una lunga sequenza di ripetizioni idealmente identiche. Se, per esempio, diciamo che la probabilità di ottenere “testa” nel lancio di una moneta è 0.5, intendiamo che, in un numero molto grande di lanci condotti nelle stesse condizioni, circa la metà degli esiti sarà “testa”.

In questa prospettiva, i parametri della popolazione sono considerati quantità fisse, ma sconosciute. Per esempio, la media della popolazione, la differenza tra due gruppi o la proporzione di persone con un certo sintomo non sono variabili casuali, ma hanno un valore definito, anche se noi non lo conosciamo. La variabilità deriva dal campione: campioni diversi produrrebbero stime diverse.

Nella prospettiva bayesiana, la probabilità esprime un grado di plausibilità o di incertezza razionale. Il parametro sconosciuto viene trattato come una quantità incerta descritta da una distribuzione di probabilità. I dati osservati modificano tale distribuzione attraverso il teorema di Bayes:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

In questa formula, $p(\theta)$ rappresenta ciò che si sa prima di osservare i dati, $p(y | \theta)$ rappresenta la verosimiglianza dei dati sotto diversi valori del parametro, e $p(\theta | y)$ rappresenta ciò che si sa dopo aver osservato i dati.

Parametri fissi, dati variabili

Il modo più semplice per comprendere la logica frequentista è ricordare questa distinzione:

- il **parametro** è fisso ma ignoto;
- il **campione** è variabile;
- la **procedura inferenziale** viene valutata chiedendosi come si comporterebbe se fosse applicata molte volte a campioni diversi generati dallo stesso processo.

Supponiamo, per esempio, di voler stimare la media del benessere psicologico di una popolazione di studenti. Il valore vero della media esiste, ma non lo conosciamo. Se estraessimo molti campioni diversi, otterremmo molte medie campionarie diverse. L'inferenza frequentista studia proprio questa variabilità da campione a campione.

Da qui nascono concetti fondamentali come:

- la **distribuzione campionaria**, ovvero la distribuzione che una statistica assumerebbe in ripetuti campionamenti;
- l'**errore standard**, ovvero la variabilità attesa di una stima da un campione all'altro;
- l'**intervallo di confidenza**, cioè una procedura che, se ripetuta molte volte, produce intervalli che contengono il parametro vero con una frequenza prestabilita;
- il **test di ipotesi**, cioè una procedura che valuta quanto i dati osservati siano insoliti rispetto a un'ipotesi nulla.

Questi strumenti non sono arbitrari, ma formano un sistema coerente. Tuttavia, la loro interpretazione è spesso meno intuitiva di quanto sembri.

Un esempio: il lancio di una moneta

Consideriamo una moneta lanciata 20 volte. Osserviamo 14 teste e 6 croci. Che cosa possiamo concludere?

Un'analisi frequentista parte da un'ipotesi, ad esempio che la moneta sia equilibrata. Se la moneta fosse davvero equilibrata, il numero di teste in 20 lanci seguirebbe una distribuzione binomiale con parametro $\theta = 0.5$. La domanda diventa:

Quanto sarebbe insolito osservare 14 o più teste, o un risultato almeno altrettanto estremo, se la moneta fosse equilibrata?

Questa domanda conduce al valore- p . Il valore- p non è la probabilità che la moneta sia equilibrata. È una probabilità calcolata assumendo che l'ipotesi nulla sia vera.

Un'analisi bayesiana formula la domanda in modo diverso. Si parte da una distribuzione a priori del grado di sbilanciamento della moneta, si osservano i dati e si ottiene una distribuzione a posteriori. La domanda diventa:

Dopo aver osservato 14 teste su 20 lanci, quali valori di θ sono più plausibili?

Le due analisi possono usare lo stesso modello probabilistico per i dati, ma rispondono a domande diverse.

! Domande diverse, risposte diverse

Nel frequentismo ci si chiede: *Quanto sarebbe raro questo risultato se una certa ipotesi fosse vera?*
Nel bayesianesimo, invece, ci si chiede: *Quanto è plausibile ciascuna ipotesi, o ciascun valore del parametro, dopo aver osservato questi dati?*

Interpretazioni da evitare

Molti errori nella lettura della letteratura scientifica derivano dal fatto che termini familiari vengono interpretati in modo intuitivo ma non corretto.

Un **intervallo di confidenza al 95%** non significa che vi sia il 95% di probabilità che il parametro vero cada nell'intervallo calcolato. Nella logica frequentista, il parametro non è casuale, ma fisso. Il 95% si riferisce al comportamento della procedura in ripetuti campionamenti.

Un **valore- p** non è la probabilità che l'ipotesi nulla sia vera. È la probabilità, calcolata assumendo vera l'ipotesi nulla, di ottenere dati uguali o più estremi di quelli osservati, secondo una regola specifica.

La **significatività statistica** non implica necessariamente importanza teorica, rilevanza clinica o replicabilità. Un effetto può essere statisticamente significativo ma piccolo, instabile o poco informativo dal punto di vista sostanziale.

La **non significatività statistica** non dimostra l'assenza dell'effetto. Può essere causata da dati insufficienti, misure rumorose, campioni piccoli o da un disegno poco sensibile.

Questi chiarimenti non intendono screditare gli strumenti frequentisti, ma insegnare a usarli correttamente.

Il ruolo del frequentismo nella ricerca psicologica

Il frequentismo ha avuto un ruolo enorme nella ricerca psicologica. Ha fornito un linguaggio condiviso per valutare i risultati empirici, confrontare i gruppi, stimare gli effetti, pianificare gli studi e controllare il rischio di conclusioni affrettate.

Tuttavia, l'uso meccanico di soglie decisionali, in particolare la soglia convenzionale $\alpha = .05$, ha contribuito a una comunicazione troppo dicotomica dei risultati: "significativo/non significativo", "effetto presente/effetto assente", "ipotesi confermata/ipotesi non confermata".

Una prospettiva bayesiana invita a spostare l'attenzione dalla semplice decisione alla quantificazione dell'incertezza. Tuttavia, per capire perché questo spostamento è utile, è necessario comprendere bene la logica che lo precede.

Che cosa impareremo in questo modulo

Il modulo è organizzato come un percorso graduale.

1. Origini storiche dell'approccio frequentista

Introdurremo il contesto storico ed epistemologico in cui si è sviluppata la statistica frequentista, con attenzione sia al suo contributo scientifico sia alle sue ambivalenze storiche.

2. Stime, stimatori e distribuzioni campionarie

Studieremo come il frequentismo rappresenta la variabilità delle stime da un campione all'altro. Questo capitolo introduce media campionaria, correttezza, errore standard e Teorema del Limite Centrale.

3. Intervalli di confidenza

Vedremo come costruire e interpretare gli intervalli di confidenza, distinguendoli dagli intervalli di credibilità bayesiani.

4. Test di ipotesi e valore- p

Analizzeremo la logica del test di significatività: ipotesi nulla, statistica test, distribuzione di riferimento, regione critica, valore- p ed errori decisionali.

5. Dimensione campionaria e potenza statistica

Una volta compresa la logica dei test, discuteremo il ruolo della dimensione campionaria, dell'errore di secondo tipo e della potenza statistica.

6. Confronto tra due gruppi indipendenti

Applicheremo gli strumenti introdotti al caso del test t per due campioni indipendenti, uno degli esempi più comuni nella ricerca psicologica.

7. Considerazioni conclusive

Chiuderemo il modulo collegando i limiti interpretativi del frequentismo alla motivazione dell'approccio bayesiano.

Come leggere questo modulo

Il modo migliore per affrontare questi capitoli è tenere sempre separate tre domande:

1. **Qual è il modello dei dati?**
Quale processo probabilistico assumiamo abbia generato le osservazioni?
2. **Qual è la procedura?**
Stiamo calcolando una stima, un intervallo di confidenza, una statistica test, un valore- p o una misura di potenza?
3. **Qual è l'interpretazione corretta?**
Il risultato parla del parametro, dei dati osservati, dell'ipotesi nulla o del comportamento della procedura nel lungo periodo?

Questa attenzione interpretativa è essenziale. Le formule sono importanti, ma in statistica l'errore più frequente non è sbagliare un calcolo, bensì attribuire al risultato di un calcolo un significato che non possiede.

Dalla procedura all'aggiornamento delle credenze

L'inferenza frequentista fornisce strumenti potenti per il controllo degli errori e la valutazione delle procedure. Il suo punto di forza è la disciplina del lungo periodo: una procedura viene giudicata in base a ciò che farebbe se fosse ripetuta molte volte.

L'inferenza bayesiana, invece, parte da una domanda diversa: dati il modello, le conoscenze iniziali e i risultati osservati, come devono cambiare le nostre credenze? Questa domanda richiede di trattare l'incertezza sui parametri in modo esplicito, attraverso distribuzioni di probabilità.

Per questo motivo, il confronto tra frequentismo e bayesianesimo non deve essere ridotto a una contrapposizione tra un metodo giusto e uno sbagliato. È più utile considerarlo come un confronto tra due grammatiche dell'inferenza:

- il frequentismo parla il linguaggio delle procedure, degli errori e delle frequenze nel lungo periodo;
- il bayesianesimo parla il linguaggio dell'incertezza, dell'evidenza e dell'aggiornamento delle credenze.

Comprendere entrambe le grammatiche rende la lettura della ricerca empirica più solida e prepara a utilizzare l'inferenza bayesiana in modo più consapevole.

Punti chiave da ricordare

! Importante

- Il frequentismo valuta le procedure statistiche in termini di comportamento nel lungo periodo.
- Nel frequentismo i parametri sono considerati fissi ma ignoti; la variabilità deriva dal campione.
- Un intervallo di confidenza non è, in senso stretto, una probabilità sul parametro dopo aver osservato i dati.

- Un valore- p non è la probabilità che l'ipotesi nulla sia vera.
- Il bayesianesimo rappresenta esplicitamente l'incertezza sui parametri mediante distribuzioni di probabilità.
- Studiare il frequentismo è essenziale per leggere la letteratura psicologica e per comprendere meglio il passaggio all'inferenza bayesiana.

Bibliografia

1. Origini storiche dell'approccio frequentista

Questo capitolo introduce le origini storiche e concettuali dell'approccio frequentista. Non lo faremo per trasformare la storia della statistica in una semplice sequenza di nomi e date, ma per capire da quali problemi scientifici, istituzionali ed epistemologici siano nati molti strumenti ancora oggi centrali nella ricerca psicologica: correlazione, regressione, distribuzione normale, test di ipotesi, intervalli di confidenza e valore- p .

Il capitolo mantiene la prospettiva del manuale: studiamo il frequentismo perché è indispensabile per leggere gran parte della letteratura empirica, ma lo collochiamo dentro un percorso più ampio che condurrà all'inferenza bayesiana.

! In questo capitolo imparerai a

- Riconoscere il contesto storico in cui si è sviluppata la statistica frequentista.
- Comprendere perché la variabilità individuale è diventata un oggetto centrale della misurazione scientifica.
- Distinguere il contributo tecnico di Galton, Pearson e Fisher dal contesto ideologico in cui alcuni di questi strumenti sono nati.
- Riassumere i principi di base del paradigma frequentista: probabilità come frequenza, parametri fissi e dati variabili, valutazione delle procedure nel lungo periodo.
- Preparare il terreno per i capitoli successivi su stime, intervalli di confidenza, test di ipotesi e potenza statistica.

💡 Prerequisiti

Per seguire questo capitolo è utile aver letto l'introduzione al modulo sull'inferenza frequentista. Non sono richieste conoscenze tecniche avanzate: l'obiettivo è costruire una mappa concettuale prima di entrare nei dettagli matematici.

Lettura complementare consigliata:

- il capitolo *Sampling* di [Statistical Inference via Data Science: A ModernDive into R and the Tidyverse](#).

1.1. Perché partire dalla storia?

La statistica non è soltanto un insieme di formule. È anche un modo di organizzare l'incertezza, di definire cosa conta come evidenza e di stabilire quali conclusioni sono considerate giustificate. Per questo motivo, quando studiamo un paradigma inferenziale, è utile chiederci non solo *come* funziona, ma anche *quali domande* è stato progettato per rispondere.

L'approccio frequentista nasce dall'esigenza di costruire procedure di analisi che siano ripetibili, standardizzate e il meno possibile dipendenti dal giudizio individuale del ricercatore. Questa aspirazione all'oggettività ha avuto un'enorme importanza nella scienza moderna. Allo stesso tempo, ha

prodotto un modo specifico di interpretare l'incertezza: non come grado di credenza in un'ipotesi, ma come variabilità che emerge ripetendo idealmente lo stesso procedimento di raccolta dei dati.

Una chiave di lettura

Nel frequentismo, la domanda tipica non è: “Quanto è plausibile questa ipotesi alla luce dei dati?”. La domanda è piuttosto: “Come si comporterebbe questa procedura se la ripetessimo molte volte in condizioni analoghe?”.

Questa distinzione sarà centrale nei capitoli successivi, soprattutto quando confronteremo gli intervalli di confidenza e gli intervalli di credibilità bayesiani.

1.2. La quantificazione della variabilità umana

1.2.1. Dal singolo individuo alla distribuzione

Nel corso dell'Ottocento, si afferma l'idea che molti fenomeni biologici, psicologici e sociali possano essere studiati in modo quantitativo. L'attenzione si sposta progressivamente dal singolo individuo alla distribuzione dei tratti all'interno di una popolazione. Altezza, peso, tempi di reazione, prestazioni cognitive, risposte a questionari e differenze individuali vengono considerati come grandezze che variano da persona a persona, ma non in modo completamente casuale.

Questa intuizione è fondamentale per la psicologia scientifica. Se un tratto psicologico varia da individuo a individuo, allora è possibile descriverne la distribuzione, calcolare la media, misurarne la dispersione e studiare le relazioni con altri tratti. La variabilità non è più soltanto rumore, ma diventa informazione.

In questo contesto si inserisce l'opera di **Francis Galton** (1822-1911), figura centrale nella trasformazione della statistica da strumento prevalentemente descrittivo-amministrativo a linguaggio matematico della variazione individuale.

1.2.2. Galton: misurare, confrontare, ordinare

Galton si interessò alla misurazione sistematica delle differenze individuali. Raccolse dati su caratteristiche fisiche e psicologiche, studiò la trasmissione dei tratti tra le generazioni e contribuì a diffondere l'idea che le popolazioni possano essere rappresentate mediante distribuzioni.

Due concetti associati al suo lavoro sono particolarmente importanti per la statistica e per la psicologia:

1. **Regressione verso la media.** Galton osservò che, quando un tratto viene misurato nei genitori e nei figli, i valori estremi dei genitori tendono a essere seguiti da valori meno estremi nei figli. Questo fenomeno, oggi noto come “regressione verso la media”, dimostra che le relazioni tra le misure non devono essere interpretate in modo deterministico: anche quando esiste una relazione, rimane una componente di variabilità.
2. **Correlazione.** Lo studio della relazione tra due variabili ha portato allo sviluppo di strumenti per quantificare quanto due misure variano insieme. La correlazione è uno dei concetti più utilizzati nella ricerca psicologica, dalla validazione dei test alla psicometria fino allo studio delle differenze individuali.

L'importanza didattica di Galton in questo modulo non sta nel presentarlo come modello di buona pratica scientifica. Piuttosto, sta nel mostrare un passaggio concettuale fondamentale: molti problemi psicologici possono essere formulati come problemi di variabilità, associazione e previsione.

 Collegamento con la psicologia

Quando ci chiediamo se due scale psicologiche misurano costrutti correlati, se un punteggio predice un esito clinico o se un trattamento modifica una variabile psicologica, stiamo lavorando all'interno di una tradizione che ha imparato a descrivere gli individui come osservazioni all'interno di distribuzioni.

1.3. Statistica ed eugenetica: una genealogia ambivalente

La storia della statistica moderna presenta anche aspetti problematici. Galton è stato il fondatore dell'eugenetica, un programma che mirava a misurare e selezionare i tratti umani al fine di migliorare la popolazione. In questo contesto, strumenti nati per descrivere la variabilità sono stati spesso associati a classificazioni gerarchiche e a giudizi normativi sulle persone.

Questa eredità va affrontata con chiarezza. Da un lato, concetti come regressione, correlazione e distribuzione normale sono oggi strumenti matematici generali utilizzabili in contesti scientifici molto diversi. D'altro canto, la loro storia ci ricorda che la misurazione non è mai completamente neutra: scegliere cosa misurare, come misurarlo e come interpretare le differenze osservate comporta sempre delle responsabilità, sia scientifiche che etiche (Chivers, 2024).

 Un punto etico importante

Riconoscere il contesto eugenetico in cui una parte della statistica moderna si è sviluppata non significa rifiutare in blocco gli strumenti statistici. Significa usarli con maggiore consapevolezza: le differenze osservate tra persone o gruppi non devono essere trasformate automaticamente in gerarchie di valore né interpretate senza considerare il contesto, la misurazione, il campionamento e le assunzioni del modello.

Questa riflessione è particolarmente rilevante per gli studenti di psicologia. Molte misure psicologiche riguardano persone, gruppi, diagnosi, abilità, vulnerabilità e differenze socialmente sensibili. Una statistica responsabile richiede quindi sia competenza tecnica sia attenzione al significato delle misure.

1.4. Pearson e Fisher: la formalizzazione dell'approccio frequentista

1.4.1. Karl Pearson e la statistica come tecnologia della regolarità

Karl Pearson (1857-1936) contribuì in modo decisivo alla matematizzazione della statistica. Il suo lavoro rese più rigorosi concetti quali la correlazione, la deviazione standard e il confronto tra dati osservati e modelli teorici. Tra gli strumenti associati alla sua tradizione vi è anche il test del chi-quadrato che permette di valutare quanto le frequenze osservate si discostino da quelle attese in base a un modello.

Il suo contributo è importante perché rafforza un'idea centrale del frequentismo: una procedura statistica deve essere definita in modo esplicito, replicabile e applicabile a nuovi dati. L'obiettivo è ridurre l'arbitrarietà del giudizio individuale attraverso regole comuni di calcolo e valutazione.

1. Origini storiche dell'approccio frequentista

Questa impostazione ha avuto un impatto enorme sulla ricerca empirica. In psicologia, per esempio, ha contribuito a rendere ordinario il ragionamento in termini di campioni, distribuzioni, associazioni tra variabili e confronto tra dati osservati e valori attesi.

1.4.2. Ronald Fisher e la logica della significatività

Ronald A. Fisher (1890-1962) sviluppò strumenti che sono diventati centrali nella pratica statistica del Novecento: il disegno sperimentale, l'analisi della varianza, la massima verosimiglianza, la significatività statistica e il valore- p .

Nel quadro fisheriano, l'inferenza parte spesso da un modello nullo. Ci si chiede se i dati osservati sarebbero insoliti se quel modello fosse vero. Il valore- p nasce in questo contesto: misura quanto sarebbe sorprendente osservare dati almeno così estremi, assumendo vera l'ipotesi nulla.

È importante sottolineare subito ciò che il valore- p non dice. Non è la probabilità che l'ipotesi nulla sia vera. Non è la probabilità che il risultato sia dovuto al caso. Non misura direttamente la grandezza dell'effetto. Si tratta di una quantità definita all'interno di una procedura che immagina la ripetizione ipotetica dell'esperimento.

i Da ricordare fin da ora

Un valore- p risponde a una domanda frequentista:

se l'ipotesi nulla fosse vera, quanto sarebbero insoliti dati come quelli osservati, o più estremi?

Non risponde direttamente alla domanda bayesiana:

quanto è plausibile l'ipotesi dopo aver osservato questi dati?

Fisher contribuì anche allo sviluppo del principio della **massima verosimiglianza**. Questo concetto sarà importante più avanti, perché la verosimiglianza rappresenta un ponte naturale tra il frequentismo e il bayesianesimo. Nel frequentismo può essere utilizzata per ottenere stime dei parametri, mentre nell'inferenza bayesiana entra a far parte della regola di aggiornamento insieme alla distribuzione a priori.

1.5. Il paradigma frequentista in sintesi

Dopo questa breve ricostruzione storica, possiamo riassumere il nucleo concettuale dell'approccio frequentista.

1.5.1. Probabilità come frequenza a lungo termine

Nel frequentismo, la probabilità è interpretata come frequenza relativa nel lungo periodo. Affermare che un evento ha una probabilità dello 0.30 significa immaginare che, ripetendo molte volte lo stesso processo nelle stesse condizioni, tale evento si verificherebbe circa il 30% delle volte.

Questa interpretazione è molto naturale per i fenomeni ripetibili, come i lanci di moneta, le estrazioni casuali, i campionamenti da una popolazione o gli esperimenti randomizzati. È meno diretta quando si vuole esprimere l'incertezza su un'ipotesi unica, su un parametro sconosciuto o su un evento irripetibile. In questi casi, la prospettiva bayesiana offre un linguaggio diverso.

1.5.2. Parametri fissi, dati variabili

Nel modello frequentista classico:

- il parametro di interesse, come una media μ o una proporzione θ , è considerato **fisso ma sconosciuto**;
- i dati osservati sono una delle molte realizzazioni possibili del processo di campionamento;
- l'incertezza nasce dal fatto che campioni diversi avrebbero prodotto risultati diversi;
- la bontà di una procedura è valutata considerando come si comporterebbe in molte ripetizioni ideali dello stesso studio.

Questa è una differenza fondamentale rispetto all'approccio bayesiano, in cui il parametro sconosciuto può essere rappresentato tramite una distribuzione di probabilità che esprime l'incertezza epistemica del ricercatore.

1.5.3. Procedure valutate nel lungo periodo

Il frequentismo giudica le procedure statistiche in base alle loro proprietà a lungo termine. Per esempio:

- uno stimatore è apprezzato se, ripetendo il campionamento, tende in media al valore vero o si avvicina ad esso al crescere del campione;
- un intervallo di confidenza al 95% è una procedura che, in condizioni ideali, produce intervalli contenenti il parametro vero nel 95% dei casi;
- un test con livello di significatività $\alpha = 0.05$ controlla, nel lungo periodo, la probabilità di rigettare erroneamente un'ipotesi nulla vera.

Queste garanzie sono importanti e hanno reso il frequentismo uno strumento potente per la ricerca empirica. Tuttavia, richiedono un'interpretazione attenta: non sempre una garanzia a lungo termine corrisponde a ciò che vorremmo sapere riguardo allo studio concreto che abbiamo appena condotto.

1.6. Una mappa dei capitoli successivi

Nei capitoli successivi, entreremo nei principali strumenti frequentisti, mantenendo una distinzione costante tra la procedura matematica e la sua corretta interpretazione.

1. **Stime dei parametri.** Studieremo come un campione viene utilizzato per stimare una quantità sconosciuta della popolazione, e perché la distribuzione campionaria è centrale nel frequentismo.
2. **Intervalli di confidenza.** Vedremo come costruire intervalli che quantificano l'incertezza procedurale e chiariremo perché non vanno interpretati come probabilità dirette sul parametro.
3. **Test di ipotesi.** Analizzeremo la logica dell'ipotesi nulla, della statistica test, del valore- p e della decisione statistica.
4. **Dimensione campionaria e potenza.** Dopo aver introdotto i test, discuteremo perché la numerosità campionaria influenza la probabilità di individuare effetti reali.
5. **Confronto tra due gruppi.** Useremo il test t per campioni indipendenti come esempio applicativo di una procedura frequentista molto diffusa nella ricerca psicologica.

1. Origini storiche dell'approccio frequentista

Questa sequenza non ha lo scopo di presentare il frequentismo come un ostacolo da superare, ma come un linguaggio da comprendere. Solo dopo aver compreso a fondo le domande poste dal frequentismo, sarà possibile apprezzare con precisione le domande diverse poste dall'inferenza bayesiana.

1.7. Frequentismo e bayesianesimo: non una guerra, ma due domande diverse

È facile presentare il frequentismo e il bayesianesimo come due scuole contrapposte. In parte lo sono, in quanto adottano interpretazioni diverse della probabilità e dell'inferenza. Tuttavia, dal punto di vista didattico, è più utile partire da una distinzione di domande.

Il frequentismo si chiede:

Se ripetessimo molte volte questa procedura, con quale frequenza produrrebbe risultati corretti o errori controllati?

Il bayesianesimo, invece, si chiede:

Alla luce dei dati osservati e delle informazioni disponibili, come dovremmo aggiornare la nostra incertezza sui parametri o sulle ipotesi?

Entrambe le domande sono legittime, ma non sono equivalenti. Molti fraintendimenti nascono quando si usa uno strumento frequentista per rispondere implicitamente a una domanda bayesiana. Per esempio, interpretare un valore- p come probabilità che l'ipotesi nulla sia vera significa attribuire a una quantità frequentista un significato che non le appartiene.

! Messaggio centrale

Il frequentismo fornisce regole per costruire procedure che abbiano buone proprietà nel lungo periodo. L'inferenza bayesiana fornisce invece regole per aggiornare l'incertezza alla luce dei dati osservati.

Nel resto del modulo useremo questa distinzione come bussola interpretativa.

1.8. Una riflessione per la ricerca psicologica

La psicologia ha fatto ampio uso di strumenti frequentisti: test t , ANOVA, regressioni, intervalli di confidenza, valori- p e analisi di potenza sono parte del linguaggio comune della disciplina. Conoscerli è quindi indispensabile per leggere gli articoli, progettare gli studi e interpretare i risultati.

Tuttavia, la crisi della replicabilità ha dimostrato che l'applicazione meccanica di procedure standardizzate non garantisce automaticamente la produzione di conoscenze affidabili. Campioni piccoli, bassa potenza, selezione dei risultati, interpretazioni improprie del valore- p e attenzione eccessiva alla soglia 0,05 possono produrre evidenze fragili.

Questo non significa che il frequentismo sia inutile. La lezione è che nessuna procedura statistica può sostituire il ragionamento scientifico. Ogni analisi richiede un disegno di ricerca solido, misure valide, trasparenza, attenzione alla dimensione degli effetti e interpretazioni coerenti con le assunzioni del metodo.

Riflessioni conclusive

In questo capitolo abbiamo collocato l'approccio frequentista nel suo contesto storico e concettuale. Abbiamo visto che la statistica moderna nasce anche dal tentativo di misurare e ordinare la variabilità umana, un progetto che ha prodotto strumenti fondamentali per la scienza, ma che ha anche dato luogo a usi eticamente problematici. Questa doppia eredità invita a una posizione equilibrata: competenza tecnica, consapevolezza storica e responsabilità interpretativa.

Abbiamo inoltre introdotto i principi del frequentismo: la probabilità come frequenza a lungo termine, i parametri come valori fissi ma sconosciuti, i dati come variabili e le procedure come oggetti da valutare in base al comportamento che avrebbero in ripetizioni ideali. Questi principi saranno alla base dei prossimi capitoli dedicati a stima, intervalli di confidenza, test di ipotesi, dimensione campionaria e confronto tra gruppi.

Il filo conduttore sarà sempre lo stesso: imparare a usare e interpretare gli strumenti frequentisti senza attribuirgli significati che non hanno. Questo lavoro preparerà il passaggio all'inferenza bayesiana, in cui l'incertezza sui parametri e sulle ipotesi viene rappresentata direttamente tramite distribuzioni di probabilità.

Punti chiave da ricordare

! Importante

1. **La statistica moderna nasce dallo studio della variabilità.** Galton, Pearson e Fisher contribuiscono a trasformare la variabilità individuale in un oggetto di misurazione e modellizzazione.
2. **La genealogia della statistica è ambivalente.** Alcuni strumenti fondamentali sono nati in contesti legati all'eugenetica. Questo non li rende inutilizzabili, ma richiede consapevolezza storica ed etica.
3. **Nel frequentismo la probabilità è frequenza a lungo termine.** La probabilità riguarda ciò che accadrebbe in molte ripetizioni dello stesso processo, non direttamente il grado di credenza su un'ipotesi.
4. **I parametri sono fissi, i dati sono variabili.** L'incertezza frequentista deriva dal campionamento: campioni diversi produrrebbero stime diverse.
5. **Le procedure sono valutate nel lungo periodo.** Stimatori, intervalli di confidenza e test sono giudicati in base alle loro proprietà sotto ripetizione dell'esperimento.
6. **Il confronto con il bayesianesimo riguarda le domande inferenziali.** Il frequentismo controlla le proprietà delle procedure; il bayesianesimo aggiorna esplicitamente l'incertezza sui parametri o sulle ipotesi.

i Per il prossimo capitolo

Nel prossimo capitolo passeremo dalla cornice storica alla prima procedura inferenziale: la **stima dei parametri**. Vedremo come una statistica calcolata su un campione può essere utilizzata per stimare una quantità sconosciuta della popolazione e perché la distribuzione campionaria è al centro del ragionamento frequentista.

1. *Origini storiche dell'approccio frequentista*

Bibliografia

2. Stime, stimatori e parametri

Questo capitolo introduce il modo in cui l'inferenza frequentista affronta il problema della **stima dei parametri**. Nel companion sulla probabilità abbiamo già discusso distribuzioni campionarie, errore standard, Legge dei Grandi Numeri e Teorema del Limite Centrale. Qui non ripeteremo quei risultati: li useremo come strumenti per comprendere che cosa significa, nel paradigma frequentista, stimare una quantità sconosciuta a partire da un campione.

! In questo capitolo imparerai a

- distinguere tra **parametro**, **stimatore** e **stima**;
- capire perché, nel frequentismo, il parametro è considerato fisso ma ignoto;
- descrivere le proprietà desiderabili di uno stimatore: correttezza, consistenza, efficienza e compromesso bias-varianza;
- interpretare l'errore standard come misura operativa dell'incertezza campionaria;
- comprendere perché la stima puntuale conduce naturalmente agli intervalli di confidenza.

💡 Prerequisiti

Per seguire questo capitolo è utile aver letto:

- il capitolo sul campione e l'evidenza del companion sulla probabilità, in particolare **?@sec-prob-inference-uncertainty**;
- il capitolo sulle proprietà delle variabili casuali, per valore atteso e varianza;
- il capitolo introduttivo di questo modulo, in cui sono state distinte le domande frequentiste dalle domande bayesiane.

In questo capitolo useremo espressioni come “distribuzione campionaria” ed “errore standard” senza ridimostrarle. Il punto non è ripetere la teoria probabilistica, ma chiarire come essa viene impiegata nelle procedure frequentiste di stima.

🔥 Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
```

2.1. Il problema della stima

Una ricercatrice vuole stimare il livello medio di ansia in una popolazione di studenti universitari. Non può osservare tutti gli studenti, quindi raccoglie un campione e calcola la media osservata. Ottiene, per esempio, una media pari a 18.4 su una scala psicometrica.

2. Stime, stimatori e parametri

Questo numero è utile, ma da solo non risponde alla domanda inferenziale principale. La media osservata è solo il risultato di uno specifico campione. Se la ricercatrice avesse osservato un altro campione, avrebbe probabilmente ottenuto un valore diverso.

Il problema della stima nasce da questa distanza tra due livelli:

- la **popolazione**, che contiene la quantità di interesse;
- il **campione**, che fornisce solo un'osservazione parziale e variabile.

Nel paradigma frequentista, il parametro della popolazione è considerato una quantità fissa ma ignota. L'incertezza non riguarda il parametro in sé, ma la procedura usata per stimarlo a partire da campioni possibili.

i La domanda frequentista

Una domanda frequentista tipica non è:

Qual è la probabilità che il parametro abbia un certo valore, dati questi dati?

ma piuttosto:

Se applicassimo questa procedura a molti campioni estratti nelle stesse condizioni, quali proprietà avrebbe la stima prodotta?

Questa distinzione è essenziale. In un approccio bayesiano, l'incertezza sul parametro viene rappresentata direttamente mediante una distribuzione di probabilità. In un approccio frequentista, invece, la probabilità descrive il comportamento dei dati e delle statistiche campionarie nel caso di ipotetiche ripetizioni del campionamento.

2.2. Parametro, stimatore e stima

Per evitare ambiguità, introduciamo tre termini fondamentali.

i Tre livelli da distinguere

Termine	Significato	Esempio
Parametro	Quantità fissa ma ignota della popolazione	La media vera dell'ansia, μ
Stimatore	Regola che usa i dati per stimare il parametro	La media campionaria, $\bar{X}$
Stima	Valore numerico ottenuto nel campione osservato	$\bar{x} = 18.4$

Il **parametro** è l'obiettivo dell'inferenza. Può essere una media, una proporzione, una varianza, una differenza tra medie, una correlazione o un coefficiente di regressione. Nel frequentismo il parametro non è casuale: ha un valore vero, anche se sconosciuto.

Lo **stimatore** è invece una funzione dei dati. Prima di osservare il campione, il suo valore è incerto perché dipende da quali osservazioni verranno effettivamente selezionate. Per questo motivo, lo stimatore ha una distribuzione campionaria.

La **stima** è il valore che otteniamo dopo aver osservato i dati. È il numero che compare nel report, nell'articolo o nella tabella dei risultati.

⚠ Errore comune

Non bisogna confondere lo stimatore con la stima. Le proprietà teoriche, come correttezza o efficienza, riguardano lo **stimatore** come procedura. La singola **stima** osservata può essere vicina o lontana dal parametro, ma da sola non permette di sapere quanto sia accurata.

2.3. La stima puntuale

La forma più semplice di inferenza è la **stima puntuale**: si usa un singolo numero per rappresentare il valore più plausibile o più naturale del parametro.

Esempi comuni sono:

- la media campionaria $\bar{x}$ come stima della media della popolazione μ ;
- la proporzione campionaria $\hat{p}$ come stima della proporzione della popolazione p ;
- la differenza tra due medie campionarie come stima della differenza tra due medie di popolazione;
- il coefficiente di correlazione campionario r come stima della correlazione nella popolazione ρ .

La stima puntuale è indispensabile perché fornisce una sintesi dei dati. Tuttavia, non basta. Una stima puntuale non comunica quanta incertezza sia associata al risultato.

Supponiamo che due studi stimino la stessa media:

```
stima_A <- 18.4
se_A <- 0.30

stima_B <- 18.4
se_B <- 1.80

risultati <- data.frame(
  Studio = c("A", "B"),
  Stima = c(stima_A, stima_B),
  Errore_standard = c(se_A, se_B)
)

risultati
#>   Studio Stima Errore_standard
#> 1     A  18.4           0.3
#> 2     B  18.4           1.8
```

Le due stime puntuali sono identiche, ma non hanno lo stesso significato inferenziale. Nel primo caso la procedura produce stime più stabili; nel secondo, la stessa stima è associata a maggiore variabilità campionaria. Questo esempio anticipa il ruolo degli intervalli di confidenza: una stima va sempre accompagnata da una misura della sua incertezza.

2.4. Che cosa rende buono uno stimatore?

Nel frequentismo, uno stimatore viene valutato in base al suo comportamento nel lungo periodo, cioè sotto ripetizione ideale dello stesso procedimento di campionamento. Le proprietà più importanti sono correttezza, consistenza, efficienza e, più in generale, errore quadratico medio.

2.4.1. Correttezza

Uno stimatore è **corretto** o **non distorto** se, nel lungo periodo, il suo valore medio coincide con il parametro che intende stimare:

$$E(\hat{\theta}) = \theta.$$

Intuitivamente, uno stimatore corretto non tende sistematicamente né a sovrastimare né a sottostimare il parametro. Questo non significa che ogni singola stima sia vicina al valore vero. Significa che gli errori positivi e negativi si compensano nel lungo periodo.

2.4.2. Bias

Il **bias** di uno stimatore misura la distanza tra il valore atteso dello stimatore e il parametro:

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

Uno stimatore con bias positivo tende a sovrastimare il parametro; uno stimatore con bias negativo tende a sottostimarli. Il bias può derivare dalla formula dello stimatore, ma anche da problemi più sostanziali: campionamento non rappresentativo, strumenti di misura distorti, dati mancanti non casuali.

! Bias statistico e bias metodologico

Nel linguaggio tecnico, il bias può indicare una proprietà matematica dello stimatore. Nella pratica della ricerca psicologica, però, molte distorsioni nascono prima dell'analisi: dalla selezione dei partecipanti, dalla qualità della misura, dal disegno dello studio o dal modo in cui i dati sono raccolti. Un campione grande riduce l'incertezza campionaria, ma non elimina automaticamente le distorsioni sistematiche.

2.4.3. Consistenza

Uno stimatore è **consistente** se, al crescere della dimensione del campione, tende ad avvicinarsi al valore vero del parametro. In forma intuitiva:

$$\hat{\theta}_n \longrightarrow \theta \quad \text{quando} \quad n \longrightarrow \infty.$$

La consistenza collega la stima al comportamento asintotico della procedura. Uno stimatore consistente può essere impreciso in campioni piccoli, ma diventa affidabile quando il campione cresce.

2.4.4. Efficienza

Tra due stimatori corretti dello stesso parametro, si dice più **efficiente** quello con varianza minore. In termini pratici, uno stimatore efficiente produce stime meno disperse da campione a campione.

Questo concetto è importante perché due stimatori possono essere entrambi centrati sul parametro, ma avere livelli molto diversi di precisione.

2.4.5. Il compromesso bias-varianza

In molti problemi reali non esiste uno stimatore perfetto. A volte uno stimatore leggermente distorto può avere una varianza molto più piccola di uno stimatore non distorto. Per valutare complessivamente uno stimatore si considera spesso l'**errore quadratico medio**:

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2.$$

Questa formula mostra che l'accuratezza di una procedura dipende sia dalla variabilità delle stime sia dalla loro eventuale distorsione sistematica.

2.5. Il ruolo della distribuzione campionaria

La distribuzione campionaria è il concetto che permette al frequentismo di valutare una procedura di stima. Essa descrive come cambierebbe lo stimatore se lo studio fosse ripetuto molte volte nelle stesse condizioni.

Nel companion sulla probabilità abbiamo visto che la media campionaria ha alcune proprietà fondamentali: è centrata sulla media della popolazione, la sua variabilità diminuisce al crescere di n e, sotto condizioni ampie, la sua distribuzione diventa approssimativamente normale per campioni grandi. Qui useremo questi risultati senza ridimostrarli.

i Funzione della distribuzione campionaria in questo modulo

La distribuzione campionaria non viene introdotta qui come nuovo oggetto probabilistico, ma come fondamento delle procedure frequentiste:

- consente di definire l'errore standard;
- permette di costruire intervalli di confidenza;
- permette di valutare test di ipotesi;
- giustifica affermazioni sul comportamento a lungo termine delle procedure.

La logica è questa: anche se osserviamo un solo campione, possiamo progettare procedure che, se applicate molte volte a campioni simili, abbiano proprietà controllate. Gli intervalli di confidenza e i test di ipotesi sono costruiti precisamente in questo modo.

2.6. L'errore standard come misura operativa

L'**errore standard** è la deviazione standard della distribuzione campionaria di uno stimatore. Esso misura quanto lo stimatore varierebbe da campione a campione.

Per la media campionaria, quando la deviazione standard della popolazione è σ , l'errore standard teorico è:

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Nella pratica, σ non è nota, quindi viene sostituita dalla deviazione standard campionaria s :

$$\widehat{SE}(\bar{X}) = \frac{s}{\sqrt{n}}.$$

Il messaggio operativo è semplice: l'errore standard misura l'incertezza della **stima**, non la variabilità dei singoli dati. Una deviazione standard descrive quanto differiscono gli individui; un errore standard descrive quanto differirebbero le stime se ripetessimo il campionamento.

Deviazione standard ed errore standard

La **deviazione standard** descrive la dispersione delle osservazioni. L'**errore standard** descrive la dispersione di uno stimatore sotto campionamento ripetuto. Confondere queste due quantità porta a interpretazioni errate dei risultati empirici.

2.7. Dal numero osservato alla procedura

Una stima puntuale risponde alla domanda:

Qual è il valore osservato nel mio campione?

L'inferenza frequentista aggiunge una seconda domanda:

Quali garanzie avrebbe la procedura che ha prodotto questa stima se fosse applicata ripetutamente?

Questa seconda domanda è il tratto distintivo del paradigma frequentista. Il singolo risultato osservato viene interpretato alla luce di una procedura più ampia: la procedura di campionamento, lo stimatore scelto, la sua distribuzione campionaria e le regole usate per costruire intervalli o test.

Per questo motivo, la stima puntuale non è il punto di arrivo, ma il punto di partenza. Nei capitoli successivi vedremo due modi frequentisti di trasformare una stima in un risultato inferenziale:

1. gli **intervalli di confidenza**, che associano alla procedura una proprietà di copertura nel lungo periodo;
2. i **test di ipotesi**, che valutano la compatibilità dei dati con un'ipotesi di riferimento attraverso il comportamento atteso della statistica test.

2.8. Confronto con la prospettiva bayesiana

Il confronto con il bayesianesimo aiuta a chiarire che le differenze non sono soltanto tecniche, ma riguardano il significato attribuito alla probabilità.

Aspetto	Frequentismo	Bayesianesimo
Parametro	Fisso ma ignoto	Incerto e descritto da una distribuzione
Fonte della probabilità	Ripetizione ipotetica del campionamento	Grado di credenza razionale dato il modello
Oggetto dell'incertezza	Stimatore, dati possibili, procedura	Parametro dato il campione osservato
Risultato tipico	Stima, errore standard, intervallo di confidenza	Distribuzione posterior, intervallo di credibilità
Domanda centrale	Come si comporta la procedura nel lungo periodo?	Che cosa crediamo sul parametro dopo aver visto i dati?

Questa differenza diventerà particolarmente importante nel capitolo sugli intervalli di confidenza. Un intervallo di confidenza al 95% non significa che ci sia il 95% di probabilità che il parametro cada nell'intervallo osservato. Significa che la procedura, applicata molte volte in condizioni analoghe, produce intervalli che contengono il parametro nel 95% dei casi.

Riflessioni conclusive

In questo capitolo abbiamo ridefinito il problema della stima dal punto di vista frequentista. Il parametro è trattato come una quantità fissa ma ignota; lo stimatore è una procedura che varia da campione a campione; la stima è il valore ottenuto nel campione osservato.

Le proprietà di uno stimatore, come correttezza, consistenza ed efficienza, riguardano il suo comportamento sotto ripetizione ipotetica del campionamento. L'errore standard sintetizza la variabilità dello stimatore e permette di passare dalla stima puntuale alla quantificazione dell'incertezza.

Il punto essenziale è che l'inferenza frequentista fornisce garanzie sulle **procedure**, non probabilità dirette sui parametri. Questa impostazione è potente e ha avuto un ruolo centrale nella ricerca psicologica, ma richiede cautela interpretativa. Il prossimo capitolo mostrerà come questa logica conduce agli intervalli di confidenza.

Punti chiave da ricordare

! Importante

1. Un **parametro** è una quantità fissa ma ignota della popolazione.
2. Uno **stimatore** è una funzione dei dati e varia da campione a campione.
3. Una **stima** è il valore numerico ottenuto nel campione osservato.
4. Uno stimatore corretto non tende sistematicamente a sovrastimare o sottostimare il parametro.
5. L'errore standard misura la variabilità dello stimatore, non la dispersione dei dati grezzi.

6. Nel frequentismo, le garanzie principali riguardano il comportamento a lungo termine delle procedure.
7. La stima puntuale deve essere accompagnata da una misura dell'incertezza.

! Esercizi

1. In uno studio su 120 studenti, la media osservata a una scala di stress è 24.6. Qual è il parametro? Qual è lo stimatore? Qual è la stima?
2. Spiega con parole tue perché uno stimatore corretto può produrre una singola stima lontana dal parametro.
3. Perché l'errore standard non deve essere interpretato come misura della variabilità individuale?
4. Quale differenza c'è tra dire "il parametro è incerto" e dire "lo stimatore è variabile"?

i Informazioni sull'ambiente di sviluppo

2. Stime, stimatori e parametri

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2        ggdist_3.3.3
#> [7] tidybayes_3.0.7      bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0       posterior_1.7.0
#> [13] loo_2.10.0           rstan_2.32.7           StanHeaders_2.32.10
#> [16] brms_2.23.0          Rcpp_1.1.2             sessioninfo_1.2.4
#> [19] conflicted_1.2.0     janitor_2.2.1          matrixStats_1.5.0
#> [22] modelr_0.1.11        tibble_3.3.1           dplyr_1.2.1
#> [25] tidyr_1.3.2          rio_1.3.0              here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8         tidyselect_1.2.1       farver_2.1.2
#> [4] S7_0.2.2             fastmap_1.2.0          tensorA_0.36.2.1
#> [7] digest_0.6.39        timechange_0.4.0       estimability_2.0.0
#> [10] lifecycle_1.0.5      magrittr_2.0.5         compiler_4.6.1
#> [13] rlang_1.3.0          tools_4.6.1            knitr_1.51
#> [16] bridgesampling_1.2-1 pkgbuild_1.4.8         curl_7.1.0
#> [19] RColorBrewer_1.1-3   abind_1.4-8            purrr_1.2.2
#> [22] grid_4.6.1           stats4_4.6.1           xtable_1.8-8
#> [25] inline_0.3.21        emmeans_2.0.3          scales_1.4.0
#> [28] cli_3.6.6            mvtnorm_1.4-1          rmarkdown_2.31
#> [31] generics_0.1.4       otel_0.2.0             RcppParallel_5.1.11-2
#> [34] cachem_1.1.0         stringr_1.6.0          parallel_4.6.1
#> [37] vctrs_0.7.3          V8_8.2.0              Matrix_1.7-5
#> [40] jsonlite_2.0.0       arrayhelpers_1.1-1     glue_1.8.1
#> [43] codetools_0.2-20     distributional_0.8.1    lubridate_1.9.5
#> [46] stringi_1.8.7        gtable_0.3.6           QuickJSR_1.10.0
#> [49] pillar_1.11.1        htmltools_0.5.9        Brodbingnag_1.2-9
#> [52] R6_2.6.1            textshaping_1.0.5      rprojroot_2.1.1
#> [55] evaluate_1.0.5       lattice_0.22-9         backports_1.5.1
#> [58] memoise_2.0.1        broom_1.0.13           snakecase_0.11.1
#> [61] rstantools_2.6.0     coda_0.19-4.1          gridExtra_2.3.1
#> [64] nlme_3.1-169         checkmate_2.3.4        xfun_0.60
#> [67] pkgconfig_2.0.3
```

3. Intervalli di confidenza

Nel capitolo precedente abbiamo distinto il **parametro**, lo **stimatore** e la **stima**. Una stima puntuale, come ad esempio una media campionaria, è un riassunto utile dei dati osservati, ma non comunica da sola l'incertezza associata al risultato.

Gli **intervalli di confidenza** sono lo strumento con cui l'inferenza frequentista accompagna una stima puntuale con una misura della sua incertezza. La loro interpretazione richiede tuttavia attenzione: un intervallo di confidenza non assegna una probabilità al parametro. Esprime, piuttosto, una garanzia sulla **procedura** che ha prodotto l'intervallo, valutata nel lungo periodo e ipotizzando la ripetizione del campionamento.

! In questo capitolo imparerai a

- costruire un intervallo di confidenza per la media di una popolazione;
- interpretare il livello di confidenza come **copertura nel lungo periodo**;
- distinguere tra intervallo di confidenza e intervallo di credibilità;
- riconoscere i fraintendimenti più comuni;
- comprendere come livello di confidenza, variabilità e dimensione campionaria influenzano l'ampiezza dell'intervallo.

💡 Prerequisiti

Per seguire questo capitolo è utile aver letto:

- Capitolo 2, per la distinzione tra parametro, stimatore e stima;
- il capitolo del companion sulla probabilità dedicato al passaggio dal campione all'evidenza, in particolare per errore standard e distribuzione campionaria;
- l'introduzione a questo modulo, dove abbiamo distinto le domande frequentiste dalle domande bayesiane.

Qui non ripeteremo in dettaglio la teoria della distribuzione campionaria. Useremo quel risultato per capire come il frequentismo costruisce intervalli con una proprietà di copertura controllata.

🔥 Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
```

3.1. Dalla stima puntuale all'intervallo

Supponiamo di voler stimare il punteggio medio di benessere psicologico in una popolazione di studenti. Raccogliamo un campione e otteniamo una media pari a 24.8. Questo valore è la nostra

3. Intervalli di confidenza

stima puntuale della media della popolazione, indicata con μ .

Il problema è che un altro campione avrebbe probabilmente prodotto una media diversa. La variabilità campionaria rende quindi incompleta una comunicazione basata solo sulla stima puntuale.

Un intervallo di confidenza fornisce una seconda informazione: non solo “qual è la stima?”, ma anche “quanto è variabile la procedura che ha prodotto questa stima?”.

Nel caso più comune, un intervallo di confidenza ha la forma:

$$\text{stima} \pm \text{margine di errore.}$$

Il margine di errore combina due elementi:

1. una misura della variabilità della stima, cioè l'**errore standard**;
2. un valore critico, scelto in base al livello di confidenza desiderato.

Per la media di una popolazione, quando la varianza viene stimata dal campione, la forma generale è:

$$\bar{X} \pm t_{n-1}^* \frac{s}{\sqrt{n}},$$

dove $\bar{X}$ è la media campionaria, s è la deviazione standard campionaria, n è la dimensione del campione e t_{n-1}^* è il valore critico della distribuzione t di Student con $n - 1$ gradi di libertà.

3.2. La logica della copertura

La nozione centrale per interpretare un intervallo di confidenza è la **copertura**.

Un intervallo di confidenza al 95% viene costruito con una procedura che, se applicata molte volte a campioni estratti nelle stesse condizioni, produrrebbe intervalli contenenti il vero valore del parametro nel 95% dei casi.

! Interpretazione corretta

Un intervallo di confidenza al 95% non significa che, per l'intervallo osservato, vi sia il 95% di probabilità che il parametro sia al suo interno.

Significa invece che la **procedura** usata per costruire l'intervallo ha una copertura del 95% nel lungo periodo.

Questa distinzione è il cuore dell'interpretazione frequentista. Prima di osservare i dati, l'intervallo è casuale, perché dipende dal campione che verrà osservato. Dopo aver osservato i dati, l'intervallo è fissato: contiene oppure non contiene il parametro vero. Nella prospettiva frequentista, non assegniamo una probabilità a questo evento per il singolo intervallo osservato, in quanto il parametro non è considerato una variabile casuale.

i La domanda frequentista

La domanda non è:

Qual è la probabilità che μ sia in questo intervallo?

ma:

Che percentuale di intervalli costruiti con questa procedura conterrebbe μ se ripetessimo lo studio molte volte?

3.3. Costruzione dell'intervallo per una media

3.3.1. Caso ideale: varianza nota

Il caso più semplice, anche se raramente realistico, è quello in cui la popolazione è normale, la media μ è ignota e la deviazione standard della popolazione σ è nota. In questo caso:

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Standardizzando:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

Per un livello di confidenza del 95%, il valore critico della normale standard è circa 1.96. L'intervallo diventa:

$$\bar{X} \pm 1.96 \frac{\sigma}{\sqrt{n}}.$$

Questo caso è utile perché mostra la struttura logica dell'intervallo: stima puntuale, errore standard e valore critico. Nella ricerca psicologica, però, σ non è quasi mai nota.

3.3.2. Caso usuale: varianza ignota

Quando la deviazione standard della popolazione non è nota, la stimiamo con la deviazione standard campionaria s . Questa sostituzione introduce ulteriore incertezza. Per tenere conto di ciò, utilizziamo la distribuzione t di Student:

$$T = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}.$$

L'intervallo di confidenza al livello $1 - \alpha$ è:

$$\left(\bar{X} - t_{n-1}^* \frac{s}{\sqrt{n}}, \bar{X} + t_{n-1}^* \frac{s}{\sqrt{n}} \right),$$

dove t_{n-1}^* è il quantile della distribuzione t di Student corrispondente al livello di confidenza scelto.

Per campioni piccoli, la distribuzione t di Student presenta code più pesanti rispetto alla distribuzione normale standard e produce intervalli più ampi. Per campioni grandi, la distribuzione t di Student diventa molto simile alla distribuzione normale.

Perché la distribuzione t?

La distribuzione t di Student tiene conto del fatto che stiamo utilizzando s al posto di σ . In altre parole, non stiamo solo stimando la media: stiamo anche stimando la variabilità della popolazione. Questa incertezza aggiuntiva rende l'intervallo più prudente, soprattutto con pochi dati.

3.4. Esempio pratico in R

Consideriamo un piccolo campione di punteggi di benessere psicologico. L'obiettivo è stimare la media della popolazione e costruire un intervallo di confidenza al 95%.

```
punteggi <- c(28, 22, 26, 18, 30, 24, 27, 17, 21, 25)

n <- length(punteggi)
media <- mean(punteggi)
dev_std <- sd(punteggi)
errore_standard <- dev_std / sqrt(n)

cat("Media campionaria:", round(media, 2), "\n")
#> Media campionaria: 23.8
cat("Deviazione standard campionaria:", round(dev_std, 2), "\n")
#> Deviazione standard campionaria: 4.26
cat("Errore standard:", round(errore_standard, 2), "\n")
#> Errore standard: 1.35
cat("Dimensione campionaria:", n, "\n")
#> Dimensione campionaria: 10
```

Calcoliamo ora manualmente l'intervallo di confidenza.

```
alpha <- 0.05
t_star <- qt(1 - alpha / 2, df = n - 1)
margine_errore <- t_star * errore_standard

limite_inf <- media - margine_errore
limite_sup <- media + margine_errore

cat("Valore critico t*:", round(t_star, 3), "\n")
#> Valore critico t*: 2.26
cat("Margine di errore:", round(margine_errore, 2), "\n")
#> Margine di errore: 3.05
cat("Intervallo di confidenza al 95%: [",
    round(limite_inf, 2), ", ", round(limite_sup, 2), "]\n")
#> Intervallo di confidenza al 95%: [ 20.8 , 26.9 ]
```

La stessa procedura può essere eseguita con `t.test()`:

```
t.test(punteggi, conf.level = 0.95)
#>
#> One Sample t-test
#>
#> data: punteggi
#> t = 18, df = 9, p-value = 3e-08
#> alternative hypothesis: true mean is not equal to 0
#> 95 percent confidence interval:
#> 20.8 26.8
#> sample estimates:
#> mean of x
#> 23.8
```

L'output di `t.test()` include anche una statistica test e un valore- p . In questo capitolo ci concentriamo sull'intervallo di confidenza; il valore- p verrà discusso nel capitolo sui test di ipotesi.

Come scrivere il risultato

Una formulazione corretta è:

La media campionaria è 23.8 e l'intervallo di confidenza al 95% per la media della popolazione va da 20.75 a 26.85.

Una formulazione da evitare è:

C'è il 95% di probabilità che la media vera sia tra 20.75 e 26.85.

3.5. Simulare la copertura

La copertura è una proprietà della procedura. Per renderla più intuitiva, possiamo simulare molti campioni da una popolazione con media nota e verificare quante volte l'intervallo contiene il valore vero.

```
set.seed(42)

mu_vero <- 50
sigma_vera <- 10
n <- 25
n_simulazioni <- 1000

intervalli <- replicate(n_simulazioni, {
  campione <- rnorm(n, mean = mu_vero, sd = sigma_vera)
  test <- t.test(campione, conf.level = 0.95)
  c(inferiore = test$conf.int[1], superiore = test$conf.int[2])
})

contiene_mu <- (intervalli["inferiore", ] <= mu_vero) &
  (intervalli["superiore", ] >= mu_vero)
```

3. Intervalli di confidenza

```
copertura_empirica <- mean(contiene_mu)

cat("Copertura empirica:", round(copertura_empirica * 100, 1), "%\n")
#> Copertura empirica: 94.8 %
cat("Copertura nominale: 95%\n")
#> Copertura nominale: 95%
```


La copertura empirica non sarà esattamente 95%, perché abbiamo simulato un numero finito di campioni. Tuttavia, dovrebbe oscillare attorno al valore nominale.

Visualizziamo i primi 50 intervalli simulati.

```
n_mostra <- 50

df_ic <- data.frame(
  id = seq_len(n_mostra),
  inferiore = intervalli["inferiore", seq_len(n_mostra)],
  superiore = intervalli["superiore", seq_len(n_mostra)],
  contiene = contiene_mu[seq_len(n_mostra)]
)

ggplot(df_ic, aes(x = id)) +
  geom_segment(aes(xend = id,
                  y = inferiore,
                  yend = superiore,
                  linetype = contiene),
              linewidth = 0.7) +
  geom_hline(yintercept = mu_vero, linetype = "dashed") +
  labs(
    title = "Intervalli di confidenza costruiti su campioni ripetuti",
    subtitle = "La linea tratteggiata indica il valore vero della media",
    x = "Campione simulato",
    y = "Intervallo di confidenza",
    linetype = "Contiene la media vera"
  ) +
  coord_flip()
```



Il grafico mostra perché l'interpretazione frequentista riguarda la procedura e non il singolo intervallo. In molti campioni l'intervallo contiene il valore vero, in altri no. Dopo aver osservato un solo intervallo, non è possibile sapere a quale dei due casi appartenga.

3.6. Interpretazioni corrette e fraintendimenti comuni

Gli intervalli di confidenza sono spesso interpretati in modo intuitivo ma scorretto. La tabella seguente riassume le distinzioni principali.

Affermazione	Corretta?	Perché
“La procedura produce intervalli che contengono il parametro nel 95% dei campioni ripetuti.”	Sì	Questa è l'interpretazione frequentista della copertura.
“C'è il 95% di probabilità che il parametro sia dentro questo intervallo.”	No	Nel frequentismo il parametro è fisso, non casuale.
“Il 95% dei valori individuali della popolazione cade nell'intervallo.”	No	L'intervallo riguarda il parametro, non i singoli valori osservabili.
“I valori centrali dell'intervallo sono più probabili dei valori vicini agli estremi.”	No	L'intervallo di confidenza non è una distribuzione di probabilità sul parametro.
“Un intervallo più stretto indica maggiore precisione della stima, a parità di condizioni.”	Sì	L'ampiezza riflette errore standard e livello di confidenza.

Il punto più importante

Un intervallo di confidenza sembra parlare direttamente del parametro, ma la sua giustificazione formale riguarda la procedura che lo genera. Questa è la ragione per cui l'interpretazione corretta è spesso meno intuitiva di quella desiderata dai ricercatori.

3.7. Che cosa determina l'ampiezza dell'intervallo?

L'ampiezza di un intervallo di confidenza dipende da tre elementi principali.

3.7.1. Livello di confidenza

Aumentare il livello di confidenza aumenta l'ampiezza dell'intervallo. Per garantire una copertura più elevata nel lungo periodo, la procedura deve produrre intervalli più larghi.

```
livelli <- c(0.80, 0.90, 0.95, 0.99)

for (livello in livelli) {
  test <- t.test(punteggi, conf.level = livello)
  ampiezza <- diff(test$conf.int)
  cat(sprintf(
    "IC al %d%: [%.2f, %.2f], ampiezza = %.2f\n",
    livello * 100,
    test$conf.int[1],
    test$conf.int[2],
    ampiezza
  ))
}

#> IC al 80%: [21.94, 25.66], ampiezza = 3.73
#> IC al 90%: [21.33, 26.27], ampiezza = 4.94
#> IC al 95%: [20.75, 26.85], ampiezza = 6.10
#> IC al 99%: [19.42, 28.18], ampiezza = 8.76
```

3.7.2. Variabilità dei dati

A parità di dimensione campionaria, dati più variabili producono un errore standard maggiore e quindi intervalli più ampi. In psicologia questo punto è cruciale: misure rumorose o costrutti eterogenei rendono più difficile ottenere stime precise.

3.7.3. Dimensione campionaria

Aumentare n riduce l'errore standard e quindi restringe l'intervallo. Tuttavia, la relazione non è lineare: l'errore standard diminuisce come $1/\sqrt{n}$. Per dimezzare l'errore standard, occorre circa quadruplicare la dimensione del campione.

```

set.seed(123)

dimensioni <- c(10, 30, 100, 300)
popolazione <- rnorm(10000, mean = 50, sd = 10)

risultati_n <- lapply(dimensioni, function(n) {
  campione <- sample(popolazione, size = n)
  test <- t.test(campione, conf.level = 0.95)
  data.frame(
    n = n,
    inferiore = test$conf.int[1],
    superiore = test$conf.int[2],
    ampiezza = diff(test$conf.int)
  )
})

risultati_n <- do.call(rbind, risultati_n)
risultati_n
#>      n inferiore superiore ampiezza
#> 1  10      42.7      54.8      12.10
#> 2  30      47.4      53.5       6.09
#> 3 100      47.8      52.1       4.23
#> 4 300      48.2      50.5       2.37

```

i Precisione e validità

Un intervallo stretto indica una bassa incertezza campionaria, ma non necessariamente una alta qualità scientifica. Se il campione non è rappresentativo o la misura è distorta, l'intervallo può essere molto preciso, ma centrato sul valore sbagliato.

3.8. Intervalli di confidenza e intervalli di credibilità

Per gli studenti che stanno studiando l'inferenza bayesiana, il confronto con gli intervalli di credibilità è inevitabile. I due strumenti possono apparire simili perché entrambi forniscono un intervallo numerico. Tuttavia, rispondono a domande diverse.

Aspetto	Intervallo di confidenza	Intervallo di credibilità
Paradigma	Frequentista	Bayesiano
Oggetto probabilistico	La procedura in campioni ripetuti	Il parametro, condizionatamente ai dati e al modello
Domanda	Quale procedura ha copertura del 95% nel lungo periodo?	Quale intervallo contiene il 95% della probabilità a posteriori?
Parametro	Fisso ma ignoto	Incerto, rappresentato da una distribuzione
Dipende da una prior?	No, nella forma standard	Sì, attraverso la distribuzione a posteriori
Interpretazione intuitiva	Procedurale	Diretta sul parametro, dato il modello

3. Intervalli di confidenza

Un intervallo di credibilità bayesiano al 95% può essere interpretato come un intervallo che contiene il 95% della probabilità a posteriori del parametro, dato il modello, la prior e i dati. Questa è spesso l'interpretazione che i ricercatori vorrebbero dare agli intervalli di confidenza, ma formalmente appartiene al paradigma bayesiano.

! Stessa forma, significato diverso

Due intervalli possono avere numeri simili e interpretazioni diverse. La differenza non è solo di natura computazionale, ma riguarda anche il significato che attribuiamo al termine “probabilità” e l'oggetto che consideriamo incerto.

3.9. Limiti e ruolo degli intervalli di confidenza

Gli intervalli di confidenza sono strumenti utili e ampiamente utilizzati. Permettono di evitare una comunicazione basata esclusivamente sulla stima puntuale e di rendere esplicita la precisione della procedura di stima.

Tuttavia, hanno alcuni limiti importanti.

1. **Interpretazione controintuitiva.** Il livello di confidenza riguarda campioni ipotetici ripetuti, non il singolo intervallo osservato.
2. **Assenza di probabilità diretta sul parametro.** Nel frequentismo non è possibile affermare che il parametro abbia il 95% di probabilità di appartenere all'intervallo.
3. **Dipendenza dalle assunzioni.** La copertura nominale è valida solo se si rispettano le condizioni previste dal modello e dal piano di campionamento.
4. **Nessuna protezione automatica dal bias.** Un intervallo può essere stretto ma fuorviante se i dati sono distorti.

Questi limiti non rendono inutili gli intervalli di confidenza. Indicano piuttosto come interpretarli correttamente e perché, in un percorso bayesiano, sia utile confrontarli con gli intervalli di credibilità.

3.10. Verso i test di ipotesi

Gli intervalli di confidenza introducono un principio fondamentale del frequentismo: valutare una procedura in base al suo comportamento nel lungo periodo. Nel prossimo capitolo incontreremo una seconda famiglia di procedure frequentiste: i **test di ipotesi**.

Il passaggio è naturale. Gli intervalli di confidenza chiedono quali valori del parametro siano compatibili con i dati secondo una procedura con copertura controllata. I test di ipotesi, invece, chiedono quanto i dati osservati siano insoliti rispetto a un'ipotesi di riferimento, solitamente chiamata **ipotesi nulla**.

In entrambi i casi, il punto chiave rimane lo stesso: l'inferenza frequentista non assegna direttamente probabilità al parametro o all'ipotesi dopo aver osservato i dati, ma valuta le procedure e le statistiche rispetto a distribuzioni di riferimento.

Riflessioni conclusive

Gli intervalli di confidenza sono uno degli strumenti più importanti della statistica applicata. La loro forza risiede nel fatto che collegano una stima puntuale a una misura della sua precisione e forniscono una garanzia procedurale: in campioni ripetuti, la procedura produce intervalli che includono il parametro vero con una frequenza prestabilita.

La loro difficoltà risiede proprio in questa caratteristica. L'intervallo osservato non è una distribuzione di probabilità sul parametro e il livello di confidenza non deve essere interpretato come una probabilità riferita al singolo risultato.

Per questo motivo, gli intervalli di confidenza sono un eccellente punto di confronto tra il frequentismo e il bayesianesimo. Il frequentismo controlla il comportamento delle procedure nel lungo periodo, mentre il bayesianesimo rappresenta direttamente l'incertezza sul parametro, condizionatamente ai dati e alle assunzioni del modello.

! Punti chiave da ricordare

1. Un intervallo di confidenza accompagna una stima puntuale con una misura della sua incertezza campionaria.
2. Il livello di confidenza è una proprietà della procedura, non del singolo intervallo osservato.
3. Un IC al 95% significa che, nel lungo periodo, circa il 95% degli intervalli costruiti con quella procedura contiene il parametro vero.
4. Non è corretto dire che c'è il 95% di probabilità che il parametro sia dentro l'intervallo osservato.
5. L'ampiezza dell'intervallo dipende da livello di confidenza, variabilità dei dati e dimensione campionaria.
6. Un intervallo di credibilità bayesiano ha un'interpretazione diversa: riguarda la probabilità a posteriori del parametro, date prior, verosimiglianza e dati.

3. Intervalli di confidenza

i Informazioni sull'ambiente di sviluppo

```

sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS:   /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib;
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1           knitr_1.51
#> [16] labeling_0.4.3      bridgesampling_1.2-1  pkgbuild_1.4.8
#> [19] curl_7.1.0          RColorBrewer_1.1-3    abind_1.4-8
#> [22] purrr_1.2.2         grid_4.6.1            stats4_4.6.1
#> [25] xtable_1.8-8        inline_0.3.21         emmeans_2.0.3
#> [28] scales_1.4.0        cli_3.6.6             mvtnorm_1.4-1
#> [31] rmarkdown_2.31      generics_0.1.4        otel_0.2.0
#> [34] RcppParallel_5.1.11-2 cachem_1.1.0          stringr_1.6.0
#> [37] parallel_4.6.1      vctrs_0.7.3           V8_8.2.0
#> [40] Matrix_1.7-5        jsonlite_2.0.0         arrayhelpers_1.1-1
#> [43] glue_1.8.1          codetools_0.2-20      distributional_0.8.1
#> [46] lubridate_1.9.5     stringi_1.8.7         gtable_0.3.6
#> [49] QuickJSR_1.10.0     pillar_1.11.1         htmltools_0.5.9
#> [52] Brodingtonag_1.2-9  R6_2.6.1              textshaping_1.0.5
#> [55] rprojroot_2.1.1     evaluate_1.0.5        lattice_0.22-9
#> [58] backports_1.5.1     memoise_2.0.1         broom_1.0.13
#> [61] snakecase_0.11.1    rstantools_2.6.0      coda_0.19-4.1
#> [64] gridExtra_2.3.1     nlme_3.1-169          checkmate_2.3.4
#> [67] xfun_0.60           pkgconfig_2.0.3

```

4. Test di ipotesi e valore-p

Il **test di ipotesi** è uno degli strumenti più diffusi dell'inferenza statistica frequentista. In psicologia, i test di ipotesi sono ampiamente utilizzati in numerosi articoli per valutare l'efficacia di un intervento, confrontare gruppi, studiare associazioni tra variabili o verificare la compatibilità di un risultato con un modello di riferimento.

In un percorso orientato all'inferenza bayesiana, lo studio dei test di ipotesi ha una funzione ben precisa: imparare a interpretare correttamente il linguaggio ancora dominante nella letteratura empirica e, al contempo, comprendere quali domande questo linguaggio è in grado di porre e quali invece lascia aperte.

La domanda centrale del test frequentista non è:

Qual è la probabilità che l'ipotesi sia vera, dati i risultati osservati?

Questa sarebbe una domanda naturale in una prospettiva bayesiana. La domanda frequentista è diversa:

Se l'ipotesi nulla fosse vera, quanto sarebbero sorprendenti dati come quelli osservati?

Questa distinzione è fondamentale. Il test di ipotesi non assegna probabilità alle ipotesi, ma valuta la **compatibilità dei dati con un modello nullo** attraverso una procedura che controlla gli errori nel lungo periodo.

! In questo capitolo imparerai a

- comprendere la logica del test di ipotesi frequentista;
- distinguere ipotesi nulla, ipotesi alternativa, statistica test e valore- p ;
- interpretare correttamente il valore- p ;
- comprendere il ruolo di α , degli errori di tipo I e II e della potenza;
- applicare la logica del test a due casi introduttivi: il test del chi-quadrato e il test per una media;
- riconoscere i limiti interpretativi della significatività statistica.

💡 Prerequisiti

Per seguire questo capitolo è utile avere già compreso:

- il concetto di distribuzione campionaria;
- il significato dell'errore standard;
- la logica degli intervalli di confidenza;
- la distinzione tra parametro, stimatore e stima osservata.

Questi concetti sono richiamati solo quando servono. Il capitolo non ripete la teoria della distribuzione campionaria, ma la usa per spiegare come funziona una procedura di test.

Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
```

4.1. La logica del test di ipotesi

4.1.1. Un punto di partenza concreto

Immaginiamo uno studio in cui si vuole valutare se un breve intervento di regolazione emotiva possa migliorare il benessere psicologico degli studenti. Dopo l'intervento, il ricercatore osserva una media leggermente più alta rispetto a un valore di riferimento.

Il problema è evidente: una differenza osservata può essere dovuta a un effetto reale dell'intervento, ma può anche essere una normale fluttuazione campionaria. Il test di ipotesi fornisce una procedura per stabilire se la differenza osservata sia sufficientemente grande non poter essere spiegata con un modello di assenza di effetto.

4.1.2. Ipotesi nulla e ipotesi alternativa

Un test frequentista comincia formulando due ipotesi:

- l'**ipotesi nulla** H_0 , che rappresenta il modello di riferimento;
- l'**ipotesi alternativa** H_1 , che rappresenta una deviazione dal modello nullo.

In molti casi, H_0 corrisponde all'assenza di una differenza, di un effetto o di un'associazione. Per esempio:

$$H_0 : \mu = 24$$

può indicare che la media della popolazione è uguale a un valore normativo pari a 24. L'ipotesi alternativa può assumere diverse forme:

$$H_1 : \mu \neq 24$$

per un test bidirezionale, oppure:

$$H_1 : \mu > 24$$

per un test monodirezionale.

Una distinzione essenziale

Nel test frequentista non si calcola $P(H_0 \mid \text{dati})$. Il procedimento calcola invece probabilità del tipo:

$$P(\text{dati almeno così estremi} \mid H_0).$$

Questa differenza è una delle principali fonti di fraintendimento nella lettura dei risultati statistici.

4.1.3. La statistica test

Per confrontare i dati con l'ipotesi nulla si costruisce una **statistica test**. Una statistica test è una funzione dei dati che misura quanto il risultato osservato si discosta da ciò che ci si aspetterebbe se H_0 fosse vera.

Esempi comuni sono:

- la statistica z , quando la deviazione standard della popolazione è nota;
- la statistica t , quando la deviazione standard della popolazione è stimata dal campione;
- la statistica χ^2 , quando si analizzano frequenze in tabelle di contingenza.

Il punto importante è che, sotto H_0 , la statistica test ha una **distribuzione di riferimento** nota o approssimabile. Questa distribuzione consente di valutare quanto il valore osservato sia raro nel mondo ipotetico in cui H_0 è vera.

4.1.4. Il valore-p

Il **valore-p** è la probabilità, assumendo vera l'ipotesi nulla, di osservare una statistica test uguale o più estrema di quella ottenuta:

$$\text{valore-p} = P(\text{risultato almeno così estremo} \mid H_0).$$

Un valore-p piccolo indica che i dati osservati sarebbero rari se H_0 fosse vera. Per convenzione, spesso si confronta il valore-p con un livello di significatività $\alpha = 0.05$:

- se $p \leq \alpha$, si **rifiuta** H_0 ;
- se $p > \alpha$, **non si rifiuta** H_0 .

La seconda formulazione è intenzionale: un test non significativo non conferma l'ipotesi nulla. Indica soltanto che i dati non sono sufficientemente incompatibili con H_0 secondo la regola decisionale scelta.

4.2. Errori di tipo I, tipo II e potenza

Il test di ipotesi è una procedura decisionale. Come ogni decisione basata su dati campionari, può produrre errori.

4.2.1. Due tipi di errore

Se H_0 è vera ma la rifiutiamo, commettiamo un **errore di tipo I**. Questo è il caso del falso positivo: concludiamo che vi sia un effetto quando, nel modello di riferimento, l'effetto non esiste.

Se H_0 è falsa ma non la rifiutiamo, commettiamo un **errore di tipo II**. Questo è il caso del falso negativo: non rileviamo un effetto che nella popolazione è presente.

Situazione reale	Decisione: rifiutare H_0	Decisione: non rifiutare H_0
H_0 vera	Errore di tipo I	Decisione corretta
H_0 falsa	Decisione corretta	Errore di tipo II

Il livello α controlla la probabilità di errore di tipo I nel lungo periodo. La probabilità di errore di tipo II si indica con β . La **potenza** del test è:

$$1 - \beta.$$

La potenza è la probabilità di rifiutare H_0 quando un effetto reale è presente. La potenza dipende da diversi fattori: la grandezza dell'effetto, la variabilità dei dati, la numerosità del campione e la soglia α .

i Perché la potenza sarà ripresa nel prossimo capitolo

Qui introduciamo la potenza solo come parte della logica del test. Il capitolo successivo approfondirà il rapporto tra potenza, numerosità campionaria e pianificazione dello studio.

4.3. Esempio 1: il test del chi-quadrato di indipendenza

Il test del chi-quadrato di indipendenza viene utilizzato quando si desidera valutare se due variabili categoriali siano associate.

4.3.1. La domanda di ricerca

Supponiamo di voler studiare la relazione tra **stress percepito** e **qualità del sonno** in un campione di adulti. Le due variabili sono categoriali:

- stress percepito: basso / alto;
- qualità del sonno: buona / scarsa.

I dati osservati sono:

```
osservati <- matrix(
  c(42, 40,
    19, 39),
  nrow = 2,
  byrow = TRUE
)

rownames(osservati) <- c("Stress basso", "Stress alto")
colnames(osservati) <- c("Sonno buono", "Sonno scarso")

knitr::kable(
  osservati,
  caption = "Frequenze osservate per stress percepito e qualità del sonno"
)
```

Tabella 4.1.: Frequenze osservate per stress percepito e qualità del sonno

	Sonno buono	Sonno scarso
Stress basso	42	40

4. Test di ipotesi e valore-p

	Sonno buono	Sonno scarso
Stress alto	19	39

La domanda è:

I dati sono compatibili con l'ipotesi che lo stress percepito e la qualità del sonno siano indipendenti?

Le ipotesi sono:

H_0 : stress percepito e qualità del sonno sono indipendenti

H_1 : stress percepito e qualità del sonno sono associati.

4.3.2. Valori attesi sotto H_0

Se le due variabili fossero indipendenti, le frequenze attese in ciascuna cella sarebbero determinate dai totali marginali. Per la cella nella riga i e nella colonna j :

$$E_{ij} = \frac{R_i \times C_j}{N},$$

dove R_i è il totale della riga, C_j il totale della colonna e N il totale generale.

```
totali_riga <- rowSums(osservati)
totali_colonna <- colSums(osservati)
totale <- sum(osservati)

attesi <- outer(totali_riga, totali_colonna) / totale

knitr::kable(
  round(attesi, 1),
  caption = "Frequenze attese sotto l'ipotesi nulla di indipendenza"
)
```

Tabella 4.2.: Frequenze attese sotto l'ipotesi nulla di indipendenza

	Sonno buono	Sonno scarso
Stress basso	35.7	46.3
Stress alto	25.3	32.7

Le frequenze attese descrivono ciò che ci si aspetterebbe di osservare se l'apparente associazione tra stress e sonno fosse dovuta esclusivamente alla composizione marginale del campione.

4.3.3. La statistica χ^2

La statistica del chi-quadrato misura la discrepanza complessiva tra le frequenze osservate e quelle attese:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Valori piccoli indicano una buona compatibilità con H_0 , mentre valori grandi indicano una discrepanza più marcata.

```
chi2 <- sum((osservati - attesi)^2 / attesi)
df_chi <- (nrow(osservati) - 1) * (ncol(osservati) - 1)
p_chi <- 1 - pchisq(chi2, df_chi)

cat("Chi-quadrato:", round(chi2, 3), "\n")
#> Chi-quadrato: 4.71
cat("Gradi di libertà:", df_chi, "\n")
#> Gradi di libertà: 1
cat("Valore-p:", round(p_chi, 4), "\n")
#> Valore-p: 0.03
```

Verifichiamo il risultato con la funzione `chisq.test()`:

```
chisq.test(osservati, correct = FALSE)
#>
#> Pearson's Chi-squared test
#>
#> data: osservati
#> X-squared = 5, df = 1, p-value = 0.03
```

La correzione di continuità è disattivata per mantenere coerenza con il calcolo manuale.

4.3.4. Visualizzare il valore-p

L'area a destra della statistica osservata è il valore- p . Se tale area è inferiore a α , il risultato cade nella regione di rifiuto.

Nel nostro esempio, il valore- p è inferiore a 0.05. Possiamo quindi rifiutare l'ipotesi nulla di indipendenza. Una formulazione prudente è:

I dati mostrano una discrepanza rispetto all'ipotesi di indipendenza sufficientemente grande da risultare statisticamente significativa al livello $\alpha = 0.05$.

Questa frase è più corretta rispetto a "abbiamo dimostrato che stress e sonno sono associati". Il test segnala l'incompatibilità con il modello nullo, ma non fornisce una probabilità diretta dell'associazione.




Figura 4.1.: Distribuzione chi-quadrato sotto H_0 e valore-p osservato

4.4. Esempio 2: il test per una media

Consideriamo ora una variabile continua. Una domanda comune in psicologia è se la media di una popolazione differisca da un valore di riferimento.

4.4.1. Dati e ipotesi

Un ricercatore vuole verificare se i punteggi di **benessere psicologico** di un gruppo di studenti universitari siano superiori alla media normativa della popolazione, pari a $\mu_0 = 24$.

I punteggi osservati sono:

```
punteggi <- c(28, 22, 26, 18, 30, 24, 27, 17, 21, 25)
n <- length(punteggi)
media_campione <- mean(punteggi)
s <- sd(punteggi)

cat("Media campionaria:", round(media_campione, 2), "\n")
#> Media campionaria: 23.8
cat("Deviazione standard campionaria:", round(s, 2), "\n")
#> Deviazione standard campionaria: 4.26
cat("Numerosità:", n, "\n")
#> Numerosità: 10
```

Le ipotesi per un test monodirezionale sono:

$$H_0 : \mu = 24$$

$$H_1 : \mu > 24.$$

La media osservata è 23.8, quindi non va nemmeno nella direzione ipotizzata. Il test consente comunque di formalizzare questa informazione.

4.4.2. La statistica t

Poiché la deviazione standard della popolazione non è nota, viene stimata con la deviazione standard campionaria s . L'errore standard stimato è:

$$SE = \frac{s}{\sqrt{n}}.$$

La statistica test è:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}.$$

Sotto H_0 , questa statistica segue una distribuzione t di Student con $n - 1$ gradi di libertà.

```
mu_0 <- 24
SE <- s / sqrt(n)
t_obs <- (media_campione - mu_0) / SE
df_t <- n - 1
p_t_greater <- 1 - pt(t_obs, df_t)

cat("Errore standard:", round(SE, 3), "\n")
#> Errore standard: 1.35
cat("Statistica t:", round(t_obs, 3), "\n")
#> Statistica t: -0.148
cat("Gradi di libertà:", df_t, "\n")
#> Gradi di libertà: 9
cat("Valore-p:", round(p_t_greater, 3), "\n")
#> Valore-p: 0.557
```

Verifichiamo con `t.test()`:

```
t.test(punteggi, mu = 24, alternative = "greater")
#>
#> One Sample t-test
#>
#> data: punteggi
#> t = -0.1, df = 9, p-value = 0.6
#> alternative hypothesis: true mean is greater than 24
#> 95 percent confidence interval:
#> 21.3 Inf
#> sample estimates:
#> mean of x
#> 23.8
```

Il valore- p è elevato. Se la media vera fosse 24, una media campionaria pari o superiore a quella osservata non sarebbe affatto rara. I dati non forniscono evidenza a sostegno dell'ipotesi che il benessere medio sia superiore alla norma.

4.4.3. Test monodirezionale e bidirezionale

Se il ricercatore non avesse specificato una direzione e volesse soltanto verificare se la media differisce da 24, dovrebbe usare un test bidirezionale:

$$H_1 : \mu \neq 24.$$

```
t.test(punteggi, mu = 24, alternative = "two.sided")
#>
#> One Sample t-test
#>
#> data: punteggi
#> t = -0.1, df = 9, p-value = 0.9
#> alternative hypothesis: true mean is not equal to 24
#> 95 percent confidence interval:
#> 20.8 26.8
#> sample estimates:
#> mean of x
#> 23.8
```

Nel test bidirezionale il valore- p considera le discrepanze in entrambe le direzioni. La scelta tra il test monodirezionale e quello bidirezionale deve essere motivata dal punto di vista teorico prima di osservare i dati, non deve essere presa in base al risultato.

4.5. Interpretare correttamente il valore-p

Il valore- p è spesso interpretato in modo scorretto. È utile fissare alcune regole.

Il valore- p **non** è:

- la probabilità che H_0 sia vera;
- la probabilità che H_1 sia vera;
- la probabilità che il risultato sia dovuto al caso;
- una misura della grandezza dell'effetto;
- una misura della probabilità di replicazione.

Il valore- p è invece:

- una probabilità calcolata assumendo vera H_0 ;
- una misura di incompatibilità tra dati e modello nullo;
- un elemento di una regola decisionale frequentista;
- una quantità dipendente dal modello, dalla statistica test e dal piano di analisi.

! Formula da ricordare

La forma corretta è:

$$P(\text{dati almeno così estremi} \mid H_0),$$

non:

$$P(H_0 \mid \text{dati}).$$

4.6. Significatività statistica e rilevanza sostanziale

Un risultato statisticamente significativo non è necessariamente rilevante dal punto di vista teorico, clinico o pratico. Con campioni molto grandi, anche effetti minimi possono produrre valori- p piccoli. Con campioni piccoli, effetti potenzialmente rilevanti potrebbero non raggiungere la soglia convenzionale.

Per questo motivo, il valore- p dovrebbe essere accompagnato da:

- una stima puntuale dell'effetto;
- un intervallo di confidenza;
- una misura della dimensione dell'effetto;
- una discussione della rilevanza teorica o applicativa;
- una valutazione della qualità del disegno di ricerca e della misura.

Nel capitolo precedente abbiamo visto che gli intervalli di confidenza aiutano a comunicare la precisione della stima. Il test di ipotesi aggiunge una regola decisionale, ma non sostituisce la valutazione dell'effetto e della sua incertezza.

4.7. Limiti del test di ipotesi frequentista

Il test di ipotesi è utile quando viene interpretato per ciò che è: una procedura per controllare gli errori decisionali nel lungo periodo. Tuttavia, diventa problematico quando viene trattato come una misura diretta della verità di un'ipotesi o della forza dell'evidenza.

I limiti principali sono i seguenti.

1. Decisione dicotomica.

La soglia $\alpha = 0.05$ trasforma una quantità continua in una decisione binaria. Due valori molto simili, come 0.049 e 0.051, possono ricevere etichette diverse pur rappresentando un'evidenza quasi indistinguibile.

2. Dipendenza dalla numerosità campionaria.

A parità di effetto, un campione più grande produce errori standard più piccoli e, di conseguenza, test più sensibili. Questo è utile, ma può rendere statisticamente significativi effetti di scarsa importanza pratica.

3. Interpretazione debole dei risultati non significativi.

Non rifiutare H_0 non significa dimostrare l'assenza dell'effetto. Può significare che lo studio non fornisce informazioni sufficienti per distinguere l'effetto dal rumore campionario.

4. Ipotesi nulla puntuale.

Molti test valutano un'ipotesi del tipo $\delta = 0$, ovvero un effetto esattamente nullo. In molte situazioni psicologiche, però, la domanda scientifica più rilevante non è se l'effetto sia esattamente pari a zero, ma se sia sufficientemente grande da essere rilevante dal punto di vista teorico o clinico.

5. Dipendenza dal piano di analisi.

Il valore- p dipende non solo dai dati osservati, ma anche da aspetti procedurali come la regola di arresto, il numero di confronti e la scelta tra test monodirezionale e bidirezionale.

Questi limiti non rendono il test di ipotesi inutile. Tuttavia, indicano che il suo significato deve essere circoscritto: il test frequentista è uno strumento decisionale, non una misura diretta della plausibilità delle ipotesi.

4.8. Ponte verso la pianificazione dello studio

Il capitolo successivo approfondisce un punto lasciato volutamente in sospeso: la **potenza**. Abbiamo visto che un risultato non significativo può dipendere dall'assenza di un effetto, ma anche da un disegno sperimentale poco informativo. Per interpretare correttamente un test, è quindi necessario porsi le seguenti domande:

- quale effetto ci aspettiamo di poter rilevare?
- quante osservazioni sono necessarie?
- con quale probabilità il test riuscirà a individuare un effetto rilevante?

Queste domande collegano direttamente il test di ipotesi alla pianificazione della numerosità del campione.

Riflessioni conclusive

Il test di ipotesi frequentista valuta la compatibilità dei dati con l'ipotesi nulla. La sua forza risiede nella chiarezza procedurale: formula una regola, controlla la probabilità di falsi positivi nel lungo periodo e consente decisioni standardizzate.

Il suo limite principale è interpretativo. Il valore- p non indica quanto sia probabile un'ipotesi, né quanto sia rilevante un effetto. Indica quanto sarebbero rari dati almeno così estremi se H_0 fosse vera.

Per questo motivo, quando si legge la letteratura psicologica, è utile distinguere tre livelli:

1. **Decisione statistica:** il risultato supera o non supera la soglia α ?
2. **Stima dell'effetto:** quanto è grande la differenza o l'associazione osservata?
3. **Interpretazione scientifica:** l'effetto è rilevante dal punto di vista teorico, clinico o pratico?

L'approccio bayesiano, che verrà approfondito nel resto del percorso, risponde a domande diverse: permette di aggiornare le credenze sui parametri e di confrontare le ipotesi alla luce dei dati osservati. Comprendere il test frequentista è quindi utile non solo per leggere la letteratura esistente, ma anche per capire con maggiore chiarezza cosa cambia quando si passa a un'impostazione bayesiana.

Punti chiave da ricordare

! Importante

- Il test di ipotesi frequentista valuta i dati **condizionatamente a H_0** .
- Il valore- p è $P(\text{dati almeno così estremi} \mid H_0)$.
- Un valore- p piccolo indica incompatibilità con il modello nullo, non la probabilità che H_0 sia falsa.
- Non rifiutare H_0 non equivale ad accettarla.
- La significatività statistica non coincide con la rilevanza sostanziale.
- La potenza collega il test di ipotesi alla pianificazione della numerosità campionaria.

i Informazioni sull'ambiente di sviluppo

4. Test di ipotesi e valore-p

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2   patchwork_1.3.2        ggdist_3.3.3
#> [7] tidybayes_3.0.7      bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.0           rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0          Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0     janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11        tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2          rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8         tidyselect_1.2.1      farver_2.1.2
#> [4] S7_0.2.2             fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39        timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5      magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0          tools_4.6.1           yaml_2.3.12
#> [16] knitr_1.51           labeling_0.4.3         bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8       curl_7.1.0            RColorBrewer_1.1-3
#> [22] abind_1.4-8          purrr_1.2.2           grid_4.6.1
#> [25] stats4_4.6.1         xtable_1.8-8          inline_0.3.21
#> [28] emmeans_2.0.3        scales_1.4.0          cli_3.6.6
#> [31] mvtnorm_1.4-1        rmarkdown_2.31        generics_0.1.4
#> [34] otel_0.2.0           RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0        parallel_4.6.1        vctrs_0.7.3
#> [40] V8_8.2.0             Matrix_1.7-5          jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1   glue_1.8.1            codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5        stringi_1.8.7
#> [49] gtable_0.3.6         QuickJSR_1.10.0       pillar_1.11.1
#> [52] htmltools_0.5.9      Brodningnag_1.2-9     R6_2.6.1
#> [55] textshaping_1.0.5    rprojroot_2.1.1       evaluate_1.0.5
#> [58] lattice_0.22-9       backports_1.5.1       memoise_2.0.1
#> [61] broom_1.0.13         snakecase_0.11.1      rstantools_2.6.0
#> [64] coda_0.19-4.1        gridExtra_2.3.1       nlme_3.1-169
#> [67] checkmate_2.3.4      xfun_0.60             pkgconfig_2.0.3
```

5. Dimensione campionaria, errore e potenza

! In questo capitolo imparerai a

- Distinguere due obiettivi di pianificazione: **stimare con precisione e testare un'ipotesi con potenza adeguata**.
- Comprendere il ruolo di errore di I tipo, errore di II tipo, potenza e dimensione dell'effetto.
- Calcolare una numerosità campionaria per una stima di media con margine di errore prefissato.
- Usare `power.t.test()` per pianificare test su una media e confronti tra due gruppi.
- Riconoscere i limiti dell'analisi di potenza, in particolare dell'uso post-hoc.

💡 Prerequisiti

Per seguire questo capitolo è utile aver letto:

- il capitolo su stime, stimatori e stima puntuale;
- il capitolo sugli intervalli di confidenza;
- il capitolo sui test di ipotesi, in particolare il valore- p , il livello di significatività α e la distinzione tra errore di I tipo ed errore di II tipo.

Come lettura complementare, si veda *Power to detect what? Considerations for planning and evaluating sample size* (Giner-Sorolla et al., 2024).

🔥 Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
```

5.1. Perché pianificare la numerosità campionaria

La scelta della numerosità campionaria non è un dettaglio tecnico da rimandare alla fine del progetto. Si tratta di una decisione metodologica che dovrebbe essere presa **prima** di raccogliere i dati, in quanto condiziona ciò che lo studio potrà dire.

Un campione troppo piccolo può produrre risultati molto incerti: le stime saranno imprecise e i test avranno bassa probabilità di rilevare effetti anche quando questi sono reali. Un campione troppo grande, invece, può richiedere risorse eccessive e può rendere statisticamente significative differenze molto piccole, che potrebbero essere prive di rilevanza teorica o clinica.

Nel quadro frequentista, la numerosità campionaria viene solitamente pianificata in relazione a due obiettivi distinti:

1. **Precisione della stima:** quanto stretto vogliamo che sia l'intervallo di confidenza?

2. **Potenza del test:** con quale probabilità vogliamo rilevare un effetto di una certa dimensione, se quell'effetto esiste?

Questi due obiettivi sono correlati, ma non coincidono. Nel primo caso, ci interessa la precisione con cui stimiamo un parametro. Nel secondo caso, invece, ci interessa il comportamento di una procedura decisionale: se rifiutare o meno l'ipotesi nulla.

i Due domande diverse

Domanda di stima

> Quanti partecipanti servono per stimare una media con un margine di errore accettabile?

Domanda di test

> Quanti partecipanti servono perché un test abbia una probabilità adeguata di rilevare un effetto considerato rilevante?

Tenere separate queste due domande aiuta a evitare confusione tra precisione, significatività statistica e rilevanza sostantiva.

5.2. Numerosità campionaria per la precisione di una stima

Supponiamo di voler stimare la media μ di una variabile psicologica, ad esempio un punteggio di autostima. Nel capitolo sugli intervalli di confidenza abbiamo visto che, in condizioni standard, un intervallo di confidenza per la media può essere approssimativamente espresso come:

$$\bar{x} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

La quantità

$$E = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

è il **margine di errore**: indica di quanto l'intervallo si estende a sinistra e a destra della stima puntuale.

Se vogliamo progettare uno studio in modo che il margine di errore non superi un valore prefissato E , possiamo risolvere l'equazione rispetto a n :

$$n = \left(\frac{z_{1-\alpha/2} \sigma}{E} \right)^2.$$

Questa formula illustra tre concetti importanti:

- richiedere un intervallo più stretto aumenta il numero di dati necessario;
- una maggiore variabilità dei dati richiede campioni più grandi;
- passare, per esempio, da un margine di errore di 2 punti a 1 punto non raddoppia il campione, ma lo quadruplica.

⚠ Attenzione alla notazione

Per un intervallo di confidenza al 95%, si usa di solito $z_{1-\alpha/2} = z_{0.975} \approx 1.96$, non $z_{0.025}$. I due quantili sono simmetrici nella normale standard, ma il valore positivo usato nella formula del margine di errore è $z_{0.975}$.

5.2.1. Esempio: stimare un punteggio medio di autostima

Immaginiamo di voler stimare il punteggio medio di autostima di una popolazione di studenti. La scala varia da 0 a 30. Da studi precedenti sappiamo che la deviazione standard è approssimativamente pari a $\sigma = 6$. Vogliamo un intervallo di confidenza al 95% con un margine di errore massimo di 2 punti.

```
# Parametri della pianificazione
sigma <- 6           # Deviazione standard attesa
E <- 2               # Margine di errore desiderato
z_alpha <- qnorm(0.975) # Quantile per IC al 95%

# Numerosità richiesta
n_stima <- (z_alpha * sigma / E)^2
ceiling(n_stima)
#> [1] 35
```

Il risultato va sempre arrotondato all'intero superiore, perché non è possibile reclutare una frazione di partecipante.

5.2.2. Sensibilità al margine di errore

La scelta del margine di errore è una decisione sostantiva. Un errore massimo di 1 punto può essere necessario in alcuni contesti, ma eccessivo in altri. La tabella seguente mostra come varia la numerosità al variare di E , mantenendo $\sigma = 6$ e una confidenza al 95%.

```
margini <- c(1, 1.5, 2, 2.5, 3)

risultati_precisione <- data.frame(
  `Margine di errore desiderato` = margini,
  `n minimo` = ceiling((z_alpha * sigma / margini)^2)
)

knitr::kable(
  risultati_precisione,
  caption = "Numerosità campionaria richiesta al variare del margine di errore."
)
```

Tabella 5.1.: Numerosità campionaria richiesta al variare del margine di errore.

Margine.di.errore.desiderato	n.minimo
1.0	139
1.5	62
2.0	35
2.5	23
3.0	16

La relazione quadratica è il punto da ricordare: **dimezzare il margine di errore richiede circa quattro volte più partecipanti.**

5.3. Numerosità campionaria per un test di ipotesi

Nel capitolo precedente abbiamo introdotto la logica dei test di ipotesi. Un test frequentista parte da un'ipotesi nulla H_0 , calcola quanto i dati siano sorprendenti se H_0 fosse vera e produce una decisione rispetto a una soglia α .

Quando pianifichiamo uno studio, però, non basta controllare l'errore di I tipo. Dobbiamo anche chiederci se lo studio avrà una probabilità ragionevole di rilevare un effetto quando questo è effettivamente presente.

5.3.1. Errori e potenza

Nella logica frequentista dei test, esistono due tipi di errore:

- **Errore di I tipo:** rifiutare H_0 quando H_0 è vera. La probabilità massima accettata di questo errore è indicata con α .
- **Errore di II tipo:** non rifiutare H_0 quando esiste un effetto reale. La probabilità di questo errore è indicata con β .

La **potenza statistica** è:

$$1 - \beta.$$

Essa rappresenta la probabilità di ottenere un risultato statisticamente significativo quando l'effetto specificato nella pianificazione è reale.

! Che cosa significa potenza 80%?

Una potenza dell'80% non significa che l'ipotesi alternativa abbia una probabilità 0.80 di essere vera. Significa che, se l'effetto specificato esistesse davvero e se ripetessimo molte volte lo stesso studio, il test rifiuterebbe H_0 in circa l'80% degli studi. Anche in questo caso l'interpretazione è frequentista e riguarda il comportamento della procedura nel lungo periodo.

5.3.2. Da cosa dipende la potenza

La potenza dipende da diversi elementi:

1. **Dimensione dell'effetto:** gli effetti più grandi sono più facili da rilevare;
2. **Variabilità dei dati:** maggiore è la variabilità, più difficile è distinguere il segnale dal rumore.
3. **Numerosità campionaria:** campioni più grandi aumentano la potenza.
4. **Livello di significatività α :** soglie più stringenti riducono la probabilità di rifiutare H_0 .
5. **Tipo di test:** i test a una coda, i test a due code, i gruppi indipendenti e le misure appaiate hanno requisiti diversi.

In pratica, la pianificazione richiede di specificare quale effetto sarebbe abbastanza rilevante da meritare attenzione. Questo valore è spesso chiamato **effetto minimo di interesse** (*smallest effect size of interest*, SESOI).

5.4. Effetto minimo di interesse

Un errore comune è quello di pianificare lo studio sulla base di un effetto atteso ottimistico, magari tratto da studi precedenti con campioni piccoli. Ciò può produrre stime di numerosità troppo basse.

Una strategia più trasparente è chiedersi:

Qual è il più piccolo effetto che sarebbe teoricamente, clinicamente o praticamente rilevante?

Nel caso di una scala psicologica, una differenza di 0.2 punti potrebbe essere rilevabile statisticamente con campioni molto grandi, ma priva di significato pratico. Una differenza di 3 punti, invece, potrebbe essere abbastanza grande da modificare una decisione di tipo clinico o educativo.

i La numerosità dipende dalla domanda sostantiva

La potenza non è solo un problema tecnico. Dipende da una decisione di natura teorica: che tipo di effetto vogliamo essere in grado di rilevare?

Per questo motivo, il calcolo di n dovrebbe essere accompagnato da una giustificazione della dimensione dell'effetto scelta.

5.5. Esempio: test t per un campione

Supponiamo di voler confrontare il punteggio medio di autostima di un gruppo di studenti con un valore di riferimento pari a 24. Consideriamo rilevante una differenza di almeno 3 punti. Supponiamo che $\sigma = 6$, $\alpha = 0.05$ e che desideriamo una potenza pari a 0.80.

```
power.t.test(
  delta = 3,          # Differenza minima da rilevare
  sd = 6,             # Deviazione standard attesa
  sig.level = 0.05,   # Errore di I tipo
  power = 0.80,       # Potenza desiderata
  type = "one.sample",
  alternative = "two.sided"
)
#>
#>      One-sample t test power calculation
#>
#>              n = 33.4
#>           delta = 3
#>            sd = 6
#>    sig.level = 0.05
#>         power = 0.8
#> alternative = two.sided
```

Il risultato fornisce il numero di elementi richiesto per il test su un campione. L'interpretazione corretta è la seguente: se la differenza reale fosse pari a 3 punti, il test avrebbe circa l'80% di probabilità di risultare significativo al livello $\alpha = 0.05$.

5.6. Esempio: confronto tra due gruppi indipendenti

Consideriamo ora uno studio che confronta due gruppi indipendenti, ad esempio un gruppo che riceve un intervento e un gruppo di controllo. Supponiamo di considerare rilevante una differenza di almeno 5 punti e di aspettarci una deviazione standard comune pari a 6.

```
power.t.test(
  delta = 5,          # Differenza tra le medie dei due gruppi
  sd = 6,             # Deviazione standard comune attesa
  sig.level = 0.05,
  power = 0.80,
  type = "two.sample",
  alternative = "two.sided"
)
#>
#>      Two-sample t test power calculation
#>
#>              n = 23.6
#>          delta = 5
#>              sd = 6
#>    sig.level = 0.05
#>          power = 0.8
#> alternative = two.sided
#>
#> NOTE: n is number in *each* group
```

Nel caso `type = "two.sample"`, il valore di `n` restituito da `power.t.test()` indica la numerosità **per ciascun gruppo**, non il totale complessivo.

5.6.1. Sensibilità alla dimensione dell'effetto

La numerosità richiesta cambia molto in base all'effetto minimo che si vuole rilevare. Riprendiamo l'esempio precedente, mantenendo $\sigma = 6$, $\alpha = 0.05$ e potenza 0.80.

```
delta_values <- c(2, 3, 4, 5, 6)

n_per_group <- sapply(delta_values, function(d) {
  res <- power.t.test(
    delta = d,
    sd = 6,
    sig.level = 0.05,
    power = 0.80,
    type = "two.sample",
    alternative = "two.sided"
  )
  ceiling(res$n)
})

risultati_potenza <- data.frame(
  `Differenza minima da rilevare` = delta_values,
```

```

`n per gruppo` = n_per_group,
`n totale` = 2 * n_per_group
)

knitr::kable(
  risultati_potenza,
  caption = "Numerosità richiesta per un test t a due campioni al variare della differenza minima rilevante."
)

```

Tabella 5.2.: Numerosità richiesta per un test t a due campioni al variare della differenza minima rilevante.

Differenza.minima.da.rilevare	n.per.gruppo	n.totale
2	143	286
3	64	128
4	37	74
5	24	48
6	17	34

Questa tabella mostra perché è fondamentale dichiarare in anticipo l'effetto che si intende rilevare. Gli effetti piccoli richiedono campioni molto più grandi.

5.7. Potenza, numerosità e interpretazione dei risultati

Uno studio con bassa potenza presenta problemi per almeno due ragioni.

In primo luogo, ha una probabilità elevata di non rilevare effetti che sarebbero invece rilevanti. In questo caso, un risultato non significativo è difficile da interpretare: potrebbe indicare l'assenza di un effetto oppure semplicemente la mancanza di informazioni.

In secondo luogo, nei contesti in cui vengono pubblicati o enfatizzati solo i risultati significativi, gli studi con bassa potenza tendono a produrre stime instabili e spesso sovrastimate. Questo problema è particolarmente rilevante nella ricerca psicologica, dove i campioni sono piccoli e i gradi di libertà analitici sono molteplici, il che può rendere fragile l'evidenza empirica.

Non significativo non significa assenza di effetto

Un test non significativo non dimostra che l'effetto sia nullo. Indica soltanto che, dati il modello, la soglia α , la numerosità e la variabilità osservate, non abbiamo ottenuto un risultato abbastanza estremo da poter rifiutare l'ipotesi H_0 .

Per valutare se i dati siano compatibili con effetti piccoli, medi o nulli, sono necessarie anche stime, intervalli di confidenza e, in un quadro bayesiano, distribuzioni posteriori o fattori di Bayes.

5.8. Analisi di potenza post-hoc

Dopo aver completato uno studio, può essere naturale chiedersi: “Qual era la potenza osservata?”. Tuttavia, questa pratica è di utilità limitata quando la potenza viene calcolata utilizzando l’effetto osservato nello stesso studio.

Il problema è che la potenza post hoc così definita è quasi interamente determinata dal valore- p : se il risultato è significativo, la potenza osservata tenderà a risultare alta; se il risultato non è significativo, tenderà a risultare bassa. In questo senso, non fornisce informazioni aggiuntive rispetto al risultato già ottenuto.

```
# Esempio illustrativo: studio con n = 30 per gruppo,  
# differenza osservata = 4 e sd = 6.  
power.t.test(  
  n = 30,  
  delta = 4,  
  sd = 6,  
  sig.level = 0.05,  
  type = "two.sample",  
  alternative = "two.sided"  
)  
#>  
#>      Two-sample t test power calculation  
#>  
#>              n = 30  
#>            delta = 4  
#>              sd = 6  
#>    sig.level = 0.05  
#>        power = 0.719  
#> alternative = two.sided  
#>  
#> NOTE: n is number in *each* group
```

Quando usare l’analisi di potenza

L’analisi di potenza è utile soprattutto **prima** di raccogliere i dati, quando serve a pianificare lo studio.

Dopo l’osservazione dei dati, è generalmente più informativo riportare la stima dell’effetto, il suo intervallo di confidenza e una discussione sulla rilevanza sostanziale dell’effetto osservato.

5.9. Limiti della pianificazione frequentista

La pianificazione frequentista è utile perché costringe il ricercatore a rendere espliciti alcuni elementi del disegno:

- quale errore di I tipo è disposto ad accettare;
- quale potenza desidera ottenere;
- quale effetto considera sufficientemente importante;
- quale variabilità si aspetta nei dati.

Tuttavia, questa impostazione presenta anche limiti importanti.

1. **Richiede valori ipotetici prima dello studio.** La deviazione standard e l'effetto minimo devono essere specificati in anticipo, spesso sulla base di evidenze incerte.
2. **Dipende da una soglia decisionale.** La pianificazione è spesso costruita attorno alla probabilità di ottenere $p < \alpha$, non direttamente attorno alla precisione della conoscenza acquisita.
3. **Può incoraggiare una lettura dicotomica.** Uno studio viene talvolta interpretato come “riuscito” o “fallito” in base alla significatività, anche se l'informazione contenuta nei dati è più sfumata.
4. **Richiede attenzione allo stopping rule.** Se si decide di aggiungere partecipanti dopo aver guardato i risultati, il controllo frequentista dell'errore di I tipo può non essere più valido, a meno che il disegno sequenziale sia stato pianificato esplicitamente.

5.10. Collegamento con la prospettiva bayesiana

In un approccio bayesiano, la pianificazione può essere formulata in modo diverso. Invece di domandarci soltanto quale numerosità sia necessaria per ottenere $p < \alpha$ con una certa probabilità, possiamo chiederci:

- quanta incertezza posteriore siamo disposti ad accettare?
- quale probabilità vogliamo avere di raggiungere una conclusione sufficientemente precisa?
- come possiamo incorporare le conoscenze precedenti nella pianificazione?
- in quali condizioni è ragionevole aggiornare sequenzialmente le credenze man mano che arrivano nuovi dati?

Tutto ciò non rende inutile l'analisi frequentista della potenza. La rende piuttosto uno strumento da comprendere nel suo ambito: serve a progettare procedure che abbiano determinate proprietà di errore nel lungo periodo. La prospettiva bayesiana, invece, sposta l'attenzione sull'incertezza relativa ai parametri e sulle decisioni da prendere alla luce della distribuzione a posteriori.

5.11. Riepilogo

In questo capitolo abbiamo visto che:

- la numerosità campionaria può essere pianificata per ottenere una certa precisione o una certa potenza;
- la precisione di una stima dipende dalla variabilità, dal margine di errore desiderato e dal livello di confidenza;
- la potenza è $1 - \beta$, ovvero la probabilità di rifiutare H_0 quando l'effetto specificato è reale;
- la potenza dipende dalla dimensione dell'effetto, dalla variabilità, dalla numerosità, da α e dal tipo di test;
- l'effetto minimo di interesse deve essere giustificato sia dal punto di vista teorico che pratico, e non deve essere scelto solo per ottenere un campione gestibile;
- l'analisi di potenza post-hoc, basata sull'effetto osservato, ha un'utilità limitata;
- la pianificazione frequentista è utile, ma resta centrata sul comportamento delle procedure decisionali nel lungo periodo.

5. *Dimensione campionaria, errore e potenza*

Nel prossimo capitolo useremo questi concetti in un'applicazione concreta: il confronto tra due gruppi indipendenti.

i Informazioni sull'ambiente di sviluppo

5. Dimensione campionaria, errore e potenza

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0      withr_3.0.3
#> [4] systemfonts_1.3.2  patchwork_1.3.2       ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0      ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0      posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7          StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2            sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1         matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1          dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0             here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidymodels_1.2.1      farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0         tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0      estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5        compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1           knitr_1.51
#> [16] bridgesampling_1.2-1 pkgbuild_1.4.8        curl_7.1.0
#> [19] RColorBrewer_1.1-3  abind_1.4-8           purrr_1.2.2
#> [22] grid_4.6.1          stats4_4.6.1          xtable_1.8-8
#> [25] inline_0.3.21       emmeans_2.0.3         scales_1.4.0
#> [28] cli_3.6.6           mvtnorm_1.4-1         rmarkdown_2.31
#> [31] generics_0.1.4      otel_0.2.0            RcppParallel_5.1.11-2
#> [34] cachem_1.1.0        stringr_1.6.0         parallel_4.6.1
#> [37] vctrs_0.7.3         V8_8.2.0             Matrix_1.7-5
#> [40] jsonlite_2.0.0      arrayhelpers_1.1-1    glue_1.8.1
#> [43] codetools_0.2-20    distributional_0.8.1  lubridate_1.9.5
#> [46] stringi_1.8.7       gtable_0.3.6          QuickJSR_1.10.0
#> [49] pillar_1.11.1       htmltools_0.5.9      Brodningnag_1.2-9
#> [52] R6_2.6.1            textshaping_1.0.5     rprojroot_2.1.1
#> [55] evaluate_1.0.5      lattice_0.22-9        backports_1.5.1
#> [58] memoise_2.0.1       broom_1.0.13          snakecase_0.11.1
#> [61] rstantools_2.6.0    coda_0.19-4.1        gridExtra_2.3.1
#> [64] nlme_3.1-169        checkmate_2.3.4       xfun_0.60
#> [67] pkgconfig_2.0.3
```

Bibliografia

6. Confrontare due gruppi indipendenti

Il confronto tra due gruppi indipendenti è una delle situazioni più comuni nella ricerca psicologica: un gruppo sperimentale viene messo a confronto con un gruppo di controllo, due condizioni di trattamento vengono messe a confronto o si confrontano sottogruppi definiti da una caratteristica osservata.

Nel quadro frequentista, il test t per campioni indipendenti risponde a una domanda specifica:

Se, nella popolazione, le due medie fossero uguali, quanto sarebbe sorprendente osservare una differenza almeno grande quanto quella trovata nel campione?

Tale domanda non coincide con la probabilità che le due medie siano uguali né con la probabilità che un trattamento funzioni. Il test t è una procedura che permette di valutare la compatibilità dei dati con un modello nullo e di controllare gli errori decisionali nel lungo periodo.

! In questo capitolo imparerai a

- riconoscere quando è appropriato un confronto tra due gruppi indipendenti;
- formulare ipotesi nulla e ipotesi alternativa per il test t ;
- distinguere il test t classico dal test t di Welch;
- interpretare insieme differenza tra medie, intervallo di confidenza, valore- p e dimensione dell'effetto;
- riportare i risultati in modo completo, evitando una lettura basata solo sulla significatività statistica;
- comprendere quali domande restano aperte e saranno affrontate in modo più diretto



dall'inferenza bayesiana.
Prerequisiti

Per seguire questo capitolo è utile aver letto:

- il capitolo su stime, stimatori e stima puntuale;
- il capitolo sugli intervalli di confidenza;
- il capitolo sui test di ipotesi e valore- p ;
- il capitolo sulla numerosità campionaria, errore e potenza.

Il capitolo applica questi concetti a un caso concreto. Non introduce una nuova filosofia dell'inferenza, ma mostra come i diversi elementi del ragionamento frequentista si combinino in una procedura ampiamente utilizzata nella letteratura psicologica.

 Preparazione del Notebook

```
here::here("code", "_common.R") |>
  source()
```

6.1. Perché confrontare due gruppi

Immaginiamo uno studio in cui si valuta l'efficacia di un breve intervento di regolazione emotiva. Un gruppo di studenti riceve l'intervento, mentre un secondo gruppo segue una condizione di controllo. Al termine dello studio, tutti i partecipanti compilano una scala di benessere psicologico.

Il ricercatore osserva due medie campionarie:

$$\bar{x}_1 \quad \text{e} \quad \bar{x}_2.$$

La differenza osservata è:

$$\bar{x}_1 - \bar{x}_2.$$

Questa differenza è una **stima puntuale** della differenza tra le medie delle popolazioni:

$$\mu_1 - \mu_2.$$

Tuttavia, come abbiamo visto nei capitoli precedenti, una stima puntuale non è sufficiente. Due campioni estratti dalla stessa popolazione possono produrre medie diverse, anche quando non esiste alcuna differenza reale tra i gruppi. Per questo motivo, il confronto tra due gruppi richiede sempre tre componenti:

1. una **stima** della differenza osservata;
2. una misura dell'**incertezza** associata a quella stima;
3. una procedura per valutare la **compatibilità** dei dati con l'ipotesi nulla.

Il test t per campioni indipendenti combina questi elementi in una procedura frequentista standard.

6.2. Il modello inferenziale del test t

6.2.1. Ipotesi nulla e ipotesi alternativa

Nel confronto tra due gruppi, l'ipotesi nulla afferma di solito che le due popolazioni abbiano la stessa media:

$$H_0 : \mu_1 = \mu_2.$$

In modo equivalente:

$$H_0 : \mu_1 - \mu_2 = 0.$$

6. Confrontare due gruppi indipendenti

L'ipotesi alternativa può essere bidirezionale:

$$H_1 : \mu_1 - \mu_2 \neq 0,$$

oppure direzionale:

$$H_1 : \mu_1 - \mu_2 > 0$$

oppure

$$H_1 : \mu_1 - \mu_2 < 0.$$

In un contesto introduttivo, è preferibile partire dal test bidirezionale, in quanto evita di introdurre una direzione dell'effetto dopo aver osservato i dati.

6.2.2. La statistica test

La logica del test t è semplice: la differenza osservata tra le medie viene confrontata con la variabilità che ci aspetteremmo se l'ipotesi nulla fosse vera.

In forma generale:

$$t = \frac{\text{differenza osservata}}{\text{errore standard della differenza}}.$$

Nel caso del test t classico con varianze uguali, la statistica è:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}},$$

dove s_p è la deviazione standard pooled:

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}.$$

Sotto H_0 , e se le assunzioni del modello sono ragionevoli, questa statistica segue una distribuzione t di Student con:

$$df = n_1 + n_2 - 2$$

gradi di libertà.

i Una formula già familiare

La struttura del test t non è nuova. Si tratta della stessa logica vista nel test per una media:

$$\text{statistica test} = \frac{\text{stima} - \text{valore atteso sotto } H_0}{\text{errore standard}}.$$

Nel confronto tra due gruppi, la stima è la differenza tra le due medie. Il denominatore misura quanto tale differenza può variare da un campione all'altro quando H_0 è vera.

6.3. Assunzioni del confronto tra due gruppi

Per interpretare correttamente il test, è necessario chiedersi se il modello sia plausibile per i dati osservati e per il disegno dello studio.

6.3.1. Indipendenza delle osservazioni

Le osservazioni devono essere indipendenti sia all'interno di ciascun gruppo sia tra i gruppi. Questa è soprattutto un'assunzione di **disegno**: dipende da come sono stati reclutati i partecipanti e da come è stato condotto lo studio.

Ad esempio, se più osservazioni provengono dagli stessi partecipanti, da coppie, da classi scolastiche o da terapeuti comuni, l'indipendenza può essere violata. In questi casi, un semplice test t per campioni indipendenti potrebbe non essere adeguato.

6.3.2. Variabile quantitativa

Il test t confronta le medie. La variabile dipendente dovrebbe quindi essere quantitativa o trattata come approssimativamente quantitativa. In psicologia, questo accade spesso con i punteggi delle scale, i tempi di risposta, i punteggi clinici o gli indici compositi.

6.3.3. Forma della distribuzione

Il test t assume che, in ciascun gruppo, la variabile sia approssimativamente normale nella popolazione. In pratica, il test è spesso abbastanza robusto di fronte a deviazioni moderate dalla normalità, soprattutto quando i campioni non sono molto piccoli e non ci sono outlier estremi.

6.3.4. Uguaglianza delle varianze

Il test t classico presuppone che le due popolazioni abbiano la stessa varianza. Quando questa assunzione non è plausibile, è preferibile utilizzare il **test t di Welch**, che non richiede varianze uguali e modifica i gradi di libertà.

In R, la funzione `t.test()` usa per impostazione predefinita il test di Welch. Questa scelta è spesso consigliabile nella pratica applicata.

Regola pratica

Nel lavoro applicato, il test di Welch è spesso una buona scelta predefinita per il confronto tra due gruppi indipendenti. Il test classico con varianze uguali richiede un'ulteriore assunzione che non sempre è giustificata.

6.4. Un esempio guidato

Consideriamo uno studio simulato sul benessere psicologico. Un gruppo di studenti segue un breve intervento di regolazione emotiva, mentre un secondo gruppo segue una condizione di controllo. Il punteggio finale viene misurato su una scala in cui i valori più alti indicano un maggiore benessere.

```
benessere_intervento <- c(27, 31, 29, 33, 35, 30, 32, 28, 34, 31, 36, 29)
benessere_controllo  <- c(24, 26, 28, 25, 29, 27, 23, 30, 26, 25, 28, 24)

cat("Gruppo intervento:\n")
#> Gruppo intervento:
cat("  Media:", round(mean(benessere_intervento), 2), "\n")
#>  Media: 31.2
cat("  Deviazione standard:", round(sd(benessere_intervento), 2), "\n")
#>  Deviazione standard: 2.83
cat("  n:", length(benessere_intervento), "\n\n")
#>  n: 12

cat("Gruppo controllo:\n")
#> Gruppo controllo:
cat("  Media:", round(mean(benessere_controllo), 2), "\n")
#>  Media: 26.2
cat("  Deviazione standard:", round(sd(benessere_controllo), 2), "\n")
#>  Deviazione standard: 2.18
cat("  n:", length(benessere_controllo), "\n")
#>  n: 12
```

La prima cosa da fare non è calcolare il valore- p , ma osservare le stime descrittive. Il gruppo di intervento presenta una media più alta rispetto al gruppo di controllo. La domanda inferenziale è se questa differenza sia abbastanza grande rispetto alla variabilità attesa da risultare poco compatibile con H_0 .


6.4.1. Visualizzazione descrittiva

```
library(ggplot2)

dati_benessere <- data.frame(
  gruppo = rep(c("Intervento", "Controllo"), each = 12),
  benessere = c(benessere_intervento, benessere_controllo)
)

ggplot(dati_benessere, aes(x = gruppo, y = benessere)) +
  geom_boxplot(width = 0.45, alpha = 0.6, outlier.shape = NA) +
  geom_jitter(width = 0.08, alpha = 0.8, size = 2) +
  stat_summary(fun = mean, geom = "point", shape = 18, size = 4) +
  labs(
    title = "Punteggi di benessere nei due gruppi",
    subtitle = "Il rombo indica la media campionaria",
    x = "Gruppo",
```

```
y = "Punteggio di benessere"
)
```



La visualizzazione aiuta a vedere insieme posizione, variabilità e possibili valori anomali. Tale ispezione non sostituisce il test, ma rende l'interpretazione più trasparente.

6.5. Il test t classico

Calcoliamo prima il test t nella versione classica con varianze uguali.

```
n1 <- length(benessere_intervento)
n2 <- length(benessere_controllo)

m1 <- mean(benessere_intervento)
m2 <- mean(benessere_controllo)

s1 <- sd(benessere_intervento)
s2 <- sd(benessere_controllo)

s_pool <- sqrt(((n1 - 1) * s1^2 + (n2 - 1) * s2^2) / (n1 + n2 - 2))
se_diff <- s_pool * sqrt(1/n1 + 1/n2)

t_stat <- (m1 - m2) / se_diff
df <- n1 + n2 - 2
p_value <- 2 * pt(abs(t_stat), df = df, lower.tail = FALSE)

cat("Differenza tra medie:", round(m1 - m2, 2), "\n")
#> Differenza tra medie: 5
cat("Errore standard della differenza:", round(se_diff, 2), "\n")
#> Errore standard della differenza: 1.03
cat("Statistica t:", round(t_stat, 3), "\n")
```

6. Confrontare due gruppi indipendenti

```
#> Statistica t: 4.85
cat("Gradi di libertà:", df, "\n")
#> Gradi di libertà: 22
cat("Valore-p:", round(p_value, 4), "\n")
#> Valore-p: 0.0001
```

Il valore- p va letto in modo condizionale: indica quanto sarebbero rari risultati almeno così estremi se, nella popolazione, le due medie fossero uguali e se il modello del test fosse appropriato.

6.5.1. Uso di `t.test()`

```
t_classico <- t.test(benessere_intervento, benessere_controllo, var.equal = TRUE)
t_classico
#>
#> Two Sample t-test
#>
#> data:  benessere_intervento and benessere_controllo
#> t = 5, df = 22, p-value = 0.00008
#> alternative hypothesis: true difference in means is not equal to 0
#> 95 percent confidence interval:
#>  2.86 7.14
#> sample estimates:
#> mean of x mean of y
#>      31.2      26.2
```

Il risultato riporta la statistica test, i gradi di libertà, il valore- p , la differenza tra le medie e un intervallo di confidenza per tale differenza.

6.6. Il test t di Welch

Nella pratica, spesso è preferibile utilizzare il test di Welch, che non richiede l'uguaglianza delle varianze. In R, questa è l'impostazione predefinita di `t.test()`.

```
t_welch <- t.test(benessere_intervento, benessere_controllo)
t_welch
#>
#> Welch Two Sample t-test
#>
#> data:  benessere_intervento and benessere_controllo
#> t = 5, df = 21, p-value = 0.00009
#> alternative hypothesis: true difference in means is not equal to 0
#> 95 percent confidence interval:
#>  2.85 7.15
#> sample estimates:
#> mean of x mean of y
#>      31.2      26.2
```

Se le varianze dei gruppi sono simili, i risultati del test classico e del test di Welch sono molto simili. Se invece le varianze o le numerosità dei gruppi sono molto diverse, il test di Welch è più prudente.

i Quale test riportare?

Per molti studi applicati, è ragionevole riportare il test di Welch, specificando che l'uguaglianza delle varianze non è stata assunta. Il test classico con varianze uguali può essere utilizzato quando tale assunzione è giustificata dal disegno dello studio o da ragioni sostanziali.

6.7. Interpretare i risultati oltre il valore-p

Un confronto tra due gruppi non dovrebbe essere riassunto solo dicendo se il risultato è “significativo” o “non significativo”. Una lettura più informativa dovrebbe integrare quattro elementi:

1. la **differenza osservata** tra le medie;
2. l'**intervallo di confidenza** per la differenza;
3. il **valore-p**;
4. la **dimensione dell'effetto**.

6.7.1. Differenza tra medie e intervallo di confidenza

L'intervallo di confidenza descrive la precisione della stima della differenza tra le medie.

```
diff_medie <- m1 - m2
ic_diff <- t_welch$conf.int

cat("Differenza tra medie:", round(diff_medie, 2), "\n")
#> Differenza tra medie: 5
cat("IC 95%:", "[", round(ic_diff[1], 2), ",", round(ic_diff[2], 2), "]\n")
#> IC 95%: [ 2.85 , 7.15 ]
```

In termini frequentisti, un intervallo di confidenza al 95% è costruito con una procedura che, nel lungo periodo, contiene il valore vero nel 95% dei campioni ripetuti. Ciò non significa che vi sia il 95% di probabilità che il valore vero cada nell'intervallo osservato.

6.7.2. Dimensione dell'effetto

La dimensione dell'effetto aiuta a distinguere la significatività statistica dalla rilevanza sostantiva. Nel confronto tra due medie, una misura comune è il d di Cohen:

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p}$$

```
cohens_d <- diff_medie / s_pool
cat("Cohen's d:", round(cohens_d, 2), "\n")
#> Cohen's d: 1.98
```

6. Confrontare due gruppi indipendenti

Questa quantità esprime la differenza tra i gruppi in unità di deviazione standard pooled. È una misura descrittiva standardizzata utile, ma non deve essere interpretata in modo meccanico. Un effetto piccolo può essere importante in alcuni contesti clinici o educativi, mentre un effetto grande può essere poco rilevante se riguarda una misura secondaria o un campione non rappresentativo.

⚠ Significativo non significa importante

Un test può risultare statisticamente significativo anche quando la differenza è trascurabile sul piano teorico o pratico, se il campione è molto grande. Al contrario, un risultato non significativo può dipendere da una bassa potenza e non dimostra che le due popolazioni siano uguali.

6.8. Come riportare il risultato

Una comunicazione trasparente dovrebbe evitare sia l'eccesso di formule sia la riduzione del risultato al solo valore- p .

6.8.1. Formulazione incompleta

Il gruppo di intervento ha ottenuto punteggi significativamente più alti rispetto al gruppo di controllo, $p < .05$.

Questa frase è incompleta: non specifica l'entità della differenza, la precisione della stima e il metodo utilizzato.

6.8.2. Formulazione consigliata

```
cat(
  "Il gruppo sottoposto all'intervento ha riportato un punteggio medio di ", round(m1, 2),
  " (DS = ", round(s1, 2), "), mentre il gruppo controllo ha riportato un punteggio medio di ",
  round(m2, 2), " (DS = ", round(s2, 2), "). ",
  "La differenza media è pari a ", round(diff_medie, 2),
  " punti, IC 95% [", round(ic_diff[1], 2), ", ", round(ic_diff[2], 2),
  "], t(", round(t_welch$parameter, 2), ") = ", round(t_welch$statistic, 2),
  ", p = ", signif(t_welch$p.value, 3),
  ", d = ", round(cohens_d, 2), ".\n",
  sep = ""
)
#> Il gruppo sottoposto all'intervento ha riportato un punteggio medio di 31.2 (DS = 2.83),
```

In un testo scientifico, il risultato potrebbe essere riportato così:

Il gruppo sottoposto all'intervento ha riportato un punteggio medio più alto ($M = 31.25$, $DS = 2.83$) rispetto al gruppo di controllo ($M = 26.25$, $DS = 2.18$). La differenza media è pari a 5.00 punti, $IC\ 95\% [2.85, 7.15]$, $t(20.64) = 4.85$, $p < .001$, $d = 1.98$.

I valori numerici dipendono dai dati utilizzati nell'esempio. Il punto didattico è la struttura del resoconto: stima, incertezza, test e dimensione dell'effetto.

6.9. Cosa il test non dice

Il test t per campioni indipendenti è utile, ma risponde a una domanda circoscritta. In particolare, il test non risponde alla domanda:

- qual è la probabilità che H_0 sia vera;
- qual è la probabilità che H_1 sia vera;
- qual è la probabilità che la differenza vera sia positiva;
- quanto sia probabile che l'effetto superi una soglia di rilevanza clinica;
- se il disegno dello studio sia valido;
- se la differenza osservata sia priva di bias sistematici.

Questi limiti non rendono il test inutile. Tuttavia, indicano che il valore- p deve essere interpretato insieme al disegno dello studio, alle stime, agli intervalli di confidenza, alla potenza e alla plausibilità teorica dell'effetto.

6.10. Collegamento con la prospettiva bayesiana

In una prospettiva bayesiana, il confronto tra due gruppi viene formulato in modo diverso. Invece di chiedersi quanto i dati siano sorprendenti sotto H_0 , si costruisce un modello probabilistico per i dati e si ottiene una distribuzione a posteriori per la differenza tra le medie:

$$\Delta = \mu_1 - \mu_2.$$

Questa distribuzione permette di rispondere direttamente a domande come:

- qual è la probabilità che $\Delta > 0$?
- qual è un intervallo di credibilità per Δ ?
- qual è la probabilità che Δ superi una soglia clinicamente rilevante?
- quanto sono sensibili le conclusioni alle assunzioni del modello e alla scelta del prior?

Il test t frequentista rimane quindi importante da conoscere perché è molto diffuso nella letteratura psicologica. Tuttavia, nel percorso bayesiano, il test t frequentista funziona soprattutto come termine di confronto, mostrando chiaramente la differenza tra una procedura basata sul controllo dell'errore nel lungo periodo e una procedura basata sull'aggiornamento delle credenze sui parametri.

Lettura complementare

Un confronto esplicito tra il test t tradizionale e una formulazione bayesiana del confronto tra due gruppi è discusso da Kruschke (2013).

Riflessioni conclusive

Il test t per campioni indipendenti è uno strumento fondamentale dell'inferenza frequentista. Consente di confrontare due gruppi quando l'esito è di tipo quantitativo e quando il disegno dello studio rende plausibile l'indipendenza delle osservazioni.

In questo capitolo lo abbiamo interpretato come applicazione finale della logica introdotta nei capitoli precedenti: a una stima puntuale sono associati un intervallo di confidenza, una statistica di test, un

6. Confrontare due gruppi indipendenti

valore p e una dimensione dell'effetto. Nessuno di questi elementi, preso singolarmente, esaurisce il significato del risultato.

Il messaggio principale è che un buon resoconto non dovrebbe limitarsi a dichiarare se un risultato è significativo. Dovrebbe invece comunicare **quanto** differiscono i gruppi, **con quale incertezza**, **rispetto a quale procedura di test** e **con quale rilevanza sostantiva**.

Da qui, il passaggio alla prospettiva bayesiana è naturale: anziché domandarsi se una differenza sia abbastanza sorprendente sotto un'ipotesi nulla, è possibile modellare direttamente l'incertezza sulla differenza tra i gruppi e aggiornare le proprie credenze alla luce dei dati osservati.

Punti chiave da ricordare

! Importante

- Il test t per campioni indipendenti confronta le medie di due gruppi distinti.
- La domanda frequentista è condizionale a H_0 : quanto sarebbero sorprendenti dati come quelli osservati se le due medie fossero uguali?
- Il test di Welch è spesso preferibile perché non richiede l'assunzione di varianze uguali.
- Il valore- p non è la probabilità che l'ipotesi nulla sia vera.
- L'intervallo di confidenza descrive la precisione della stima secondo una procedura con copertura nel lungo periodo.
- La dimensione dell'effetto aiuta a valutare la rilevanza sostantiva della differenza.
- Un risultato completo integra stima, incertezza, test, valore- p e dimensione dell'effetto.
- La prospettiva bayesiana permette di formulare direttamente domande sulla differenza tra le medie e sulla probabilità di effetti rilevanti.

i Informazioni sull'ambiente di sviluppo

6. Confrontare due gruppi indipendenti

```
sessionInfo()
#> R version 4.6.1 (2026-06-24)
#> Platform: aarch64-apple-darwin23
#> Running under: macOS Tahoe 26.5.2
#>
#> Matrix products: default
#> BLAS: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
#> LAPACK: /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; L
#>
#> locale:
#> [1] C.UTF-8/UTF-8/C.UTF-8/C/C.UTF-8/C.UTF-8
#>
#> time zone: Europe/Rome
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats      graphics  grDevices  utils      datasets  methods    base
#>
#> other attached packages:
#> [1] ragg_1.5.2          tinytable_0.17.0    withr_3.0.3
#> [4] systemfonts_1.3.2  patchwork_1.3.2     ggdist_3.3.3
#> [7] tidybayes_3.0.7     bayesplot_1.15.0    ggplot2_4.0.3
#> [10] reliabilitydiag_0.2.1 priorsense_1.2.0     posterior_1.7.0
#> [13] loo_2.10.0          rstan_2.32.7        StanHeaders_2.32.10
#> [16] brms_2.23.0         Rcpp_1.1.2          sessioninfo_1.2.4
#> [19] conflicted_1.2.0    janitor_2.2.1       matrixStats_1.5.0
#> [22] modelr_0.1.11       tibble_3.3.1        dplyr_1.2.1
#> [25] tidyr_1.3.2         rio_1.3.0           here_1.0.2
#>
#> loaded via a namespace (and not attached):
#> [1] svUnit_1.0.8        tidymodels_1.2.1    farver_2.1.2
#> [4] S7_0.2.2            fastmap_1.2.0       tensorA_0.36.2.1
#> [7] digest_0.6.39       timechange_0.4.0    estimability_2.0.0
#> [10] lifecycle_1.0.5     magrittr_2.0.5      compiler_4.6.1
#> [13] rlang_1.3.0         tools_4.6.1         yaml_2.3.12
#> [16] knitr_1.51          labeling_0.4.3       bridgesampling_1.2-1
#> [19] pkgbuild_1.4.8      curl_7.1.0          RColorBrewer_1.1-3
#> [22] abind_1.4-8         purrr_1.2.2         grid_4.6.1
#> [25] stats4_4.6.1        xtable_1.8-8        inline_0.3.21
#> [28] emmeans_2.0.3       scales_1.4.0        cli_3.6.6
#> [31] mvtnorm_1.4-1       rmarkdown_2.31      generics_0.1.4
#> [34] otel_0.2.0          RcppParallel_5.1.11-2 cachem_1.1.0
#> [37] stringr_1.6.0       parallel_4.6.1      vctrs_0.7.3
#> [40] V8_8.2.0            Matrix_1.7-5        jsonlite_2.0.0
#> [43] arrayhelpers_1.1-1  glue_1.8.1          codetools_0.2-20
#> [46] distributional_0.8.1 lubridate_1.9.5     stringi_1.8.7
#> [49] gtable_0.3.6        QuickJSR_1.10.0     pillar_1.11.1
#> [52] htmltools_0.5.9     Brodningnag_1.2-9   R6_2.6.1
#> [55] textshaping_1.0.5   rprojroot_2.1.1     evaluate_1.0.5
#> [58] lattice_0.22-9      backports_1.5.1     memoise_2.0.1
#> [61] broom_1.0.13        snakecase_0.11.1    rstantools_2.6.0
#> [64] coda_0.19-4.1       gridExtra_2.3.1     nlme_3.1-169
#> [67] checkmate_2.3.4     xfun_0.60           pkgconfig_2.0.3
```

Bibliografia

Parte II.

Epilogo

7. Considerazioni conclusive: dal controllo dell'errore all'aggiornamento delle credenze

Questo modulo ha introdotto l'inferenza frequentista all'interno di un percorso più ampio dedicato all'inferenza bayesiana. Non lo abbiamo fatto per sostituire un paradigma con un altro, né per presentare il frequentismo come un insieme di tecniche superate. Lo abbiamo fatto perché gran parte della ricerca psicologica continua a essere scritta, letta e valutata con il linguaggio frequentista: stime puntuali, errori standard, intervalli di confidenza, valori- p , test di significatività, potenza statistica e confronti tra gruppi.

Comprendere questo linguaggio è quindi indispensabile. Allo stesso tempo, è importante comprenderlo nel modo corretto. Molti fraintendimenti non nascono da errori di calcolo, ma dal fatto che le quantità frequentiste vengono spesso interpretate come se rispondessero a domande bayesiane. Un valore- p viene letto come probabilità dell'ipotesi nulla; un intervallo di confidenza viene letto come intervallo in cui il parametro si trova con una certa probabilità; un risultato non significativo viene letto come prova dell'assenza di effetto. Queste interpretazioni sono intuitive, ma non corrispondono a quelle previste dalla teoria frequentista.

Lo scopo di questo epilogo è raccogliere i fili del percorso: che cosa abbiamo imparato, che cosa il frequentismo permette di fare bene, quali domande non può rispondere direttamente e perché il passaggio alla prospettiva bayesiana diventa naturale.

7.1. Il filo conduttore del modulo

Il modulo ha preso le mosse dalle origini storiche dell'approccio frequentista, mostrando come la statistica moderna sia nata anche dall'esigenza di descrivere, classificare e confrontare la variabilità osservata nelle popolazioni umane. Questo passaggio storico è importante perché aiuta a comprendere una caratteristica centrale del frequentismo: l'attenzione non è rivolta principalmente alla probabilità di una singola ipotesi, ma al comportamento di procedure applicate ripetutamente a campioni generati dallo stesso processo (Chivers, 2024).

Successivamente, abbiamo introdotto il problema della stima. Nel frequentismo, il parametro è considerato fisso, ma sconosciuto; ciò che varia è lo stimatore, perché campioni diversi produrrebbero stime diverse. Da ciò derivano concetti come correttezza, bias, consistenza, efficienza ed errore standard. La domanda non è: "Qual è la probabilità di questo valore del parametro?", ma: "Come si comporta questa procedura di stima nel lungo periodo?".

Gli intervalli di confidenza hanno esteso tale logica dalla stima puntuale a quella intervallare. Un intervallo di confidenza non assegna una probabilità al parametro osservato in uno studio singolo, ma descrive una procedura che, se ripetuta molte volte, produrrebbe intervalli in grado di contenere il parametro vero con una frequenza prestabilita.

I test di ipotesi introducono un altro uso della distribuzione campionaria: valutare quanto un risultato osservato sarebbe sorprendente se l'ipotesi nulla fosse vera. Il valore- p non misura la probabilità che l'ipotesi nulla sia vera, ma la probabilità di osservare dati uguali o più estremi di quelli ottenuti, a condizione che l'ipotesi nulla sia corretta.

Il capitolo sulla numerosità campionaria ha mostrato che la pianificazione dello studio è parte integrante della logica frequentista. Controllare l'errore di I tipo, limitare l'errore di II tipo e raggiungere una potenza adeguata richiede decisioni da prendere prima di osservare i dati. Infine, il confronto tra due gruppi indipendenti ha riunito molti elementi del modulo in un esempio applicativo: differenza tra medie, intervallo di confidenza, statistica test, valore- p e dimensione dell'effetto.

! Il nucleo comune

Il filo conduttore di tutti questi strumenti è la valutazione del comportamento di una procedura in caso di ripetizione ipotetica del campionamento. Questo è il punto di forza del frequentismo, ma anche il motivo per cui le sue quantità non hanno sempre l'interpretazione intuitiva che i ricercatori vorrebbero attribuirgli.

7.2. Che cosa il frequentismo permette di fare bene

Il frequentismo ha svolto un ruolo fondamentale nello sviluppo delle scienze empiriche. Ha fornito un linguaggio condiviso per comunicare i risultati, confrontare gli studi, progettare gli esperimenti e controllare il rischio di conclusioni affrettate. Questo contributo non va sottovalutato.

In primo luogo, il frequentismo costringe a distinguere ciò che osserviamo nel campione da ciò che vorremmo sapere sulla popolazione. Questa distinzione è essenziale in psicologia, dove i dati sono spesso rumorosi, i campioni sono limitati e le misure sono solo imperfetti indicatori dei costrutti teorici.

In secondo luogo, l'approccio frequentista fornisce strumenti pratici per quantificare la variabilità campionaria. L'errore standard, gli intervalli di confidenza e le distribuzioni di riferimento aiutano a evitare che una stima osservata venga trattata come se fosse il valore vero.

In terzo luogo, la logica dei test e della potenza rende espliciti alcuni rischi decisionali. Quando si pianifica uno studio, è importante sapere con quale probabilità una procedura potrebbe produrre un falso positivo o non rilevare un effetto sostanziale. Anche adottando una prospettiva bayesiana, questi concetti rimangono utili per comprendere la qualità del disegno di ricerca.

Infine, il frequentismo ha imposto una disciplina procedurale: specificare le ipotesi, definire una regola di analisi, dichiarare il livello di significatività e riportare la numerosità campionaria, nonché comunicare l'incertezza. Tali pratiche hanno contribuito alla standardizzazione della ricerca empirica.

7.3. Che cosa il frequentismo non dice direttamente

Le difficoltà interpretative nascono quando si chiede agli strumenti frequentisti di rispondere a domande per cui non sono stati costruiti.

Un intervallo di confidenza non dice direttamente: "C'è il 95% di probabilità che il parametro sia compreso in questo intervallo". Nel quadro frequentista, il parametro non è una quantità casuale, ma è fisso, anche se sconosciuto. L'incertezza riguarda la procedura e la variabilità dei campioni, non il parametro nell'intervallo osservato.

Un valore- p non dice: "C'è una probabilità pari a p che l'ipotesi nulla sia vera". Il valore p è calcolato assumendo vera l'ipotesi nulla e non fornisce la probabilità dell'ipotesi nulla data l'evidenza osservata.

Un risultato significativo non implica necessariamente che l'effetto sia teoricamente rilevante, clinicamente significativo o replicabile. La significatività statistica dipende anche dalla numerosità del campione e dalla variabilità dei dati. Gli effetti molto piccoli possono diventare significativi in campioni molto grandi, mentre gli effetti importanti potrebbero non raggiungere la significatività in campioni troppo piccoli.

Un risultato non significativo non significa che l'effetto sia assente. Può indicare l'assenza di prove sufficienti, una bassa potenza, misure rumorose, un'ampia incertezza o un disegno poco sensibile.

 Una regola pratica

Quando interpreti un risultato frequentista, chiediti sempre se la quantità in questione descrive l'evidenza di uno studio specifico o il comportamento di una procedura in molti studi ipotetici. Molti fraintendimenti nascono proprio dalla confusione tra questi due livelli.

7.4. Le principali distinzioni da ricordare

7.4.1. Stima e parametro

La stima è il numero osservato nel campione. Il parametro è la quantità sconosciuta della popolazione. Nel frequentismo, invece, il parametro è fisso e la stima varia da campione a campione. Nel bayesianesimo, invece, il parametro è descritto da una distribuzione di probabilità che rappresenta il nostro grado di incertezza.

7.4.2. Intervallo di confidenza e intervallo di credibilità

Un intervallo di confidenza riguarda la copertura, nel lungo periodo, di una procedura. Un intervallo di credibilità riguarda invece la probabilità a posteriori del parametro, condizionata ai dati e al modello. Spesso i due intervalli possono avere valori simili, ma il loro significato è diverso.

7.4.3. Valore-p e probabilità dell'ipotesi

Il valore- p è una probabilità dei dati, o di dati più estremi, condizionata a H_0 . Non si tratta di una probabilità di H_0 condizionata ai dati. La seconda quantità richiede un modello bayesiano, una prior e una posterior.

7.4.4. Potenza ed evidenza osservata

La potenza è una proprietà prospettica di una procedura: indica con quale frequenza il test rifiuterebbe H_0 se un certo effetto fosse vero. È fondamentale in fase di pianificazione, ma non misura direttamente quanta evidenza sia contenuta in uno studio già completato.

7.4.5. Significatività e rilevanza sostantiva

La significatività statistica indica che il risultato è sufficientemente incompatibile con H_0 secondo una regola prestabilita. La rilevanza sostantiva richiede invece una valutazione teorica, clinica o pratica della dimensione dell'effetto.

7.5. Una valutazione equilibrata

Una conclusione equilibrata non è che il frequentismo sia inutile, né che il bayesianesimo sia automaticamente superiore in ogni circostanza. La conclusione più utile è che i due approcci rispondono a domande diverse.

Il frequentismo è particolarmente adatto quando l'obiettivo principale è valutare e controllare il comportamento di una procedura nel lungo periodo. Ciò è rilevante nella progettazione di studi, nella regolazione di processi decisionali ripetuti, nel controllo dei falsi positivi e nella standardizzazione dei criteri analitici.

L'approccio bayesiano è invece più naturale quando l'obiettivo è quantificare l'incertezza relativa a parametri, ipotesi o modelli dopo l'osservazione di dati specifici. Consente, infatti, di formulare domande come: "Qual è la probabilità che l'effetto sia positivo?" Qual è la probabilità che superi una soglia clinicamente rilevante? In che modo i dati modificano le credenze iniziali? Quanto sono robuste le conclusioni rispetto a ipotesi alternative?

Queste sono le domande che i ricercatori si pongono realmente. Per questo motivo, un approccio bayesiano può risultare più vicino al ragionamento scientifico quotidiano. Tuttavia, anche l'inferenza bayesiana richiede attenzione: le conclusioni dipendono dal modello, dalla qualità dei dati, dalla scelta della prior e dalla validità del disegno della ricerca. Nessun metodo statistico può sostituire il pensiero critico.

i Non due ricette, ma due cornici

Il frequentismo non è solo una raccolta di test e il bayesianesimo non è solo una raccolta di formule con prior e posterior. Si tratta di due cornici concettuali che permettono di collegare dati, modelli e incertezza. Comprendere la differenza tra le due cornici aiuta a utilizzarle in modo più consapevole.

7.6. Dal controllo dell'errore all'aggiornamento delle credenze

Il passaggio alla prospettiva bayesiana può essere riassunto come uno spostamento di enfasi.

Nel frequentismo, la domanda tipica è:

Se ripetessimo molte volte questa procedura sotto certe assunzioni, quanto spesso commetteremmo un certo tipo di errore?

Nel bayesianesimo, la domanda tipica è:

Dati il modello, le conoscenze iniziali e i dati osservati, che cosa è ora più plausibile?

La prima è di tipo procedurale. La seconda è epistemica. La prima riguarda il comportamento di un metodo in un insieme ipotetico di ripetizioni. La seconda riguarda l'aggiornamento dell'incertezza nel caso specifico.

Il teorema di Bayes formalizza questo aggiornamento:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

La prior $p(\theta)$ rappresenta ciò che sappiamo o assumiamo prima di osservare i dati. La verosimiglianza $p(y | \theta)$ descrive quanto i dati siano compatibili con i diversi valori del parametro. La posterior $p(\theta | y)$ rappresenta ciò che sappiamo dopo aver osservato i dati.

Questa formulazione consente di trattare direttamente l'incertezza relativa ai parametri e alle ipotesi. Consente anche di aggiornare progressivamente le conclusioni quando si ricevono nuovi dati, di integrare le informazioni precedenti e di comunicare i risultati in termini probabilistici più vicini alle domande fondamentali della ricerca.

7.7. Come portare con sé ciò che abbiamo imparato

Anche se il resto del percorso adotterà una prospettiva bayesiana, quanto imparato in questo modulo rimane utile.

Quando leggerai un articolo frequentista, potrai chiederti:

- Qual è la stima dell'effetto?
- Qual è l'incertezza associata alla stima?
- Il valore- p è interpretato correttamente?
- L'intervallo di confidenza viene presentato come proprietà della procedura o come probabilità del parametro?
- La dimensione dell'effetto è rilevante dal punto di vista sostanziale?
- Lo studio aveva una potenza adeguata per rispondere alla domanda che voleva affrontare?
- Il risultato non significativo è davvero informativo o i dati sono semplicemente insufficienti?
- Le conclusioni prendono in considerazione possibili bias di misura, selezione o disegno?

Quando costruirai un'analisi bayesiana, potrai usare questi stessi concetti come punti di confronto. La stima puntuale non scompare, ma viene inserita in una distribuzione a posteriori. L'incertezza non scompare, ma viene rappresentata direttamente tramite probabilità condizionate ai dati. La pianificazione dello studio rimane essenziale e può essere formulata in termini di precisione attesa, probabilità decisionali posteriori o utilità attesa.

Riflessioni conclusive

Questo modulo ha presentato il frequentismo come un sistema coerente di procedure inferenziali basate sul controllo dell'errore nel lungo periodo. Abbiamo visto che questo sistema ha fornito strumenti fondamentali alla ricerca psicologica: stime, intervalli, test, analisi di potenza e procedure standardizzate per il confronto tra gruppi e la comunicazione dei risultati.

Abbiamo anche visto che le quantità frequentiste richiedono interpretazioni precise. Tali quantità non assegnano direttamente probabilità ai parametri o alle ipotesi dopo l'osservazione dei dati. Quando vengono lette in questo modo, possono generare fraintendimenti: il valore p viene interpretato come probabilità dell'ipotesi nulla, l'intervallo di confidenza come probabilità del parametro e la non significatività come assenza di effetto.

Il passaggio all'inferenza bayesiana nasce dall'esigenza di formulare direttamente l'incertezza sui parametri, di aggiornare le credenze alla luce dei dati e di comunicare l'evidenza in termini più vicini alle domande fondamentali della ricerca scientifica. Non si tratta di dimenticare il frequentismo, ma di collocarlo nel suo spazio corretto e di riconoscere quando una domanda richiede strumenti diversi.

In questo senso, il frequentismo non rappresenta il punto di arrivo del percorso, ma una tappa essenziale. Conoscerlo bene aiuta a capire perché l'inferenza bayesiana sia utile, quali problemi intenda risolvere e quali responsabilità concettuali comporti.

Punti chiave da ricordare

! Importante

- Il frequentismo valuta il comportamento delle procedure inferenziali in caso di ripetizione ipotetica del campionamento.
- I parametri sono considerati fissi, ma ignoti; la variabilità riguarda i campioni e gli stimatori.
- Gli intervalli di confidenza descrivono una proprietà di copertura della procedura e non una probabilità diretta del parametro nell'intervallo osservato.
- Il valore- p è calcolato assumendo vera l'ipotesi nulla, ma non indica la probabilità che l'ipotesi nulla sia vera.
- La significatività statistica non coincide con la rilevanza teorica, clinica o pratica.
- La non significatività non dimostra l'assenza di un effetto: può indicare dati insufficienti o bassa potenza.
- La numerosità campionaria deve essere pianificata in funzione della domanda: precisione della stima, potenza del test o rilevanza sostanziale dell'effetto.
- Il frequentismo rimane essenziale per interpretare la letteratura psicologica e comprendere molte pratiche di ricerca.
- L'approccio bayesiano sposta l'attenzione dal controllo dell'errore nel lungo periodo all'aggiornamento delle credenze nel caso specifico.
- Nessun metodo statistico può sostituire la qualità del disegno della ricerca, la validità delle misure e il giudizio scientifico.

Bibliografia

- Chivers, T. (2024). *Everything is Predictable: How Bayesian Statistics Explain Our World*. Simon; Schuster.
- Giner-Sorolla, R., Montoya, A. K., Reifman, A., Carpenter, T., Lewis Jr, N. A., Aberson, C. L., Bostyn, D. H., Conrique, B. G., Ng, B. W., Schoemann, A. M., et al. (2024). Power to detect what? Considerations for planning and evaluating sample size. *Personality and Social Psychology Review*, 28(3), 276–301.
- Kruschke, J. K. (2013). Bayesian estimation supersedes the t test. *Journal of Experimental Psychology: General*, 142(2), 573–603.